Notizen DS Grundlagen

Agile Data Product - Entwicklung

Data Product-Entwicklung

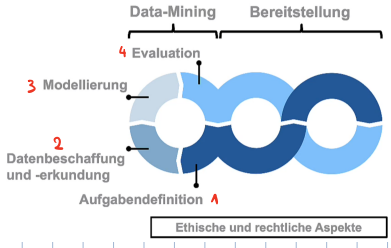

Das Wasserfallmodell ist für die Entwicklung digitaler Produkte ungeeignet!

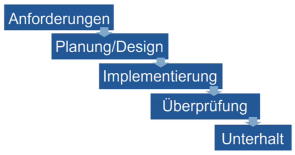

The Agile Manifesto

veröffentlicht 2001 von 17 Softwareentwicklern

Wir erschließen bessere Wege, Software zu entwickeln, indem wir es selbst tun und anderen dabei helfen. Durch diese Tätigkeit haben wir diese **Werte** zu schätzen gelernt:

- Individuen und Interaktionen
  mehr als Prozesse und Werkzeuge
- Funktionierende Software
  mehr als umfassende Dokumentation
- Zusammenarbeit mit dem Kunden
  mehr als Vertragsverhandlungen
- Reagieren auf Veränderung
  mehr als das Befolgen eines Plans

Im Bezug auf Data Science - Products:

- Produktivität durch Selbstorganisation
- Fokus auf die Erfüllung der Nutzerbedürfnisse
- Unsicherheit als Chance
- Inkrementelles und Iteratives Vorgehen

Priorisierung der Beschränkungen beim Agilen Vorgehen

Zu den **Ressourcen** zählen das **Budget** und die an der Auslieferung und Umsetzung arbeitenden **Teammitglieder**.

Die **Zeit** gibt vor, wann das Team etwas ausliefert, zum Beispiel Releases, und wann Meilensteine erreicht werden.

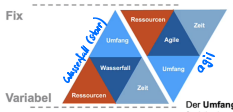

Der **Umfang** ist die für ein funktionierendes Produkt zu erledigende Arbeit, ausgedrückt beispielsweise in Form von Features und Funktionen.

Iterativ vs. Inkrementell

Iterativ

Inkrementell

Creative Common License [1]

Aufgabendefinition / Business / Project Understanding

1. Beschreibung der Problemstellung
2. Situationsbewertung
3. Projektziele und Erfolgskriterien
4. Data Mining Ziele
5. Projektplan

→ Projektcharta

④ Domänenwissen, Anspruchsgruppen identifizieren, Nutzeranspruch

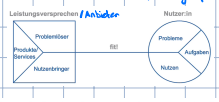

Nutzergruppen bilden: Persona

Archetypische Repräsentation einer nutzenden Person(engruppe)

Name: Gib dieser Persona einen möglichst realistischen aber dennoch fiktiven Namen.	**Alter:**	**Zitat:** Was wäre ein typisches Zitat dieser Persona?	**Frustrationen:** Was frustriert die Persona am meisten? Welche Hindernisse muss diese Persona überwinden?
Wohnort: Wie und wo wohnt diese Persona? Grossstadt? Dorf? Doppelhaushälfte? Hausboot?	**Hobbies:** Womit verbringt diese Persona am liebsten ihre Freizeit?		**Bedürfnisse:** Was würde dieser Persona weiterhelfen? Was würde sie unterstützen? Was braucht sie am meisten?
Beschäftigung: Was macht die Persona hauptberuflich?	**Motivation:** Wofür brennt diese Persona? Was lässt sie aktiv werden? Was motiviert sie am meisten?	**Kernproblem:** Was ist das zentrale Problem, für das die Person eine Lösung sucht? Welche Ziele verfolgt die Person dabei?	

Zürcher Fachhochschule

② Ressourcen (Kompetenzen, Erfahrungen), Zeit, Randbedingungen, Risiken

③ **3. Projektziele und Erfolgskriterien**

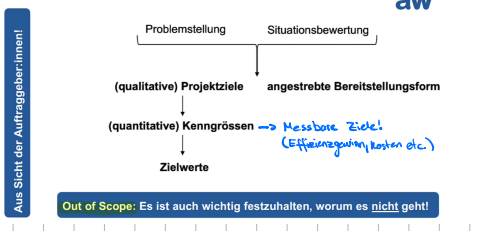

Out of Scope: Es ist auch wichtig festzuhalten, worum es nicht geht!

④ Übersetzung der primären Projektziele von der Projektdomäne in eine technische, datenzentrierte Formulierung.

Data Mining-Aufgaben:

Vorhersagen:
- Regression → Prognose numerischer Werte (Börsenkurs)
- Klassifikation → Prognose diskreter Werte (Kreditwürdig)

Analyse:
- Clusteranalyse → Gruppenweise Betrachtung (Kundengruppen)
- Anomalie-Erkennung → Erkennung von Abweichungen (Fraud detection)
- Assoziationsanalyse → Erkennung von Zusammenhängen (Kunden kaufen auch...)
- Empfehlungsdienste → Erkennung von z.B. Nutzerverhalten

⑤ Rollen und Aufgaben, Kollaborations-/Projektmodus, Projektphasen, Infrastruktur

Stakeholder Map:

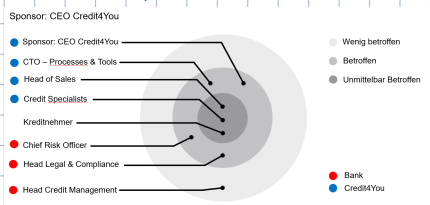

Daten und Informationen

Was sind Daten?
- Beobachtungen, Messungen, Zahlenwerte
- Zeichen die ein Information darstellen
- Computer aufbereitete Daten

13 : 2 = 6 , 1
6 : 2 = 3 , 0
3 : 2 = 1 , 1
1 : 2 = 0 , 1
↳ 1101

1011001
$2^0 + 2^3 + 2^6 = 41$

Umwandlung zwischen Dezimal- und Binärsystem

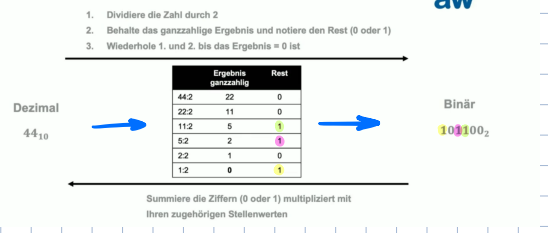

Digitalisierung am Beispiel eines Audiosignals

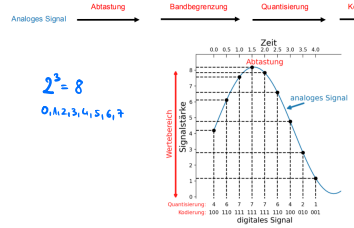

$2^3 = 8$
0,1,2,3,4,5,6,7

Digitalisierung von Bildern (Scannen)

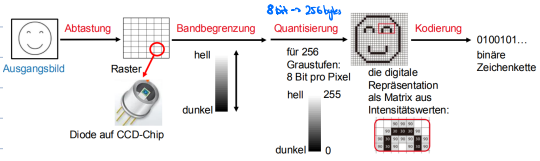

Farbbild im RGB Farbraum: eine Matrix pro Kanal → 3*8 Bit pro Pixel
Für schwarz/weiss: einen Kanal 1.8 Bit = 256 bytes

- American Standard Code for Information Interchange.
- 1 Byte pro Buchstabe

Zeichen	Bits
A	01000001
B	01000010
C	01000011
D	01000101
E	01000110
usw.	

ASCII

Erstes Bit ungenutzt → 7 Bits → Kodierung von maximal 128 verschiedenen Zeichen: Ausreichend für Englisch.

- **Unicode** mapt auf bis zu 32 Bit (4 Bytes)-Code Points. Variable Length-Definitions (z.B. **UTF-8** (Standard-Kodierung in Python) erlauben eine effizientere Platznutzung.
- In **UTF-8** werden die **ersten 128 Character** genau gleich wie in **ASCII** repräsentiert.
- Das höchste ("sign") Bit - in ASCII ungenutzt – **kodiert den Beginn einer Multi-Byte Sequenz**. Die Anzahl aufeinanderfolgender 1s im ersten Byte kodieren die totale Anzahl genutzter Bytes, dann folgt eine 0, und die verbleibenden Bits (x) tragen zum Wert bei:
  0xxxxxxx UTF-8 Code für diesen Character ist total 1 Byte lang, entspricht ASCII
  110xxxxx **Ein** Byte folgt (d.h. UTF-8 Code für diesen Character ist total 2 Bytes lang)
  1110xxxx **Zwei** Bytes folgen (d.h. UTF-8 Code für diesen Character ist total 3 Bytes lang)
  11110xxx **Drei** Bytes folgen (d.h. UTF-8 Code für diesen Character ist total 4 Bytes lang)
- Die "Folge-Bytes" (Continuation Bytes) beginnen immer mit 10 – **nur 6 Bits kodieren** die Werte: 10xxxxxx
- So können in **beschädigten Sequenzen** die jeweils nächsten vollständigen Character leichter erkannt werden.

Digitale vs. Analoge Daten

- Herstellung digitaler Daten sehr hoch
- Reproduktionskosten sind aber gering
- keine Qualitätsverluste durch kopieren
- nicht Rivalität, Digitale Daten können zentral bereitgestellt werden
- Kompressierbar / Sequentierbar

Datei

- Ist eine Zusammenfassung gleichartiger Daten
- Wird durch einen Dateinamen identifiziert
- Das Dateiformat gibt die Zeichenabfolge vor
- Kann mithilfe eines Anwendungsprogramms identifiziert werden

Strukturierte Daten
- Besitzen ein Datenmodell
- Verschiedene Datensätze können demselben Datenmodell folgen

Beispiele
- Daten in Tabellenform

Dateiformate
- csv
- ods (Open Spreadsheet Data format)
- xlsx
- HDF (Hierarchical Data Format)
- Apache Parquet

Unstrukturierte Daten
- Haben kein festes Datenmodell
- Haben keine explizite Struktur, aber ev. eine implizite, z.B. Grammatikregeln in Text

Beispiele und gängige Dateiformate

Inhalte	Formate
Texte	txt, odt, docx, html
Bilder	jpeg, png
Audio	wave, aiff, flac, mp3, aac
Video	mp4, mov, wmv

Semistrukturierte Daten

Haben **kein festgeschriebenes Datenmodell**, können aber einen Teil der Strukturinformation in Form von **Tags** oder **Markern** mit sich tragen, sodass das Schema teilweise (re)konstruiert werden kann.

Entitäten derselben Klasse können **unterschiedliche Attribute** haben und die **Reihenfolge** ist beliebig.

Wichtige Dateiformate: **XML** und **JSON** – sowohl maschinell, als auch visuell lesbar

Anwendungen/Technologien
- Übertragung von Daten zwischen Servern und **Web-Applikationen** JSON (REST) heute verbreiteter als XML
- **E-Mail**
- Objekt-basierte (**No SQL**) Datenbanken wie MongoDB und Elasticsearch (**Volltextsuche**)

+ Objekte können **ohne festgelegtes Schema** gespeichert werden
+ **Mapping** auf ein relationales Datenmodell unnötig
+ Einfache Abbildung **verschachtelter Objekte oder hierarchischer Abhängigkeiten**
− Keine performante Abfragesprache wie **SQL**
− **Fehleranfällig** durch fehlendes Datenmodell

XML: Extensible Markup Language

Case-sensitive!

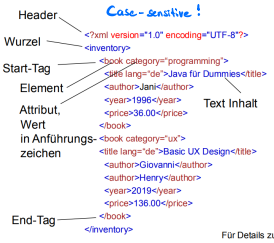

Es gibt **keine vordefinierten Tags** wie in HTML

Extensible: Die Applikationen sollten auch funktionieren, wenn dem Dokument Tags fehlen oder wenn es zusätzliche hat

Enthält Daten, aber keine Information, wie diese dargestellt werden sollen (im Gegensatz zu HTML)

Hierarchische Struktur:
```
<root>
  <child>
    <subchild>.....</subchild>
  </child>
</root>
```

Für Details zur Syntax siehe https://www.w3schools.com/xml/default.asp

JSON: JavaScript Object Notation

```
{
 "inventory": [
   {
    "category": "programming",
    "title": {
     "lang": "de",
     "text": "Java für Dummies"
    },
    "author": "Jani",
    "year": 1996,
    "price": 36.00
   },
   {
    "category": "programming",
    "title": {
     "lang": "en",
     "text": "Python für Dummies""
    },
    "author": "John",
    "year": 2015,
    "price": 22.00
   }
 ]
}
```

Syntaxvalidierung: https://jsonlint.com/

- Abgeleitet von **J**ava**S**cript **O**bject-**N**otation ist aber sprachunabhängig
- Format ist **reiner Text**, was Speicherung und Austausch sehr einfach macht
- Daten liegen als **Key/Value-Paare** vor,
- Durch **Kommas** voneinander getrennt
- **Keys** sind immer Strings
- Erlaubte **Datentypen** für **Values**:
  - String in double quotes "<string>"
  - Number
  - JSON-Objekt (in geschweiften Klammern)
  - Array (in eckigen Klammern)
  - Boolean: true/false
  - null

Vorteil: **Übersichtlicher** und **einfacher** zu parsen als XML

Datenbeschaffung

Übersicht Datenbeschaffung und -erkundung

	Tätigkeiten	Output/Artefakte
Datenbeschaffung (Data Acquisition)	• Datenquellen identifizieren • Daten beschaffen • Daten ablegen und organisieren • Datenkatalog erstellen	• **Datenbericht**
Datenerkundung (Data Exploration)	• Explorative Datenanalyse	

Im Datenbericht werden alle Informationen zu den im Projekt verwendeten Daten zusammengetragen, um die Nachvollziehbarkeit und Reproduzierbarkeit der Ergebnisse sicherzustellen und eine systematische Erweiterung der Datenbasis zu ermöglichen.

Beispiele für Datenquellen

- Datensätze aus **Forschungsprojekten**
  - https://paperswithcode.com/ -> Datasets
  - Harvard Dataverse: https://dataverse.harvard.edu/dataverse/harvard
  - UC Irvine Machine Learning Repository https://archive.ics.uci.edu/ml/index.php
- **Kaggle**: https://www.kaggle.com/
- Öffentliche **Ämter**
  - z.B. https://www.bfs.admin.ch/bfs/de/home.html
  - https://opendata.swiss/de
- Wikipedia
- Google Datasets
- Projectgutenberg.org (e-Books)
- Webseiteninhalte (-> **Scraping**)
- **Kommerzielle** Anbieter

- Datenquellen innerhalb der **eigenen Organisation**
  - Zentrales Data Warehouse
  - Applikations-spezifische Datenbanken
  - Sharepoint, shared drives
  - Wiki
  - Email-Server

Prinzipien von REST-Services

REST: **RE**presentational **S**tate **T**ransfer
Die REST-Prinzipien definieren Regeln für den Aufbau eines Webservice

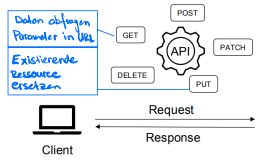

Die API definiert, wie welche Daten ausgetauscht werden können
- Endpunkte
- HTTP-Methoden

Der REST-Service läuft auf einem Server

Ein REST-Service ist zustandslos

Aspekte der Datenbeschaffung

- Erforderliche **Frequenz** der **Datenabfrage**/Refresh Rate
  - Entweder weil auf Seiten der Quelle neue Daten zur Verfügung stehen
  - oder weil auf Abfrage-Seite andere Daten benötigt werden
- **Push vs Pull**
- **Batch**-Download oder ***ad hoc***-Einzelabfragen?
- **Anforderungen** an die Infrastruktur der **Datenquelle** zur Bereitstellung der Daten
  - **Verfügbarkeit** (z.B. 7*24, 99.99%)
  - **Throughput** / **Maximale Last** der Anfragen (z.B. 1000 Anfragen pro Sekunde, 1GB/s)
  - **Latenz** (wie lange muss man auf die Daten warten)
  - **Stabilität** des **Schnittstellendesigns** (wie oft muss die Datenbeschaffungspipeline an Veränderungen der Schnittstelle angepasst werden?)
- Können abgefragte Daten **lokal gespeichert** oder dürfen/können sie **nur gestreamt** werden?
- Werden die Daten von der Quelle persistiert? → können sie **wiederholt abgefragt** werden? Falls ja: wie lange werden die Daten vorgehalten?

Data Governance

Aufgrund des inhärenten Wertes von Daten, werden je nach Kontext unterschiedliche **Anforderungen an den Umgang** mit Daten gestellt
- **wie** sie **geschützt** werden müssen
- wer auf sie **Zugriff** hat
- und **wofür** sie **verwendet** werden **dürfen**

Diese **Anforderungen** können unterschiedlichen **Ursprungs** sein:
- **Gesetze** (z.B. Datenschutzgesetz)
- **Erwartungen** allgemeines Verständnis von Nutzern und Gesellschaft
- **Industrie-Standard**
- **Organisationsinterne Vorschriften** (z.B: zum Schutz vertraulicher Daten)
- …

Datenaufbereitung

Vor- und Nachteile verschiedener Vorgehensweisen beim Ersetzen einzelner Werte

1. Wert manuell bestimmen:
+ maximal mögliche Genauigkeit
- ineffizient bei grossen Datensätzen

2. Eliminierung der Samples:
+ einfache Implementierung
- Informationsverlust
- mögliche Verzerrung der Daten

3. Substitution durch eine Konstante:
+ einfache Implementierung
+ ersetzte Werte «bleiben markiert»
- mögliche Verzerrung der Daten
- ignoriert Korrelation zwischen Merkmalen

4. Substitution durch Lagemasse
+ einfache Implementierung
+ i.A. genauer als Eliminierung und Subst. durch Konstant
- mögliche Verzerrung der Daten
- ignoriert Korrelation zwischen Merkmalen
- systematisch unterschätzte Varianz

5. Schätzung mithilfe eines Modells
+ hohe Genauigkeit
- Rechenaufwand

Ordinal-Kodierung

Mapping kategorischer Features auf Integer-Werte [0, Anzahl Kategorien-1]

Marke	Form	Preis
saab	sedan	25443
bmw	sedan	22367
mitsubishi	hatchback	9895
mitsubishi	sedan	16503
bmw	sedan	30760
vw	hatchback	8145
vw	hatchback	8256
saab	sedan	21756
saab	sedan	28477
mitsubishi	sedan	26444

saab: 0
bmw: 1
mitsubishi: 2
vw: 3

sedan: 0
hatchback: 1

Marke	Form	Preis
0	0	25443
1	0	22367
2	1	9895
2	0	16503
1	0	30760
3	1	8145
3	1	8256
0	0	21756
0	0	28477
2	0	26444

One-Hot-Kodierung

Mapping kategorischer Features auf binäre Darstellung (0,1)

Marke	Form	Preis
saab	sedan	25443
bmw	sedan	22367
mitsubishi	hatchback	9895
mitsubishi	sedan	16503
bmw	sedan	30760
vw	hatchback	8145
vw	hatchback	8256
saab	sedan	21756
saab	sedan	28477
mitsubishi	sedan	26444

Marke_saab	Marke_bmw	Marke_mitsubishi	Marke_vw	Form_sedan	Form_hatchback	Preis
1	0	0	0	1	0	25443
0	1	0	0	1	0	22367
0	0	1	0	0	1	9895
0	0	1	0	1	0	16503
0	1	0	0	1	0	30760
0	0	0	1	0	1	8145
0	0	0	1	0	1	8256
1	0	0	0	1	0	21756
1	0	0	0	1	0	28477
0	0	1	0	1	0	26444

Weighted term frequency

$$tf(t,d) = \frac{\text{count of term in doc}}{\text{total word count (ohne stopwords)}}$$

Inverse Document Frequency

$$idf(t) = \log\left(\frac{\text{count of documents}}{\text{count of documents with term } t}\right)$$

tf idf

Kombination durch Multiplikation beider Methoden

Datenerkundung

Ergebnisse werden im Datenbericht festgehalten → Datenkatalog

Datenqualität:
- Unvollständigkeit → Einschränkungen
- Inkonsistenz → Andere Daten beschaffen
- Rauschen und Ausreisser → Projektabbruch

Datentypen

Variablentyp	Skalenniveau	sinnvoll interpretierbare Berechnungen	Beispiele
numerisch - diskret - kontinuierlich	Verhältnis	zählen, sortieren, subtrahieren, dividieren	Kosten, Alter, Grösse, Temperatur in Kelvin
	Interval	zählen, sortieren, subtrahieren	Zeit, Temperatur in Celsius
kategorisch	ordinal	zählen, sortieren	Ratings, Schulnoten
	nominal	zählen	Berufsbezeichnung, Geschlecht

Streumasse

- **Spannweite (Range)**

$$Range(x) = x_{max} - x_{min}$$

- **Interquartilsabstand (Interquartile Range IQR)**
  Gibt an, wie weit eine Verteilung auseinandergezogen ist.

$$IQR = Q_3 - Q_1$$

- **Varianz**

$$Var(x) = \tilde{s}_x^2 = \frac{1}{M}\sum_{m=1}^{M}(x_m - \bar{x})^2$$

- **Standardabweichung**

$$\tilde{s}_x = \sqrt{\tilde{s}_x^2} = \sqrt{\frac{1}{M}\sum_{m=1}^{M}(x_m - \bar{x})^2}$$

Zürcher Fachhochschule

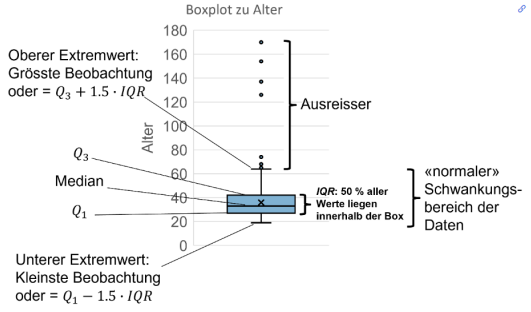

Um die Beziehung zweier numerischer Merkmale zu quantifizieren wird die Kovarianz verwendet

$$\tilde{s}_{xy} = \frac{1}{M}\sum_{m=1}^{M}(x_m - \bar{x})(y_m - \bar{y})$$

Der Korrelationskoeffizient nach Bravais-Pearson r_{xy}

$$r_{xy} = \frac{\tilde{s}_{xy}}{\tilde{s}_x \tilde{s}_y}$$

ist die standardisierte Kovarianz: Die Kovarianz wird durch das Produkt der Standardabweichungen von x und y geteilt. r_{xy} wird dadurch unabhängig von den Masseinheiten. Er misst die Stärke des linearen Zusammenhangs zwischen den beiden Variablen X und Y.

Der Rangkorrelationskoeffizient nach Spearman ist eine modifizierte Variante des Korrelationskoeffizienten nach Pearson. Die Formel hat dieselbe Struktur, wird jedoch auf die rangtransformierten Daten $x_m \rightarrow rg(x_m)$ angewendet:

$$r_{xrgyR} = \frac{\sum_{m=1}^{M}\left(rg(x_m) - \bar{rg}_x\right)\left(rg(y_m) - \bar{rg}_y\right)}{\sqrt{\sum_{m=1}^{M}\left(rg(x_m) - \bar{rg}_x\right)^2}\sqrt{\sum_{m=1}^{M}\left(rg(y_m) - \bar{rg}_y\right)^2}}$$

Damit misst der Korrelationskoeffizient nach Spearman die monotone Beziehung zwischen X und Y und kann damit auch nicht-lineare Zusammenhänge erfassen. Er ist robuster gegenüber Ausreissern und ist anwendbar neben verhältnis- und interval-skalierten auch auf ordinal-skalierte Daten

Der Jaccard-Koeffizient für Samples mit ausschliesslich kategorischen Merkmalen

School of Engineering

Jaccard-Koeffizient: $J(A,B) = \frac{|A \cap B|}{|A \cup B|}$

Intersection → Anzahl Elemente, welche sowohl in A als auch B enthalten sind

Union → Anzahl Elemente, welche in A oder B enthalten sind

Werte zwischen 0:maximal unähnlich und 1:maximale Ähnlichkeit

Jaccard-Metrik ist das entsprechende Distanzmass: $D_J(A,B) = 1 - J(A,B)$

Cosine - Similority

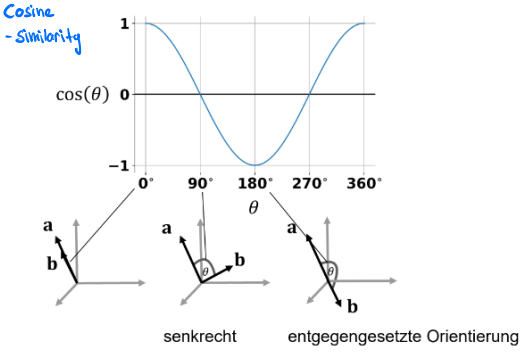

Quantifizierung der Ähnlichkeit/Unähnlichkeit

School of Engineering

- Wichtiges Konzept in der Datenanalyse, bzw. des maschinellen Lernens
- Erlaubt den Vergleich von Samples, z.B. zur Erkennung von Beinahe-Duplikaten
  - bedingt die Festlegung eines Grenzwertes
- Für kategorische Merkmale:
  - Jaccard-Distanz
- Für numerische Merkmale:
  - Manhattan-Distanz
  - Euklidische Distanz
  - Kosinus-Ähnlichkeit
- Für Text:
  - Levenshtein-Distanz

Typen von Lernproblemen

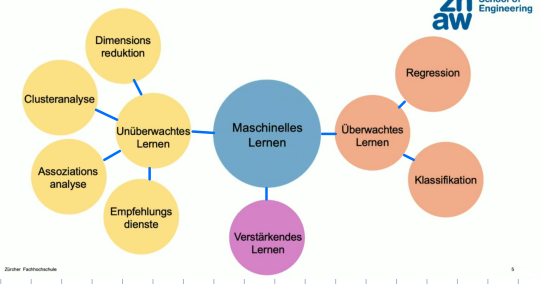

Beim überwachten Lernen wird ein Ausgabewert y_m basierend auf einer Eingabe $\mathbf{x}_{m,:}$ vorausgesagt, wobei für den Lernprozess Trainingsdaten bestehend aus Wertepaaren (Eingabe, Ausgabe) benutzt wird.

Vorhersageproblem: $f(\mathbf{x}_{m,:}) \rightarrow y_m$

Klassifikation:

$y_m \in \{C_1, C_2, \ldots, C_K\}$

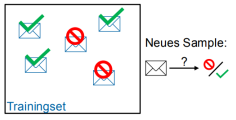

Regression:

$y_m \in \mathbb{R}^L$

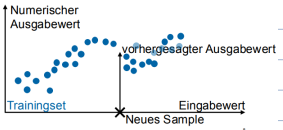

Einfache Lineare Regression

Lineares Modell: Die Ausgaben sind ungefähr $y \approx \theta_0 + \theta_1 x$

$\rightarrow$ Diabetes Fortschritt $\approx \theta_0 + \theta_1 \cdot$ BMI

Modell-Parameter: θ_0, θ_1

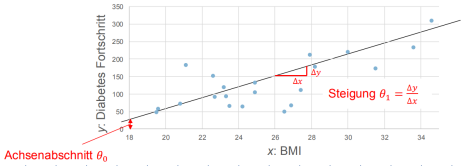

Einfache Lineare Regression: Verlustmass

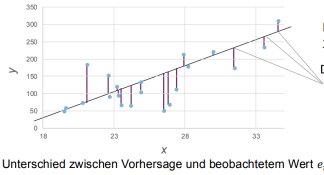

Die Residuen: Unterschied zwischen Vorhersage und beobachtetem Wert $e_m = y_m - \hat{y}_m$

Mass für die Übereinstimmung des Modells mit den Trainingsdaten:
Summe der Residuenquadrate

$$RSS = \sum_{m=1}^{M} (e_m)^2 = (y_1 - \hat{\theta}_0 - \hat{\theta}_1 x_1)^2 + \cdots + (y_M - \hat{\theta}_0 - \hat{\theta}_1 x_M)^2$$

Die Trainingsdaten im Überwachten Lernen

	$\mathbf{x}_{:1}$	$\mathbf{x}_{:2}$	…	$\mathbf{x}_{:N}$	$\mathbf{y}$
$\mathbf{x}_{1,:}$	x_{11}	x_{12}	…	x_{1N}	y_1
$\mathbf{x}_{2,:}$	x_{21}	x_{22}	…	x_{2N}	y_2
$\mathbf{x}_{3,:}$	x_{31}	x_{32}	…	x_{3N}	y_3
…	…	…	…	…	…
$\mathbf{x}_{M,:}$	x_{M1}	x_{M2}	…	x_{MN}	y_M

$\mathbf{X}: M \times N$

M: Anzahl verfügbarer **Trainingsdaten**punkte

$\mathbf{x}_{m,:} \in \mathbb{R}^D$: Die Eingabewerte sind typischerweise endlich-dimensionale Vektoren. Die einzelnen Dimensionen der Vektoren $\mathbf{x}_{m,:}$, die Merkmale, werden auch **Features, Covariates, Predictors oder unabhängige Variablen** genannt.

y_m: Die Ausgabewerte werden auch **Target**, **Response**, **Zielvariable**, **abhängige Variable** oder **Label** (bei kategorischen Merkmalen) genannt

Evaluationsmetriken für Regressionsprobleme

Der Mean Squared Error: $MSE = \frac{1}{M_{\text{test}}} \sum_{m=1}^{M_{\text{test}}} \left(y_{\text{test}_m} - \hat{y}_{\text{test}_m}\right)^2$

Der Root Mean Squared Error ($RMSD$): $RMSD = \sqrt{MSE} = \sqrt{\frac{1}{M_{\text{test}}} \sum_{m=1}^{M_{\text{test}}} \left(y_{\text{test}_m} - \hat{y}_{\text{test}_m}\right)^2}$

Der mittlere absolute Fehler (Mean Absolute Error): $MAE = \frac{1}{M_{\text{test}}} \sum_{m=1}^{M_{\text{test}}} \left|y_{\text{test}_m} - \hat{y}_{\text{test}_m}\right|$

→ Wie viel weichen die aus dem Modell stammenden Werte von den tatsächlichen Werten ab?

Vorgehensweise unter Anwendung der *k*-Nächste-Nachbarn-Heuristik

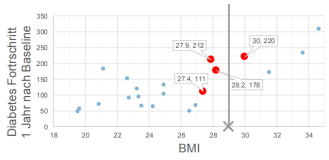

$k = 4$

Ähnlichkeitsmass: Abstand im BMI

Berechne Vorhersage als Durchschnitt über nächste Nachbarn:

$$y_{BMI=29} = (111 + 212 + 178 + 220)/4 = 180.3$$

+ Einfach
+ keine Trainingsphase
+ Interpretierbarkeit

- Rechenintensiv
- Datensatz wird nicht vollständig genutzt
- Sensitivität gegenüber Ausreisser
- Fluch der Dimensionen

Berücksichtigung von Effekten Höherer Ordnung: Polynomiale Regression

z.B. quadratische Funktion:

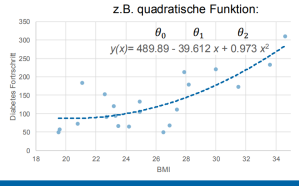

Mit dem Grad des Polynoms steigt die Flexibilität des Modells.

Überanpassung (Overfitting)

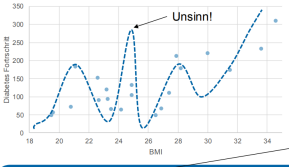

(hier die Ordnung des Polynoms)

Die Erhöhung der Flexibilität des Modells kann bis zu einem gewissen Grad zu einer besseren Übereinstimmung mit den Trainingsdaten führen.

Überanpassung liegt vor, wenn gleichzeitig der Fehler auf den Testdaten zunimmt und ein Modell mit geringerer Flexibilität einen geringeren Fehler auf den Testdaten erreicht.

Elemente einer Pipeline für Überwachtes Maschinelles Lernen

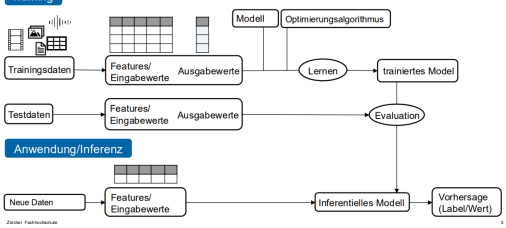

Binäre Klassifikation

Output: 0/1, JA/NEIN, Positiv/Negativ

Multinomiale (Multiclass) Klassifikation

Output: Eine von mehreren Klassen

Multilabel Klassifikation

Output: Ein oder mehrere Labels

Precision und Recall

Erwartet \ Vorhersage	+	-
+	TP	FN
-	FP	TN

$$\text{Precision} = \frac{TP}{TP+FP} \qquad \text{Recall} = \frac{TP}{TP+FN}$$

Es hängt vom Anwendungsfall ab, ob Precision oder Recall als Evaluationsmetrik stärker berücksichtigt werden soll.

Precision vs. Recall

↳ Was ist schlimmer FP oder FN

F-Mass

Das harmonische Mittel aus Precision und Recall:

$$F = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Die Accuracy bei unausgewogenen Daten

Extremfall: Der Datensatz besteht aus 100 Wertepaaren $(\mathbf{x}_{m,:}, y_m)$

- 90 Wertepaare tragen das Label $y_m = 0$
- 10 Wertepaare $y_m = 1$

Dummy-Klassifikator mit Vorhersagen $\hat{y}_m = 0$ für alle $m = 1, \ldots 100$

erreicht $\text{Accuracy} = \frac{\text{richtig klassifiziert}}{\text{alle Fälle}} = \frac{TP+TN}{TP+TN+FP+FN} = \frac{90}{100} = 0.9$

Die Accuracy als Evaluationsmetrik für Klassifkationsalgorithmen ist problematisch bei unausgewogenen (imbalanced) Datensätzen.

Evaluation Multinomialer Klassifikationen

Medizinische Diagnose in 3 Klassen: {Gesund, Erkältung, Grippe}
100 Testresultate:

$$\text{Precision}_k = \frac{TP_k}{TP_k + FP_k}$$

$$\text{Recall}_k = \frac{TP_k}{TP_k + FN_k}$$

Erwartet \ Vorhersage	Gesund	Erkältung	Grippe	Randhäufigkeit (Support) von *k*
Gesund	60	8	2	70
Erkältung	4	12	4	20
Grippe	0	2	8	10

Precision	Recall	F-Metrik
0.94	0.86	0.9
0.54	0.6	0.57
0.57	0.8	0.67
0.68	0.75	0.71

Durchschnitt (Makro): ungewichteter Durchschnitt!

$$\text{Accuracy} = \frac{TP_{Gesund} + TP_{Erkältung} + TP_{Grippe}}{\sum_{k=Gesund,Erkältung,Grippe} \text{Support}_k} = \frac{60+12+8}{100} = 0.8$$

Die Auswirkungen der unterschiedlichen Fehlerarten

True Positive (TP)

Typ I-Fehler: False Positive (FP)

Typ II-Fehler: False Negative (FN)

True Negative (TN)

Je nach Anwendungsfall hat ein Typ I-Fehler (False Positive) grössere Auswirkungen als ein Typ II-Fehler (False Negative) oder umgekehrt. Dies muss in der Auswahl der Kenngrössen und entsprechender Zielwerte für die Datenmodellierung berücksichtigt werden.

Multy-Label Klassifikation: Mehrere Labels möglich

Fehlerarten und Konfusionsmatrix

Beispiel binäre Klassifikation schwanger:+, nicht schwanger:-

Eingaben $\mathbf{x}_{m,:}$	Erwartete Ausgaben y_m	Vorhersagen $\hat{y}_m$	
	+	+	True Positive (TP)
	-	-	True Negative (TN)
	+	+	True Positive (TP)
	+	-	False Negative (FN)
	+	-	False Negative (FN)
	-	+	False Positive (FP)
	+	-	False Negative (FN)

Konfusionsmatrix:

Erwartete Ausgabe y \ Vorhersage $\hat{y}$	+	-
+	$TP = 2$	$FN = 3$
-	$FP = 1$	$TN = 1$

Überwacht vs. Unüberwacht

Typen von Lernproblemen

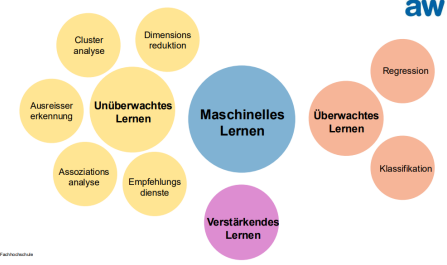

Elemente einer Pipeline für Unüberwachtes Maschinelles Lernen

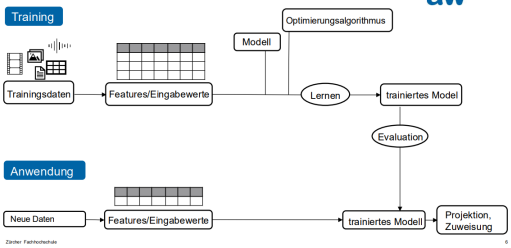

Dimensionsreduktion am Beispiel des Iris-Datensatzes

4 Dimensionen:
Visualisierung schwierig

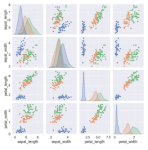

Dimensionsreduktion

z.B. PCA

2 neue Dimensionen, welche die «meiste Information» enthalten

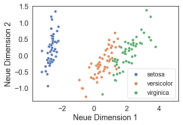

K-Means: Ein einfaches Clustering-Verfahren

- Hyperparameter ***k***: Anzahl zu bestimmender Cluster
- ***Means***: die Mittelpunkte der Cluster (Centroids)
- Annahme: **sphärische Verteilung** der Datenpunkte rund um die ***Means***
- Distanzmass muss gewählt werden

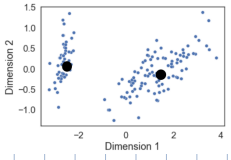

Iterativer Algorithmus - bis Stopp-Kriterium erfüllt wird:

1. Zufällige **Initiierung** der *Means*
2. **Jeder Datenpunkt** wird dem jeweils nächstgelegenem *Mean* zugeordnet.
3. **Neuberechnung der *Means*** als Zentrum der ihnen aktuell zugeordneten Punkte.
4. **Wiederholung der Schritte 2 und 3** bis die *Means* ihre Positionen nicht mehr ändern.

Wenig bekannte Produkte, mit wenigen Bewertungen sind schwierig zu vermitteln → Inhaltsbasierte Analyse:

Vor- und Nachteile von Inhaltsbasierten Systemen

Vorteile
- **Keine Daten der nutzenden Personen** benötigt
- **Kein Cold Start-Problem**

Nachteile
- Eine **vektorielle Repräsentation** der Items wird benötigt.
- **Aktuelles Interesse** wird aus dem **vergangenen Verhalten** der anderen Nutzer abgeleitet
- **Serendipity** wird nicht ermöglicht → Überraschungen
- **Kontext** wird nicht berücksichtigt

Vor- und Nachteile des Kollaborativen Filterns

Vorteile
- **Keine vektorielle Repräsentation** der Items notwendig
- **Serendipity** möglich

Nachteile
- Informationen über die **Präferenzen der Nutzer (Ratings)** werden benötigt
- **Cold Start-Problem**
- **Methodische Herausforderung durch** dünnbesetzte Rating-Matrix
- **Kontext** wird nicht berücksichtigt
- **Aktuelles Interesse** wird aus dem **vergangenen Verhalten** der anderen Nutzer abgeleitet

Mean Average Precision@k

k: Anzahl berücksichtigte Vorschläge

$Precision@k$: $P@k = \frac{\text{Anzahl relevante in } k \text{ vorgeschlagenen Items}}{k}$

Typischerweise wird die $Precision@k$ für jeden User separat bestimmt.

Average Precision@k ($AP@k$): Mittelwert aus $P@1, P@2, \ldots, P@k$

Mean Average Precision@k (MAP@k): Mittelwert von $AP@k$ über alle User

Bereitstellung eines Modells als Software-Lösung

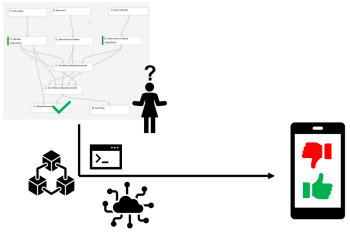

Formen der Bereitstellung

einfach — komplex

Einmaliger Bericht

«Kontinuierlich lernender» Empfehlungsdienst im Onlineshop

Übersicht Phase Bereitstellung

Zur Bereitstellung gehören	Lieferobjekte
1. Planung 2. Implementierung 3. Auslieferung (Delivery) 4. Betrieb (Operations)	• Dokumentation der bereitgestellten Lösung (z.B. Software **Architektur-Diagramm**) • Beschreibung der notwendigen **Anpassungen von Prozessen** (Change Management)

Data Product-Entwicklung

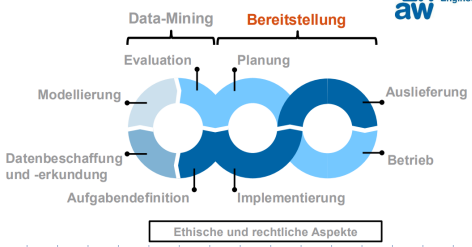

Ethik philosophische Frag, menschliches Handeln (rational)
Moral persönliche und gesellschaftliche Werte (subjektiv)
Recht System von Regeln (institutionell)

Beispiel für Leitgedanken einer Datenethik

- Die **Digitalisierung** soll dem **Wohl** der **gesamten Gesellschaft** dienen und ihren **Zusammenhalt stärken**
- **Menschenzentrierte** und werteorientierte Gestaltung der Technologie
- **Förderung digitaler Kompetenzen** und **kritischer Reflexion** in der digitalen Welt
- **Stärkung des Schutzes von persönlicher Freiheit**, **Selbstbestimmung** und **Integrität**
- **Risikoadaptierte Regulierung** und **wirksame Kontrolle** algorithmischer Systeme
- Wahrung und **Förderung von Demokratie**
- Ausrichtung digitaler Strategien an Zielen der **Nachhaltigkeit**

Ethische Grundorientierungen im Kodex

	Schadenvermeidung	Gerechtigkeit	Autonomie
Werte:	• Schutz • Sicherheit • Nachhaltigkeit	• Gleichheit • Fairness • Solidarität	• Wahlfreiheit • Privatsphäre • Würde

→ ergänzen

Überblick: Rechtssystem Schweiz /Rechtsordnung

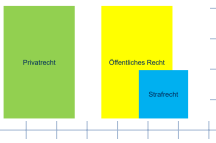

Überblick: Rechtsgrundlagen und Geltungsbereich

Überblick: Rechtsgrundlagen und Geltungsbereich (Schweiz / EU)

Datenschutz

	Allgemeines, formelles Datenschutzrecht		Bereichsspezifisches, materielles Datenschutzrecht	
Bund	DSG	Allgemeine Grundsätze, Rechte der betroffenen Personen; Aufsicht	Strafrecht, Steuerrecht, Finanzmarkt, Ausländerrecht, Sozialversicherungsrecht usw.	Gesetzliche Grundlage, Bearbeitungs- bzw. Bekanntgabenormen, Schweigepflichten, etc.
Kantone	Kantonale Datenschutz-erlasse		Polizeiwesen, Gesundheitsrecht, Sozial-hilferecht, Organisationsrecht, Schulwesen usw.	

Datenschutz

Gesetz/ Verordnung	Gilt für:	Verfahren	Datenschutzbeauftragte/-r
Bundesgesetz über den Datenschutz (DSG)	Bundesbehörden/ Private	Verwaltungs-verfahrensgesetz/ Zivilgesetzbuch z.T. im DSG	Eidg. Datenschutz- und Öffentlichkeits-beauftragter (EDÖB)
Gesetz (des Kt. ZH) über die Information und den Datenschutz (IDG)	Behörden im Kt. ZH/ (Private) soweit sie öffentliche Aufgaben für den Kt. ZH erfüllen	Im IDG geregelt	Datenschutzbeauf-tragte/-r des Kt. ZH
Datenschutzverordnung (DSV) der Stadt Zürich	Behörden der Stadt Zürich	IDG und DSV	Datenschutzbeauf-tragte/-r der Stadt ZH

Überblick: Computerdelikte (Auswahl)

Unbefugte Datenbeschaffung (Art. 143 StGB) sog. **Datendiebstahl**

Unbefugtes Eindringen in ein Datenverarbeitungssystem (Art. 143 bis StGB) sog. **Hacking**

Unbefugte Datenbeschaffung (Art. 143 StGB) sog. **Datendiebstahl**

Unbefugtes Eindringen in ein Datenverarbeitungssystem (Art. 143 bis StGB)

Datenbeschädigung (Art. 144 bis Ziff. 1 StGB)

Herstellen von datenschädigenden Programmen (Art. 144 bis Ziff. 2 StGB) sog. **Viren-Tatbestand**

Betrügerischer Missbrauch einer Datenverarbeitungsanlage (Art. 147 StGB) sog. **Computerbetrug**

Handlung mit Wissen und Willen bzw. Inkauf nehmen

Prüfschema im Überblick (Vorsatzdelikt)

I. Objektiver Tatbestand (Tatobjekt, Tathandlung) (Irrtum ausgeschl.)
II. Subjektiver Tatbestand (Eventualvorsatz: Wissen und Willen))
III. Rechtswidrigkeit (sind Rechtfertigungsgründe vorhanden?)
IV. (Schuld) (sind Schuldausschliessungsgrüne vorliegend?)
V. Ergebnis

Das Datenschutzrecht schützt nicht die Daten sondern die Personen! -> Persönlichkeitsverletzung

Personendaten: Alle Daten, die sich auf Personen beziehen
(Besondere) Identität ergibt sich aus den Daten (Rhtos!)
+ Nur natürliche Personen Identifizierbarkeit ist relativ -> abhängig vom Wissen des Täters -> Relative Theorie
Sachdaten: Nicht im DSG geregelt

Besonders schützenswerte Personendaten
Daten über:
1. Die religiösen, weltanschaulichen, politischen oder gewerkschaftlichen Ansichten oder Tätigkeiten,
2. Die Gesundheit, die Intimsphäre oder die Zugehörigkeit zu einer Rasse oder Ethnie,
3. Verwaltungs- und strafrechtliche Verfolgungen oder Sanktionen,
4. Massnahmen der sozialen Hilfe,

Sowie genetische Daten und biometrische Daten, die eine natürliche Person eindeutig identifizieren

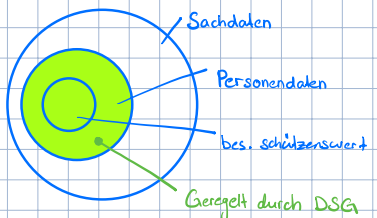

StGB:

Art. 143
Unbefugte Datenbeschaffung
1 Wer in der Absicht, sich oder einen andern unrechtmässig zu bereichern, sich oder einem andern elektronisch oder in vergleichbarer Weise gespeicherte oder übermittelte Daten beschafft, die nicht für ihn bestimmt und gegen seinen unbefugten Zugriff besonders gesichert sind, wird mit Freiheitsstrafe bis zu fünf Jahren oder Geldstrafe bestraft.
2 Die unbefugte Datenbeschaffung zum Nachteil eines Angehörigen oder Familiengenossen wird nur auf Antrag verfolgt.

Art. 143bis
Unbefugtes Eindringen in ein Datenverarbeitungssystem
1 Wer auf dem Wege von Datenübertragungseinrichtungen unbefugterweise in ein fremdes, gegen seinen Zugriff besonders gesichertes Datenverarbeitungssystem eindringt, wird, auf Antrag, mit Freiheitsstrafe bis zu drei Jahren oder Geldstrafe bestraft.
2 Wer Passwörter, Programme oder andere Daten, von denen er weiss oder annehmen muss, dass sie zur Begehung einer strafbaren Handlung gemäss Absatz 1 verwendet werden sollen, in Verkehr bringt oder zugänglich macht, wird mit Freiheitsstrafe bis zu drei Jahren oder Geldstrafe bestraft.

Angriffsobjekt:
- Gespeicherte oder übermittelte Daten
  - -> alle Arten von Daten (Zeichen, Buchstaben etc.)
- Keine Berechtigung an den Daten (Ausgenommen: Datenverarbeitung (Nutzungsbedingungen))
- Besonders gesichert (Absicht)

Tathandlung
- Beschaffung (Zugriffs-Schranken überwinden)

Absicht / Motiv
- Bereicherung

Rechtswidrigkeit
- Rechtfertigender Umstand
- Täter schuldfähig

Tatobjekt / Angriffsobjekt
- Datenverarbeitungs-SYSTEME (Server) (Systeme, keine Datenträger oder Sensoren)
- Muss für den Täter fremd sein
- Geschützt / Zugriffssicherung
- „Computer-Hausfriedensbruch"

Absicht / Motiv
- Vorsatz
- Keine Bereicherungsabsicht notwendig

Ergebnis
- Nur auf Antrag strafbar

Abs. 1: Antragsdelikt
Abs. 2: Offizialdelikt

Folien von SW11 (Teil 1)

Prüfschema ...

1. Grundsätze des Datenschutzes

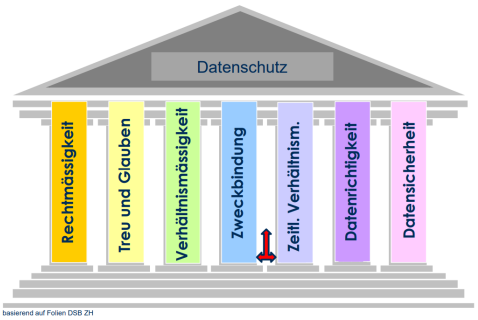

basierend auf Folien DSB ZH

* Einwilligung ist kein Grundsatz

Was ist eine Datenbearbeitung?

→ Alles !

- Aufbewahrung
- Bearbeitung
- Löschung
- etc.

Rechtmässigkeit

- Datenbearbeitungen müssen rechtmässig sein (Art. 6 Abs. 1 DSG)
- Alles ist erlaubt solange sie nicht verboten ist

- Selbstverständlichkeit / keine spezifische Bedeutung
- Beruht Bearbeitung auf unrechtmässigem Verhalten → Verletzung Persönlichkeit
- Beispiele unrechtmässiges Verhalten? (Drohung, Hacking)
- Auch darauf folgende Datenbearbeitungen unrechtmässig
- Besonders wichtig bei Beschaffung von Personendaten
- Differenzierung: Rechtfertigung möglich?

Treu und Glauben

- Verfassungsrechtliche Grundlage (Art. 5 Abs. 3 und Art. 9 BV)
- Privatrechtliche Grundlage (Art. 2 Abs. 1 ZGB)
- Datenschutzrechtliche Generalklausel (Art. 6 Abs. 2 DSG)

Ein loyales und vertrauenswürdiges Verhalten im Rechtsverkehr ist grundlegend, ein widersprüchliches Verhalten läuft diesem zuwider.

Der Grundsatz von Treu und Glauben stellt eine Generalklausel dar und kann in all denjenigen Konstellationen zum Zuge kommen, in denen die anderen Bearbeitungsgrundsätze nicht greifen.

Relevanz in der Praxis?

→ Neu Bspw. heimliche Datenbearbeitung; neu allenfalls Grundsatz der Transparenz (mit Erkennbarkeit des Zwecks nur noch teilweise abgedeckt)?

Bsp.: Datenlecks offen legen

Verhältnissmässigkeit

Grundlagen

- Verfassungsrechtliche Grundlage (Art. 5 Abs. 2 BV) (richtet sich an öffentliche Organe)
- Datenschutzrechtliche Grundlage (Art. 6 Abs. 2 DSG) auch für Private anwendbar

Grundsatz(Art. 6 Abs. 2 DSG)

«Die Bearbeitung muss (…) verhältnismässig sein.»

Verhältnismässige Datenbearbeitung

- Ist geeignet, den verfolgten Zweck zu erreichen (*Geeignetheit*);
- Bearbeitet nur Daten, die zur Zweckerreichung erforderlich sind, und (*Erforderlichkeit*);
- Zweck der Bearbeitung steht in einem vernünftigen Verhältnis zum Eingriff (*Zumutbarkeit*).

→ Der Zweck der Verarbeitung muss klar sein, um die Verhältnismässigkeit beurteilen zu können.

- Ausdruck davon ist bspw.
  - Aufbewahrungsdauer (Art. 6 Abs. 4 DSG)
  - **Datenvermeidung**
  - **Datenminimierung**/Datensparsamkeit

- Also bspw:
  - Zugriff auf Personendaten intern beschränken
  - Keine neuen Daten erheben, wenn Zweck mit vorhandenen Daten erreicht werden kann
  - Nur diejenigen Daten erheben, die zur Erreichung des Zwecks erforderlich sind

- Beurteilung Einhaltung: Einzelfallentscheid

Zweckbindung

Grundsatz der Zweckbindung, -erkennbarkeit und -vereinbarkeit (Art. 6 Abs. 3 DSG)

"Personendaten dürfen nur zu einem bestimmten und für die betroffene Person erkennbaren Zweck beschafft werden; sie dürfen nur so bearbeitet werden, dass es mit diesem Zweck vereinbar ist."

Zweck offen legen (AGB)

- Keine Datenbeschaffung auf Vorrat
- Transparenz über den Zweck der Datenbearbeitung
- Verbindliche Zweck**bindung** für Datenbearbeiter, d.h. Zweck muss erkennbar sein resp. nur so bearbeiten, dass mit dem erkennbaren Zweck **vereinbar** (breiter als früher) → Beispiel Anonymisierung …

- Zugriffsbeschränkung je nach Aufgabe

Speicherbeschränkung

Art. 6 Abs. 4 DSG («Speicherbeschränkung» oder «zeitliche Verhältnismässigkeit»):

«Sie werden vernichtet oder anonymisiert, sobald sie zum Zweck der Bearbeitung nicht mehr erforderlich sind.»

→ auch Ausfluss aus dem Verhältnismässigkeitsprinzip

Datenrichtigkeit

Art. 6 Abs. 5 DSG

«Wer Personendaten bearbeitet, muss sich über deren Richtigkeit vergewissern. Sie oder er muss alle angemessenen Massnahmen treffen, damit die Daten berichtigt, gelöscht oder vernichtet werden, die im Hinblick auf den Zweck ihrer Beschaffung oder Bearbeitung unrichtig oder unvollständig sind. Die Angemessenheit der Massnahmen hängt namentlich ab von der Art und dem Umfang der Datenbearbeitung sowie vom Risiko, das die Bearbeitung für die Persönlichkeit oder Grundrechte der betroffenen Personen mit sich bringt.»

Art. 6 Abs. 5 DSG

- Pflicht, sich über die Richtigkeit zu vergewissern
- Kann eine Pflicht zur Nachführung von Daten oder zur periodischen Überprüfung implizieren
- Pflicht zur Einführung angemessener Massnahmen zur Berichtigung, Löschung oder Vernichtung gewisser Daten

"Richtig" sind Personendaten immer dann, wenn sie eine Tatsache oder einen Umstand im Hinblick auf den **Zweck ihrer Beschaffung oder Bearbeitung** sachgerecht wiedergeben.

"Unrichtig" in diesem Sinne können Personendaten damit auch dann sein, wenn sie an sich korrekte Angaben enthalten, jedoch im Hinblick auf den Bearbeitungszweck in irgendeiner Form irreführend sind.

- Anspruch auf Löschung

Datensicherheit

Art. 8 Abs. 1 bis 3 DSG

«Der Verantwortliche und der Auftragsbearbeiter gewährleisten durch geeignete technische und organisatorische Massnahmen eine dem Risiko angemessene Datensicherheit.»

«Die Massnahmen müssen es ermöglichen, Verletzungen der Datensicherheit zu vermeiden»

«Der Bundesrat erlässt Bestimmungen über die Mindestanforderungen an die Datensicherheit»

Grundsätzliche Aspekte, die im Vordergrund stehen: (a) Vertraulichkeit; (b) Verfügbarkeit; (c) Datenintegrität; (d) Nachvollziehbarkeit (Art. 2 DSV)

Vertraulichkeit: Nur diejenigen Personen dürfen Zugriff auf die vorhandenen Daten haben, die auch über eine entsprechende Berechtigung hierfür verfügen

Verfügbarkeit: Daten sind verfügbar, wenn sie benötigt werden

Datenintegrität: Daten werden nicht unberechtigt oder unbeabsichtigt verändert

Nachvollziehbarkeit: Daten werden nur nachvollziehbar bearbeiten (mE auch Ausdruck oder zumindest enger Zusammenhang mit Integrität)

2. Wann ist die Datenbearbeitung zulässig?

«Erlaubnis mit Verbotsvorbehalt»

Grundsatz

Wer Personendaten bearbeitet, darf (dabei) die Persönlichkeit der betroffenen Personen nicht widerrechtlich verletzen (Art. 30 Abs. 1 DSG) → Konkretisierung von Art. 28 ZGB

Dieser Grundsatz wird wie folgt konkretisiert:

Eine Persönlichkeitsverletzung liegt **insbesondere** vor, wenn:

- Personendaten entgegen den Grundsätzen nach den Artikeln 6 und 8 bearbeitet werden
- Personendaten entgegen der ausdrücklichen Willenserklärung der betroffenen Person bearbeitet werden
- Dritten besonders schützenswerte Personendaten bekannt gegeben werden

Persönlichkeitsverletzung kann gerechtfertigt werden durch

- Einwilligung der betroffenen Person
- Überwiegendes privates oder öffentliches Interesse
- Gesetz → Gerichts-entscheid
- Siehe dazu Art. 31 Abs. 1 DSG

Falllösungsschema

Schema für Herangehensweise an Datenschutzfälle

- Anwendbarkeit DSG?
- Personendaten?
- Werden diese Personendaten *bearbeitet*?
- Einhaltung der datenschutzrechtlichen Grundsätze (Rechtmässigkeit, Treu & Glauben, Verhältnismässigkeit, Zweckbindung, Erkennbarkeit etc.)
- *Keine Bearbeitung gegen den ausdrücklichen Willen der betroffenen Person*
- Keine Bekanntgabe besonders schützenswerter Personendaten oder Persönlichkeitsprofile an Dritte
- Ansonsten: Rechtfertigungsgrund?

- **Auskunftsrecht**

«Jede Person kann vom Verantwortlichen Auskunft darüber verlangen, ob Personendaten über sie bearbeitet werden.“ (Art. 25 Abs. 1 DSG)

In der Regel kostenlos, innert 30 Tagen, kein Verzicht im Voraus

- **Informationspflicht (Art. 19 DSG)**

- Relevant: Zeitpunkt der Beschaffung
- Erweiterte Informationspflicht im DSG (seit Revision)
- Stichwort: Planmässigkeit

Rechte und Pflichten nach DSG (Auswahl)
- Informationspflicht bei einer automatisierten Einzelentscheidung
- Recht auf Datenherausgabe und -übertragung (Art. 28 und 29 DSG)
- Verzeichnis der Bearbeitungstätigkeit
- Datenschutz-Folgenabschätzung (DSFA)

2. Funktion: Datenschutzberater

Art. 10 DSG, Art. 23 ff. DSV

– Kann-Vorschrift bei Bearbeitung durch private Personen, anders bei der Bearbeitung durch Bundesorgane nach DSG

– Abgrenzung zu öffentlichen Aufsichtsbehörden (z.B. EDÖB, kantonale Datenschutzbeauftragte)

– Interner oder extern möglich

– Vorteile ?

– Weisungsungebunden

– Fachlich unabhängig

– Aufgaben (z.B. Schulungen)

Was macht für Sie Eigentum aus?

Art. 641 ZGB

Daten sind keine Sachen

↗ Kein Daten-eigentum

jedoch z.B. Datenträger

Vierter Teil: Das Sachenrecht
Erste Abteilung: Das Eigentum
Achtzehnter Titel: Allgemeine Bestimmungen

Art. 641

A. Inhalt des Eigentums
I. Im Allgemeinen

1 Wer Eigentümer einer Sache ist, kann in den Schranken der Rechtsordnung über sie nach seinem Belieben verfügen.
2 Er hat das Recht, sie von jedem, der sie ihm vorenthält, herauszuverlangen und jede ungerechtfertigte Einwirkung abzuwehren.

Art. 641a[BG]

II. Tiere

1 Tiere sind keine Sachen.
2 Soweit für Tiere keine besonderen Regelungen bestehen, gelten für sie die auf Sachen anwendbaren Vorschriften.

Rechtliche Rahmenbedingungen
Es gibt kein Dateneigentum. Was gilt dann?

- **Geistiges Eigentum (insb. Urheberrecht)**
- **Datenbankrechte**
- **Wettbewerbsrecht**
- **Betriebs- und Geschäftsgeheimnisse**
- **Verträge?**

4. Überblick: Eigentum an Daten?

Was ist Immaterialgüterrecht?

Immaterialgüterrechte
- … sind vom Gesetz gewährte Ausschliesslichkeitsrechte.
- … sind absolute Rechte.
- … betreffen im Gegensatz zu Eigentum nicht körperliche Sachen, sondern immaterielle Güter (daher auch „geistiges Eigentum“ genannt).

absolute Rechte ⟷ **relative Rechte**

Rechte, die gegen jedermann wirken, z.B. Eigentum

Rechte, die nur zwischen den Parteien des Rechtsverhältnisses wirken, z.B. Vertrag

Urheberrecht

- Bundesgesetz über Urheberrecht (URG)
- Verordnung über das Urheberrecht (URV)

Vertiefung – Urheberrecht

Überblick URG

- **Was wird geschützt?**
  - Werke der Literatur und Kunst inklusive Computerprogramme. Der Urheber kann allein bestimmen, ob, wann und wie sein Werk verwendet werden soll
- **Wie entsteht der Schutz?**
  - Automatisch im Moment der Schöpfung
- **Minimalanforderungen:**
  - Geistige Schöpfung mit individuellem Charakter (neu nach revidiertem Recht: Fotos geschützt unabhängig von «individuellem Charakter»)
- **Kein Schutz**: Inhalt (Ideen, Konzepte), Gesetze, amtliche Erlasse, Entscheidungen von Behörden, Zahlungsmittel, Patentschriften
- **Schutzausnahmen:** Privatgebrauch, Zitate, Sicherungskopien, Berichterstattung

Überblick Urheberrecht / URG

- **Schutzumfang:** Definiert durch das konkrete Werk
- **Schutzdauer:** 70 Jahre nach dem Tod des Urhebers / der Urheberin (50 Jahre bei Computerprogrammen)
- **Gängige Symbole oder Hinweise:** ©, «Copyright», «Alle Rechte vorbehalten», «Tous droits réservés» oder ähnliche Anmerkungen (Verwendung fakultativ)
- **Anmeldegebühr (CH)**: Keine
- **Verlängerung (CH)**: Keine
- **Besonderheiten**: Verwertungsgesellschaften: SUISA, SUISSIMAGE, ProLitteris, SSA, SWISSPERFORM

Lizenzvertrag

- **Es wird ein immaterielles Gut zur Nutzung überlassen**
- **Verletzung: Art. 97 OR, Art, 67 URG, Art. 5 lit. c UWG**

- **Proprietäre Software** ≠ **Open Source Software**
  - Entwickelte Software als Geschäftsgeheimnis
  - Sourcecode ist offengelegt

The Open Source Definition – Open Source Initiative

Copyleft-Lizenz
Pflicht alle Änderungen am Sourcecode wieder allen zur Verfügung zu stellen

Non- Copyleft-Lizenz
Programmiererin entscheidet, ob sie den neuen Quelltext der Öffentlichkeit zugänglich machen oder geheim halten will

3. DSGVO

– Inkrafttreten der EU DSGVO per 25. Mai 2016
– Übergangsfrist am 25. Mai 2018 ausgelaufen
– Anwendbarkeit auch auf viele Schweizer Unternehmen (Art. 3 Abs. 2 DSGVO), bspw.
  - EU-Niederlassung (Verarbeitung veranlasst oder vorgenommen durch in der EU niedergelassenen Verantwortlichen oder Auftragsverarbeiter)
  - Betroffene Person mit Aufenthalt in der EU, wenn Verarbeitung im Zusammenhang mit
    - Angebot von Waren und Dienstleistungen an betroffene Personen in der EU;
    - Beobachtung von Verhalten der betroffenen Person, das in der EU erfolgt.

Art. 3 DSGVO

Räumlicher Anwendungsbereich

(1) Diese Verordnung findet Anwendung auf die Verarbeitung personenbezogener Daten, soweit diese im Rahmen der Tätigkeiten einer Niederlassung eines Verantwortlichen oder eines Auftragsverarbeiters in der Union erfolgt, unabhängig davon, ob die Verarbeitung in der Union stattfindet.

(2) Diese Verordnung findet Anwendung auf die Verarbeitung personenbezogener Daten von betroffenen Personen, die sich in der Union befinden, durch einen nicht in der Union niedergelassenen Verantwortlichen oder Auftragsverarbeiter, wenn die Datenverarbeitung im Zusammenhang damit steht

a) betroffenen Personen in der Union Waren oder Dienstleistungen anzubieten, unabhängig davon, ob von diesen betroffenen Personen eine Zahlung zu leisten ist;

b) das Verhalten betroffener Personen zu beobachten, soweit ihr Verhalten in der Union erfolgt.

(3) Diese Verordnung findet Anwendung auf die Verarbeitung personenbezogener Daten durch einen nicht in der Union niedergelassenen Verantwortlichen an einem Ort, der aufgrund Völkerrechts dem Recht eines Mitgliedstaats unterliegt.

Vertiefung: Wettbewerbsrecht

- CH kennt keine spezifische Datenbankgesetzgebung
- *Aber*: bestimmter Schutz aufgrund Wettbewerbsrecht

Verwertung fremder Leistungen (Art. 5 lit. c. UWG)
- marktreifes Arbeitsergebnis einer anderen Person
- ohne angemessenen eigenen Aufwand
- durch technische Reproduktionsverfahren (z.B. Download)
- als «als solches» übernimmt und verwertet.

- Hohe Hürde, damit Schutz im Datenbank-Kontext greift

Nach Amortisierung des Ersterstellers entfällt der Schutz