Data Science Grundlagen

Manuel Dömer

Invalid Date

Inhaltsverzeichnis

Einleitung **3**

I. Data Product-Entwicklung **4**

1. Data Product **5**

2. Agile Data Product-Entwicklung **8**
2.1. Das Wasserfall-Modell und komplexe Situationen 8
2.2. Prinzipien agiler Arbeitsmethoden 9
2.2.1. Selbstorganisation 10
2.2.2. Fokus auf die Nutzerbedürfnisse 10
2.2.3. Unsicherheit als Chance 11
2.2.4. Fixe Ressourcen und Zeit 11
2.2.5. Inkrementelles und iteratives Vorgehen 12
2.2.6. Agile Arbeitsmethoden im Vergleich zum Wasserfall-Modell 13
2.2.7. Modelle agiler Arbeitsmethoden 14

II. Der Data Science-Prozess **18**

3. Aufgabendefinition **21**
3.1. Beschreibung der Problemstellung 21
3.1.1. Domänenwissen 22
3.1.2. Nutzende Personen 22
3.1.3. Anspruchsgruppen (Stakeholder) 23
3.2. Situationsbewertung 23
3.3. Projektziele und Erfolgskriterien 24
3.4. Data Mining-Ziele 25
3.5. Projektplan 27
3.5.1. Rollen und Aufgaben 27
3.5.2. Kollaborationsmodus 27
3.5.3. Planung der Projektphasen 27
3.6. Projektcharta 28

4. Datenbeschaffung und -erkundung **29**
4.1. Daten und Information . . . 29
4.1.1. Analoge Daten . . . 29
4.1.2. Digitale Daten . . . 29
4.1.3. Bits und Bytes . . . 30
4.1.4. Digitalisierung von Daten . . . 31
4.1.5. Datei . . . 36
4.1.6. Daten im Kontext “Data Science” . . . 36
4.1.7. Datenmodell . . . 37
4.1.8. Strukturierte und unstrukturierte Daten . . . 38
4.1.9. Metadaten . . . 43
4.1.10. Rohdaten . . . 43
4.2. Datenbeschaffung . . . 43
4.2.1. Datenquellen identifizieren . . . 44
4.2.2. Datenbeschaffung über Webservices . . . 45
4.2.3. Aspekte der Datenbeschaffung . . . 47
4.2.4. Daten ablegen und organisieren . . . 47
4.2.5. Datenkatalog erstellen . . . 49
4.2.6. Data governance . . . 50
4.3. Datenerkundung . . . 51
4.3.1. Statistische Variablentypen . . . 52
4.3.2. Explorative Analyse strukturierter Daten . . . 54
4.3.3. Explorative Analyse unstrukturierter Daten . . . 63
4.4. Datenaufbereitung . . . 63
4.4.1. Integration und Konsolidierung . . . 64
4.4.2. Datenbereinigung . . . 64
4.4.3. Transformationen . . . 68
4.4.4. Datenreduktion . . . 75
4.4.5. Die Datenmatrix . . . 75
4.4.6. Datenaufbereitung unstrukturierter Daten . . . 76
4.5. Datenbericht (Data report) . . . 82

5. Modellierung **84**
5.1. Paradigmen des Maschinellen Lernens . . . 84
5.2. Überwachtes Lernen . . . 85
5.2.1. Der Verallgemeinerungsfehler . . . 85
5.2.2. Regression . . . 86
5.2.3. Klassifikation . . . 93
5.3. Unüberwachtes Lernen . . . 98
5.3.1. Dimensionsreduktion . . . 99
5.3.2. Clusteranalyse . . . 101
5.3.3. Empfehlungsdienste . . . 103

6. Evaluation **114**
6.1. Übersicht . . . 114
6.2. Beurteilung der Zielerreichung . . . 114
6.3. Planung der nächsten Schritte . . . 115
6.4. Checkpoint-Entscheidung . . . 115
6.5. Evaluationsbericht . . . 115

7. Bereitstellung **116**
7.1. Ziele und Phasen der Bereitstellung . . . 116
7.2. Lieferobjekte der Bereitstellung . . . 117
7.3. Ein Architektur-Blueprint für Machine Learning-Anwendungen . . . 117
7.4. Machine Learning Operations (MLOps) . . . 118

III. Ethische Aspekte **120**

8. Ethische Aspekte **121**
8.1. Moral, Ethik und Recht . . . 121

9. Datenethik **123**

10. Der Ethik-Kodex für Datenbasierte Wertschöpfung **124**

IV. Rechtliche Aspekte **127**
Überblick Rechtssystem/Rechtsordnung In der Schweiz . . . 128

11. Strafrecht **129**
11.1. Aufbau vorsätzliches Handlungsdelikt (grob umrissen) . . . 129
11.1.1. Prüfschema (grob) . . . 129
11.2. Überblick Computerdelikte (Auswahl) . . . 130
11.2.1. Unbefugte Datenbeschaffung . . . 130
11.2.2. Unbefugtes Eindringen in ein Datenverarbeitungssystem . . . 131
11.2.3. Datenbeschädigung . . . 132
11.2.4. Herstellen von datenschädigenden Programmen . . . 132
11.2.5. Betrügerischer Missbrauch einer Datenverarbeitungsanlage . . . 132
11.3. Weiterführende Informationen . . . 132

12. Datenschutz **133**
12.1. Allgemeines . . . 133
12.2. Terminologie . . . 133
12.3. Hinweise zur Revision . . . 134
12.4. Grundsätze . . . 135

12.5. Bestimmungen zum Datenschutz durch Technik und datenschutzfreundliche Einstellung . . . 137
12.6. Zulässige Datenbearbeitung und Rechtfertigung . . . 138
12.7. Rechte und Pflichten nach DSG (Auswahl) . . . 138
12.7.1. Auskunftsrecht . . . 139
12.7.2. Informationspflicht . . . 139
12.7.3. Informationspflicht bei einer automatisierten Einzelentscheidung . . . 139
12.7.4. Recht Datenherausgabe und -übertragung (Art. 28 und 29 DSG) . . . 139
12.7.5. Bearbeitungsverzeichnis und DSFA . . . 140
12.8. Auslagerung und Bekanntgabe ins Ausland. . . . 140
12.9. Funktion Datenschutzberater . . . 140
12.10DSGVO . . . 140

13. Immaterialgüterrecht **142**
13.1. Rechtliche Einordnung von "Daten", bezogen auf die Schweiz . . . 142
13.1.1. Vertiefung Urheberrecht: . . . 143
13.1.2. Vertiefung Wettbewerbsrecht . . . 144
13.2. Lizenzvertrag: . . . 145
13.3. Open Source-Software: . . . 145

Literaturverzeichnis **147**

Einleitung

Data Science Grundlagen

Teil I.

Data Product-Entwicklung

1. Data Product

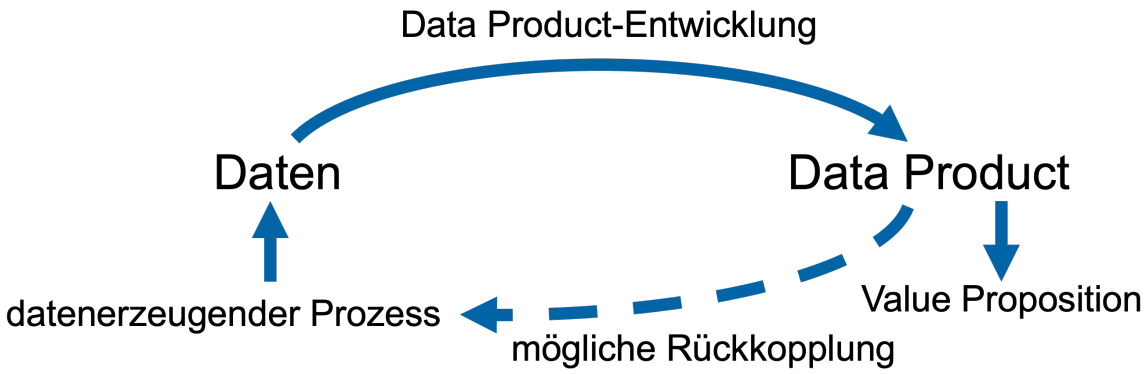


Abbildung 1.1.: Entwicklung und Rückkopplung datenbasierter Produkte [1]

Statistische Studien beginnen typischerweise mit der Planung der Datenerhebung (Experiment), um mit der darauffolgenden. In einer solchen experimentellen Studie, kann der datengenerierende Prozess kontrolliert und beeinflusst werden. Beispielsweise, können bei einer Studie zum Einfluss der Ernährung auf die Gesundheit verschiedene Personengruppen unterschiedliche Diäten vorgeschrieben bekommen. In einer Beobachtungsstudie hingegen, kann man den datengenerierenden Prozess nicht kontrollieren. Beispielsweise können zufällig ausgewählte Menschen nach ihrem Ernährungsverhalten und ihrer Gesundheit befragt werden. Dabei ist nicht beeinflussbar, über welche Diäten Daten gesammelt werden können und wie viele Menschen für jedes Ernährungsverhalten berücksichtigt werden.

Ein typisches Data Science-Projekt stützt sich auf Beobachtungsdaten (observational data). Das heisst, die Arbeit mit den Daten beginnt, ohne den datengenerierenden Prozess und seinen Kontext genau zu kennen oder beeinflussen zu können. Dabei werden die Daten genutzt, um zielorientiert bestimmte Fragestellung zu beantworten oder ein spezifisches Problem zu lösen. Um dieses Ziel zu erreichen werden pragmatisch die am besten passenden Methoden eingesetzt. In diesem Sinne ist Data Science eine typische Ingenieurswissenschaft: Es geht nicht primär darum, eine vereinheitlichende Theorie zu entwickeln, sondern wissenschaftliche Vorgehensweisen werden eingesetzt, um einen direkten Mehrwert in Form eines datenbasierten Produktes (Data Product - siehe [2] für eine detaillierte Ausführung) für spezifische nutzende Personen zu erarbeiten. Ein solches Produkt kann einen Mehrwert (Value Proposition) in Form von ökonomischem Profit, sozialem Nutzen oder wissenschaftlichem Erkenntnisgewinn

darstellen. In diesem Sinne wird der Begriff Data Product als Etikett für die Umsetzungsform der jeweiligen Data Science-Aktivität verwendet, unabhängig davon, ob diese in einem kommerziellen, sozialen oder wissenschaftlichen Kontext durchgeführt wird.

Dabei kommt auch der Bereitstellung (Deployment) des Data Products und der Integration in den entsprechenden (Geschäfts-)Prozessen und Nutzergemeinschaften eine grosse Bedeutung zu: Der Mehrwert entsteht erst, wenn die Erkenntnisse und Vorhersagen aus der Datenanalyse für die nutzenden Personen zugänglich und optimal in deren Aufgaben nutzbar sind. Dann ist eine nutzende Person bereit, auch einen Gegenwert, z.B. monetär oder in Form von Aufmerksamkeit - vergleiche dazu die Definition nach Kotler: "A product provides a set of benefits for which the customer has a willingness to return a value, typically in the form of money" [3]. Bei den Nutzergruppen kann es sich sowohl um externe, als auch Organisations-interne Nutzer handeln.

Abbildung 1.1 betont die Daten als die Grundlage für den Mehrwert, der in Form eines Produktes hergestellt werden kann. Obwohl (oder gerade weil) es sich um Beobachtungsdaten handelt, ist in der Entwicklung des datenbasierten Produktes (oberer Pfeil in der Abbildung oben) der Kontext, in denen die Daten entstanden sind (datenerzeugender Prozess), so gut wie möglich zu berücksichtigen. Auch wird das Produkt in einem bestimmten Kontext bereitgestellt und für bestimmte Personen(gruppen) nutzbar gemacht. Diese Kenntnis des Kontextes (sowohl der Datenentstehung als auch der Nutzung des darauf basierenden Produktes) wird häufig als Domänenwissen (Domain Expertise oder Substantive Expertise) bezeichnet.

Der untere Pfeil in Abbildung 1.1 zeigt eine mögliche Rückkopplung des Data Products auf die für die (Weiter)Entwicklung genutzten Daten auf. Das bereitgestellte Produkt produziert neue (Arten von) Daten, welche ein neues Verständnis der Problemstellung ermöglicht oder für die Verbesserung des Produktes verwendet werden können (z.B. Nutzer-Rückmeldungen, Applikationslogs, Telemetriedaten der Infrastruktur). Aber auch die Kernfunktionen des Produktes können direkt über neue Erkenntnisse, Vorhersagen oder Empfehlungen zu einer Veränderung des Nutzerverhaltens führen, was wiederum den datenerzeugenden Prozess und damit ein auf diesen sich verändernden Daten basierendes Produkt beeinflussen kann.

Das ursprünglich von Drew Conway vorgestellte Data Science Venn-Diagramm [4] (Abbildung 1.2) verdeutlicht, dass sich der Mehrwert eines Data Products jeweils aus einer ganz spezifischen Kombination von Kompetenzen und damit aus dem Mehr als die Summe seiner Teile ergibt. Es nennt die Kompetenzen Domänenwissen (Substantive Expertise), Kompetenzen im Software Engineering-Bereich (Hacking Skills) und angewandter Mathematik (Maths & Statistics Knowledge).

Eine Ausformulierung der Gedanken hinter dem Data Science Venn-Diagramm ist in [4] unter «How to read the Data Science Venn Diagramm» zu finden.

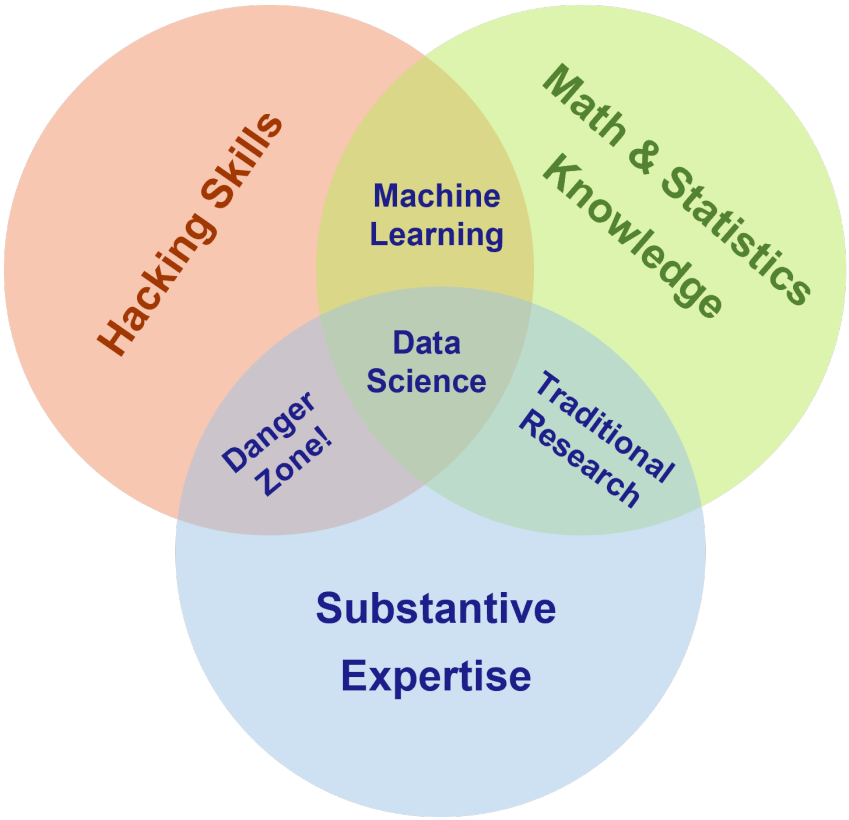


Abbildung 1.2.: Das Data Science-Venn Diagramm nach [4]

2. Agile Data Product-Entwicklung

2.1. Das Wasserfall-Modell und komplexe Situationen

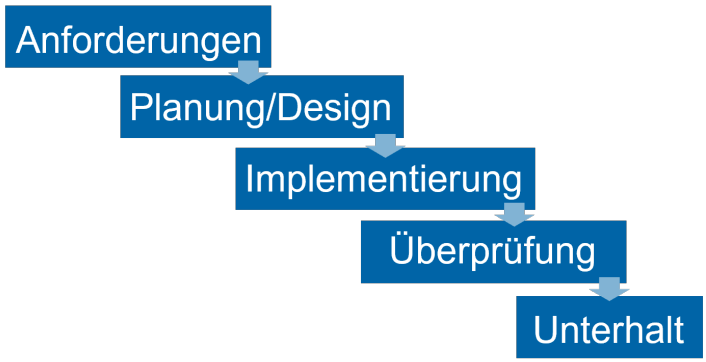


Abbildung 2.1.: Die Projektphasen im Wasserfallmodell

Das Wasserfallmodell wurde ursprünglich für Produktionsprozesse entwickelt, wo späte Änderungen der Anforderungen prohibitiv teuer oder unmöglich umzusetzen sind (z.B. Baubranche) und wo sich Anforderungen, Leistungen und Abläufe in der Planungsphase relativ präzise beschreiben lassen. Die direkte Übertragung dieser Vorgehensweise auf die Softwareentwicklung

1. Anforderungsanalyse und -spezifikation resultiert im Lastenheft
2. Systemdesign und -spezifikation resultiert in der Softwarearchitektur
3. In der Implementierungsphase wird die eigentliche Software entwickelt
4. Die Überprüfung beinhaltet Integrations- und Systemtests
5. In der letzten Phase wird die Software ausgeliefert und es schliesst sich die Wartung und der Unterhalt an

hat sich jedoch als nicht vorteilhaft erwiesen. Ähnliches gilt aufgrund der hohen Komplexität auch für Data Science-Projekte. Der Data Science-Prozess setzt die Prinzipien agiler Arbeitsmethoden um und addressiert die spezifischen Anforderungen in der Entwicklung datenbasierter Produkte (Kapitel 1).

2.2. Prinzipien agiler Arbeitsmethoden

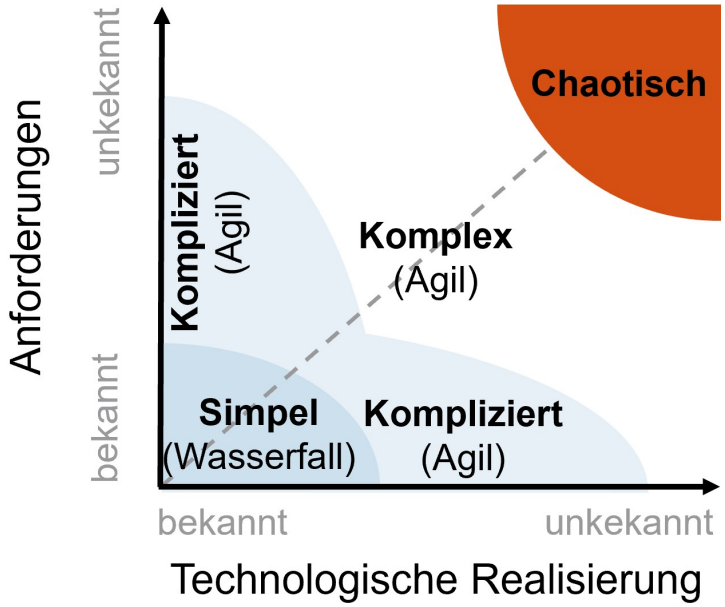


Abbildung 2.2.: Wasserfall und Agil im Spannungsfeld verlässlicher Anforderungen und etablierter technologischer Lösungen. Darstellung nach [5]

Abbildung 2.2 zeigt auf, dass agile Arbeitsmethoden unter bestimmten Voraussetzungen Vorteile gegenüber dem traditionellen Wasserfall-Modell haben: Wenn die Anforderungen (teilweise) unbekannt sind oder sich stark verändern und wenn die technologische Realisierung, das gesuchte Ergebnis, noch unbekannt ist – in anderen Worten: Wenn Innovation notwendig ist. Hingegen sind in einfachen, kleinen Projekten, in denen das erwartete Ergebnis und die Anforderungen bekannt sind, traditionelle Wasserfall-Methoden effektiver. Bei Standardprozessen mit gesetzlichen Vorgaben, etwa in der Buchhaltung oder im Rechnungswesen, bringen agile Methoden kaum Mehrwert.

Das Agile Manifesto wurde 2001 von 17 Softwareentwicklern veröffentlicht. Es ist als Gegenvorschlag zu den traditionellen Wasserfall-Methoden zu verstehen, welche sich in der Softwareentwicklung als ungeeignet herausgestellt haben. Denn Softwareprojekte sind häufig sehr komplex. Dies liegt in erster Linie am Kontext und den Rahmenbedingungen der Organisationen, in denen typische Softwareprojekte ausgeführt werden, an den Erwartungen von Stakeholdern und den Anforderungen der nutzenden Personen von Softwareprodukten. Frei übersetzt lautet das Manifesto:

Wir erschließen bessere Wege, Software zu entwickeln, indem wir es selbst tun und anderen dabei helfen. Durch diese Tätigkeit haben wir diese **Werte** zu schätzen gelernt:

- Individuen und Interaktionen mehr als Prozesse und Werkzeuge

- Funktionierende Software mehr als umfassende Dokumentation
- Zusammenarbeit mit dem Kunden mehr als Vertragsverhandlungen
- Reagieren auf Veränderung mehr als das Befolgen eines Plans

Dem «Agile Manifesto» sind die Principles behind the Agile Manifesto angefügt worden, welche teilweise konkreter und ausführlicher formuliert sind. Im Folgenden eine Auswahl an Prinzipien (und eine Ergänzung), welche aus Sicht des Autors im Bezug auf Data Science-Projekte besonders relevant sind:

- Produktivität durch **Selbstorganisation**
- Fokus auf die Erfüllung der **Nutzerbedürfnisse**
- **Unsicherheit** als Ressource
- **Fixe Ressourcen** und **Zeit**
- **Inkrementelles und iteratives Vorgehen**

Stehen diese Prinzipien für sich alleine, bleiben sie relativ abstrakt. Den wahren Wert entfalten sie im Bezug auf konkrete Praxis-Erfahrungen und in der Implementierung in der Form von agilen Frameworks (Kapitel 2.2.7).

2.2.1. Selbstorganisation

Projekte entwickeln sich am besten rund um motivierte Mitarbeiter. Agile Teams sind interdisziplinär zusammengesetzt, kollaborativ und organisieren sich aus intrinsischer Motivation. Sie arbeiten mit klaren Zielvorgaben, welche in der Regel zusammen mit Stakeholdern und dem Management vereinbart wurden, sind jedoch für die Umsetzung alleine zuständig.

Das Management hält ihnen den Rücken frei und sorgt für optimale Bedingungen, anstatt detaillierte Anweisungen zu geben. Management- und Kontrollstrukturen werden möglichst schlank und flach gehalten. Das bedeutet nicht, dass sämtliche Regeln und Hierarchien abgeschafft werden. Sie werden jedoch nur dort eingesetzt wo sie tatsächlich einen Nutzen bringen. Grundsätzlich basiert die Zusammenarbeit eher auf Vertrauen als auf Befehl und Kontrolle.

Idealerweise bleibt die Teamzusammensetzung während des Entwicklungsprozesses konstant. Dadurch entstehen Vertrauen und Kontinuität, wodurch das Team effizienter wird.

Zur Selbstorganisation gehört auch Selbstreflexion: Das Team tauscht sich aus darüber, was gut und was schlecht gelaufen ist und versucht sich kontinuierlich zu verbessern.

2.2.2. Fokus auf die Nutzerbedürfnisse

Der Fokus agiler Vorgehensweisen liegen auf der Erfüllung der Nutzerbedürfnisse. Das zu entwickelnde Produkt hat nur einen Wert für den Kunden, wenn es einen Nutzen bringt (increase gains) und/oder konkrete Probleme (decrease pains) löst.

Dies ist nur möglich, wenn die Bedürfnisse der Nutzer verstanden werden und möglichst früh und kontinuierlich in die Entwicklungsarbeit mit einbezogen werden. Lösungsvorschläge müssen ständig auf ihre Nützlichkeit direkt von den nutzenden Personen getestet und Feedback gesammelt werden.

Siehe auch das Kapitel zu nutzenden Personen in der Phase Aufgabendefinition des Data Science-Prozesses.

2.2.3. Unsicherheit als Chance

Es ist schwierig, komplexe Aufgaben in ihrer Gesamtheit durchzuplanen. Unsicherheiten lassen sich in den wenigsten Fällen mit vertretbarem Aufwand eliminieren. Als Konsequenz akzeptiert man die Unsicherheit und beschränkt sich in der Planung auf überschaubare, klar abgegrenzte Einheiten.

Die Unsicherheit rührt auch von variierenden Anforderungen aufgrund von Veränderungen

- in der Umgebung
- bei den Nutzern
- der internen Organisation
- in der Technologie
- in den Abhängigkeit von anderen Projekten
- …

Trotz geringerer langfristiger Sicherheit im Planungsprozess, erlaubt ein agiles Vorgehen schneller und besser auf Veränderungen zu reagieren.

Selbst in fortgeschrittenem Entwicklungsstadium muss mit Änderungen gerechnet werden und die agilen Prinzipien besagen sogar, dass Veränderungen zu begrüssen sind: “Late changes are welcome”. Sie sollen als Chance verstanden werden, gegenüber sequentiell und langfristig planender Konkurrenz einen Wettbewerbsvorteil herauszuarbeiten.

2.2.4. Fixe Ressourcen und Zeit

Der Umgang mit festgelegten Zielen wie Arbeitsergebnissen unter Berücksichtigung von Fristen und Ressourcen wie Budgetvorgaben ist oft schwierig. Das ursprünglich von Martin Barnes 1969 vorgestellte Magische Dreieck folgt einem Wasserfallansatz für die Produktentwicklung (Abbildung 2.3 linke Seite): Der Umfang ist fest vorgegeben, während die Ressourcen und die verfügbare Zeit variabel sind. Für ein Softwareteam würde dies bedeuten, dass es zu Beginn des Projekts die Produktanforderungen definiert und auf dieser Grundlage den Projektumfang (eine Liste mit Aufgabenelementen) festlegt. Die Ressourcen und der Zeitplan sind variabel und werden anhand des festgelegten Umfangs eingeschätzt. Kommt es während des Projektes

zu Veränderungen, so wird am Umfang festgehalten, während Ressourcen und Zeit angepasst werden können.

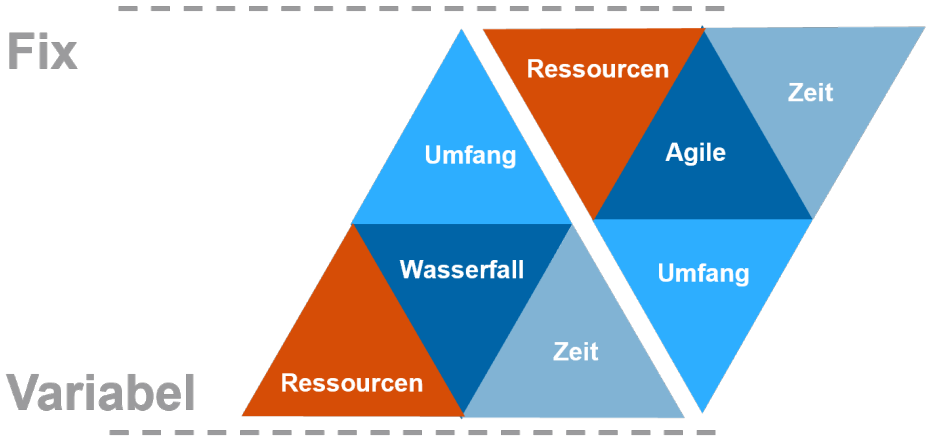


Abbildung 2.3.: Das magische Dreieck der Planung - im Wasserfall-Ansatz (links) gegenüber der agilen Vorgehensweise (rechts) nach [6].

Das Magische Dreieck (Abbildung 2.3) macht die unter Berücksichtigung der Beschränkungen möglichen Kompromisse zugunsten des Unternehmens transparent. Wenn Teams beispielsweise mit einem festgelegten Umfang arbeiten und nach der Hälfte des Projekts feststellen, dass das Release-Datum nicht einzuhalten ist, können sie nur zwei Variablen beeinflussen:

- Zeit – sie können sich mit dem späteren Release-Datum arrangieren.
- Ressourcen – sie können zusätzliche Mitarbeiter zum Projekt hinzuziehen, wodurch die Kosten steigen.

Anders als im Wasserfallmodell sind bei agilen Vorgehensweisen der Zeitrahmen und die Ressourcen festgelegt, während der Umfang veränderlich ist (rechte Seite in Abbildung 2.3). Da die Ressourcen und der Zeitrahmen festgelegt sind, können die Entwicklerteams leichter auf Veränderungen am Markt reagieren und schneller einen Mehrwert für Kund:innen schaffen [6].

2.2.5. Inkrementelles und iteratives Vorgehen

Inkrementelles und iteratives Vorgehen helfen, Risiken in der Umsetzung zu minimieren, indem eine komplexe Aufgabe in kleiner Arbeitspakete aufgeteilt wird. Das Ergebnis jedes einzelnen Arbeitspaketes wird jeweils (idealerweise in Nutzertests) auf seine Tauglichkeit überprüft. Die Ergebnisse aus diesen Überprüfungen werden in der Planung der darauffolgenden Arbeitspakete berücksichtigt. So können schnell und ressourcenschonend Fehlüberlegungen korrigiert, unvorhergesehene Komplikationen adressiert und veränderte Anforderungen berücksichtigt werden.

Bei einem iterativen Prozess werden Funktionen oder Eigenschaften eines Produktes schrittweise verbessert. “Ein gutes Beispiel dafür sind Skulpturen. Als erstes sucht sich der Bildhauer einen Stein in der richtigen Größe aus. Dann arbeitet er die grobe Form des Kunstwerks heraus. An diesem Punkt kann man vielleicht schon den Kopf und den Körper erkennen und sehen, dass es eher ein Mensch als ein Vogel werden soll. Im nächsten Schritt verfeinert der Bildhauer sein Werk und arbeitet Details heraus. Er wird keinen Teil seines Kunstwerks als fertig ansehen, ehe nicht das gesamte Werk fertig ist” [7].
Bei einem inkrementellen Prozess entstehen in den einzelnen Arbeitspaketen in sich weitgehend abgeschlossene Einzelteile - Inkremente - des Gesamtproduktes. Jedes dieser Inkremente repräsentiert eine eigenständige Funktionalität. Ihr Umfang ist dabei nicht festgelegt. Grundsätzlich wird aber davon ausgegangen, dass diese Teile nach Abschluss des jeweiligen Arbeitspaketes nicht noch einmal überarbeitet werden müssen. “Ein Bildhauer, der inkrementell arbeitet, wird sich solange auf einen Teil seiner Arbeit konzentrieren, bis dieser fertig gestellt ist. Das können kleine Inkremente (erst die Nase, dann die Augen, dann der Mund usw.) oder große Inkremente (Kopf, Torso, Beine, Arme) sein. Unabhängig von der Größe der Inkremente wird der Bildhauer aber immer erst versuchen, die Arbeit an einem bestimmten Inkrement komplett fertigzustellen” [7].

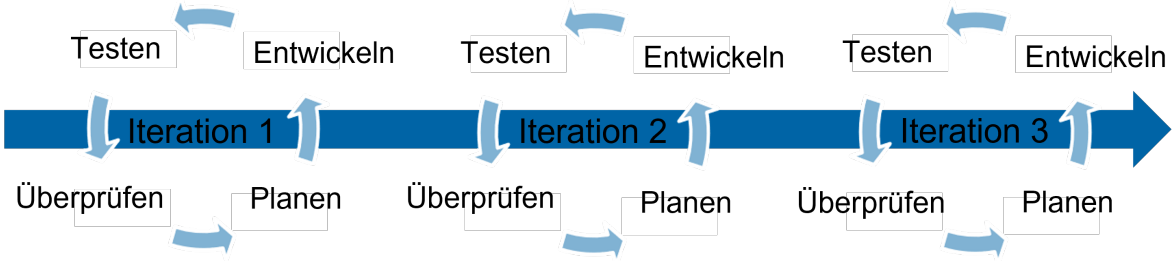


Abbildung 2.4.: Evolution durch kombiniertes inkrementelles und iteratives Vorgehen

Agil kombiniert oft inkrementelles und iteratives Vorgehen (siehe Abbildung 2.4). Die Evolution findet in zeitlich begrenzten Entwicklungssequenzen – den Iterationen – statt. Dabei können je nach Bedarf in sich abgeschlossene Inkremente oder Verbesserungen bereits bestehender Funktionalitäten entstehen. Jede Iteration beinhaltet die Phasen 1) Planen (Plan), 2) Entwickeln (Develop), 3) Testen (Test), 4) Überprüfen (Review) bzw. eine Retrospektive.

2.2.6. Agile Arbeitsmethoden im Vergleich zum Wasserfall-Modell

Tabelle 2.1.: Vergleich agiler Arbeitsmethoden mit d

Agil	Wasserfall
Iteratives und inkrementelles Vorgehen (evolutionäre Entwicklungszyklen)	Lineares sequentielles Vorgehen
Flexible, kontinuierliche (Weiter)Entwicklung	Aktivitäten werden in der geplant

Agil	Wasserfall
Ressourcen und Zeit sind fix	Umfang ist fix – keine Änderunge
Einbezug der Nutzer während des gesamten Entwicklungsprozesses	Einbezug der Nutzer nur um im E
Selbstorganisation der Teams	Befehls-und-Kontroll-Organisation

2.2.7. Modelle agiler Arbeitsmethoden

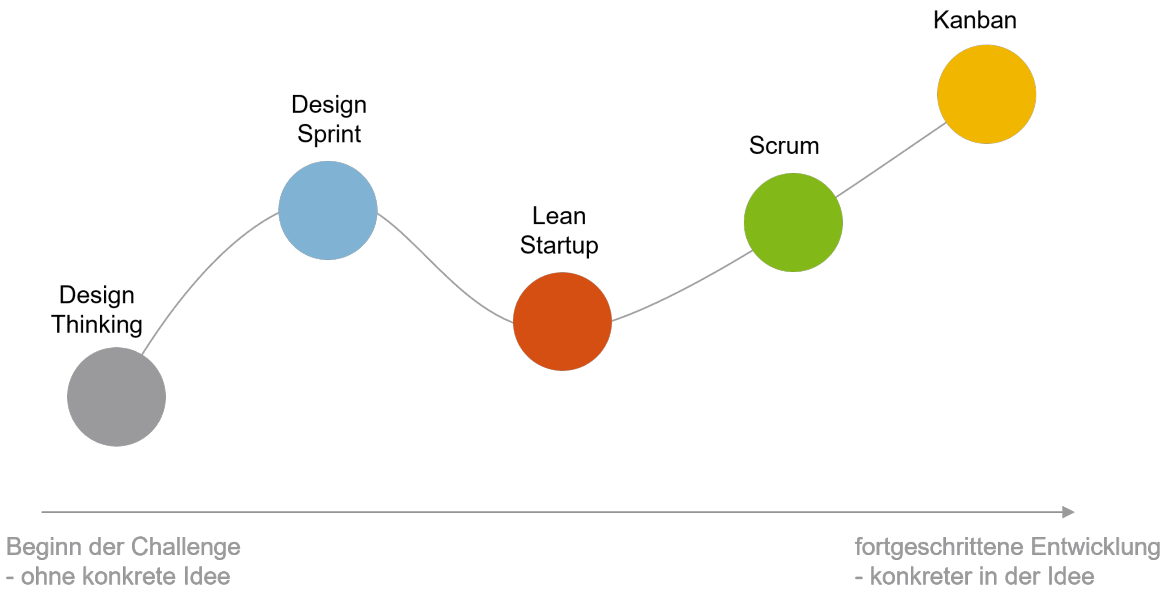


Abbildung 2.5.: Eine Übersicht populärer agiler Methoden angeordnet entlang der Konkretisierung der Idee in einem Innovationsprojekt

Unterschiedliche Agile-Frameworks konkretisieren und implementieren die agilen Prinzipien auf jeweils eine bestimmte Art und Weise. Sie verwenden zum Teil verschiedene Terminologien und setzen unterschiedliche Schwerpunkte. Jedoch lassen sich immer wieder dieselben grundlegenden Prinzipien (siehe Kapitel 2.2) identifizieren.

Abbildung 2.5 zeigt eine Übersicht einer Auswahl populärer Methoden, angeordnet entlang der Konkretisierung des jeweiligen Innovationsprojektes, in dem sie eingesetzt werden. Diese Anordnung ist rein tendenziell zu verstehen und dient einzig einer groben Einordnung.

Design Thinking eignet sich besonders in einer sehr frühen Phase, wenn zunächst ein Ideenraum aufgespannt werden soll. Die geistige Haltung dabei ist, dass Innovation da entsteht, wo konkrete Bedürfnisse von Menschen mit technologischer Realisierbarkeit, ökonomisch sinnvoll und unter Berücksichtigung ökologischer Nachhaltigkeit erfüllt werden können (Abbildung 2.6).

Die Ausgestaltung der Entwicklungsschritte beruht auf den Grundprinzipien Team (die richtigen Leute zusammenbringen), Raum (in geeigneten Räumen arbeiten) und Prozess (die auf das Problem und das Team passenden Methoden).

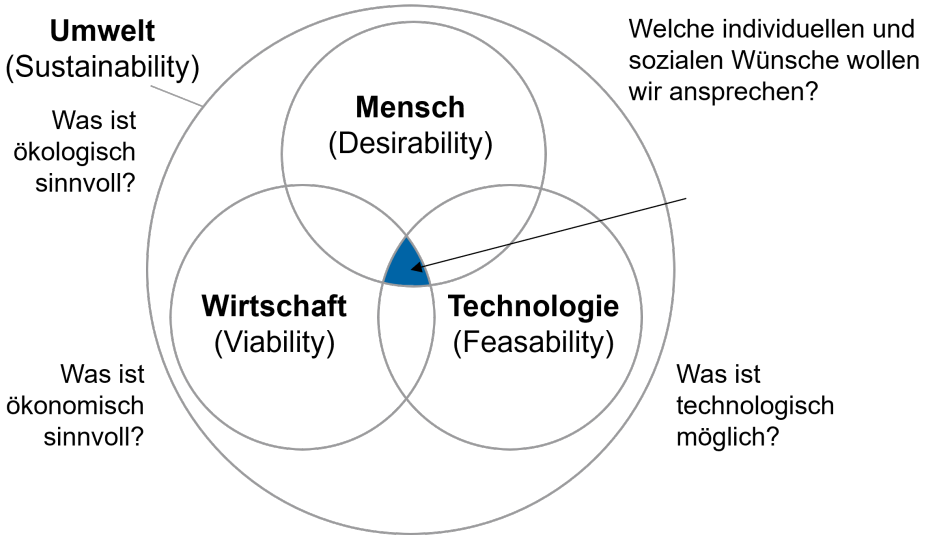


Abbildung 2.6.: Die Prinzipien im Design Thinking

Der **Design Sprint** ist ein sehr strukturierter Design Thinking-Prozess, welcher von Google Ventures entwickelt wurde [8]: In einem fünftägigen Workshop werden nach einem vorgegebenem Schema Probleme analysiert, Lösungen entwickelt und Ideen mit Kunden getestet.

Im **Lean Startup**-Approach [9] steht die möglichst schnelle Entwicklung eines Minimum Viable Product (MVP) im Fokus. Ein MVP ist die "Version eines neuen Produkts, mit der ein Team mit geringstem Aufwand die maximale Menge an validiertem Kundenwissen sammeln kann (ähnlich einem Pilotversuch) [10]. Basierend auf der initialen Idee wird ein"Prototyp erstellt", welcher die wesentlichen Eigenschaften der Produktidee bietet, sodass in einem "Experiment" Daten über die Akzeptanz auf Seiten der nutzenden Personen gesammelt werden können. Diese Erkenntnisse werden für die iterative und inkrementelle Weiterentwicklung der Produktidee genutzt. Auf die Erstellung aufwändiger Geschäftspläne wird dabei weitgehend verzichtet.

Scrum ist sehr etabliert in der Software-Entwicklung. Das Framework legt Rollen, Ereignisse, Lieferobjekte (Artefakte) und die Regeln für den Entwicklungsprozess fest. Ein Scrum-Team ist sehr flach organisiert - es besteht im Wesentlichen aus den Entwicklern. Zwei besondere Rollen, welche auch von Personen neben ihrer Entwicklungstätigkeit übernommen werden können, sind

- Product Owner: Ist für die Aufnahme von Arbeiten und deren Priorisierung im Produkt-Backlogs verantwortlich und damit auch für die Maximierung des Wertes, welcher aus der Arbeit des Scrum-Teams resultiert.

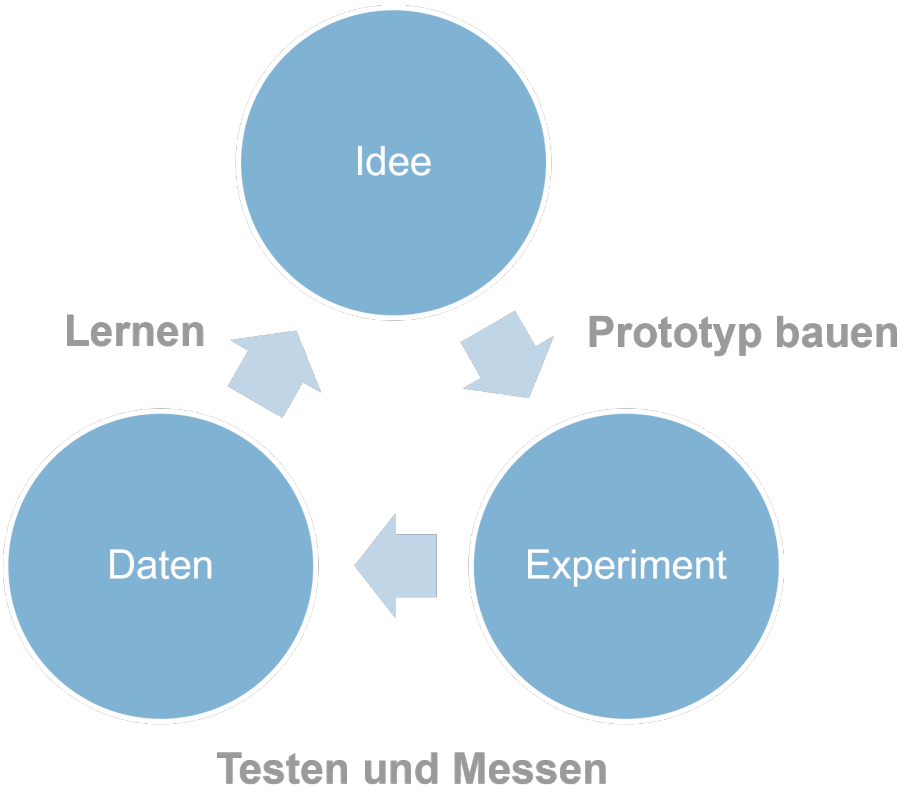


Abbildung 2.7.: Tätigkeiten (Pfeile) und Artefakte (blaue Kreise) im Vorgehen nach Lean Startup

- Scrum Master: Ist verantwortlich dafür, dass Ereignisse und Termine für Lieferobjekte eingehalten werden und damit für die effektive Zusammenarbeit im Team.

Die Artefakte umfassen:

- Produkt-Backlog: Liste an notwendigen Arbeiten, um das Produkt zu verbessern
- Sprint-Backlog: Auswahl an Elementen aus dem Produkt-Backlog, welche im Sprint bearbeitet werden sollen
- Inkrement: Während eines Sprints entwickelter Beitrag zu der Erreichung des Produkt-Zieles

Ein Sprint (Entwicklungszyklus) dauert in der Regel 2 bis 3 Wochen, in dem das sogenannte Inkrement entsteht. Die Ereignisse im Sprint sind:

- Planung: Erstellung des Sprint-Backlogs
- Tägliches Scrum-Meeting: Austausch über
  - die seit dem letzten Meeting abgeschlossenen Arbeiten
  - die derzeit laufenden Arbeiten
  - neu aufgetretende Hindernisse
- Review: Präsentation des Inkrements vor Anspruchsgruppen (Stakeholdern) und Diskussion des Fortschritts im Hinblick auf die Produkt-Ziele
- Retrospektive: Reflexion des Teams über die Qualität und Effektivität der Zusammenarbeit - Was hat gut funktioniert? Was könnte verbessert werden? Zu welchen Verbesserungen verpflichtet sich das Team im nächsten Sprint?

Für eine detailliertere Darstellung ist auf die verschiedenen Ressourcen auf [11] und den Scrum Guide [12] verwiesen.

Der Einsatz von **Kanban** in der Softwareentwicklung [13] übernimmt grundlegende Prinzipien des ursprünglich von Toyota für die Optimierung der industriellen Fertigung entwickelten Prozesses, wo die Reduktion von Engpässen einen gleichmässigen Produktionsfluss (Stillstände vermeiden) der einzelnen Teile herstellen und Lagerbestände reduzieren soll. Als zentrales Werkzeug hilft das Kanban-Board, Aufgaben zu visualisieren, die Anzahl laufender (WIP-)Aufgaben zu begrenzen und den Workflow zu optimieren. Eine griffige Einführung zu den verschiedenen Elementen auf dem Board findet sich auf [14].

Teil II.

Der Data Science-Prozess

Aufgrund der hohen Komplexität eignen sich für Data Science-Projekte typischerweise agile Arbeitsmethoden besonders gut. In diesem Gebiet haben sich der CRISP-DM (Cross-Industry Standard Process for Data Mining, [15]) und KDD-Prozess (Knowledge Discovery in Databases, [16], [17]) etabliert - siehe auch [18] für einen detaillierten Vergleich. Als Praxis-Handbuch und ausführliche Behandlung von CRISP-DM ist [19] zu empfehlen. Der hier vorgestellte Prozess [1] kombiniert diese Elemente mit dem (auf denselben Grundprinzipien basierenden) Microsoft Team-Data-Science-Prozess [20] und MLOps (Machine learning Operations, [21]), wobei letzteres Framework Elemente aus den im Software-Engineering etablierten CI/CD (Continuous Integration/Continuous Deployment)-Prozessen, bzw. DevOps, mit den Daten-zentrierten Entwicklungsphasen verknüpft.

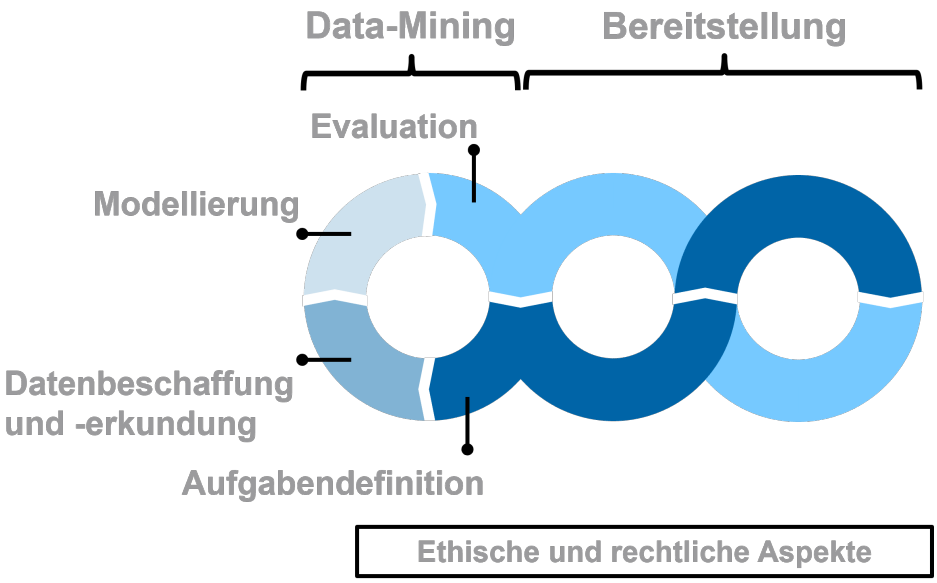


Abbildung 2.8.: Der Data Science-Prozess [1]

Der **Data Mining**-Teil des Data Science-Prozesses (Abbildung 2.8) besteht aus den 4 Phasen

- Aufgabendefinition (engl.: Business Understanding oder Project Understanding)
- Datenbeschaffung und -erkundung (engl.: Data Acquisition and Understanding)
- Modellierung (engl.: Modelling)
- Evaluation , welche mit jeweils spezifischen Tätigkeiten und Lieferobjekten. In der Regel werden die einzelnen Phasen, wie in agilen Vorgehensweisen üblich, in iterativen Entwicklungszyklen mehrmals durchlaufen.

Die Phase **Aufgabendefinition** (Kapitel 3) zielt auf ein umfassendes Verständnis der Problemstellung und der Ausgangslage ab. Sie sollte den möglichen Nutzen, Risiken und den Aufwand eines erfolgreichen Projektes identifizieren. Daraus ergeben sich spezifische Projektziele

mit Erfolgskriterien und ein Projektplan. Zudem wird die Problemstellung von der Projektdomaine in eine technische, datenzentrierte Formulierung übersetzt. Als Artefakt entsteht die Projektcharta. Diese Phase wird typischerweise im Englischen mit Business Understanding bezeichnet, jedoch ist eine allgemeinere Bezeichnung wie Project Understanding passender, da eine Problemstellung auch rein technischer Natur sein kann oder einem wissenschaftlichen Erkenntnisgewinn oder gesellschaftlichem Nutzen dienen kann.

In der Phase **Datenbeschaffung und -erkundung** (Kapitel 4.2 und Kapitel 4.3) werden Datenquellen identifiziert und Daten beschafft. Diese werden in einem Datenkatalog als Übersicht erfasst. In einer explorativen Analyse wird die Qualität der Daten und deren Eignung in der Bearbeitung der gegebenen Problemstellung beurteilt. Zudem werden über statistische Masse und Visualisierungen die Eigenschaften der Variablen und deren Beziehungen zueinander beschrieben, was zu ersten Erkenntnissen und Hypothesen führt. An dieser Stelle muss auch kritisch hinterfragt werden, ob die Datenlage ausreicht, um die gegebene Problemstellung zu lösen. Wenn nicht, müssen die Projektziele revidiert werden. Im Datenbericht werden alle die Datenbeschaffung betreffenden Informationen und Ergebnisse aus der explorativen Analyse dokumentiert, um Nachvollziehbarkeit und Reproduzierbarkeit zu gewährleisten.

Abhängig von den eingesetzten Modellierungsverfahren und den vorliegenden Daten ist in der Phase **Modellierung** (Kapitel 5) zunächst eine Datenvorbereitung (data preparation) notwendig: Daten müssen selektiert, von den in der explorativen Datenanalyse erkannten Probleme bereinigt, möglicherweise transformiert und, basierend auf existierenden Attributen, neue, aussagekräftigere Attribute abgeleitet (feature engineering) werden. Abgestimmt auf das Projektziel werden dann in der eigentlichen Datenmodellierung Methoden aus dem Bereich der Statistik und des maschinellen Lernens angewendet, um Muster in den Daten zu erkennen und/oder Vorhersagen zu machen - also im Sinne der Projektziele nutzbare Erkenntnisse aus den Daten zu gewinnen. Als Artefakt entsteht der Modellierungsbericht.

Die Phase **Evaluation** (Kapitel 6) ist als Kontrollpunkt zu verstehen, in der geklärt wird, ob die Ergebnisse aus der Modellierungsphase die Erfolgskriterien erfüllen. Mit den Auftraggebern und allenfalls anderen Stakeholdern muss entschieden werden, ob es einer weiteren Iteration durch die Phasen Aufgabendefinition, Datenbeschaffung und -erkundung und Modellierung bedarf oder ob das Projekt nun in die Bereitstellung übergeht.

Die **Bereitstellung** (engl.: Deployment - Kapitel 7) hat zum Ziel, die sich aus den Daten ergebenden Erkenntnisse den nutzenden Personen in der bestmöglichen Form zugänglich und nutzbringend einsetzbar, d.h. in den betreffenden (Geschäfts-)Prozessen integrierbar, zu machen. Die passende Form wird identifiziert, deren Implementierung geplant und umgesetzt. Ausserdem wird sichergestellt, dass die Nützlichkeit des bereitgestellten Produktes kontinuierlich überprüft werden kann, sodass Verbesserungen in weiteren Entwicklungszyklen entsprechend zielgerichtet geplant werden können.

In allen Phasen sind **ethische und rechtliche Aspekte** (Kapitel 8) zu beachten.

3. Aufgabendefinition

Die Aufgabendefinition steht typischerweise zu Beginn des Data Science-Prozesses. Da es sich um einen iterativen Prozess handelt, kann diese Phase auch mehrmals durchlaufen werden. Die englische Bezeichnung lautet Business Understanding oder Project Understanding.

Der Arbeit liegt die Annahme zugrunde, dass die gegebene Aufgabenstellung mithilfe von Daten (welche allenfalls noch identifiziert und beschafft werden müssen) und passenden Modellierungsmethoden gelöst werden und dass die sich daraus ergebenden Erkenntnisse den nutzenden Personen auch gewinnbringend zugänglich gemacht werden können. Das in den Data Science-Aktivitäten zu entwickelnde Data Product soll einen Mehrwert bieten, sodass die nutzenden Personen auch bereit sind, einen entsprechenden Gegenwert aufzubringen.

In der Aufgabendefinition sollen **Problemstellung**, zur Verfügung stehende **Ressourcen, Einschränkungen und Risiken** erfasst werden, sodass die **Projektziele und Erfolgskriterien** aus Sicht der Auftraggebenden festgelegt werden können. Darauf aufbauend kann die Problemstellung von der Projektdomaine in eine technische, datenzentrierte Formulierung übersetzt werden und die **Ziele der Datenmodellierung** festgelegt werden. Daraus ergibt sich der Projektplan. In der **Projektcharta** werden diese Erkenntnisse und Entscheidungen festgehalten. Diese ist das Lieferobjekt (Artefakt) der Phase Aufgabendefintion.

Tabelle 3.1.: Aufgaben und Lieferobjekt (Artefakt) der Phase Aufgabendefinition.

Teile der Aufgabendefinition	Lieferobjekte
1. Beschreibung der Problemstellung 2. Situationsbewertung 3. Projektziele und Erfolgskriterien 4. Modellierungsziele 5. Projektplan	Projektcharta

3.1. Beschreibung der Problemstellung

Häufig ist die von Business-Funktionen, bzw. Projekt-Sponsoren oder Auftraggebern, an das Data Science-Team herangetragene Problemstellung noch relativ unpräzise formuliert und muss im Laufe der Aufgabendefinition verfeinert werden. Dabei muss das Problem zunächst aus der (geschäftlichen) Sicht der Auftraggebenden verstanden werden:

- Was ist das Problem, für das eine Lösung gesucht wird?
- Was soll mit dem Projekt wirklich erreicht werden? Falls bereits Vorstellungen über die Lösung bestehen, bietet sich die Gelegenheit, diese sehr genau zu hinterfragen. In der Regel sollte eine Lösung zurückgestellt, und zunächst detailliert die Anforderungen erfasst werden, bevor die Umsetzung angestrebt wird. Dazu gehört für das Data Science-Team typischerweise auch
- **Domänenwissen** aufbauen
- **nutzende Personengruppen** analysieren
- **Anspruchsgruppen** analysieren

3.1.1. Domänenwissen

Um die auftraggebenden Personen und den potentiellen Nutzen der zu entwickelnden Lösung zu verstehen, muss der Kontext verstanden werden, in dem das datenbasierte Produkt entstehen soll. Das für den Projekterfolg notwendige Domänenwissen ist abhängig vom konkreten Anwendungsfall. Dazu können akademisches Wissen, Verständnis und technische Anwendungserfahrung spezifischer Technolgien und Kenntnisse über Geschäftsmodelle, regulatorische Anforderungen, ethische und rechtliche Aspekte gehören. Auch eine Marktanalyse und die Kenntnisse über bestehende Angebote/Konkurrenten kann dazu gehören. Data Scientists versuchen hier so effizient wie möglich mit Domänen-Experten zusammenzuarbeiten.

3.1.2. Nutzende Personen

Der Value Proposition Canvas [22] (siehe Abbildung 3.1) besagt, dass Mehrwert dann entsteht, wenn Leistungsversprechen auf die Bedürfnisse der nutzenden Personen passen: Die Nutzer:innen müssen bestimmte **Aufgaben** bearbeiten, bzw. Leistungen erbringen. Diese haben funktionale (eigentliche Tätigkeiten), aber auch soziale und emotionale Aspekte. **Probleme** oder Hürden hindern sie an der Erledigung der Aufgaben, bzw. der Erbringung der Leistungen. Es gibt aber auch Dinge oder Ereignisse, welche die Nutzer:innen unterstützen und von ihnen gewünscht oder gefordert werden: **Nutzen**.

Auf der Anbieterseite werden **Produkte und Dienstleistungen** gelistet, die für das entsprechende Kundensegment relevant sind. **Problemlöser** sind Aspekte des Angebotes, welche bestimmte Probleme der nutzenden Personen lösen. Analog dazu bieten die **Nutzenbringer** relevante und gewünschte Unterstützung in der Erfüllung von Aufgaben.

Das Leistungsversprechen können Anbieter naturgemäss stärker beeinflussen als die der nutzenden Personen. Deshalb müssen die Aufgaben und Bedürfnisse (Probleme und Nutzen – Pains and Gains) der nutzenden Personen möglichst gut verstanden werden, um ein passgenaues

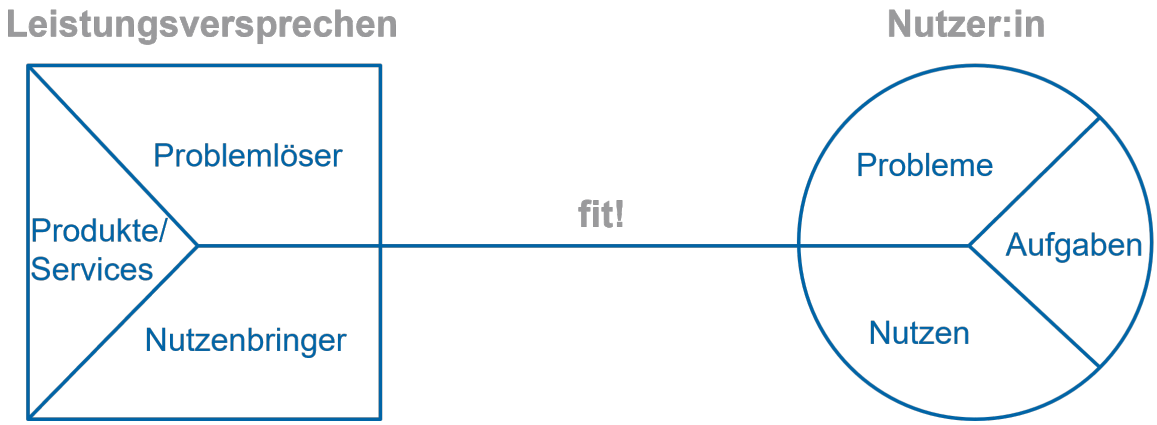


Abbildung 3.1.: Der Value Proposition Canvas nach [22]

Angebot entwickeln zu können. Zu diesem Zweck können schematische Repräsentation archtetypischer Nutzer:innen erstellt werden: Eine sogenannte **Persona** repräsentiert dabei ein bestimmtes Segment von nutzenden Personen und enthält Informationen zu Lebensumständen, Interessen, Aufgaben, Problemen und Bedürfnissen. Zur Erstellung von Personas werden Hintergrundrecherchen, Interviews und quantitative Umfragen durchgeführt.

3.1.3. Anspruchsgruppen (Stakeholder)

Zu den Anspruchsgruppen zählen Personen, welche **direkt am Projekt beteiligt** und **von dessen Auswirkungen betroffen** sind. Beispielsweise gehören dazu die für die Prozesse verantwortlichen Personen, welche durch die Ergebnisse aus dem Projekt tangiert werden. In der Projektumfeldanalyse (**Stakeholderanalyse**) werden die verschiedenen Anspruchsgruppen im Hinblick auf die Projektziele strukturiert und anschliessend deren Wichtigkeit für das Projekt bestimmt. Dabei werden die Faktoren Einfluss auf das Projekt (Macht) und Einstellung zum Projekt (Ziele) untersucht. Eine Stakeholder-Map

- schafft einen Überblick über die Anspruchsgruppen
- erlaubt die Entwicklungsarbeit auf die wesentlichen Personen und Interessengruppen zu konzentrieren
- und hilft versteckte Beziehungen und Motivationen offenzulegen, um dem “non-technical failure”, dem Scheitern aus politischen Gründen vorzubeugen.

3.2. Situationsbewertung

In der Situationsbewertung werden möglichst viele Aspekte zusammengetragen, welche die Erfolgschancen des Projektes bestimmen. Dazu gehören

- die Ausgangssituation (z.B. bisherige unzulängliche Lösungsversuche)
- für das Projekt zur Verfügung stehende **Ressourcen** wie beispielsweise Personal, Material, (Software-)Tools, Infrastruktur, Daten und nicht zuletzt **Expertenwissen**
- zu Verfügung stehende **Zeit**
- **Randbedingungen** wie z.B. Anforderungen an die Erklärbarkeit der Modelle (um darauf basierende Entscheidungen nachvollziehbar zu machen), ethische, politische oder rechtliche Einschränkungen, nicht-funktionale Anforderungen (z.B. Geschwindigkeit, mit der Ausgaben des Modells berechnet werden können)
- und damit einhergehende **Risiken** wie z.B. Nichtverfügbarkeit oder schlechte Qualität der Daten

3.3. Projektziele und Erfolgskriterien

Basierend auf der Beschreibung der Problemstellung und unter Berücksichtigung der Situationsbewertung ist es nun möglich, primäre Projektziele (Objectives) aus Sicht der auftraggebenden Personen zu formulieren. Diese übergreiffenden Projektziele sind typischerweise weitgehend qualitativer Natur, können aber auch angestrebte Formen für die Bereitstellung des Data Products enthalten. Dazu müssen, in Abstimmung mit den Sponsoren, quantitative Kenngrössen und entsprechende Zielwerte gewählt werden, welche den Projektfortschritt möglichst einfach messbar und damit transparent machen. Dabei sollte bei der Wahl der Zielwerte darauf geachtet werden, dass sie einem echten Mehrwert für die nutzenden, bzw. auftraggebenden, Personen entsprechen. Sie können auch relativ zu bestehenden Referenzwerten (Baseline) formuliert werden.

Um das Verständnis des Projektumfangs zu festigen und "Project Creep" (während des Projektverlaufs fortschreitende Erweiterung der Anforderungen) zu vermeiden, ist es häufig auch hilfreich als "Out of Scope" festzuhalten, was NICHT Teil des Projektes ist.

Tabelle 3.2 enthält ein Beispiel für die Formulierung von Projektzielen und Erfolgskriterien.

Tabelle 3.2.: Beispiel für die Formulierung v

Projektziel (Objective)	Steigerung der Einnahmen durch personalisierte Angebote in der Mailingaktion
Bereitstellungsform	Software-Komponente, welche eine Auswahl der jeweils aktuellen Angebote auf die ei
Kenngrösse	Bestellrate
Zielwert	Steigerung der Bestellrate um 5% innerhalb von 4 Wochen nach der Mailingaktion im
Out-of-scope	Identifizierung neuer Kundensegmente

3.4. Data Mining-Ziele

An dieser Stelle werden die primären Projektziele aus Sicht der Auftraggeber:innen in eine technische, datenzentrierte Formulierung übersetzt. Das Problem wird in eine der typischen Kategorien von Data Mining-Aufgaben eingeteilt:

- Regression
- Klassifikation
- Clusteranalyse
- Anomalie-Erkennung
- Assoziationsanalyse
- Empfehlungsdienste
- …

Bei der Regression und der Klassifikation handelt es sich um Vorhersageaufgaben: Wir können an einer Vorhersage interessiert sein, weil sich das wahre Ergebnis erst in der Zukunft herausstellen wird oder weil es teuer, schwierig oder umständlich ist, es zu ermitteln. Der Unterschied zwischen Regression und Klassifikation liegt in der Natur des vorhergesagten Wertes: In der Regression werden kontinuierliche numerische Werte vorhergesagt, in der Klassifikation handelt es sich um diskrete, kategorische Werte (Klassen). Typische Fragestellungen für Regressionsprobleme sind: Was ist der EUR/USD-Kurs am nächsten Tag? Wie viel Geld wird der Kunde im nächsten Jahr für seinen Urlaub ausgeben? Wie stark wird sich die Temperatur der Maschine im nächsten Zyklus verändern?

Bei der Klassifizierung wird ein Wert mit einer endlichen Anzahl möglicher Ergebnisse (wie ja/nein oder inakzeptabel/akzeptabel/gut/sehr gut) vorhergesagt wird. Typische Fragen sind: Ist dieser Kunde kreditwürdig? Wird ein bestimmter Kunde auf unser Werbe-Mailing reagieren? Wird die technische Qualität des Produktes akzeptabel sein?

Im Clustering werden in den Daten Gruppen ähnlicher Fälle (die Cluster) identifiziert. Auf diese Weise lässt sich ein Einblick in die Struktur des gesamten Datensatzes gewinnen und charakteristische Repräsentationen für die unterschiedlichen Gruppierungen bestimmen. Typische Fragestellungen für Clusteranalysen sind: In welche Segmente unterteilen sich die Kunden eines Online-Shops? In welchen Betriebsstufen wird ein bestimmter Motor in einer Maschine genutzt, und in welchen Merkmalen sich diese?

Bei der Anomalieerkennung geht es um die Erkennung ungewöhnlicher Datenpunkte, die auf abnormales Verhalten oder Fehler hindeuten. Typische Fragen in der Anomalieerkennung sind: Welche Kunden sind nicht einem bereits bekannten Segment zuordbar? Welche Finanztransaktionen könnten eine betrügerische Ursache haben?

Bei der Assoziationsanalyse geht es um die Erkennung von Abhängigkeiten von Beobachtungen, wie zum Beispiel die Identifizierung von Produkten, welche jeweils gemeinsam gekauft werden: Wenn Jemand Spaghetti in den Warenkorb legt, ist es sehr wahrscheinlich, dass sie

oder er noch Tomatensauce dazulegt. Solche Erkenntnisse können dann genutzt werden, um die Produktauslagen in einem Supermarkt zu optimieren.

Empfehlungsdienste bieten Nutzer:Innen aufgrund ihrer Eigenschaften, bzw. ihres Nutzerverhaltens, Empfehlungen von für sie persönlich passende Produkte an. Z.B. in Online-Shops, bei Streaminganbietern usw.

Zur Lösung der verschiedenen Data Mining-Aufgaben werden unterschiedliche Methoden und mathematische Modelle verwendet. Auch wird die Güte solcher Lösungen mit unterschiedlichen Kenngrössen gemessen. Z.B wird in der Regression die Root Mean Square Deviation (RMSD) verwendet, wohingegen für Klassifikationsprobleme Accuracy, Precision oder Recall verwendet werden (siehe Kapitel 5.2.2 - Kapitel 5.3.3).

Tabelle 3.3.: Übersicht gängiger Data Mining-Aufgaben mit passenden Kenngrössen.

Data Mining-Aufgabe	Kenngrösse/Evaluationsmetrik
Regression	• Mean Absolute Error (\(MAE\)) • Mean Squared Error (\(MAE\)) • Root Mean Square Deviation \((RMSD)\) • \(R^2\)-Value
Klassifikation	• Accuracy • Precision • Recall • F-Score
Clustering	• Silhouette Score
Assoziationsanalyse	
Empfehlungsdienste	Mean Average Precision@\(k\) \((MAP@k)\)

Im Kapitel Kapitel 5 werden einige dieser Methoden und auf sie passende Kenngrössen im Detail behandelt. Ein vertieftes Verständnis der Modellierungsverfahren und erste praktische Erfahrung sind für die effektive Ausarbeitung der Data Mining-Ziele essentiell. Es empfiehlt sich, nach dem Thema Modellierung nochmals zum Thema der Data Mining-Ziele im Rahmen der Aufgabendefinition zurückzukehren.

Auch bei den Data Mining-Zielen können Zielwerte relativ zu einer Baseline festgelegt werden. Es ist jeweils zu reflektieren, wie diese Zielwerte im Bezug zu den primären Projektzielen stehen. Wenn dies an dieser Stelle noch nicht abschätzbar ist, bzw. keine Erfahrungswerte bestehen, sollte dies transparent (in der Projektcharta) dokumentiert werden.

N.B.: Es mag erstaunen, dass an dieser Stelle die Dimensionsreduktion (Kapitel 5.3.1) als Data Mining-Aufgabe nicht aufgeführt ist. In der Tat handelt es sich dabei um eine wichtige Aufgabe

aus dem Bereich des unüberwachten Lernens, genauso wie die Clusteranalyse, Anomalieerkennung, Assoziationsanalse und Empfehlungsdienste. Allerdings wird häufig die Dimensionsreduktion nicht als primäre Aufgabe, sondern als Teil einer anderen Data Mining-Aufgabe, der explorativen Datenanalyse (Kapitel 4.3) oder einer Datenvisualisierung angewendet.

3.5. Projektplan

3.5.1. Rollen und Aufgaben

Der Projektplan enthält die Rollen- und Aufgabenverteilung der Team-Mitglieder und anderer primärer Stakeholder.

Tabelle 3.4.: Beschreibung verschiedener Rollen in einem Data Science-Proje

Rolle	Aufgabe
Sponsor:in	Gibt als auftraggebende Person das Projekt frei und entscheidet an Meilensteinen über Proj
Entwicklerteam	Verrichtet die eigentliche Arbeit
Teamsprecher:in	Achtet darauf, dass Prozess und Termine eingehalten werden. Organisiert die Kommunikati

3.5.2. Kollaborationsmodus

Zudem sollte festgehalten werden, nach welchen Regeln das Team zusammenarbeitet:

- Form und Häufigkeit von Meetings
- wie die Kommunikation mit Steakholdern erfolgt
- Kontaktangaben - wie die wichtigsten Personen erreichbar sind

3.5.3. Planung der Projektphasen

Basierend auf den Projektzielen ist es of sinnvoll, die Entwicklungsarbeit in Phasen zu zerlegen und einen groben Zeitplan zu erstellen. Für jede Projektphase sollten die Arbeitsinhalte und die zu erreichenden (Teil-)Ziele festgelegt werden. Jede Projektphase endet mit einem Milestone, dessen Erreichen den Sponsoren und ausgewählten Stakeholdern jeweils präsentiert wird. Beispielsweise eignen sich Gantt-Charts für eine solche Darstellung.

Ein solcher Zeitplan sollte nicht als Korsett wirken, sondern der Orientierung dienen und eine realistische Einschätzung der Machbarkeit des Projektes in der zur Verfügung stehenden Zeit ermöglichen. Unter Absprache mit den Stakeholdern kann dieser Plan auch nach jeder Iteration angepasst werden.

3.6. Projektcharta

In der Projektcharta werden die Ergebnisse aus der Phase "Aufgabendefinition" zusammengefasst. Sie dient einerseits der Dokumentation der Ergebnisse, andererseits sollte sie am Ende der Projektphase auch von den Auftraggebern/Sponsoren "unterzeichnet" werden, um ein gemeinsames Verständnis des Projektumfanges sicherzustellen.

Eine Vorlage (basierend auf den Vorlagen des Microsoft Team Data Science-Prozesses [23]) kann hier heruntergeladen werden. Jedoch hat jedes "Data Science"-Projekt seine Eigenheiten und somit müssen auch die Abschnitte allenfalls angepasst werden.

4. Datenbeschaffung und -erkundung

4.1. Daten und Information

Im Folgenden werden einige grundlegende Begriffe und Konzepte rund um Daten, wie sie im Data Science-Kontext zur Generierung von Mehrwert in form von Data Products (siehe Kapitel 1) verwendet werden, erläutert.

4.1.1. Analoge Daten

Analoge Daten repräsentieren ein direktes Abbild physikalischer Zustände und können dementsprechend auf für die menschliche Wahrnehmung relevanten Skalen (makroskopisch - ohne Berücksichtigung von Quanteneffekten) kontinuierliche Werte annehmen. Beispiele sind Farbvariationen auf Leinwand oder Papier, Prägungen auf Schallplatte etc.

4.1.2. Digitale Daten

Im Gegensatz zu analogen Daten bestehen **digitale Daten** aus Reihen von diskreten Zeichen aus einem vorgegebenen, begrenzten Satz (Alphabet), mit deren Hilfe auf elektronischen bzw. magnetischen Speichermedien Informationen (zwischen)gespeichert oder übermittelt werden können.

Elektronische Speichermedien nutzen Halbleitertechnologie, um Daten in Form von elektrischen Ladungen zu speichern. Beispiele sind USB-Sticks, SSDs (Solid State Drives), und Arbeitsspeicher (RAM). Daten auf diesen Speichermedien werden durch elektronische Schaltkreise gelesen und geschrieben.
Magnetische Speicher nutzen magnetisierbare Materialien, um Daten zu speichern. Ein Lese-Schreib-Kopf magnetisiert oder entmagnetisiert Bereiche auf dem Medium, um Daten zu schreiben oder zu lesen. Beispiele sind Festplatten, Magnetbänder und Disketten. Solche Daten werden durch magnetische Felder gespeichert und gelesen, was robust und langlebig ist.

Der Begriff Digital wurde abgeleitet vom lateinischen digitus „Finger“, denn das Fingerrechnen gilt als das älteste Rechenverfahren.

Die Desoxyribonukleinsäure (DNS) im Zellkern biologischer Systeme ist ein Beispiel für ein biologisches Speichermedium, wobei auch hier die Daten mithilfe eines vorgegebenen Alphabets

in diskreten Einheiten kodiert vorliegen: Vier chemische Moleküle (Adenin, Thymin, Cytosin und Guanin) bilden als Paare eine Sequenz.
Die Speicherdichte von DNS ist extrem hoch: Jeder menschliche Zellkern enthält den gesamten Bauplan für einen Menschen, was ca. 1.5 GB an Daten entspricht. 1 Schuhschachtel DNA könnte mehr Daten speichern als das gesamte Internet.
Die auf der DNS enthaltene Informationen werden durch biologische, bzw. chemische Prozesse wie Transkription und Translation verarbeitet.

4.1.3. Bits und Bytes

Die elektronischen Schaltkreise heutiger Computer können zwei Zustände repräsentieren. Typischerweise werden diese mit den Ziffern "0" und "1" dargestellt. Dabei ist das Bit (Kofferwort aus englisch "binary digit", geprägt Mitte der 50er Jahre von J. Tukey und C. Shannon) die Masseinheit für den Informationsgehalt, der in einer Auswahl aus zwei gleich wahrscheinlichen Möglichkeiten enthalten ist. Der Informationsgehalt kann ein beliebiger reeller, nicht negativer Wert sein.
Das Bit ist auch eine Masseinheit für die gespeicherte oder übertragene Datenmenge.

Mehrere Bits werden zu Bytes zusammengefasst, wobei die Anzahl Bits pro Byte Hardware-abhängig ist. Der heutige Standard sieht 8 Bits pro Byte for. Bytes wiederum werden zu Words zusammengefasst - die Anzahl ist wiederum Hardware-abhängig:

Architektur	Anzahl Bytes pro Word
32 Bit	4
64 Bit	8

Um grössere Werte darzustellen werden Vorsätze für Masseinheiten verwendet. Dezimalpräfixe sind Einheitenvorsätze, die Vielfache bestimmter Zehnerpotenzen bezeichnen:

Präfix		
kilo (k)	$=10^3$	=1000
mega (M)	10^6	=1000000
giga (G)	10^9	=1000000000
tera (T)	10^{12}	=1000000000000
peta (P)	10^{15}	=1000000000000000
…		

Das Bit ist auch eine Bezeichnung für eine Stelle einer Zahl im **Binärsystem**:

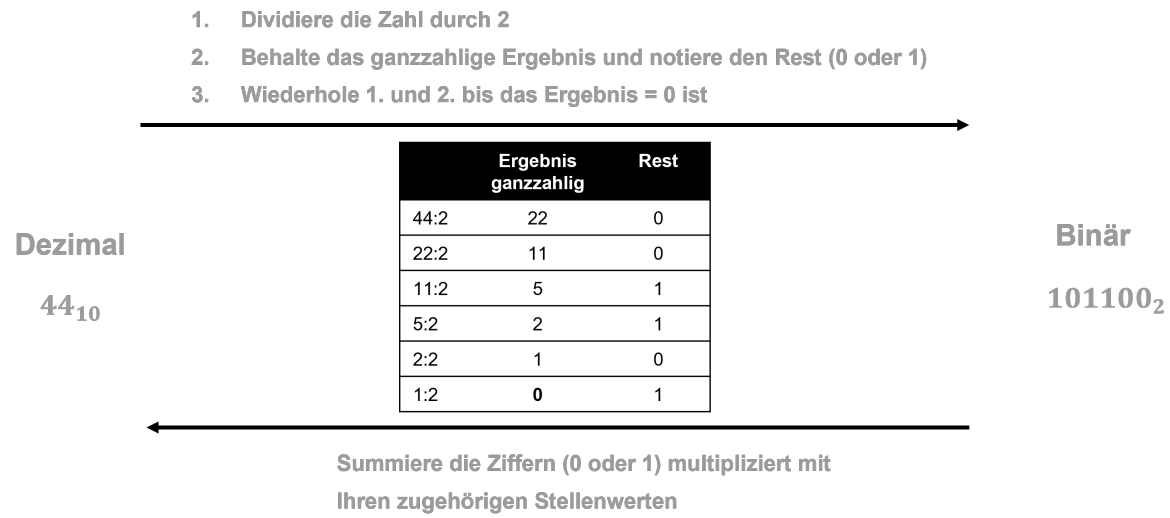


Abbildung 4.1.: Anleitung zur Umwandlung zwischen Dezimal- und Binärsystem für ganze Zahlen

4.1.4. Digitalisierung von Daten

Analoge Signale müssen in passende Formate umgewandelt werden, um sie auf digitalen Computern verarbeiten zu können. Dabei sind für die Qualität, das heisst für den Erhalt des Informationsgehaltes, folgende Hauptfaktoren entscheidend:

- die **Abtastung** entspricht der Diskretisierung in Raum und/oder Zeit, denn die Werte des kontinuierlichen Signals werden nur an bestimmten (Raster- und/oder Zeit-)Punkten ausgelesen. Je feiner die Abtastung, desto genauer entspricht der Informationsgehalt des digitalisierten Signals demjenigen des analogen Ausgangssignals. Jedoch steigt mit feinerer Abtastung auch der Speicherbedarf der digitalen Repräsentation.
- die **Bandbegrenzung** legt den erfassbaren Wertebereich fest. Nimmt das analoge Eingangssignal einen Wert oberhalb (oder unterhalb) des darstellbaren Bereiches an, wird er auf den maximalen (oder minimalen) darstellbaren Wert begrenzt. Das heisst, diese Werte werden gegenüber des Eingangssignals verfälscht.
- die **Quantisierung** legt die Auflösung der ausgelesenen diskreten Werte auf dem darstellbaren Wertebereich fest. Je mehr Bits bzw. Codeworte zur Darstellung der Werte zur Verfügung stehen (=Bittiefe), umso kleiner werden die Abstände zwischen den digital darstellbaren Werten und umso genauer entsprechen diese den Werten im analogen Eingangssignal, das heisst umso kleiner wird der sogenannte Quantisierungsfehler. Mit der Bittiefe steigt jedoch auch der Speicherbedarf für die Repräsentation des digitalisierten Signals.
- Die **Kodierung** bezieht sich auf die Umwandlung der quantisierten Werte in das Binärsystem (siehe Abbildung 4.1).

Das digitalisierte Signal besteht also schlussendlich aus einer binären Zeichenkette.

Aus dem digitalisierten Signal kann das analoge Signal innerhalb der Abtastfrequenz, des Quantisierungsfehlers und der Bandbegrenzung wieder rekonstruiert werden.

4.1.4.1. Digitale Audiodaten

In Abbildung 4.2 werden die Begriffe am Beispiel der Digitalisierung eines Audiossignals (auch "Sampling" genannt) illustriert: Das zeit- und wertkontinuierliche Eingangssignal (blau) ist im Falle eines Audiosignals eine in analoge elektronische Schwingungen verwandelte Schallwelle.
In der **Abtastung** wird entlang der Zeit-Achse in fixen Abständen das Signal gemessen (abgetastet). Das heisst, es wird zeitdiskretisiert. Um das ursprüngliche Analogsignal später möglichst gut rekonstruieren zu können, muss die Abtastrate größer als das Doppelte der maximal möglichen Frequenz im Eingangssignal sein (siehe Nyquist-Frequenz). Anderenfalls kommt es zu einer Unterabtastung und führt im rekonstruierten Signal zu im Eingangssignal nicht vorhandenen Frequenzen.
In der **Bandbegrenzung** wird der erfassbare Wertebereich bezüglich der Schallintensität festgelegt.
In der **Quantisierung** legt die Bittiefe fest, wie viele unterschiedliche diskrete Intensitätswerte in der digitalen Repräsentation abgebildet werden. Im vorliegenden Beispiel beträgt die Bittiefe 3, was 8 unterschiedliche diskrete Werte im Binärsystem erlaubt - im vorliegenden Beispiel sind dies 0, 1, 2, 3, 4, 5, 6, und 7.
Die **Kodierung** übersetzt die quantisierten Werte auf die binäre Repräsentation (siehe Abbildung 4.1).

4.1.4.2. Digitale Bilddaten

Um ein Bild digital aufzunehmen (siehe Abbildung 4.3), wird der Aufnahmebereich gescannt (entspricht der Abtastung), das heißt in Zeilen und Spalten eines Rasters (Matrix) zerlegt. Für jeden der dadurch entstehenden Bildpunkte (Pixel) wird der Grauwert bzw. Farbwert ausgelesen und mit einer bestimmten Quantisierung gespeichert. Dafür kann ein CCD-Chip (Charged Coupled Device) verwendet werden, der aus einem Grid von licht-empfindlichen Dioden, welche je nach Intensität des auf sie treffenden Lichtes eine elektrische Ladung generieren. Die elektrische Ladung wird dann in ein zur Lichtintensität proportionales elektrisches Signal pro Pixel umgewandelt. Bei einer Schwarz-Weiß-Rastergrafik ohne Grautöne nimmt dann der Wert für ein Pixel die Werte "0" für "Schwarz" und "1" für "Weiß" an. Die Matrix wird zeilenweise ausgelesen, wodurch man eine Folge aus den Ziffern 0 und 1 erhält, welche das Bild codiert. In diesem Fall wird also eine Quantisierung von einem Bit verwendet. Um ein Graustufenbild digital zu repräsentieren, wird eine höhere Bittiefe benötigt: z.B. können mit 8 Bit (1 Byte) 256 Intensitätsstufen abgebildet werden – jeder ausgelesene Intensitätswert wird der nächstliegenden Quantisierungsstufe zugeordnet. „0“ entspricht dann schwarz, "255" weiss und "127" dem mittleren Grau.

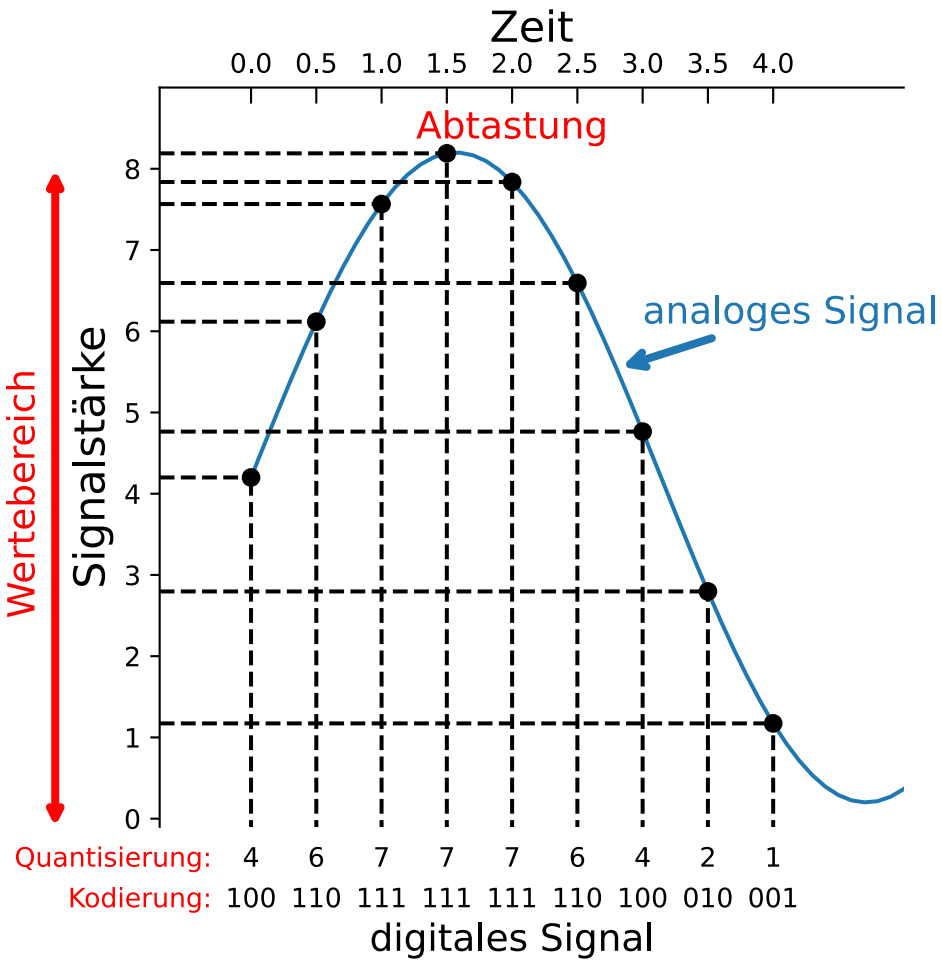


Abbildung 4.2.: Illustration der Digitalisierung eines Audiosignals mit einer Abtastrate von 0.5 und Bittiefe von 3.

Für die Abbildung eines Farbbildes muss ein Farbraum gewählt werden, z.B. RGB (Red, Green, Blue). Auf jedem Farbkanal wird die Lichtintensität auf einem separaten Raster gemessen und quantisiert. Wenn jeder Kanal 8 Bit benötigt, werden für das Farbbild insgesamt 3*8=24 Bit pro Pixel benötigt. Zum Beispiel wird ein roter Pixel als (R=255,G=0,B=0) repräsentiert. Einige Formate erlauben auch einen zusätzlichen Kanal für die Transparenz (Durchsichtigkeit) bzw. Opazität (Deckkraft). Bei RGB-Bildern mit einem solchen sogenannten Alphakanal spricht man auch von RGBA-Bildern (Rot, Grün, Blau, Alpha).
Die quantisierten Intensitätswerte werden dann noch in eine binäre Zeichenkette codiert.

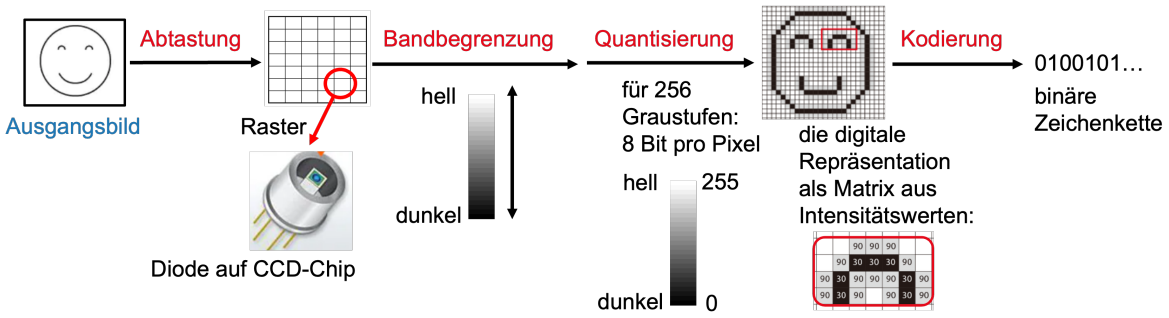


Abbildung 4.3.: Illustration der Digitalisierungsschritte bei der Aufnahme eines Graustufen-Bildes.

4.1.4.3. Digitale Textdaten

Bei der Digitalisierung von Text (siehe Abbildung 4.4) wird das Dokument zuerst genauso wie ein Bild digitalisiert, das heißt gescannt. Soll zusätzlich zum Bild auch der sprachliche Inhalt des Dokumentes ausgelesen werden, so wird das digitalisierte Textbild von einem Texterkennungsprogram (OCR=Optical Character Recognition) in einen Zeichensatz (Alphabet) übersetzt. Die binäre Repräsentation dieser Zeichen wird durch ein Kodierungs-Schema festgelegt. Dieses besteht im Wesentlichen aus einer Tabelle, welche jedem Zeichen eine binäre Sequenz zuordnet. ASCII (American Standard Code for Information Interchange, siehe Tabelle 4.3) ist vermutlich nachwievor die verbreiteste Text-Kodierung in 8 Bit (1 Byte). Die ursprüngliche ASCII-Definition benutzt jedoch nur 7 Bits - das erste Bit ist immer 0. Dementsprechend kann es ein Alphabet von 128 verschiedenen Buchstaben kodieren, was für Englisch, Zahlen und einige Kontroll- und Sonderzeichen ausreicht.

Tabelle 4.3.: Ein Ausschnitt der ASCII Code-Tabelle. Für eine komplette Übersicht siehe https://www.ascii-code.com/.

Buchstabe	Binärform
A	01000001
B	01000010

Buchstabe	Binärform
C	01000011
D	01000101
E	01000110
...	

Um auch andere Alphabete repräsentieren zu können, wurde Unicode als eine Obergruppe von verschiedenen Kodierungsverfahren eingeführt. Unicode erlaubt bis zu 32 Bits (4 Bytes) pro Buchstaben und bietet damit ausreichend Platz für alle verschiedenen Alphabete, Emojis etc. Um Speicherplatz zu sparen, wurden Definitionen mit variabler Länge, wie z.B. UTF-8, entwickelt. UTF-8 benutzt 1 bis 4 Bytes, wobei die ersten 128 Buchstaben deckungsgleich mit ASCII kodiert sind, nach folgendem Schema:

- Das höchste ("sign") Bit, welches in ASCII ungenutzt ist, kodiert in UTF-8 den Beginn einer Multi-Byte Sequenz. Eine "0" an erster Stelle bedeutet, dass die Sequenz nur aus einem Byte besteht. "1" bedeutet, dass sie aus mehreren Bytes besteht.
- Die Anzahl aufeinanderfolgender "1"en von links im ersten Byte kodiert die totale Anzahl Bytes in der Sequenz. Dann folgt immer eine 0.
- Die verbleibenden Bits kodieren den eigentlichen Wert ("x" in Tabelle 4.4)
- Die allfälligen "Folge-Bytes" (Continuation Bytes) beginnen immer mit "10" – nur 6 Bits kodieren die Werte: 10xxxxxx. So können in beschädigten Sequenzen die jeweils nächsten vollständigen Bereiche leichter erkannt werden.

Tabelle 4.4.: Struktur der UFT-8 Kodierung mit einer variablen Länge zwischen 1 und 4 Bytes pro Buchstabe. Die "x" markieren die Stellen, welche den eigentlichen Wert codieren.

Anzahl Bytes	Struktur der Sequenz
1	0xxxxxxx
2	110xxxxx 10xxxxxx
3	1110xxxx 10xxxxxx 10xxxxxx
4	11110xxx 10xxxxxx 10xxxxxx 10xxxxxx

Siehe hier für eine vollständige Liste der UTF-8 Codepoints.

Gespeichert wird der erkannte Text also schlussendlich in Binärform nach einem bestimmten Kodierungs-Schema. Der Speicherbedarf des reinen Textes ist dabei erheblich geringer als für das Bild. Allerdings gehen unter Umständen Informationen verloren, die nicht im reinen Text dargestellt werden können, zum Beispiel die Formatierung. Deshalb wird oft auch das digitalisierte Bild zusammen mit dem extrahierten Text gespeichert. So kann im Text nach Begriffen gesucht werden, aber dennoch das (digitalisierte) Originaldokument angezeigt werden (zum Beispiel bei Google Books oder gescannten PDF Dokumenten).

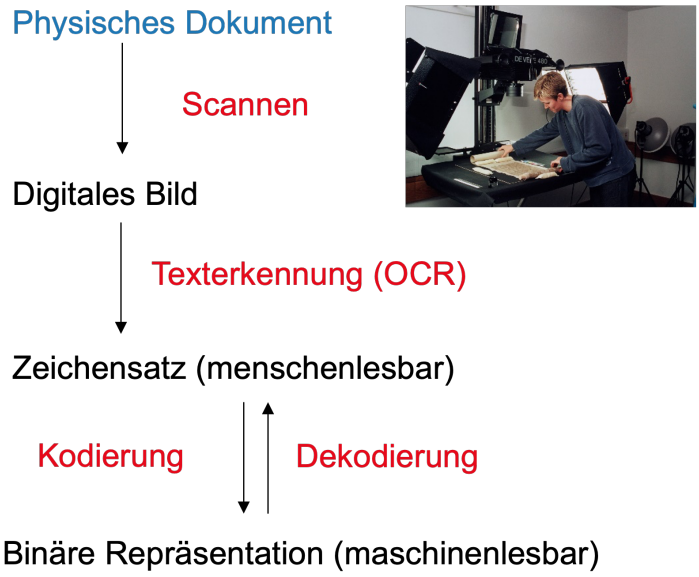


Abbildung 4.4.: Schritte in der Digitalisierung von Texten

4.1.5. Datei

Eine Datei (englisch file) ist in der elektronischen Datenverarbeitung die Zusammenfassung gleichartiger digitaler Daten, die zum Speichern auf maschinenlesbaren Datenträgern oder Speichermedien, zur Wiedergabe, zum Bearbeiten und zur Datenübertragung dient und durch einen Dateinamen identifiziert wird.
Der Inhalt jeder Datei ist zunächst eine eindimensionale Aneinanderreihung von Bits, die normalerweise in Datenblöcken (Bytes, Words etc.)zusammengefasst interpretiert werden. Wie diese Zeichenfolgen interpretiert werden sollen, gibt das Dateiformat vor. Mithilfe eines Anwendungsprogramms kann das Dateiformat auf die vorliegende Bit-Sequenz angewendet und die Daten verarbeitet (zum Beispiel als Bild oder Text dargestellt) werden.

4.1.6. Daten im Kontext “Data Science”

> Mit Daten im Data Science-Kontext werden digitale Daten auf elektronischen Medien bezeichnet, welche in Binärform von Computersystemen verarbeitet werden. In der Regel liegen diese in Form von Dateien mit einem gegebenen Format vor und sind damit für spezifische Anwendungen interpretierbar, z.B. als Text, Tabelle, ausführbares Programm, Bild oder Ton etc.

4.1.7. Datenmodell

Ein Datenmodell beschreibt die Struktur der in Informationssystemen zu verarbeitenden Daten in Form von Entitäten und deren Beziehungen zueinander, wie beispielsweise in einem Entity Relationship (ER)-Diagramm dargestellt (Abbildung 4.5).

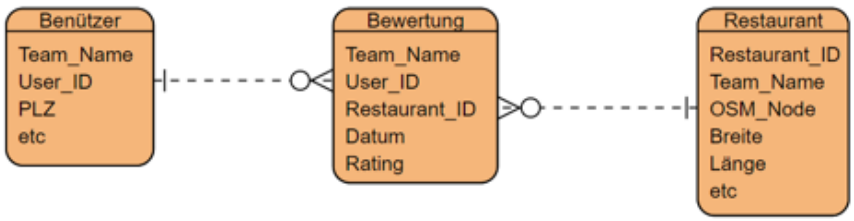


Abbildung 4.5.: Beispiel für ein Entity Relationship-Diagramm

In Relationalen Datenbanken entspricht eine Entität einer Tabelle. Ein Attribut einer Entität entspricht einer Spalte der Tabelle mit einem definierten Datentyp. Der Schlüssel (primary key) identifiziert jede Zeile in der Tabelle eindeutig. Er stellt sicher, dass es in einer Tabelle keine Duplikate geben kann. Der Primary Key der Tabelle 'Bewertung' im Beispiel Abbildung 4.5 sind die Attribute 'User_Id' und 'Restaurant_ID'. Da der Schlüssel eindeutig sein muss, wird sichergestellt, dass jeder Benützer nur ein Rating pro Restaurant abgeben kann.
Die Beziehungen entsprechen den sogenannten Fremdschlüsseln. Sie stellen sicher, dass die Daten in mehreren Entitäten sauber zusammenpassen und damit einfach verknüpft ('joined') werden können. In Abbildung 4.5 ist in der Tabelle 'Bewertung' das Attribut 'User_ID' ein Fremdschlüssel auf den Schlüssel der Tabelle 'Benützer'. Die Datenbank stellt sicher, dass ein Wert im Attribut 'User_ID' in der Tabelle 'Bewertung' zwingend(!) in der Tabelle 'Benützer' im Attribut 'User_ID' enthalten sein muss. Damit wird sichergestellt, dass die Tabelle 'Bewertung' keine obsoleten User enthalten kann und somit wird die Integrität der Daten sichergestellt. Dasselbe gilt analog für das Attribute 'Restaurant_ID' und die Tabelle Restaurant.
$m : n$-Beziehungen: Pro Zeile der Tabelle 'Benützer' kann die Tabelle 'Bewertung' 0:m Zeilen enthalten. D.h. Jeder User kann 0…m Bewertungen abgeben. Pro Zeile der Tabelle 'Restaurant' kann die Tabelle 'Bewertung' 0:n Rows enthalten. D.h. Jedes Restaurant kann 0…n Bewertungen zugewiesen haben. Damit kann ein Benützer pro Restaurant keine oder mehrere Bewertungen abgeben. Damit stellt die Tabelle 'Bewertung' eine m:n Beziehung her zwischen den Usern und den Restaurants. Eine solche Zwischentabelle ist ein sehr häufiges Mittel in Datenbanken, um m:n Beziehungen abzubilden.

Im Beispiel Abbildung 4.5 kann ein Benützer 0…n Ratings haben und ein Restaurant 0…m Ratings. Die Ratings-Tabelle 'Bewertung' bildet damit die $m : n$-Beziehung zwischen Benützer und Restaurant ab.

Die Entität ‘Benützer’ hat die Attribute ‘Team_Name’, ‘User_Id’, ‘PLZ’, etc. In einer Datenbank würde man das mit einer Tabelle ‘Benützer’ umsetzen, welche die Spalten ‘Team_Name’, ‘User_Id’, ‘PLZ’, etc hat.

4.1.8. Strukturierte und unstrukturierte Daten

4.1.8.1. Strukturierte Daten

Strukturierte Daten besitzen ein Datenmodell, wobei unterschiedliche Datensätze demselben Datenmodell folgen können. Sie sind in Form von Tabellen abbildbar. Gängige Dateiformate sind:

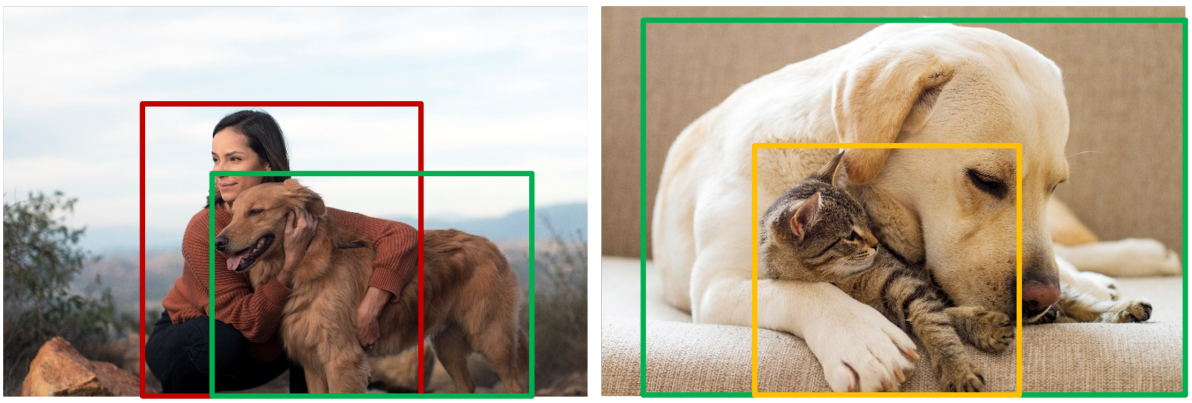
- csv
- ods (Open Spreadsheet Data format)
- xlsx
- HDF (Hierarchical Data Format)
- Apache Parquet

4.1.8.2. Unstrukturierte Daten

Unstrukturierte Daten haben im Gegensatz zu strukturierten Daten kein festes Datenmodell. Obwohl ihnen eine explizite Struktur fehlt, können sie eine implizite Struktur aufweisen, wie z.B. Grammatikregeln in Text. Beispiele für Inhalte unstrukturierter Daten und gängigen Dateiformaten:

- Texte: txt, odt, docx, html
- Bilder: jpeg, png
- Audio: wave, aiff, flac, mp3, aac
- Video: mp4, mov, wmv

Strukturierte Daten können aus unstrukturierten Daten computergestützt gewonnen werden. In der Anwendung auf Textdaten spricht man von Informationsextraktion (IE). Beispiel: Aus Online-Nachrichten sollen Informationen zu Firmenzusammenschlüssen (engl. merger events) extrahiert werden. Mithilfe von Machine Learning-Methoden werden dabei Instanzen der Relation merge(Firma1, Firma2, Datum) erkannt und in einer Tabelle abgelegt.
In der Anwendung auf Bilddaten entsprechen die in der Objekterkennung und Klassifizierung identifizierten Entitäten einer strukturierten Repräsentation (siehe Abbildung 4.6).



Objekterkennung

Frauen	1	0
Männer	0	0
Hunde	1	1
Katzen	0	1
Umgebung	Outdoor	Indoor

Abbildung 4.6.: Illustration von Objekterkennung in Bildern und Darstellung der extrahierten Information in strukturierter Form (Tabelle).

4.1.8.3. Semistrukturierte Daten

Semistrukturierte Daten haben kein festgeschriebenes Datenmodell, können aber gewisse Strukturinformation in Form von Tags oder Markern mit sich tragen, sodass das Schema teilweise (re)konstruiert werden kann. Semistrukturierte Repräsentationen erlauben, dass Entitäten derselben Klasse unterschiedliche Attribute in beliebiger Reihenfolge aufweisen. Typische Dateiformate sind XML (eXtensible Markup Language) und JSON (Javascript Object Notation), welche sowohl maschinell als auch menschenlesbar sind. Anwendung finden diese in der Übertragung von Daten zwischen Servern und Web-Applikationen, wobei heute JSON durch die Verwendung im REST-Standard (REpresentational State Transfer) verbreiteter ist als XML, Email, Objekt-basierten (No SQL) Datenbanken wie MongoDB und Elasticsearch.

Die Vorteile semistrukturierter Repräsentationen sind, dass ein Mapping auf ein relationales Datenmodell unnötig ist und somit Objekte ohne festgelegtes Schema gespeichert werden können - dies ist besonders praktisch, wenn die Struktur der gesammelten Daten vor deren Speicherung nicht bekannt ist. Zudem können verschachtelte Objekte oder hierarchische Abhängigkeiten einfacher abgebildet werden.

Auf der anderen Seite sind die Abfragesprachen deutlich weniger effizient als SQL für relationale Datenbanken und durch das fehlende Datenmodell und dadurch, dass die Konsistenz nicht erzwungen wird, werden die Abfragen auch fehleranfälliger.

4.1.8.3.1. XML

Die wichtigste Struktureinheit eines XML-Dokumentes ist das Element. Elemente sind die Träger der Information in einem XML-Dokument. Elemente können Text wie auch weitere Elemente als Inhalt enthalten. Elemente bilden die Knoten des Strukturbaumes eines XML-Dokumentes. Der Name eines XML-Elementes kann in XML-Dokumenten ohne Dokumenttypdefinition (DTD) frei gewählt werden.

Für die Auszeichnung von Elementen werden Tags verwendet:

- ein Starttag für den Beginn eines Elementes:
- ein Endtag für das Ende eines Elementes:
- ein Leertag für ein Element ohne Inhalt:

XML-Regeln zur Struktur:

- Das Dokument besitzt genau ein Wurzelelement. Als Wurzelelement wird dabei das jeweils äußerste Element bezeichnet, z. B.
  in XHTML.
- Alle Elemente mit Inhalt besitzen einen Start- und einen Endtag (z. B. Eintrag 1). Elemente ohne Inhalt können mit einem Leertag gekennzeichnet werden (z. B.).

- Die Start- und Endtags sind ebenentreu-paarig verschachtelt. Das bedeutet, dass alle Elemente geschlossen werden müssen, bevor die End-Auszeichner des entsprechenden Elternelements oder die Beginn-Auszeichner eines Geschwisterelements erscheinen.
- Ein Element darf nicht mehrere Attribute mit demselben Namen besitzen.
- Attributwerte müssen in Anführungszeichen stehen (“…” oder ‘…’).
- Die Start- und Endtags beachten die Groß- und Kleinschreibung (z. B. ist nicht gültig).

Ein XML-Dokument ist hierarchisch aufgebaut:

```
<root>
  <child>
    <subchild>.....</subchild>
  </child>
</root>
```



Abbildung 4.7.: Beispiel für eine mögliche XML-Repräsentation einer Sammlung von Büchern

Im Unterschied zu HTML gibt es im XML keine vordefinierten Tags und keine Information, wie die im Dokument enthaltenen Daten dargestellt werden sollen.

4.1.8.3.2. JSON

Die Bezeichnung ist zwar abgeleitet von JavaScript Object-Notation ist aber sprachunabhängig. Das Format ist übersichtlicher und einfacher zu parsen als XML. Es besteht aus reinem Text, was Speicherung und Austausch sehr einfach macht. Die Daten liegen als durch Kommas voneinander getrennte Key/Value-Paare vor. Die Keys bestehen immer aus Strings. Für die Values sind folgende Datentypen erlaubt:

- Zeichenkette (String) eingeschlossen in doppelten Anführungszeichen `"<string>"`
- Zahl als eine Folge der Ziffern `0-9`, Vorzeichen `-` und Dezimalpunkt `.`
- Boolscher Wert: `true` oder ‘false
- Nullwert wird durch das Schlüsselwort `null` dargestellt
- Array (in eckigen Klammern)
- Objekt (in geschweiften Klammern) Bei der Erstellung von JSON-Objekten sind Online Syntax-Validerungstools sehr nützlich, z.B. auf https://jsonlint.com/.

Beispiel für eine mögliche JSON-Repräsentation einer Sammlung von Büchern:

```
{
  "inventory": [
    {
      "category": "programming",
      "title": {
        "lang": "de",
        "text": "Java für Dummies"
      },
      "author": "Jani",
      "year": 1996,
      "price": 36.00
    },
    {
      "category": "programming",
      "title": {
        "lang": "en",
        "text": "Python für Dummies""
      },
      "author": "John",
      "year": 2015,
      "price": 22.00
    }
  ]
}
```

4.1.9. Metadaten

Metadaten oder Metainformationen sind strukturierte Daten, die Informationen über Merkmale anderer Daten (auch Anwendungsdaten genannt) enthalten deren Interpretation unterstützen. Beispielsweise beschreiben sie das Datenmodell oder die Herkunft der Daten. Bei den durch Metadaten beschriebenen Daten handelt es sich oft um größere Sammlungen von Textdokumenten, Bildern, Tabellen, etc.

Bilder werden z.B. zusammen mit Metadaten wie Quelle, Lizenz, Autor, Dateiformat, Speicherbedarf, Dimensionen, Auflösungen, verwendeter Farbraum in der Kodierung etc. abgelegt.

4.1.10. Rohdaten

Als Rohdaten werden Daten vor spezifischen Prozessierungsschritten bezeichnet. Die genaue Bedeutung hängt vom Kontext der Data Science-Aktivitäten ab. Z.B.: - Daten werden nach der Aufnahme durch einen Sensor digitalisiert, aber ohne weiteren Bearbeitungsschritt auf das Speichermedium geschrieben (Raw). - Ein Unternehmen lizenziert Satellitenbilder und bezeichnet sie vor dem ersten internen Prozessierungsschritt als “roh”. Allerdings wurden die Bilder durch den Satellitenbetreiber (ausserhalb der Kontrolle des Unternehmens) bereits einer geometrischen und radiometrischen Korrektur unterzogen - für diesen sind die Daten also nicht “roh”.

4.2. Datenbeschaffung

Tätigkeiten in der Phase Datenbeschaffung

- Datenquellen identifizieren
- Daten beschaffen
- Daten ablegen und organisieren
- Datenkatalog erstellen

Im Datenbericht werden alle Informationen zu den im Projekt verwendeten Daten zusammengetragen, um die Nachvollziehbarkeit und Reproduzierbarkeit der Ergebnisse sicherzustellen und eine systematische Erweiterung der Datenbasis zu ermöglichen Kapitel 4.5.

Auch die Datenbeschaffung ist Teil eines iterativen Prozesses, in dem oft zunächst ein initialer Datensatz analysiert, prozessiert und gegebenenfalls in einem Modellierungs-Schritt verwendet wird. Insbesondere nach der Evaluation müssen aber eventuell zusätzliche oder andere Daten beschafft (und entsprechend organisiert und in einem Datenkatalog erfasst) werden. Auch kann die Bereitstellung neue, für die Weiterentwicklung des Data Products relevante Daten generieren (siehe unterer Pfeil in Abbildung 1.1).

4.2.1. Datenquellen identifizieren

Zunächst müssen die für die Lösung der Problemstellung relevanten Datenquellen identifiziert werden. Es empfiehlt sich, genügend Zeit einplanen für eine gründliche Recherche und die Konsultation von Domänen-Experten. Folgende (nicht abschliessende) Liste an Fragen soll verdeutlichen, welche Aspekte bei der Identifizierung und Bewertung der Datenquellen relevant sein können - diese muss auf die konkrete Problemstellung angepasst werden:

- Handelt es sich um interne oder externe Datenquellen? (Bezogen auf die eigene Organisation, z.B. Firma)
- Sind die Daten öffentlich verfügbar oder handelt es sich um ein kommerzielles Angebot?
- Sind die benötigten Daten auf Seiten der Quelle bereits vorhanden? Allenfalls müssen die Entwicklungsarbeiten mit zusätzlichen Teams koordiniert werden
  - Allenfalls muss, ein bestehendes System erweitert oder ein neues entwickelt werden?
  - Müssen neue Experimente zur Datengewinnung auf Seiten der Datenquelle durchgeführt werden?
- Handelt es sich um persönliche oder geschäftskritische, bzw. vertrauliche Daten?

Beispiele für Datenquellen sind:

- Datensätze aus Forschungsprojekten
  - https://paperswithcode.com/ -> Datasets
  - Harvard Dataverse: https://dataverse.harvard.edu/dataverse/harvard
  - UC Irvine Machine Learning Repository https://archive.ics.uci.edu/ml/index.php
- Kaggle: https://www.kaggle.com/
- Öffentliche Ämter
  - z.B. https://www.bfs.admin.ch/bfs/de/home.html
  - https://opendata.swiss/de
- Wikipedia
- Google Datasets
- Projectgutenberg.org (e-Books)
- Webseiteninhalte (-> Scraping)
- Kommerzielle Anbieter
- Datenquellen innerhalb der eigenen Organisation
  - Zentrales Data Warehouse
  - Applikations-spezifische Datenbanken
  - Sharepoint, shared drives
  - Wiki
  - Email-Server

4.2.2. Datenbeschaffung über Webservices

Daten werden of über Webservices ausgetauscht. Ganz generell sind dies Schnittstellen für die Maschine-zu-Maschine-Kommunikation über Rechnernetze wie das Internet. Dabei werden Daten ausgetauscht und auf entfernten Computern (Servern) Funktionen aufgerufen. [24]
Gängige Kommunikationsprotokolle dafür sind HTTP (HyperText Transfer Protocol) oder HTTPs (HyperText Transfer Protocol Secure). Die Daten werden in Formaten wie XML oder JSON übertragen (siehe Kapitel 4.1.8.3.1, 4.1.8.3.2).
Ein Webservice ist plattformunabhängig und steht in der Regel mehreren Programmen zur Verfügung.

Representational State Transfer (abgekürzt REST) ist ein sehr verbreitetes Paradigma für den Aufbau von Werbservices, welcher, unter anderem, folgende Prinzipien (Constraints) befolgt:

- Client-Server Architektur: Der Server stellt einen Dienst bereit, der bei Bedarf vom Client (z.B. Webseite oder eine App) angefragt werden kann. Server und Client agieren unabhängig voneinander und können separat skaliert werden
- Zustandslosigkeit (Statelessness): Jede REST-Nachricht (Request) enthält alle Informationen, die für den Server bzw. Client notwendig sind, um die Nachricht zu verstehen. Weder der Server noch die Anwendung soll Zustandsinformationen zwischen zwei Nachrichten speichern. Jede Anfrage ist somit in sich geschlossen ist und Anwendungsinformationen werden ausschließlich auf der Seite des Clients vorgehalten.
- Mehrschichtigkeit: Dem Client wird eine Schnittstelle angeboten - weitere Ebenen (z.B. Firewall, Proxy, load balancer) werden separat skaliert und haben keinen Einfluss auf die Form wie der Client Anfragen stellen muss.

Die zentralen Komponenten in der REST-Architektur sind (Abbildung 4.8):

1. Der REST-Client ist die Applikation, welche Anfragen an den REST-Service schickt. Z.B. der Browser im Falle einer Webseite.
2. Der REST-Service ist die Gesamtheit der vom Server bereitgestellten Resourcen
3. REST-API: Definiert die zur Verfügung stehenden Endpunkte und Methoden, um Daten an den Server zu übermitteln und um auf Daten des Servers zuzugreifen.

Ein Request besteht aus

- Endpoint: Die URL, an welche die Anfrage geschickt wird
- Methode: Gibt an, welche Operation des Dienstes gewünscht ist. Folgende sind die häufigsten
  - GET: Abfragen einer Ressource, ohne diese zu verändern. Daten können nur in Form von url-Parametern mitgeschickt warden.
  - POST: Wird für die Abfrage oder veränderung von Ressourcen verwendet. Muss auch für Abfragen verwendet werden, welche Daten im “body” mitschicken.
  - PATCH: teilweises Ersetzen einer Resource (Update)

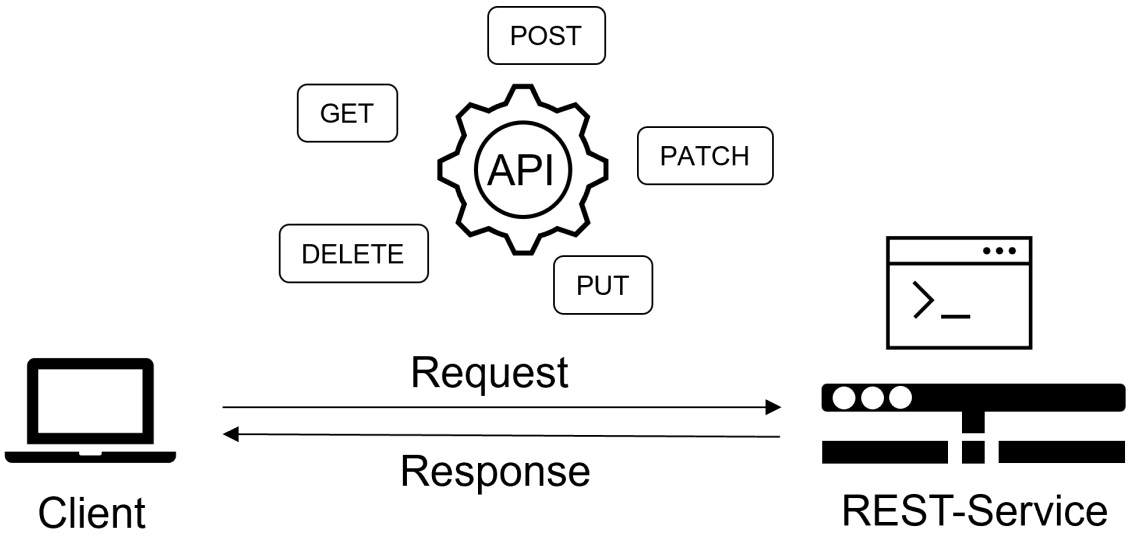


Abbildung 4.8.: Illustration der REST-Architektur

  - PUT: Ersetzen einer existierenden Resource (vollständiges Update) durch eine neue
  - DELETE: Löschen einer Resource

- Headers:zusätzliche Informationen, welche an den Server geschickt werden, wie z.B.
  - Zugangs-Tokens
  - host oder user-agent: Identifikation des Request-Senders
  - accept-language: Sprache, welche der Client interpretiert

- Body: Enthält Daten, welche an den Server geschickt werden sollen

Die Response enthält

- status: Der Status des Requests oder HTTP-Code, wie z.B.
  - 200 OK
  - 201 Created
  - 400 Bad Request
  - 401 Unauthorized
  - 403 Forbidden
  - 404 Not Found
  - 408 Timeout

- die Daten, welche der Server liefert, in einem vorgegebenen Format
- Headers, wie z.B.
  - content-type: Format der vom Server übermittelten Daten

4.2.3. Aspekte der Datenbeschaffung

Folgende (nicht abschliessende) Liste zeigt einige Aspekte auf, welche bei der eigentlichen Datenbeschaffung relevant sein können - diese muss auf die konkrete Problemstellung angepasst werden:

- Erforderliche Frequenz der Datenabfrage/Refresh Rate
  - entweder weil auf Seiten der Quelle neue Daten zur Verfügung stehen
  - oder weil auf Abfrage-Seite andere Daten benötigt werden
- Push vs Pull
- Batch-Download oder ad hoc-Einzelabfragen (zb via rest Webservice)?
- Anforderungen an die Infrastruktur der Datenquelle zur Bereitstellung der Daten
  - Verfügbarkeit (z.B. 7-24, 99.99%)
  - Throughput / Maximale Last der Anfragen (z.B. 1000 Anfragen pro Sekunde, 1GB/s)
  - Latenz (wie lange muss man auf die Daten warten)
  - Stabilität des Schnittstellendesigns (wie oft muss die Datenbeschaffungspipeline an Veränderungen der Schnittstelle angepasst werden?)
- Können abgefragte Daten lokal gespeichert oder dürfen/können sie nur gestreamt werden?
- Werden die Daten von der Quelle persistiert? Können sie wiederholt abgefragt werden? Falls ja: wie lange werden die Daten vorgehalten?

4.2.4. Daten ablegen und organisieren

Beim Ablegen/Speichern der Daten ist auf ein auf die Projektbedingungen angepasstes Datenmanagement zu achten, um die folgenden Phasen des Data Science-Prozesses

- Datenerkundung
- Modellierung
- Evaluation
- Bereitstellung

optimal zu unterstützen. Bei der Wahl des Ablage-Systems spielen Anwendungs-spezifische Anforderungen eine Rolle wie

- Datenmenge
- Skalierbarkeit (die Datenmenge kann sich im Laufe des Projekts drastisch ändern)
- Zugriffs-Frequenz
- Bereitstellungsgeschwindigkeit/Latency (Übertragung!)
- Verfügbarkeit/Reliability

- Zeithorizont/Projektdauer
- Datenmodell
- Kenntnisse und Gewohnheiten im Team
- Sicherheit und Governance (Datenschutz)
- Kosten
- Funktionale Aspekte, z.B. Volltextsuche
- …

Beispiele für verschiedene Systeme und Technologien zur Speicherung und Bereitstellung von Daten:

- Datenbanken
  - Relational (z.B. Oracle, mysql, etc)
  - Nicht-relational (NoSQL, z.B. MongoDB)
  - Graphen (z.B. GraphDB)
- Event Streaming Platform (z.B. Kafka)
- File Shares
- Object Stores (z.B. BLOB[1])
- …

Die Organisation für einen denkbar einfachen Fall wird im Listing 4.1 illustriert: 3 verschiedene Datensätze wurden für ein Data Science-Projekt heruntergeladen und in einem Projekt-Ordner `DSG-PROJECT` unter `DATA` abgelegt. Dieser Ordner könnte zum Beispiel auch auf einem Cloud-Storage im Team geteilt werden. Innerhalb des `Data`-Ordners macht es Sinn, die verschiedenen Stadien der Bereinigung und Aufbereitung zu separieren, z.B. von `RAW` über `PROCESSED` zu `FEATURE SETS`[2], um die Nachvollziehbarkeit und Wiederholbarkeit der gesamten Datenverarbeitungskette zu gewährleisten. Desweiteren sollte der Code von den Anwendungsdaten in

[1] Das Filesystem ist eine hierarchische Struktur von Dateien, auf welche über einen Pfad zugegriffen werden kann. Das Dateisystem definiert Metadaten für Dateien, wie zum Beispiel Beschreibung, Besitzer, Zugriffsrechte und Größe (für alle Dateien dieselben, Attribute vom Dateisystem vorgegeben).
Im Unterschied dazu sind Objekte im BLOB (Binary Large Object-Storage) Daten (eine Datei) gebündelt mit zugehörigen Metadaten. Diesem Objekt wird eine ID zugewiesen, die normalerweise aus den Inhalten (sowohl Datei als auch Metadaten) berechnet wird. Anwendungen identifizieren das Objekt mit der ID. Anders als bei Dateien und Dateisystemen werden Objekte in einer flachen Struktur gespeichert: Ein Pool von Objekten, die aufgrund ihrer Objekt-ID abgefragt werden können. Dabei ist der eigentliche physische Speicherort des Objektes irrelevant (verteilte Speichersysteme). Die Attribute in den Metadaten können von Objekt zu Objekt variabel von der Anwendung festgelegt werden und sind nicht von einem zentralen Speichersystem vorgegeben.
Bei BLOB kann auf Objekte mit einer HTTP-basierten REST-API zugegriffen werden. Object Storage ist einfach zu verwalten, lässt sich fast unendlich skalieren, ist nicht lokal begrenzt und kann sehr viele und variable Metadaten beinhalten. Allerdings ist die Leistung geringer als bei Dateisystemen.

[2] In der explorativen Datenanalyse werden die notwendigen Bereinigungsschritte identifiziert. `PROCESSED` enthält die bereinigten und aus allenfalls unterschiedlichen Quellen zusammengeführten Daten. Allenfalls müssen für die nachfolgende Modellierung auch Attribute codiert, bzw. neue, aussagekräftigere Features abgeleitet werden (feature engineering). Dafür ist in diesem Beispiel der Ordner `FEATURE SETS` vorgesehen.

Listing 4.1 Biespiel für eine einfache Ordner-Struktur zur Organisation der Daten in einem Data Science-Projekt

```
DSG-PROJECT
  DATA
      RAW
           Dataset_1.csv
           Dataset_2.csv
           Dataset_3.csv
      PROCESSED
           Processed_Dataset_1.csv
           Processed_Dataset_2.csv

      FEATURE_SETS
            Feature_Set_1.csv
            Feature_Set_2.csv
|
  CODE
  DOCS
```

einem separaten Ordner `CODE` gehalten und versioniert werden. `DOCS` enthält für das Projektmanagement relevante Dokumente wie die Projektcharta, Zeitplan, Datenbericht, Modellierungsbericht etc.[3]

4.2.5. Datenkatalog erstellen

Ein Datenkatalog ist eine detaillierte Bestandsaufnahme der im Projekt verwendeten Datensätze in Form von Metadaten - also Daten, welche die eigentlichen Datensätze (Anwendungsdaten) beschreiben oder zusammenfassen. Er dient dazu, die nachfolgenden Phasen wie explorative Datenanalyse, Datenaufbereitung und Modellierung zu planen und abzuschätzen, inwieweit die Projektziele mit den vorliegenden Daten erreichbar sind.
In grossen Projekten ist es essentiell, dass sich die Team-Mitglieder schnell und wenn immer nötig einen aktuellen Überblick über die zugänglichen Daten verschaffen können - insbesondere wenn neue Mitglieder dazukommen. Auch bietet Datenkatalog eine Grundlage für weiterführende Dokumentation und Data Governance Kapitel 4.2.6.

Die beschriebenen Datensätze können aus

[3] Dieses Struktur ist als Beispiel zu verstehen, um die verschiedenen Aspekte der Organisation der Projektdaten zu verdeutlichen. Selbstverständlich müssen immer die konkreten Anforderungen des Projektes und des Teams berücksichtigt werden. Der Prozess muss den Menschen dienen, nicht umgekehrt.

- strukturierten (Tabellen oder ganzen Datenbanken)
- und unstrukturierten Daten (Textdokumente, Webseiten, E-Mails, Social-Media-Inhalte, Bilder, Audio und Video)
- Berichte und Abfrageergebnisse
- Datenvisualisierungen und Dashboards
- Modelle für maschinelles Lernen
- Verbindungen zwischen Datenbanken

bestehen. Je nach Art der Daten werden unterschiedliche Metadaten erfasst. In einem einfachen Beispiel wie in Tabelle 4.5 werden die Attribute einer Tabelle mit Datentyp, Wertebereich und einer Beschreibung/Bemerkung versehen.

Tabelle 4.5.: Beispiel für einen Datenkatal
anträgen.

Spalte	Datentyp	Wertebereich
Index	Integer	[0,1000]
Alter	Integer	[19,180]
Geschlecht	Integer	(0,1)
Arbeitsstelle	String	(”niedrige Qualifikation - temporär”, ”niedrige Qualifikation - permanent”,”m
Wohnsituation	String	(”Eigentum”, ”Kostenlos”, ”Miete”)
Sparkonto	String	(gering, mittel, hoch, sehr hoch)
Lohnkonto	String	(gering, mittel, hoch)
Kreditbetrag	Float	[1086,79999]
Laufzeit	Integer	[4,72]
Verwendungszweck	String	”Fahrzeug”, ”Wohnungseinrichtung”,(”Unterhaltungselektronik”, ”Haushaltsg
Risiko	Integer	(0,1)

4.2.6. Data governance

Aufgrund des inhärenten Wertes von Daten, werden je nach Kontext unterschiedliche Anforderungen an den Umgang mit Daten gestellt

- wie sie geschützt werden müssen
- wer auf sie Zugriff hat
- und wofür sie verwendet werden dürfen

Diese Anforderungen können unterschiedlichen Ursprungs sein. Wie beispielsweise - Gesetze (z.B. Datenschutzgesetz), - Erwartungen allgemeines Verständnis von Nutzern und Gesellschaft, - Industrie-Standard, - oder Organisationsinterne Vorschriften (z.B: zum Schutz vertraulicher Daten).

Deshalb werden oft in Guidelines oder Governance-Frameworks Daten nach ihrer Sensibilität eingeteilt, z.B.:

- öffentlich
- geschäftsrelevant
- geschäftskritisch
- personenbezogen (PID – personally identifiable data)

unterschieden und konkrete Vorschriften für den Umgang formuliert. Solche Vorschriften werden häufig als hinderlich für Innovation und die Entwicklungsarbeit an datenbasierten Produkten empfunden. Es ist jedoch zu bedenken, dass sie dem nachhaltigen Schutz der Organisation, ihren Mitarbeiter:innen und den nutzenden Personen dienen. Deshalb sind die Vorschriften und die entsprechenden Governance-Prozesse einerseits regelmässig zu überprüfen, eine Einbettung in die Entwicklungsarbeiten and datenbasierten Produkten sicherzustellen und ihre Einhaltung von den Entwicklungsteams möglichst effizient zu organisierern.

4.3. Datenerkundung

Mithilfe deskriptiver Statistik lassen sich in der explorativen Datenanalyse, insbesondere durch statistische Kennzahlen und Visualisierungen, Besonderheiten und Probleme im Datensatz erkennen. Daraus ergeben sich

- Aussagen zur Datenqualität
  - Unvollständigkeit: Fehlende Attribute und/oder Werte
  - Rauschen und Ausreisser
  - Inkonsistenz: Widersprüchliche Einträge oder unerklärliche Abweichungen
- die notwendige Datenaufbereitung
  - Bereinigung
  - Transformationen und Feature Engineering
- die Notwendigkeit mehr oder andere Daten zu beschaffen
- Einschränkungen in der darauf folgenden Modellierung

Im Extremfall muss das Projekt abgebrochen werden, wenn die zur Erreichung der Ziele notwendigen Daten nicht zur Verfügung stehen

Die Ergebnisse werden zusammen mit den Informationen zur Datenbeschaffung im Datenbericht (Data Report) dokumentiert, um die Nachvollziehbarkeit und Reproduzierbarkeit der Ergebnisse sicherzustellen und eine systematische Erweiterung der Datenbasis zu ermöglichen.

4.3.1. Statistische Variablentypen

Daten werden typischerweise auf Computersystemen in Datentypen wie Strings, Integer, Floats und komplizierteren Datenstrukturen (Datetime) verarbeitet. Diese Repräsentations entsprechen jedoch nicht direkt der Bedeutung, welche wir den Daten zuschreiben. Insbesondere die Interpretation in Form von statistischen Variablentypen ist zentral, denn sie gibt vor, welche mathematischen Operationen auf ihnen ausgeführt werden können. Wir unterscheiden also zwischen informationstechnischem Datentyp und statistischem Variablentyp.

Auf der statistischen Ebene wird zwischen kontinuierlichen (stetigen) und diskreten Variablen unterschieden. Kontinuierliche Variablen können innerhalb eines gegebenen Intervalls eine unendliche Anzahl verschiedener Werte annehmen. Zum Beispiel gibt es zwischen zwei beliebigen Zeitdauern, z. B. 10 und 11 Sekunden, eine beliebige Anzahl von Zwischenwerten, wie 10.1, 10.51, 10.568 und so weiter. In der Praxis ist die die Messgenauigkeit immer beschränkt. Das heisst, es gibt es genau genommen gar keine stetigen Daten. In der Praxis nimmt man trotzdem Stetigkeit an, sobald "genügend" verschiedene Werte vorliegen. Andere Beispiele sind Körpergröße, Länge - Dinge, die wir typischerweise mit Messungen von physikalischen Größen in Verbindung bringen.
Diskrete Variablen hingegen können nur eine endliche Anzahl von möglichen Werten in einem gegebenen Intervall annehmen. Ein Beispiel: "die Anzahl der Personen in einem Raum" kann kein Bruchteil sein - 2.4 Personen in einem Raum ist nicht sinnvoll. Nominale Bezeichnungen, wie z. B. die Namen von Tierarten, sind ebenfalls diskret: Zwischen der Bezeichnung "Elefant" und "Zebra" gibt es keine sinnvollen Zwischenstufen.

- diskret: Nur endlich viele Werte innerhalb eines bestimmten Intervalls sind möglich
- kontinuierlich: Ausprägungen können jeden beliebigen Wert innerhalb eines bestimmten Intervalls annehmen

Eine weitere Unterscheidung erfolgt anhand des Skalenniveaus (scale of measure), auf dem ein Merkmal gemessen wird. Hier gibt es vier grundlegende Typen: Auf der untersten Ebene befindet sich die Nominalskala, bei der die einzelnen Werte Namen oder Kategorien ohne innere Ordnung zugeordnet werden können, wie Farbe, Geschlecht oder Religion.
Ordinal skalierte Variablen haben eine innere Ordnung, aber der Abstand zwischen den einzelnen Werten kann nicht konsistent interpretiert werden. Man kann also Vergleiche in Form von größer oder kleiner anstellen, aber man kann keine Unterschiede berechnen oder die Werte addieren. Ein typisches Beispiel sind Bewertungen, wie ein bis fünf Sterne: Fünf Sterne sind besser als drei Sterne, aber der Unterschied zwischen zwei und drei Sternen ist nicht unbedingt derselbe wie zwischen vier und fünf Sternen.
Die nächste Stufe ist die Intervallskala, bei der Unterschiede eine sinnvolle Interpretation haben, es aber keinen "echten" Nullpunkt oder festen Anfang gibt, auch wenn einer der Werte die Bezeichnung "Null" trägt. Zum Beispiel die Temperatur in Grad Celsius: bei null Grad Celsius gibt es noch eine physikalische Temperatur. Auf dieser Skala können wir keine Verhältnisse interpretieren: 30 Grad Celsius ist nicht dreimal mehr Temperatur als 10 Grad Celsius. Allerdings können verschiedene Temperaturwerte addiert und voneinander subtrahiert werden.

Die höchste Stufe ist die Verhältnisskala, die einen echten Nullpunkt aufweist. Ein Beispiel ist die Temperatur in Grad Kelvin: Hier entspricht der absolute Nullpunkt der physikalischen Situation, dass die kinetische Energie im System gleich null ist und die Temperatur daher wirklich null beträgt. Auf der Verhältnisskala können wir Werte miteinander multiplizieren und dividieren. Nun können wir auch Verhältnisse berechnen: 20 Grad Kelvin haben die doppelte kinetische Energie im System als 10 Grad Kelvin.

- nominal: Werte lassen sich nicht sortieren
- ordinal: Werte haben eine Rangordnung und lassen sich sortieren. Die Abstände sind aber nicht sinnvoll interpretierbar
- interval-skaliert: Abstände lassen sich berechnen und sind sinnvoll interpretierbar
- verhältnis-skaliert: Quotienten lassen sich bilden.

Schließlich wird zwischen kategorischen und numerischen Daten unterschieden. kategorische Daten sind immer diskret und liegen entweder auf einer nominalen oder ordinalen Skala. Die Werte stehen für eine Qualität und nicht für eine Quantität. Numerische Daten stellen Intensitäten oder Mengen dar, typischerweise im Sinne von physikalischen Messungen. Sie liegen entweder auf einer Intervall- oder einer Verhältnisskala vor.

- kategorisch: Ausprägungen lassen sich nicht als Zahlen interpretieren (Kategorien, Klassen)
- numerisch: Ausprägungen lassen sich als Zahlenwerte interpretieren

Tabelle 4.6.: Hierarchische Übersicht der statistischen Variablentypen entlang des Skalenniveaus nominal bis verhältnis-skaliert. Bei jedem übergang zur nächst höheren Ebene sind zusätzliche Berechnungen möglich.

Variablentyp	Skalenniveau	sinnvoll interpretierbare Berechnungen	Beispiele
numerisch - diskret - kontinuierlich	Verhältnis	zählen, sortieren, subtrahieren, dividieren	Kosten, Alter, Grösse, Temperatur in Kelvin
	Interval	zählen, sortieren, subtrahieren	Zeit, Temperatur in Celsius
kategorisch	ordinal	zählen, sortieren	Ratings, Schulnoten
	nominal	zählen	Berufsbezeichnung, Geschlecht

4.3.2. Explorative Analyse strukturierter Daten

4.3.2.1. Übersicht

Die Übersicht eines Datensatzes kann die Anzahl oder relative Häufigkeit von

- Merkmalen nach Datentyp Numerisch/Kategorisch
- Beobachtungen
- fehlenden Einträge (pro Merkmal)
- Duplikaten

enthalten.
Als Duplikate werden Samples mit identischen Ausprägungen aller im Datensatz vorhandenen Merkmale verstanden. Ein solcher Abgleich ist algorithmisch relativ unkompliziert möglich, wenngleich möglicherweise auf grossen Datensätzen entsprechend rechenintensiv. Häufig unterscheiden sich Samples jedoch nur geringfügig in einzelnen Werten, beispielsweise durch Eingabefehler oder fehlende Werte. In solchen Fällen spricht man von Beinahe-Duplikaten. Deren Erkennung ist nicht nur rechnerisch, sondern auch algorithmisch aufwändiger und beruht auf sogenannten Ähnlichkeits- oder Distanzmassen, auf die im Kapitel **??** näher eingegangen wird.

4.3.2.2. Univariate Beschreibung kategorischer Variablen

In der univariaten Datenanalyse werden die Merkmale (Variablen, d.h. Spalten/Attribute) einzeln für sich genommen analysiert. Für kategorische Variablen sind die beschreibenden Kenngrössen und Visualisierungen begrenzt:

- Anzahl eindeutiger Werte (Klassen)
- Anzahl fehlender Werte
- Häufigkeitsverteilung

4.3.2.3. Univariate Beschreibung numerischer Variablen

Im Falle von numerischen Variablen sind umfangreichere Analysen möglich:

- Anzahl, bzw. Anteil
  - eindeutiger Werte
  - fehlender Werte
  - Nullwerte
  - negativer Werte
- Häufigkeitsverteilung

- Extremwerte (Minimum und Maximum)
- Histogram
- Lagemasse:
  - arithmetisches Mittel
  - Median
  - Modus
- Streumasse:
  - Spannweite (Range)
  - Quantile und Interquartilsabstand (Interquartile Range - IQR)
  - Box-Plot
  - Varianz und Standardabweichung
- Masszahlen für Schiefe (Skewness) und Wölbung (Kurtosis)
  - Momentkoeffizient der Schiefe
  - Wölbungsmass nach Fisher

Für M Beobachtungen im Datensatz wird das arithmetische Mittel (Durchschnitt, Englisch Mean) berechnet als:

$$\bar{x} = \frac{1}{M} \sum_{m=1}^{M} x_m$$

Median:

$$\tilde{x} = \begin{cases} x_{[\frac{M+1}{2}]} & \text{für } M \text{ ungerade} \\ \frac{1}{2} \cdot (x_{[\frac{M}{2}]} + x_{[\frac{M}{2}+1]}) & \text{für } M \text{ gerade} \end{cases}$$

Der Modus ist diejenige Ausprägung, welche am häufigsten in den Daten vorkommt.

Die Spannweite (Range) ist die Differenz zwischen grösstem und kleinstem Wert:

$$Range(x) = x_{max} - x_{min}$$

Der Interquartilsabstand ist die Differenz zwischen dem dritten und ersten Quartil:

$$IQR = Q_3 - Q_1$$

Das erste Quartil (Q_1) teilt die Daten im Verhältnis 25:75, bei Q_2 handelt es sich um den Median, der die Daten 50:50 aufteilt, und Q_3 ist das dritte Quartil, welches die Daten im Verhältnis 75:25 trennt.

Der Boxplot (Abbildung 4.9) ist eine übersichtliche grafische Zusammenfassung der 5 Kennzahlen Q_1, Q_3, Median, unterer und oberer Extremwert. Der Bereich zwischen letzteren wird

als der normale Schwankungsbereich der Daten, bzw. Werte ausserhalb werden als Ausreisser, angesehen. Lage und Streuung einer Variablen können mit dem Boxplot gut erfasst werden. Ausreisser werden offensichtlich und auch eine allfällige Schiefe lässt sich erkennen. Allerdings ist der Boxplot weniger geeignet für bi- oder multimodale Daten (mit mehreren lokalen Maxima).

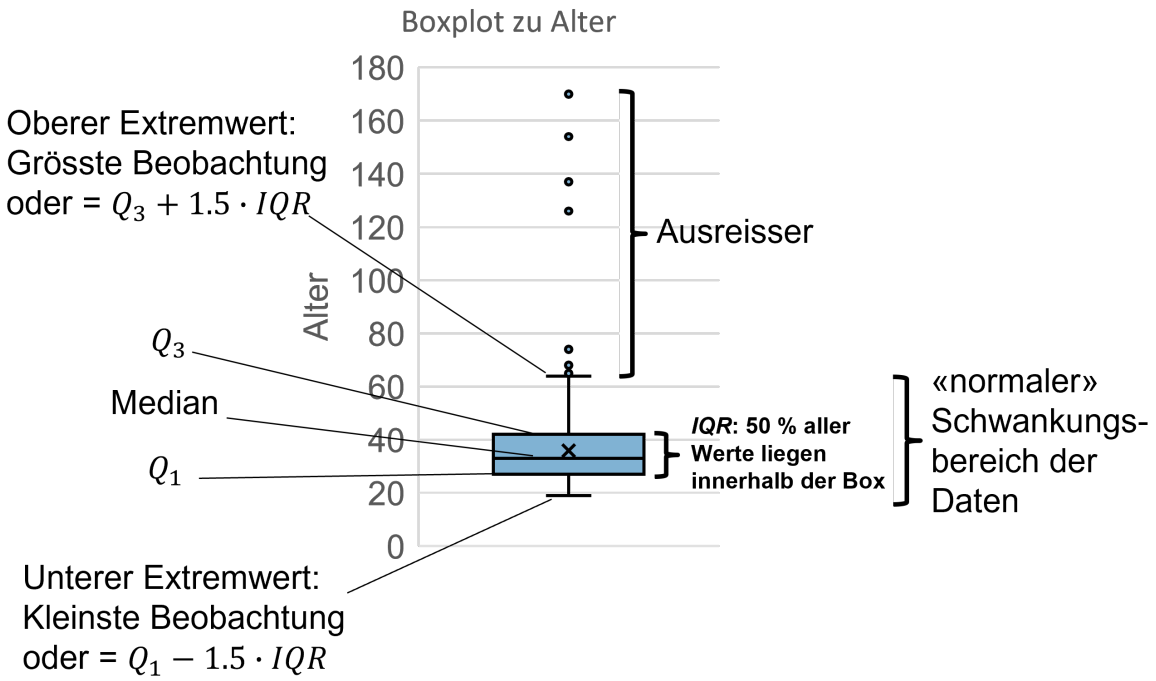


Abbildung 4.9.: Boxplot zur Variable Alter.

Die Varianz ist die standardisierte Summe der quadrierten Differenzen zwischen den Beobachtungen und dem Mittelwert:

$$\tilde{s}_x^2 = \frac{1}{M} \sum_{m=1}^{M} (x_m - \bar{x})^2$$

Die Stichproben-Varianz ist definiert, indem man statt durch M durch $M-1$ dividiert :

$$s_x^2 = \frac{1}{M-1} \sum_{m=1}^{M} (x_m - \bar{x})^2$$

Die Stichproben-Standardabweichung, die Wurzel der Varianz,

$$s_x = \sqrt{s_x^2} = \sqrt{\frac{1}{M-1} \sum_{m=1}^{M} (x_m - \bar{x})^2}$$

hat im Gegensatz zur Varianz dieselbe Einheit wie die ursprünglichen Werte.

4.3.2.4. Die Beschreibung der Beziehung zwischen Variablen

Über die Beschreibung einzelner für sich genommener Variablen hinaus, soll häufig auch die Abhängigkeit der Verteilung mehrerer Variablen voneinander statistisch untersucht und mithilfe von Kennzahlen und Visualisierungen beschrieben werden.

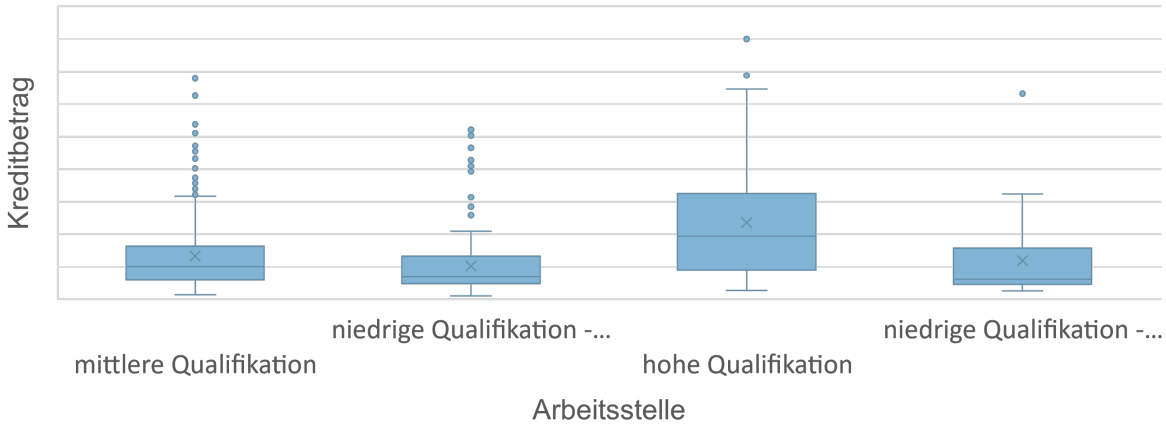


Abbildung 4.10.: Gruppierte Boxplots der verschiedenen Klassen einer kategorischen Variable (Arbeitsstelle) bezüglich einer numerischen Variable (Kreditbetrag)

Zum Vergleich verschiedener Gruppen einer kategorischen Variable bezüglich einer numerischen Variable können gruppierte Boxplots (Abbildung 4.10) verwendet werden.

Streudiagramme (Abbildung 4.11) werden zur Visualisierung der Beziehung zwischen zwei numerischen Merkmalen verwendet. Daraus wird die Form (linear/nicht-linear), Richtung (positiv/negativ) und Stärke des Zusammenhangs ersichtlich.

Um die Beziehung zweier numerischer Merkmale zu quantifizieren wird die Kovarianz verwendet

$$\tilde{s}_{xy} = \frac{1}{M} \sum_{m=1}^{M} (x_m - \bar{x})(y_m - \bar{y})$$

Der Korrelationskoeffizient nach Bravais-Pearson r_{xy}

$$r_{xy} = \frac{\tilde{s}_{xy}}{\tilde{s}_x \tilde{s}_y}$$

ist die standardisierte Kovarianz: Die Kovarianz wird durch das Produkt der Standardabweichungen von x und y geteilt. r_{xy} wird dadurch unabhängig von den Masseinheiten. Er misst die Stärke des linearen Zusammenhangs zwischen den beiden Variablen X und Y.

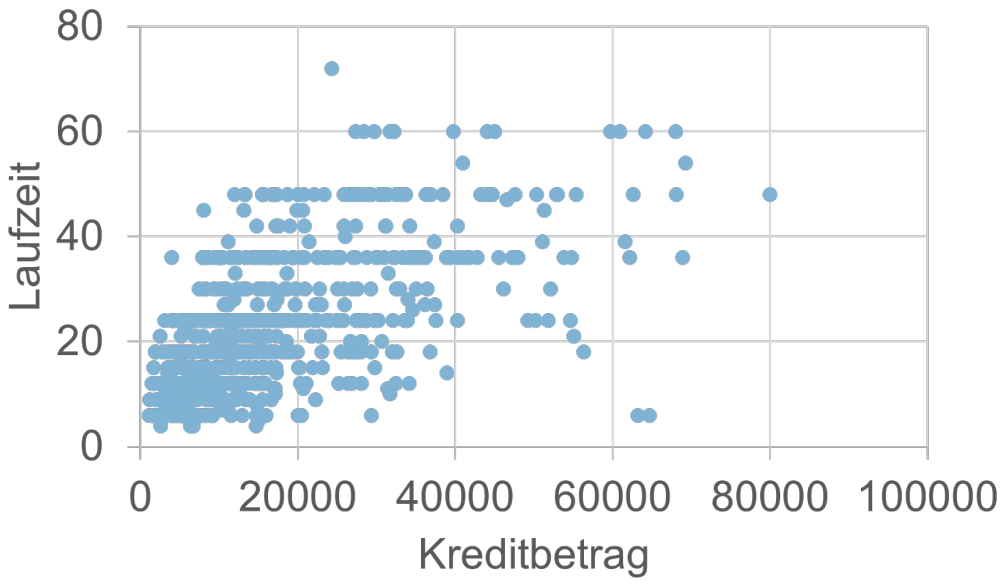


Abbildung 4.11.: Streudiagramm

Der Rangkorrelationskoeffizient nach Spearman ist eine modifizierte Variante des Korrelationskoeffizienten nach Pearson. Die Formel hat dieselbe Struktur, wird jedoch auf die rangtransformierten Daten $x_m \rightarrow rg(x_m)$ angewendet:

$$r_{x_R y_R} = \frac{\sum_{m=1}^{M} \left(rg(x_m) - \bar{rg}_x\right)\left(rg(y_m) - \bar{rg}_y\right)}{\sqrt{\sum_{m=1}^{M} \left(rg(x_m) - \bar{rg}_x\right)^2} \sqrt{\sum_{m=1}^{M} \left(rg(y_m) - \bar{rg}_y\right)^2}}$$

Damit misst der Korrelationskoeffizient nach Spearman die monotone Beziehung zwischen X und Y und kann damit auch nicht-lineare Zusammenhänge erfassen. Er ist robuster gegenüber Ausreissern und ist anwendbar neben verhältnis- und interval-skalierten auch auf ordinal-skalierte Daten.

4.3.2.5. Ähnlichkeits- und Distanzberechnung

Ein wichtiges Konzept in der Datenanalyse und -modellierung ist die Ähnlichkeit, bzw. Unähnlichkeit (entspricht einer Distanz oder einem Abstand), zwischen Objekten. In diesem Zusammenhang handelt es sich meistens um die Beobachtungen (Samples, d.h. Zeilen) im zu analysierenden Datensatz, zwischen denen die Ähnlichkeit oder Unähnlichkeit quantifiziert werden soll. Aber die hier vorgestellten Metriken lassen sich auch auf den Vergleich von Merkmalen (d.h. Spalten) anwenden.

Mithilfe solcher Ähnlichkeits- oder Distanzmasse können auch sogenannte Beinahe-Duplikate im Datensatz erkannt werden, wobei ein Schwellenwert (Engl. threshold) für einen kritischen Ähnlichkeits- oder Distanzwert festgelegt werden muss.

Die Ähnlichkeit zwischen Samples bestehend aus kategorischen Merkmalen kann durch den **Jaccard-Koeffizienten**, auch Jaccard-Index oder Intersection over Union (IoU) genannt, berechnet werden: Die Formulierung stammt aus der Mengenlehre, eine Menge entspricht dann einem Sample aus dem Datensatz. Der Jaccard-Koeffizient wird berechnet, indem man die Anzahl der gemeinsamen Elemente (Schnittmenge) durch die Größe der Vereinigungsmenge teilt (siehe auch Abbildung 4.12):

$$J(A,B) = \frac{|A \cap B|}{|A \cup B|}$$

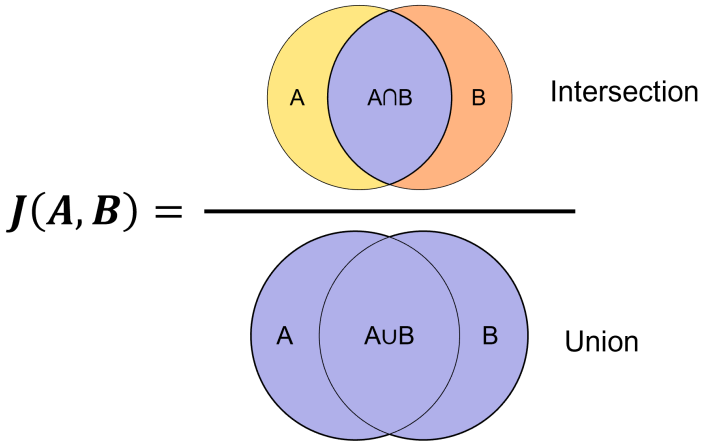


Abbildung 4.12.: Darstellung zur Berechnung des Jaccard-Koeffizienten (Intersection over Union). Schnittmenge (Intersection - oben) wird durch die Vereinigungsmenge (Union - unten) von zwei Mengen A und B geteilt

Je näher der Jaccard-Koeffizient bei 1 liegt, desto größer ist die Ähnlichkeit der Mengen. Der minimale Wert des Jaccard-Koeffizienten ist 0.
Die auf dem Jaccard-Koeffizienten basierende Jaccard-Metrik $d_J(A,B)$ ist ein Mass für die Unähnlichkeit (Distanz), deshalb auch Jaccard-Distanz genannt:

$$D_J(A,B) = 1 - J(A,B) = \frac{|A \cup B| - |A \cap B|}{|A \cup B|}$$

Je näher die Jaccard-Metrik an 0 liegt, desto näher liegen die Mengen A und B beieinander, weil sie sich sehr ähnlich sind. Der maximale Wert der Jaccard-Metrik ist 1. Dann sind die Mengen überschneidungsfrei.

Beispiel für die Berechnung der Ähnlichkeit zwischen aus Tabelle 4.7 (der Index wird nicht berücksichtig):

Die beiden Samples 2 und 4 stimmen in 2 von 12 Merkmalsausprägungen überein(Arbeitsstelle="mittlere Qualifikation" und Sparkonto="gering"). Daraus erechnet sich der Jaccard-Koeffizient für die beiden Samples wiefolgt:

$$J(2,4) = \frac{|A \cap B|}{|A \cup B|} = \frac{2}{12} = 0.17$$

Tabelle 4.7.: Beispiel-Datensatz aus Informationen zu Konsum-Kreditanträgen bei einer Bank und der entsprechenden Risikobewertung (Spalte Risiko).

Index	Geschlecht	Arbeitsstelle	Wohnsituation	Sparkonto	Lohnkonto	Verwendungszweck
...						
2	1	mittlere Qualifikation	Eigentum	gering	mittel	Unterhaltungselektron
...						
4	0	mittlere Qualifikation	kostenlos	gering	gering	Wohnungsreinrichtung
...						

Liegen alle Merkmale in numerischer Form vor, so können die Samples als reellwertige Vektoren verstanden werden, deren Unähnlichkeit (Distanz oder Abstand) über Vektor-Normen berechnet werden kann.
Die **Minkowski-Distanz** berechnet den Abstand zwischen zwei reellen Vectoren **a** und **b** über die L_p-Norm des Abstandsvektors $\mathbf{b} - \mathbf{a}$:

$$D(\mathbf{a}, \mathbf{b}) = \left(\sum_{n=1}^{N} |b_n - a_n|^p \right)^{\frac{1}{p}}$$

Die Minkowski-Distanz wird in der Regel mit $p = 1$ oder $p = 2$ verwendet, was dem Manhattan-Abstand (Engl. Cityblock oder Taxicab Distance) - L_1-Norm des Differenzenvektors:

$$D_T = \sum_{n}^{N} |b_n - a_n|$$

bzw. dem euklidischen Abstand -L_2-Norm des Differenzenvektors):

$$D_E = ||\mathbf{b} - \mathbf{a}|| = \sqrt{\sum_{n=1}^{N} |b_n - a_n|^2}$$

entspricht.

Ein weiteres Ähnlichkeitsmass für reelle Vektoren ist die **Kosinus-Ähnlichkeit**. Dabei wird der Kosinus des Winkels θ zwischen beiden Vektoren $\mathbf{a}$ und $\mathbf{b}$ aus ihrem Skalarprodukt $\mathbf{a} \cdot \mathbf{b}$ normiert über das Produkt ihrer Beträge bestimmt:

$$\text{Kosinusähnlichkeit} = \cos\theta = \frac{\mathbf{a} \cdot \mathbf{b}}{||\mathbf{a}|| \cdot ||\mathbf{b}||} = \frac{\sqrt{\sum_{n=1}^{N} a_n \cdot b_n}}{\sqrt{\sum_{n=1}^{N} (a_n)^2} \cdot \sqrt{\sum_{n=1}^{N} (b_n)^2}}$$

Der Kosinus nimmt Werte zwischen $+1$ und -1 an. Ist der eingeschlossene Winkel $= 0$, das heisst die beiden Vektoren haben dieselbe Orientierung - sie sind sich ähnlich, ist der Kosinus $+1$. Je weiter sich der Zwischenwinkel vergrössert, desto unähnlicher werden sie. Stehen sie senkrecht zueinander (orthogonal), wird der Kosinus des Zwischenwinkels $= 0$. Wird der Winkel noch grösser, so zeigen sie immer weiter in entgegengesetzter Richtung, der Kosinus nimmt negative Werte bis -1 an (siehe Abbildung 4.13).
Eine wichtge Eigentschaft ist, dass der Kosinus (im Gegensatz zu der euklidischen Distanz) durch die Normierung über $||\mathbf{a}|| \cdot ||\mathbf{b}||$ unabhängig von der Länge der beiden Vektoren ist. Sind die Elemente der Vektoren $\mathbf{a}$ und $\mathbf{b}$ alle positiv, so liegt die Kosinusähnlichkeit immer zwischen 0 und 1. In diesem Fall kann man $D_C = 1 -$ Kosinusähnlichkeit entsprechend als Unähnlichkeit interpretieren.

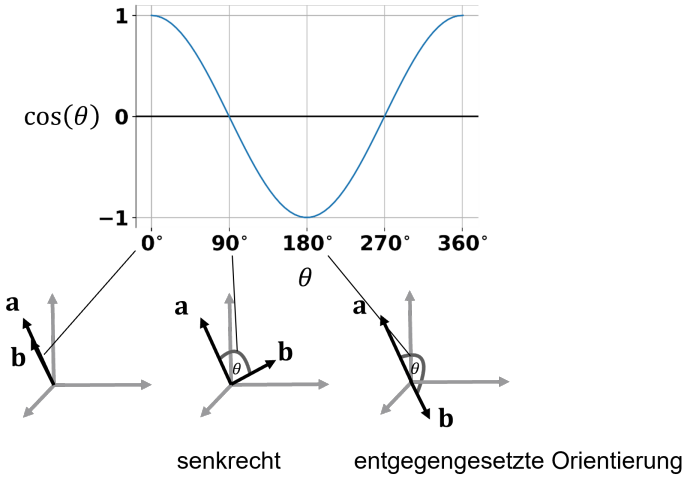


Abbildung 4.13.: Der Kosinus als Funktion des Zwischenwinkels zweier Vektoren $\mathbf{a}$ und $\mathbf{b}$.

Falls nun ein Datensatz aus einer Kombination aus kategorischen und numerischen Merkmalen besteht, so werden typischerweise die kategorischen Merkmale zunächst in numerischer Form kodiert (siehe Kapitel 4.4.3.1), sodass die zu vergleichenden Objekte (Samples oder Merkmale) als reellwertige Vektoren vorliegen.

Der Vollständigkeit halber soll an dieser Stelle noch die **Gower-Distanz** (oder -Abstand) erwähnt werden, welche es erlaubt, eine Distanz basierend auf einer Mischung aus numerischen und kategorischen Merkmalen zu berechnen [25]. Für jedes Merkmal $n = 1, \dots, N$ wird ein Wert $s_n \in [0, 1]$ berechnet. Wenn **a** und **b** entlang des Merkmals n nahe beieinander liegen, dann ist s_n nahe bei 1. Umgekehrt ist der Wert s_n nahe bei 0, wenn sie entlang des Merkmals n weit voneinander entfernt sind. s_n wird wiefolgt berechnet:

1. Für numerische Merkmale: $s_n = 1 - \frac{|b_n - a_n|}{R_n}$, wobei R_n dem Rang des Merkmals n entspricht
2. Für kategorische Merkmale: $s_n = 1\{b_n = a_n\}$

Es wird auch eine Größe δ_n berechnet: Wenn a_n und b_n entlang des Merkmals n verglichen werden können, dann ist $\delta_n = 1$. Falls dies nicht möglich ist (z. B. wegen fehlender Werte), wird $\delta_n = 0$ gesetzt. Der Gower-Abstand wird als Durchschnitt der (bekannten) Werte berechnet:

$$D_G = \frac{\sum_{n=1}^{N} s_n \delta_n}{\sum_{n=1}^{N} \delta_n}$$

Die **Levenshtein-Distanz** (auch Editierdistanz) D_L ist eine Methode speziell für die Ähnlichkeitsberechnung zwischen Zeichenketten (Strings). Die Metrik ist definiert als die minimale Anzahl an Editierschritte, um die erste Zeichenkette A in die zweite B umzuwandeln. Die dafür erlaubten Operationen sind:

- Einfügen (**i**nsert)
- Löschen (**d**elete)
- Ersetzen (**s**ubstitute)

Zum Beispiel kann die Umwandlung von `A=Meilenstein` nach `B=Levenshtein` (Abbildung 4.14) durch das Ersetzen des ersten M, dann Löschen des i und Einfügen des h nach dem s erfolgen. Es werden also mindestens 4 Schritte benötigt. Die praktische Berechnung erfolgt mithilfe einer Methode der dynamischen Programmierung, deren Beschreibung jedoch über den Umfang dieses Kurses hinausgeht.

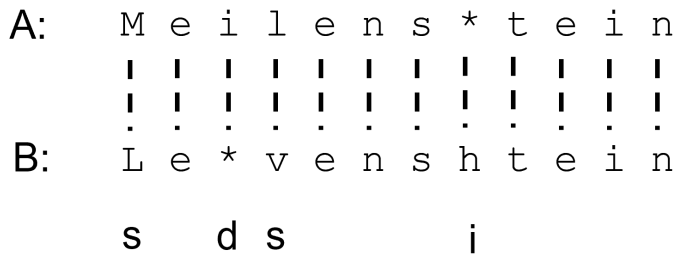


Abbildung 4.14.: Illustration der Editierschritte zur Berechnung der Levenshtein-Distanz zwischen `Meilenstein` und `Levenshtein`.

4.3.2.6. Ausreisser-Erkennung

Als Ausreisser werden Datenpunkte (Samples) mit **abnormalem Verhalten** (was auch immer dies bedeutet) bezeichnet. Insbesondere in kleineren Datensätzen können sie die Resultate verfälschen und sollten erkannt und allenfalls im Rahmen der Datenaufbereitung entfernt werden. Das Erkennen der Ausreisser kann aber auch das eigentliche Ziel einer Datenanalyse und -modellierung sein, wenn zum Beispiel bisher unbekannte Fehler in einem Produktionsprozess oder betrügerische Finanztransaktionen erkannt werden sollen.
Mit dem Boxplot, bzw. dem unteren und oberen Extremwert als Schwellenwerte, wurde bereits innerhalb der univariaten Analyse eine effektive Methode zum Erkennen von Ausreissern vorgestellt. Sollen alle Merkmale des Datensatzes zusammen berücksichtigt werden, so sind jedoch fortgeschrittenere Modellierungsverfahren aus dem Bereich des unüberwachten Lernens (unsupervised learning - outlier detection) notwendig, auf welche an dieser Stelle nicht näher eingegangen wird.

4.3.3. Explorative Analyse unstrukturierter Daten

Die explorative Analye unstrukturierter Daten ist durch die grosse Bandbreite an projektspezifischen Anforderungen und der erschwerten Zugänglichkeit der für die Analyse entscheidende Information in den Rohdaten weniger eindeutig zu fassen als im Fall von unstrukturierten Daten.

Typischerweise sind unstrukturierte Daten mit Metadaten verknüpft, welche nach den Vorgehensweisen für strukturierte Daten analysiert werden und eine Übersicht zur Zusammensetzung des unstrukturierten Datensatzes geben können.
Handelt es sich beispielsweise um einen Textkorpus, welcher Dokumente mit einem zugeordneten Zeitstempel enthält, so lässt sich die Anzahl Dokumente pro Zeiteinheit berechnen und visualisieren. Auch die Verteilung der Länge der Dokumente (in Anzahl Zeichen bzw. Wörtern) pro Zeiteinheit oder eine andere über die Metadaten zugängliche Gruppierung (Dokumententyp, Autor:in, Themengebiet etc.) ist interessant. Ähnliches gilt für Bilddatensätze.

Komplexere Analysen wie Spracherkennung, Sentimentanalyse, Eigennamenerkennung (Englisch named entity recognition - NER) oder andere Formen der Informationsextraktion im Falle von Textkorpora, bzw. Kanten- und Texturerkennung oder Segmentierung im Falle von Bildsammlungen werden ebenfalls häufig im Zusammenhang der explorativen Analyse genannt. Diese basieren in der Regel jedoch bereits auf Modellen für die Datenverteilungen und sind in diesem Sinne als Modellierungsschritte anzusehen.

4.4. Datenaufbereitung

Die Datenaufbereitung umfasst Aktivitäten wie

- Integration und Konsolidierung
- Bereinigung
- Transformationen
- Datenreduktion

mit dem Ziel, den Datensatz in Form einer Datenmatrix (Kapitel 4.4.5) darstellen zu können, welche mit den vorhanden Resourcen und passenden Methoden in der Datenanalyse und -modellierung verarbeitet werden kann.

Die Schritte der Datenaufbereitung werden häufig iterativ basierend auf jeweils aktuellen Erkenntnissen nicht nur aus der explorativen Datenanalyse sondern auch der Modellierung durchgeführt.

Die verschiedenen Bereinigungs- und Transformationsmethoden werden am folgenden Beispielsdatensatz illustriert. Er besteht aus 6 Merkmalen (Marke, Form, Länge, Anzahl Zyliner, Pferdestärken PS und Preis) und einem Index, welche 10 Automodelle (Beobachtungen oder Samples) beschreiben. Zwei Werte fehlen.

Id	Marke	Form	Länge	Zylinder	PS	Preis
1	saab	sedan	186.6	6	110	25443
2	bmw	sedan	186.7	6	98	22367
3	mitsubishi	hatchback	172.5	4		9895
4	mitsubishi	sedan	178.4	6	175	16503
5	bmw		189	6	182	30760
6	vw	hatchback	172	4	82	8145
7	vw	hatchback	173.2	4	85	8256
8	saab	sedan	152.3	6	73	21756
9	saab	sedan	192.7	5	110	28477
10	mitsubishi	sedan	182.6	4	160	26444

4.4.1. Integration und Konsolidierung

Mit Integration und Konsolidierung ist zum Einen das Zusammenbringen verschiedener Datensätze gemeint. Denn häufig entstehen gerade durch die Analyse und Modellierung von aus unterschiedlichen Quellen kombinierten Daten neue Erkenntnisse und nutzenbringende Möglichkeiten für datenbasierte Produkte. Zum anderen ist das Erkennen und Entfernen redundanter Information gemeint.

4.4.2. Datenbereinigung

Bei der Datenbereinigung geht es um das Ersetzen als fehlerhaft erkannter oder fehlender Werte, sodass eine vollständige Datenmatrix resultiert.

Verfahren	Vorteile	Nachteile
Manuelles Ersetzen	- hohe Qualität	hoher Aufwand
Eliminierung der Samples	- einfache Implementierung	- Informationsverlust- Mögliche Verzerrung der Daten
Substitution durch Konstante	- einfache Implementierung- Markierung der ersetzten Werte	- Mögliche Verzerrung der Daten- Korrelation zwischen Merkmalen wird ignoriert- systematisch unterschätzte Varianz
Substitution durch Lagemasse	- einfache Implementierung- i.A. genauer als Eliminierung und Substitution durch Konstante	- Mögliche Verzerrung der Daten - Korrelation zwischen Merkmalen wird ignoriert - systematisch unterschätzte Varianz
Schätzung mithilfe eines Modells	- hohe Genauigkeit	- Rechenaufwand

4.4.2.1. Wert manuell bestimmen

Am besten werden die Werte mithilfe von Expertenwissen korrigiert, d.h. durch die korrekten Werte ersetzt. Allerdings ist dies in der Regel sehr aufwändig und bei grossen Datenmengen nicht praktikabel.

Tabelle 4.10.: Die fehlenden Werte wurden manuell nach einem Abgleich mit einem Referenzsystem bereinigt.

Id	Marke	Form	Länge	Zylinder	PS	Preis
1	saab	sedan	186.6	6	110	25443
2	bmw	sedan	186.7	6	98	22367
3	mitsubishi	hatchback	172.5	4	**86**	9895
4	mitsubishi	sedan	178.4	6	175	16503
5	bmw	**sedan**	189	6	182	30760
6	vw	hatchback	172	4	82	8145
7	vw	hatchback	173.2	4	85	8256
8	saab	sedan	152.3	6	73	21756
9	saab	sedan	192.7	5	110	28477
10	mitsubishi	sedan	182.6	4	160	26444

4.4.2.2. Eliminierung der Samples

Dabei werden sämtliche Samples, bei denen eines oder mehrere Merkmale fehlende Werte aufweisen, aus dem Datensatz gestrichen. Dieses Verfahren ist zwar sehr einfach, hat aber erhebliche Nachteile: Insbesondere bei einer größeren Anzahl fehlender Werte hat es einen erheblichen Informationsverlust zur Folge. Ferner kann diese Technik zu einer Verfälschung der Verteilung im verbleibenden Datensatz führen, wenn die Systematik des Datenausfalls von den Ausprägungen des unvollständig erhobenen Merkmals abhängt.
Als häufiges Beispiel gelten Umfragen bezüglich des Einkommens, bei denen es durchaus vorkommen kann, dass gerade Personen mit einem relativ hohen Einkommen dieses ungerne angeben und es daher in solchen Fällen tendenziell zu fehlenden Werten kommt.

Tabelle 4.11.: Samples 3 und 5, welche eines oder mehrere Merkmale fehlende Werte aufweisen, wurden aus dem Datensatz gestrichen

Id	Marke	Form	Länge	Zylinder	PS	Preis
1	saab	sedan	186.6	6	110	25443
2	bmw	sedan	186.7	6	98	22367
4	mitsubishi	sedan	178.4	6	175	16503
6	vw	hatchback	172	4	82	8145
7	vw	hatchback	173.2	4	85	8256
8	saab	sedan	152.3	6	73	21756
9	saab	sedan	192.7	5	110	28477
10	mitsubishi	sedan	182.6	4	160	26444

4.4.2.3. Substitution durch eine Konstante

Die zu ersetzenden Werte können durch eine fixe Konstante mit auf das jeweilige Merkmal passendem Datentyp ersetzt werden. Damit werden zumindest Fehler bei Analyse- und Modellierungs-Algorithmen, welche mit fehlenden Werten nicht umgehen können, vermieden. Ersetzte Werte «bleiben markiert». Allerdings wird damit die Verteilung der Daten verändert und Wechselwirkungen zwischen den Merkmalen werden ignoriert.

Tabelle 4.12.: Die gesuchten Ausprägungen wurden durche eine fixe Konstante mit auf das jeweilige Merkmal passendem Datentyp ersetzt.

Id	Marke	Form	Länge	Zylinder	PS	Preis
1	saab	sedan	186.6	6	110	25443
2	bmw	sedan	186.7	6	98	22367
3	mitsubishi	hatchback	172.5	4	**-1**	9895
4	mitsubishi	sedan	178.4	6	175	16503

Id	Marke	Form	Länge	Zylinder	PS	Preis
5	bmw	**xxxx**	189	6	182	30760
6	vw	hatchback	172	4	82	8145
7	vw	hatchback	173.2	4	85	8256
8	saab	sedan	152.3	6	73	21756
9	saab	sedan	192.7	5	110	28477
10	mitsubishi	sedan	182.6	4	160	26444

4.4.2.4. Imputation

Unter dem Begriff Imputation werden Verfahren zusammengefasst, mit denen fehlende Werte oder als fehlerhaft erkannte Werte systematisch durch plausible Werte ersetzt werden, indem sie unter anderem mit Hilfe der beobachteten Werte des gleichen Datensatzes geschätzt werden.

4.4.2.4.1. Substitution durch Lagemasse

Eines der einfachsten Imputationsverfahren besteht darin, sämtliche fehlenden Ausprägungen eines Erhebungsmerkmals durch das empirische Lagemass der beobachteten Ausprägungen – meist also den Mittelwert oder Median, bzw. bei kategorischen Merkmalen den Modus – zu ersetzen. Dieses Verfahren hat jedoch den Nachteil, dass dabei – ähnlich wie bei der Eliminierung – Verzerrungen auftreten, sofern der Datenausfall von der Ausprägung des betreffenden Merkmals abhängt. Ferner weist der resultierende Datensatz eine systematisch unterschätzte Standardabweichung auf, da die imputierten Werte konstant sind und daher unter sich keine Streuung aufweisen.

Tabelle 4.13.: Die gesuchten Ausprägungen wurden beim quantitativen Merkmal “PS” durch das arithmetische Mittel und beim kategorischen Merkmal “Form” durch den Modus (häufigster Wert) ersetzt.

Id	Marke	Form	Länge	Zylinder	PS	Preis
1	saab	sedan	186.6	6	110	25443
2	bmw	sedan	186.7	6	98	22367
3	mitsubishi	hatchback	172.5	4	**119**	9895
4	mitsubishi	sedan	178.4	6	175	16503
5	bmw	**sedan**	189	6	182	30760
6	vw	hatchback	172	4	82	8145
7	vw	hatchback	173.2	4	85	8256
8	saab	sedan	152.3	6	73	21756
9	saab	sedan	192.7	5	110	28477

Id	Marke	Form	Länge	Zylinder	PS	Preis
10	mitsubishi	sedan	182.6	4	160	26444

4.4.2.4.2. Schätzung mithilfe eines Modells

Bei der Schätzung der fehlenden oder zu ersetzenden Wertes mithilfe eines statistischen Modelles, beispielsweise basierend auf der Nächste Nachbarn-Heuristik oder Regressionsverfahren, können etwaige funktionale Zusammenhänge (Korrelationen) zwischen zwei oder mehreren Merkmalen ausgenutzt werden. Allerdings ist zu beachten, dass die Vorhersagen immer nur so gut sind, wie es eben die Güte des Modells zulässt! Mehr dazu im Abschnitt Modellierung.

Tabelle 4.14.: Hier wurden die gesuchten Ausprägungen durch die Nächste-Nachbar-Heuristik geschätzt.

Id	Marke	Form	Länge	Zylinder	PS	Preis
1	saab	sedan	186.6	6	110	25443
2	bmw	sedan	186.7	6	98	22367
3	mitsubishi	hatchback	172.5	4	**84**	9895
4	mitsubishi	sedan	178.4	6	175	16503
5	bmw	**sedan**	189	6	182	30760
6	vw	hatchback	172	4	82	8145
7	vw	hatchback	173.2	4	85	8256
8	saab	sedan	152.3	6	73	21756
9	saab	sedan	192.7	5	110	28477
10	mitsubishi	sedan	182.6	4	160	26444

4.4.3. Transformationen

4.4.3.1. Kodierung kategorischer Merkmale

Wenn wir die Daten als Matric prozessieren möchten, dann müssen die kategorischen Merkmale in numerische Werte überführen. Das nennt sich Kodierung kategorischer Variablen.

4.4.3.2. Ordinal-Kodierung

Bei der Ordinalcodierung wird jedem eindeutigen Kategoriewert ein ganzzahliger Wert zugewiesen. Zum Beispiel wird eine Bewertung “Sehr gut” zu 4, “gut” zu 3, “mittelmässig” zu 2 und “schlecht” zu 1. Häufig werden ganzzahlige Werte verwendet, die bei Null beginnen. Die

ganzzahligen Werte stehen in einem natürlichen Ordnungsverhältnis und sind daher eine natürliche Kodierung für ordinale Variablen. Einige Algorithmen des maschinellen Lernens sind in der Lage, diese Beziehung zu verstehen und zu nutzen. Bei Daten ohne ordinale Beziehung kann dies jedoch zu Problemen führen, so dass stattdessen besser eine One-Hot-Kodierung verwendet wird.

In Tabelle 4.15 werden die kategorischen Merkmale "Marke" und "Form" aus dem Beispieldatensatz Tabelle 4.10 ordinal kodiert. Die Zuweisung der entsprechenden Ausprägungen wurde nach Auftreten im Datensatz für Marke:

- saab: 0
- bmw: 1
- mitsubishi: 2
- vw: 3

und Form:

- sedan: 0
- hatchback: 1

festgelegt. Dabei wird dem Merkmal "Marke" eine inhärente Ordnung zugewiesen, welche eigentlich nicht besteht. Beim Merkmal "Form" fällt dies bei nur zwei Ausprägungen (binäres Merkmal) nicht weiter auf.

Tabelle 4.15.: Ordinal-Kodierung der kategorischen Merkmale "Marke" und "Form" aus dem Beispieldatensatz in Tabelle 4.10

Marke	Form
0	0
1	0
2	1
2	0
1	0
3	1
3	1
0	0
0	0
2	0

4.4.3.2.1. One-Hot-Kodierung

In der One-Hot-Kodierung wird ein kategorisches Merkmal ersetzt durch ein neues binäre Merkmal (0,1) für jeden eindeutigen Wert. In Tabelle 4.16 werden die kategorischen Merkmale "Marke" und "Form" aus dem Beispieldatensatz Tabelle 4.10 One-Hot kodiert.

Tabelle 4.16.: One-Hot-Kodierung der kategorischen Merkmale “Marke” und “Form” aus dem Beispieldatensatz in Tabelle 4.10

Marke_saab	Marke_bmw	Marke_mitsubishi	Marke_vw	Form_sedan	Form_hatchback
1	0	0	0	1	0
0	1	0	0	1	0
0	0	1	0	0	1
0	0	1	0	1	0
0	1	0	0	1	0
0	0	0	1	0	1
0	0	0	1	0	1
1	0	0	0	1	0
1	0	0	0	1	0
0	0	1	0	1	0

4.4.3.3. Skalierung numerischer Merkmale

Wenn die verschiedenen numerischen Merkmale des Datensatzes sehr unterschiedliche Grössenordnungen (Skalen) aufweisen (z.B. Wagenlänge in cm [152.3,192.7] vs Anzahl Zylinder [4-6] in Abbildung 4.15), kann dies in Visualisierungen, aber auch in Analyse- und Modellierungsverfahren zu Problemen führen.

Mithilfe von Skalierungsverfahren werden unterschiedliche Merkmale auf einen gemeinsamen Wertebereich transformiert.

4.4.3.3.1. Min-Max-Normalisierung

In der Min-Max-Normalisierung wird ein numerisches Merkmal $\mathbf{x}$ linear auf den Bereich $[0, 1]$ skaliert. Von den einzelnen Ausgangswerten x_m wird das Minimum der beobachteten Werte abgezogen und dann durch die Spannweite $(x_{max} - x_{min})$ dividiert:

$$x'_m = \frac{x_m - x_{min}}{x_{max} - x_{min}}$$

4.4.3.3.2. Standardisierung

Die Standardisierung eines numerischen Merkmals $\mathbf{x}$

$$x'_m = \frac{x_m - \bar{x}}{\tilde{s}_x}$$

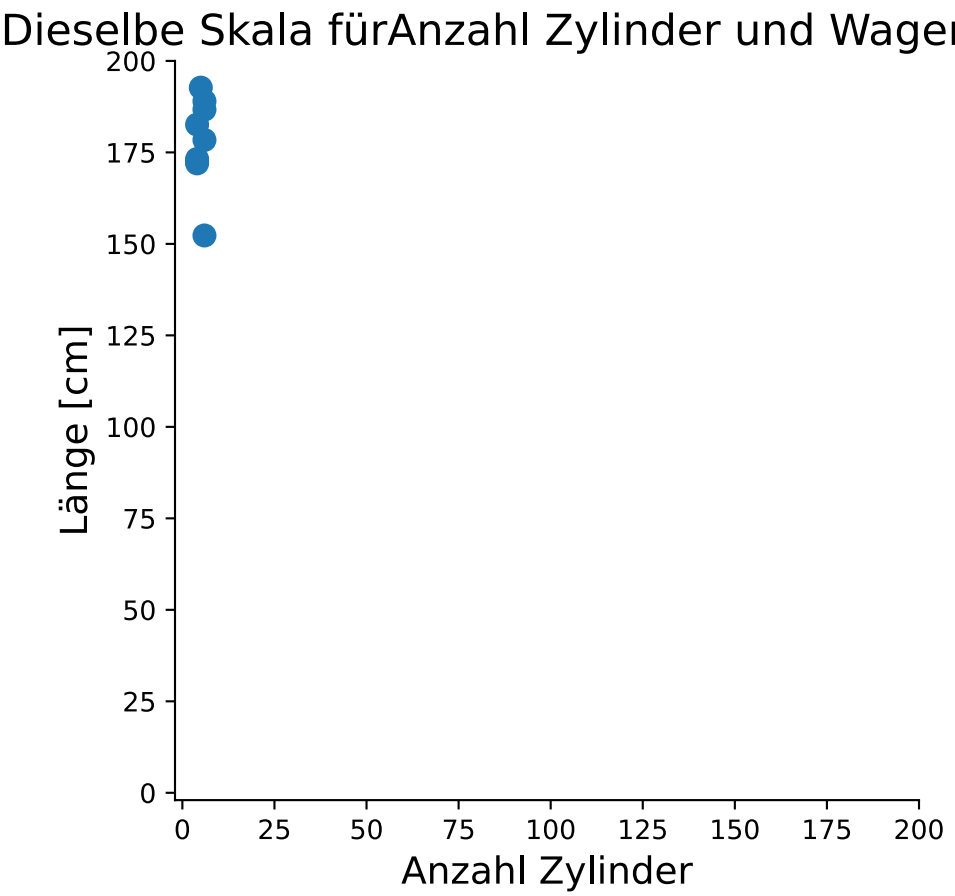


Abbildung 4.15.: Beispiel für zwei numerische Merkmalen mit sehr unterschiedlichen Skalen aus Tabelle 4.10.

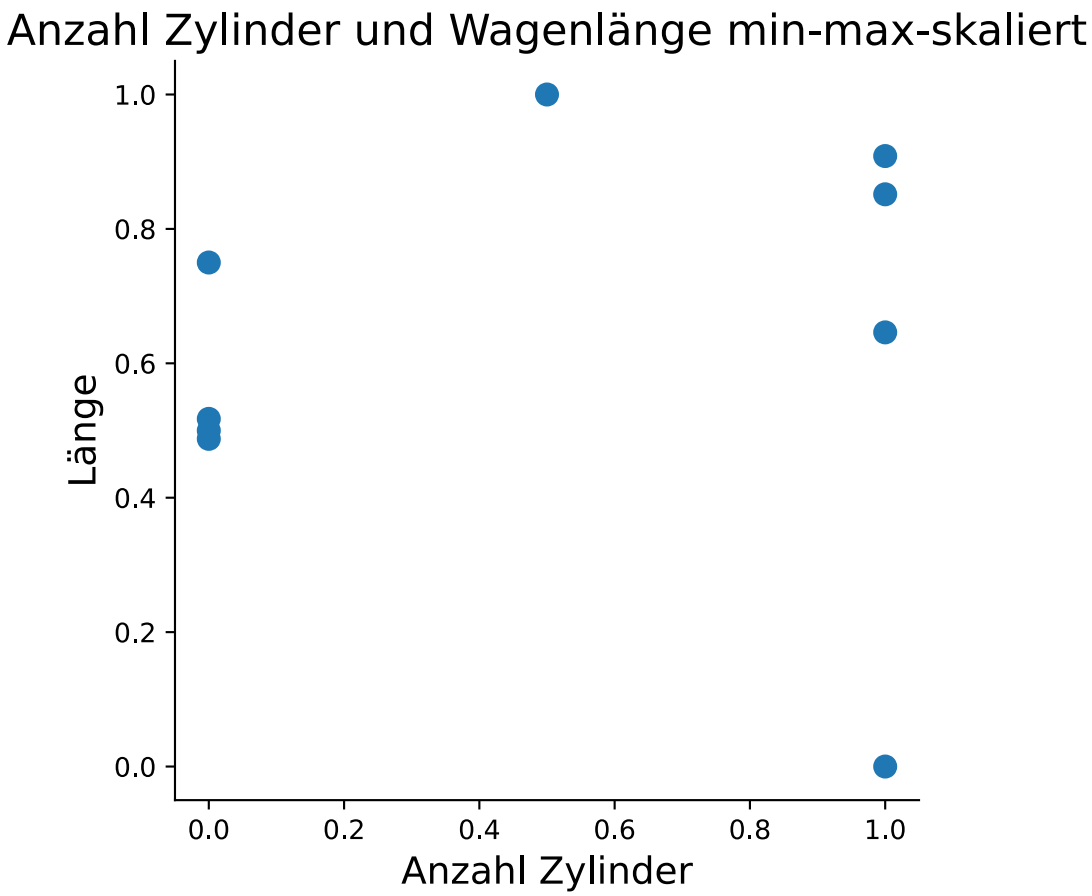


Abbildung 4.16.: Die min-max-skalierten Werte von Länge und Anzahl Zylinder aus Tabelle 4.10.

bewirkt, dass die Werte einen Mittelwert von 0 (bei Subtraktion des Mittelwerts im Zähler) und eine varianz von eins (durch die Normalisierung durch die Standardabweichung s_x) aufweisen. Die Transformation ist besonders angebracht bei (annähernd) normalverteilten Variablen.

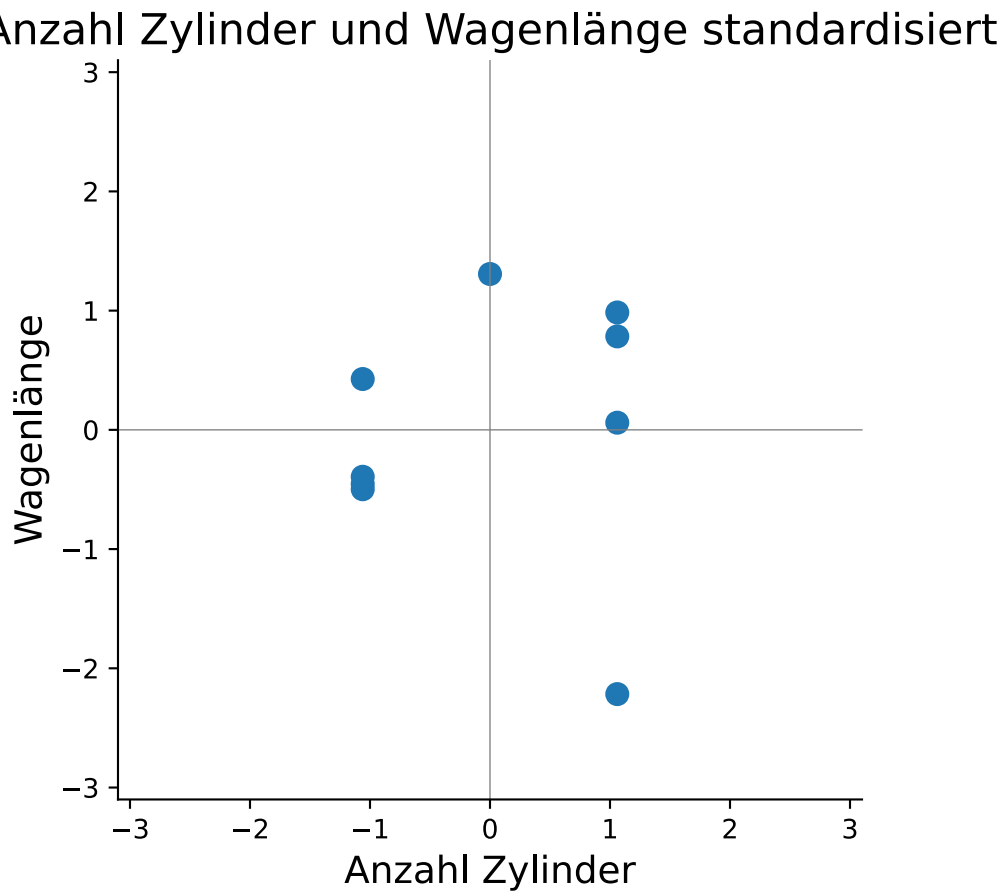


Abbildung 4.17.: Die standardisierten Werte von Länge und Anzahl Zylinder aus Tabelle 4.10.

4.4.3.4. Diskretisierung numerischer Merkmale

Bei der Konvertierung kontinuierlicher in diskrete Merkmale durch Binning werden die Zielmengen der Attribute der Größe nach aufsteigend in Intervalle – sogenannte Bins (englisch für Behälter) – eingeteilt. Alle Attributwerte werden dann mit einem Repräsentanten des Intervalls ersetzt, in dem sich der Wert befindet. Dieser auch englisch interval label genannte Repräsentationswert ist oft etwa der Durchschnitt oder der Median innerhalb des Intervalls. Es handelt sich damit um eine Form von Quantisierung.

Diese Form von Binning kann zum einen dazu dienen, die Anzahl der Werte eines gegebenen

Attributs und damit die Datenmenge zu reduzieren. Zum Anderen können dadurch die Folgen kleinerer Abweichungen in den Ausprägungen, etwa aufgrund von Messfehlern, verringert werden.

4.4.3.5. Aggregation kategorischer Variablen

kategorische Merkmale haben eine endliche (aber möglicherweise große) Anzahl eindeutiger Werte. Beispiele hierfür sind der geografische Standort, die Berufskategorie und der Gegenstandstyp. Über eine sogenannte Konzeptierarchie können nun mehrere Ausprägungen zu Gruppen zusammengefasst werden. Zum Beispiel können Benutzer oder Domänenexperten solche Konzepthierarchien manuell definieren, indem sie eine teilweise oder vollständige Reihenfolge der Attribute auf der Schemaebene angeben. Eine Datenbank kann beispielsweise die Attribute Straße, Stadt, Provinz oder Bundesland und Land enthalten. Eine Hierarchie kann definiert werden, indem die Gesamtreihenfolge dieser Attribute auf der Schemaebene angegeben wird, z. B. Straße < Stadt < Provinz oder Staat < Land.
Bei grossen Datenmengen ist die manuelle Erstellung solcher Konzepthierarchien nicht praktikabel und einfache heuristische Vorgehensweisen[4] bis hin zu statistischen Verfahren in Kombination mit handkuratierten digitalen lexikographischen Ressourcen (z.B. WordNet [26] - siehe [wordvis]http://wordvis.com) kommen zum Einsatz (Natural Language Processing und Information Retrieval).

4.4.3.6. Feature Engineering

Feature Engineering ist der Prozess der Erstellung neuer, möglichst informativerer, Merkmale (Features), welche in der nachfolgenden Analyse und Modellierung die Zielgrösse besser beschreiben, beziehungsweise ein den Daten zugrunde liegendes Muster deutlicher zutage treten lassen. Insbesondere in klassischen Verfahren des maschinellen Lernens (nicht Deep Learning) und kleineren Datenmengen ist das Feature Engineering oft entscheidend für die Qualität der Ergebnisse. Neue Merkmale können durch die Transformation und/oder Kombination bestehender Merkmale erstellt werden. Dabei setzt die Auswahl passender mathematischer Operationen oft eine gute Kenntnis der Natur der Daten und der Domäne voraus. Insbesondere beim Einsatz klassischer Verfahren des maschinellen Lernens auf unstrukturierten Daten wie Bildern ist ein ausgefeiltes Feature Engineering, z.B. Kantenerkennung in Bildern, zentral.

[4] Da übergeordnete Konzepte im Allgemeinen mehrere untergeordnete Konzepte umfassen, enthält ein Attribut, das eine hohe Konzeptebene definiert (z. B. Land), in der Regel eine geringere Anzahl unterschiedlicher Werte als ein Attribut, das eine niedrigere Konzeptebene definiert (z. B. Straße). Auf der Grundlage dieser Beobachtung kann automatisch eine Konzepthierarchie auf der Basis der Anzahl der eindeutigen Werte pro Attribut in der gegebenen Attributmenge erstellt werden. Das Attribut mit den meisten eindeutigen Werten wird auf die unterste Ebene der Hierarchie gesetzt. Je niedriger die Anzahl der eindeutigen Werte eines Attributs ist, desto höher steht es in der generierten Konzepthierarchie. Diese heuristische Regel funktioniert in vielen Fällen gut. Wenn nötig, können die Benutzer oder Experten nach Prüfung der generierten Hierarchie einige Verschiebungen oder Anpassungen auf lokaler Ebene vornehmen.

4.4.4. Datenreduktion

Die Datenmenge kann sowohl durch Eingrenzung der Merkmale als auch der Samples reduziert werden. Zudem können auch Transformationen wie Diskretisierung und Aggregation zur Datenreduktion genutzt werden.
Die Datenreduktion kann zum Einen zur Begrenzung der benötigten Rechen- und Speicherressourcen dienen, zum Anderen kann bei Datensätzen mit unausgewogener Klassen- oder Werteverteilung die Qualität der Modellierung durch das sogenannte Downsampling der stärker vertretenen Klassen oder Wertebereiche verbessert werden.

4.4.5. Die Datenmatrix

Die M Beobachtungen (Samples) der N Merkmale (Variablen, Features) im Datensatz können kompakt in Form der Datenmatrix (Englisch design matrix) X der Dimension $M \times N$ dargestellt werden. Die Einträge der Matrix sind reelle Zahlen - kategorische Merkmale müssen demnach zunächst in numerischer Form kodiert werden (siehe Kapitel 4.4.3.1).

$$\mathbf{X}_{M\times N} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1N} \\ x_{21} & x_{22} & \cdots & x_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ x_{M1} & x_{M2} & \cdots & x_{MN} \end{pmatrix}$$

enthält für das Merkmal n die entsprechende Spalte:

$$\mathbf{X}_{:,n} = \begin{pmatrix} x_{1n} \\ x_{2n} \\ \vdots \\ x_{Mn} \end{pmatrix}$$

Die m-te Beobachtung entspricht der m-ten Zeile - ausgedrückt als Spaltenvektor:

$$\mathbf{X}_{m,:} = \begin{pmatrix} x_{m1} \\ x_{m2} \\ \vdots \\ x_{mN} \end{pmatrix}$$

Die Datenmatrix kann also sowohl als Zeilenvektor der N Merkmale als auch als Spaltenvektor der M transponierten Beobachtungen ausgedrückt werden:

$$\mathbf{X}_{M\times N} = \begin{pmatrix} \mathbf{X}_{:1} & \mathbf{X}_{:2} & \cdots & \mathbf{X}_{:N} \end{pmatrix} = \begin{pmatrix} \mathbf{X}_{1:}^T \\ \mathbf{X}_{2:}^T \\ \vdots \\ \mathbf{X}_{M:}^T \end{pmatrix}$$

Die Datenmatrix zum Beispiel in Tabelle 4.10 nach

- Substitution der fehlenden Werte durch das arithmetische Mittel bei numerischen und den Modus bei kategorischen Merkmalen
- Standardisierung der numerischen Merkmale
- Ordinalskalierung des kategorischen Merkmals “Form”
- One-Hot-Kodierung des Merkmals “Marke”

sieht nun folgendermassen aus:

$$\mathbf{X} = \begin{pmatrix} 0.71 & 0.95 & -0.25 & 0.69 & 0 & 0 & 1 & 0 & 1 \\ 0.72 & 0.95 & -0.57 & 0.32 & 1 & 0 & 0 & 0 & 1 \\ -0.54 & -1.17 & 0.00 & -1.22 & 0 & 1 & 0 & 0 & 0 \\ -0.02 & 0.95 & 1.48 & -0.41 & 0 & 1 & 0 & 0 & 1 \\ 0.93 & 0.95 & 1.67 & 1.35 & 1 & 0 & 0 & 0 & 1 \\ -0.59 & -1.17 & -1.00 & -1.44 & 0 & 0 & 0 & 1 & 0 \\ -0.48 & -1.17 & -0.92 & -1.42 & 0 & 0 & 0 & 1 & 0 \\ -2.35 & 0.95 & -1.24 & 0.24 & 0 & 0 & 1 & 0 & 1 \\ 1.26 & -0.11 & -0.25 & 1.07 & 0 & 0 & 1 & 0 & 1 \\ 0.36 & -1.17 & 1.08 & 0.82 & 0 & 1 & 0 & 0 & 1 \end{pmatrix}$$

Mit Spalten 1:Länge, 2:Zylinder, 3:PS, 4:Preis, 5:Marke_bmw, 6:Marke_mitsubishi, 7:Marke_saab, 8:Marke_vw, 9:Form
Die Spalte “Id” wurde nicht berücksichtigt, da sie nur der eindeutigen Identifizierung der Beobachtungen dient, aber keine weitere für die Analyse und Modellierung relevante Information trägt.

4.4.6. Datenaufbereitung unstrukturierter Daten

4.4.6.1. Text

Texte sind lineare Folgen von Wörtern. Sie häufig in einer hierarchischen Struktur organisiert, die die Ontologie der entsprechenden Domäne widerspiegelt. Mit anderen Worten: Die Organisation von Texten folgt Dimensionen, die mit den spezifischen Funktionen des Textes zusammenhängen. Natürlich kann ein und dieselbe Textsammlung für verschiedene Personengruppen, zu verschiedenen Zeitpunkten usw. unterschiedliche Funktionen haben.

Die höchste Organisationsebene ist der **Korpus**, eine computerlesbare Sammlung von Text oder Sprache. Die **Dokumente** stellen die einzelnen Texteinheiten des Korpus dar. Sie können mit Metadaten versehen sein. Beispiele für Dokumenttypen sind twitter-Posts, Emails, Webseiten, Bücher etc. die Dokumente können im Korpus beispielsweise nach Sprache, Genre, Themen bzw. Domänen und Subdomänen oder Zeit organisiert sein.

```
ColumnTransformer(transformers=[('pipeline-1',
                                 Pipeline(steps=[('simpleimputer',
                                                  SimpleImputer()),
                                                 ('standardscaler',
                                                  StandardScaler())]),
                                 ['Länge', 'Zylinder', 'PS', 'Preis']),
                                ('pipeline-2',
                                 Pipeline(steps=[('simpleimputer',
                                                  SimpleImputer(strategy='most_frequent')),
                                                 ('onehotencoder',
                                                  OneHotEncoder(handle_unknown='ignore'))]),
                                 ['Marke']),
                                ('pipeline-3',
                                 Pipeline(steps=[('simpleimputer',
                                                  SimpleImputer(strategy='most_frequent')),
                                                 ('ordinalencoder',
                                                  OrdinalEncoder())]),
                                 ['Form'])])
```

Abbildung 4.18.: Datenaufbereitungspipeline zur Erstellung der Datenmatrix dem Datensatz Tabelle 4.10 enthält 3 Spalten-spezifische Sub-Pipelines.

Die nächste Ebene ist der **Absatz**, der für die Gliederung eines Textes nicht zwingend erforderlich ist. Er dient hauptsächlich dazu, Zusammenhänge zu trennen und dem Leser zu helfen, die verschiedenen Ideen und Konzepte im Text zu verstehen.
Die **Sätze** in einem Dokument sind Texteinheiten, die aus einem oder mehreren Wörtern bestehen, die grammatikalisch miteinander verbunden sind. Und der Satz ist ein grammatikalisch vollständiger Ausdruck. Funktional gesehen ist ein Satz eine Einheit von geschriebenen Texten, die durch graphologische Merkmale wie Großbuchstaben und Markierungen wie Punkte, Frage- und Ausrufezeichen abgegrenzt wird. Ein Satz kann aus Wörtern bestehen, die sinnvoll gruppiert sind, um eine Aussage, eine Frage, einen Ausruf, eine Aufforderung, einen Befehl oder einen Vorschlag auszudrücken.
Utterance bezieht sich auf eine transkribierte Form eines gesprochenen Satzes, der Füllwörter und Wortfragmente enthalten kann
Ein **Wort** ist eine einzelne Einheit der Sprache, die eine Bedeutung (oder ein Konzept) ausdrückt. Das Vokabular ist die Menge der einzelnen Wörter oder Wortarten in einem Korpus.
Token sind die einzelnen Instanzen der Vokabularwörter im laufenden Text. Es kann also mehrere Token geben, die sich auf dasselbe Vokabularwort an verschiedenen Stellen des Textes beziehen.

4.4.6.1.1. Bereinigung von Textdaten

In der statistischen Analyse und Modellierung von Freitext ist die Bereiniging (preprocessing) besonders wichtig. Sie besteht meist aus:

- Segmentierung und Tokenisierung: dem Zerlegen von Text in einzelne Sätze an Punkten, Ausrufezeichen etc. und dem Zerlegen der Sätze in einzelne Wörter
- Textnormalisierung: Umwandlung des Textes in eine einheitliche kanonische Form, um konsistente Eingaben für alle nachgelagerten Analyseschritte bereitszustellen. Mit dem Ziel Rauschen zu reduzieren, das Vokabular kompakt zu halten und die Genauigkeit der Sprachmodellierungsaufgaben zu verbessern. Z.B. dem
  - Entfernen von speziellen Schriftzeichen wie Satzzeichen
  - Angleichen der Gross-/Kleinschreibung
  - Umwandlung von Umlauten und dem scharfen "s"
  - Entfernen häufiger Wörter ohne semantischer Bedeutung
  - Zurückführen auf Wortstamm und -lemma
  - Ersetzen von Synonymen

4.4.6.1.2. Kodierung von freiem Text

Um freien Text computergestützt statistisch analysieren zu können, muss er in eine strukturierte numerische Form überführt werden. Im Folgenden wird das Bag-of-Words (BoW)-Modell beschrieben. Bei der Anwendung dieses Modells auf einen gegebenen Korpus an Dokumenten $D = (D_1, D_2, D_3, ..., D_M)$ muss einerseits ein Vokabular festgelegt werden, also die Gesamtheit aller eindeutigen Wörter (i.A. auch aufeinanderfolgende Wortfragmente, sogenannte N-Gramme), welche in der Repräsentation berücksichtig werden sollen. Die Wörter des Vokabulars $W = (w_1, w_2, w_3, \dots, w_N)$ entsprechen den Merkmalen, geben also die Spalten in der resultierenden tabellarischen Darstellung der Dokumente vor (Tabelle 4.17). Deshalb haben die Dokumente unabhängig von der Länge ihres ursprünglichen Textes dieselbe Länge in der BoW-Darstellung (einzelne Zeilen in Tabelle 4.17)

Zum anderen muss eine Kodierungsfunktion f gewählt werden, welche für jedes Dokument und jedes Wort aus dem Vokabular eine reelle Zahl ausgibt.

Tabelle 4.17.: Tabellarische Darstellung eines Korpuses an Dokumenten im BoW-Modell.

	w_1	$w2$	w_3	...	w_N
Dokument D_1	$f(D_1; w_1)$	$f(D_1; w_2)$	$f(D_1; w_2)$	...	$f(D_1; w_N)$
Dokument D_2	$f(D_2; w_1)$	$f(D_2; w_2)$	$f(D_2; w_2)$	...	$f(D_2; w_N)$
Dokument D_M	$f(D_M; w_1)$	$f(D_M; w_2)$	$f(D_M; w_2)$	...	$f(D_M; w_N)$

Im Folgenden werden 3 gängige Koderierungsfunktionen am Korpus in Tabelle 4.18 illustriert. Vor der Kodierung werden die Texte auf Kleinbuchstaben normalisiert.

Tabelle 4.18.: Beispielkorpus

Dokument	Text
D_1	This is the first document.
D_2	This is the second second document.
D_3	And the third one.
D_4	Is this the first document?

Die **One-Hot-Kodierung** weist einfach den Wert 1 zu, wenn das der jeweiligen Spalte entsprechende Wort im Dokument vorhanden ist, und 0, wenn es nicht vorhanden ist. Mit anderen Worten: Jedes Element eines One-Hot-kodierten Vektors spiegelt entweder das Vorhandensein oder das Fehlen des Wortes im Dokument wider.

Tabelle 4.19.: Tabellarische Darstellung des auf Kleinbuchstaben normalisierten und One-Hot-kodierten Korpus aus Tabelle 4.18.

Dokument	first	one	the	second	third	is	this	document	and
D_1	1	0	1	0	0	1	1	1	0
D_2	0	0	1	1	0	1	1	1	0
D_3	0	1	1	0	1	0	0	0	1
D_4	1	0	1	0	0	1	1	1	0

Die One-Hot-Kodierung reduziert die Ungleichgewichts-Problematik der Token-Verteilung, indem sie ein Dokument auf seine Bestandteile vereinfacht. Diese Reduktion ist am effektivsten bei sehr kleinen Dokumenten (Sätzen, Tweets), die nicht viele sich wiederholende Elemente enthalten, und wird in der Regel auf Modelle angewandt, die sehr gute Glättungseigenschaften haben. Die One-Hot-Codierung wird auch häufig in künstlichen neuronalen Netzen verwendet, deren Aktivierungsfunktionen eine Eingabe im diskreten Bereich von [0,1] oder [-1,1] erfordern.

Die **Häufigkeits-Kodierung** weist dem entsprechenden Vokabular-Wort seine Häufigkeit im Dokument zu. Der Wert für jedes Wort kann die reine Zählung sein oder auf die Gesamtzahl der Wörter im Dokument normiert werden.

Tabelle 4.20.: Tabellarische Darstellung des auf Kleinbuchstaben normalisierten und One-Hot-kodierten Korpus aus Tabelle 4.18.

Dokument	first	one	the	second	third	is	this	document	and
D_1	1	0	1	0	0	1	1	1	0
D_2	0	0	1	2	0	1	1	1	0
D_3	0	1	1	0	1	0	0	0	1

Dokument	first	one	the	second	third	is	this	document	and
D_4	1	0	1	0	0	1	1	1	0

Sowohl die One-Hot- als auch die einfache Häufigkeitskodierung berücksichtigen nicht die relative Häufigkeit des Auftretens eines Begriffs in einem Dokument in Bezug auf den gesamten Korpus. In der Annahme, dass seltene Begriffe wichtige Informationen ausdrücken, insbesondere wenn sie ungewöhnlich häufig in einigen wenigen Dokumenten des Korpus vorkommen, können wir die **Tf-idf-Kodierung** (von englisch term frequency "Vorkommenshäufigkeit" und inverse document frequency "inverse Dokumenthäufigkeit") anwenden. Das tf-idf-Maß für das Wort w_n im Dokument D_m des Korpus D wird als das Produkt der Häufigkeit (tf) des Wortes w_n im Dokument D_m multipliziert mit der inversen Dokumenthäufigkeit (idf) berechnet:

$$\text{tf-idf}(w_n, D_m, D) = tf(w_n, D_m) \cdot idf(w_n, D)$$

tf wird berechnet als die Häufigkeit, wie oft das Wort w_n im Dokument D_m vorkommt $\#(w_n, D_m)$ geteilt durch die Gesamtzahl der Wörter in D_m, um einer Verzerrung des Wertes alleine durch die unterschiedliche Länge von Dokumenten entgegenzuwirken:

$$\text{tf}(w_n, D_m) = \frac{\#(w_n, D_m)}{\max_{w_j \in D_m} \#(w_j, D_m)}$$

Die inverse Dokumenthäufigkeit ist der logarithmisch skalierte inverse Anteil der Dokumente im Korpus, die den Begriff w_n enthalten:

$$\text{idf}(w_n, D) = \log \frac{|D|}{1 + \sum_{D_j : w_n \in D_j} 1}$$

Hier ist $|D|$ die Anzahl der Dokumente im Korpus und $\sum_{D_j : w_n \in D_j} 1$ ist die Anzahl Dokumente, in denen w_n. Die idf hängt nicht vom einzelnen Dokument, sondern vom Dokumentkorpus ab. Sie misst, wie selten der Begriff in allen Dokumenten des Korpus ist. Begriffe, welche in vielen Dokumenten des Korpus vorkommen (z.B. "und" oder "ein" - sogenannte Stopwords) erhalten einen kleinen idf-Wert. Die +1 glättet den Wert für Wörter, die im Korpus nicht vorkommen. Die log-Funktion hilft bei der Berücksichtigung einer großen Anzahl von Dokumenten in einem Korpus.

Tabelle 4.21.: Tabellarische Darstellung des auf Kleinbuchstaben normalisierten und Tf-idf-kodierten Korpus aus Tabelle 4.18.

Dokument	first	one	the	second	third	is	this	document	and
D_1	0.060	0.000	0.000	0.000	0.000	0.025	0.025	0.025	0.000

Dokument	first	one	the	second	third	is	this	document	and
D_2	0.000	0.000	0.000	0.201	0.000	0.021	0.021	0.021	0.000
D_3	0.000	0.150	0.000	0.000	0.151	0.000	0.000	0.000	0.151
D_4	0.060	0.000	0.000	0.000	0.000	0.025	0.025	0.025	0.000

Im BoW-Modell bleibt die sequentielle Anordnung der Wörter in den ursprünglichen Dokumenten unberücksichtig, als ob die Texte der Dokumente werden in einzelne Säcke "geworfen" und durcheinander geschüttelt worden wären (daher die Bezeichnung "Bag of Words"). Die Kodierungsfunktion kann dann nicht mehr die Abfolge der Wörter im ursprünglichen Text abbilden und die grammatikalische und semantische Struktur der Texte geht verloren. Um die Information, welche in der Reihenfolge von Wörtern im Text steckt, zumindest teilweise zu erhalten, können N-Gramme höherer Ordnung auf Wortebene (z.B. das Bigramm "this is") in das Vokabular einbezogen werden.

Die Dokumente entsprechen nun reellwertigen Vektoren in einem hochdimensionalen semantischen Raum. Der Abstand zwischen den Punkten in diesem Raum ist ein Mass für die Ähnlichkeit der Dokumente - meistens wird diese mithilfe der Kosinus-Ähnlichkeit berechnet.

Ein gesamter Freitext-Korpus lässt sich so als Datenmatrix darstellen (und computergestützt analysieren). Die Zeilen entsprechen den einzelnen Dokumenten, die Spalten den Vokabular-Wörtern - deshalb wird sie auch Dokument-Term-Matrix (document-term matrix, die Transponierte der term-document matrix) genannt

$$\mathbf{X}_{M\times N} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1N} \\ x_{21} & x_{22} & \cdots & x_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ x_{M1} & x_{M2} & \cdots & x_{MN} \end{pmatrix}$$

mit $x_{mn} = f(D_m; w_n)$ für einen Korpus aus $|D| = M$ Dokumenten und ein Vokabular $W = (w_1, w_2, w_3, \dots, w_N)$.

4.4.6.2. Bilder

Die digitale Darstellung von Bildern (Kapitel 4.1.4.2) besteht aus einem rechteckigen Grid (Breite × Höhe) von Pixeln, wobei jeder Pixel einen numerischen Wert pro Kanal des gewählten Farbraumes trägt (Kapitel 4.1.4.2).

4.4.6.2.1. Bereinigung und Vorverarbeitung von Bilddaten

Die Bereinigung und Vorverarbeitung von Bilddaten hängt stark von den Eigenschaften des zu verarbeitenden Datensatzes, den Projektzielen und den gewählten Modellierungsverfahren ab. Meistens muss in der Bereinigung sichergestellt werden, dass alle Bilder des Datensatzes dieselbe Dimension und im gleichen Farbraum kodiert sind. Vorverarbeitungsschritte umfassen:

- Grössenskalierung: Anpassung der Dimension ((Breite × Höhe) der Bilder
- Änderung des Farbraumes
- Intensitätsskalierung: Standardisierung oder Normalisierung pro Kanal entweder über den gesamten Datensatz oder das jeweilige Bild
- Datenanreicherung: Oft sind die für Bilder verwendeten Modellierungsverfahren sehr datenhungrig und die Datensätze müssen mit künstlichen Transformationen angereichert werden. Dazu gehören
  - zufällige Neuskalierung
  - sowie zufälliges Beschneiden
  - horizontale Spiegelungen
  - Störungen von Helligkeit, Kontrast und Farbe

4.4.6.2.2. Die Datenmatrix bei Bilddaten

Digitale Bilder liegen bereits in numerischer Form als Matrizen pro Farbkanal vor. Um einen Satz von Bildern in einer Datenmatrix abzubilden, werden alle Intensitätswerte der einzelnen Bilder nach einem einheitlichen Schema in jeweils inen Vektor umgeordnet - sodass die Rückumwandlung der Vektor in die als Bilder darstellbaren Repräsentation jederzeit möglich ist.

Die Datenmatrix besteht dann aus einer Zeile pro Bild und einer Spalte pro Pixel auf einem bestimmten Rasterpunkt und Farbkanal. Mit M Bilder im Datensatz und $N = \text{Breite} \times \text{Höhe} \times \text{Anzahl Farbkanäle}$:

$$\mathbf{X}_{M\times N} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1N} \\ x_{21} & x_{22} & \cdots & x_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ x_{M1} & x_{M2} & \cdots & x_{MN} \end{pmatrix}$$

4.5. Datenbericht (Data report)

Das Template-Dokument enthält die folgenden Abschnitte:

- Beschreibung der Datensätze und deren Kontext!

- Datenkatalog
- Hinweise zur Beschaffung
- und Verwendung der Daten
- Data Governance-Aspekte
- Datenqualität (Resultate der explorativen Datenanalyse)

Die Templates sind als Ausgangsgerüst gedacht. Sie sind auf die konkreten «Data Science»-Projekte jeweils anzupassen.

5. Modellierung

5.1. Paradigmen des Maschinellen Lernens

Ein Modell im maschinellen Lernen (engl. Machine Learning) stellt einen mathematischen oder probabilisitischen Zusammenhang zwischen Variablen dar in Form einer mathematischen Funktionen, deren freie Parameter im Lernprozess auf die zur Verfügung stehenden Daten angepasst werden. Ziel des maschinellen Lernens ist es nun, Muster in den Daten zu erfassen, um Zusammenhänge quantiativ zu erklären und/oder Vorhersagen zu machen. Solche Informationen unterstützen Entscheidungsprozesse und ermöglichen konkrete, zielgerichtete Handlungen (Stichwort: actionable insights). Dadurch kann auch der Daten generierende Prozess beeinflusst werden.

Grundlagen für die Methoden des maschinellen Lernen sind die Wahrscheinlichkeitstheorie und Statistik. Algorithmische und numerische Aspekte dienen der computergestützten Berechenbarkeit dieser Methoden. Man spricht auch von: Statistisches Lernen, Predictive Modelling, Mustererkennung oder künstliche Intelligenz (engl. Artificial Intelligence). Problemstellungen im maschinellen Lernen umfassen:

- überwachtes Lernen (engl. supervised learning)
  - Regression (Kapitel 5.2.2)
  - Klassifikation (Kapitel 5.2.3)
- unüberwachtes Lernen (engl. unsupervised learning)
  - Clusteranalyse (Clustering, Kapitel 5.3.2)
  - Dimensionsreduktion (Dimensionality Reduction, Kapitel 5.3.1)
  - Ausreissererkennung (Outlier Detection)
  - Assoziationsanalyse (Association Rule Mining)
  - Empfehlungsdienste (Recommender Systems, Kapitel 5.3.3)
  - …
- bestärkendes Lernen (Reinforcement Learning)

Die Struktur der zur Verfügung stehenden Daten bestimmt den Unterschied zwischen überwachtem (Kapitel 5.2) und unüberwachtem Lernen (Kapitel 5.3).

5.2. Überwachtes Lernen

Im überwachten Lernen bestehen die zur Verfügung stehenden Daten aus M Paaren von Ein- und Ausgaben $\left(\mathbf{X}_{m,:}, y_m\right)_{m=1}^{M}$. Jedes Sample $\mathbf{X}_{m,:}$ entspricht einer Zeile m der Matrix $\mathbf{X}$ (vgl. Notation in Kapitel 4.4.5). Die entsprechenden Ausgabewerte y_m werden typischerweise in einem separaten Vektor $\mathbf{y}$ gelistet:

$$\mathbf{X}_{M\times N} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1N} \\ x_{21} & x_{22} & \cdots & x_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ x_{M1} & x_{M2} & \cdots & x_{MN} \end{pmatrix}, \quad \mathbf{y}_{M\times 1} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_M \end{pmatrix}$$

Der Algorithmus "lernt" nun basierend auf den zur Verfügung stehenden Daten eine Funktion $f(\mathbf{X}_{m,:})$ so, dass deren Ausgabwerte $\hat{y}_m = f(\mathbf{X}_{m,:})$ möglichst gut mit den erwarteten Ausgabewerten y_m übereinstimmen (für alle Samples $m = 1, ..., M$).
Ein Beispiel für ein überwachtes Lernproblem wäre die Vorhersage von Preisen von Häusern auf Basis von bestimmten Variablen wie Grundfläche, Anzahl Zimmern etc.

Die N Spalten von $\mathbf{X}$ stellen die Merkmale dar, welche die Eingabedaten beschreiben. Je nach Kontext werden sie auch unabhängige oder erklärende Variablen, Inputdaten, Vorhersagefaktoren, Features, Prädiktoren, Attribute oder Kovariate genannt.

Die Ausgabewerte y_m werden auch Target, Response, Zielvariable, abhängige Variable oder Label (insbesondere bei kategorischen Merkmalen) genannt.

Je nachdem, wie die Ausgangsdaten vorliegen, sind $\mathbf{X}$ und $\mathbf{y}$ bereits das Resultat aus Bereinigungs-, Transformations- und Reduktionsschritten (Kapitel 4.4).

5.2.1. Der Verallgemeinerungsfehler

Sowohl in der Regression als auch in der Klassifikation wird ein mathematisches Modell auf die Trainingsdaten angepasst, so dass es das den Daten zugrundeliegende Muster optimal erfasst und nach dem Training verlässliche Ausgaben auf beliebigen Eingabewerten genieren kann. Man ist also eigentlich an einer möglichst hohen Genauigkeit des Modells auf "neuen" Daten, seiner Verallgemeinerungsfähigkeit, interessiert. Die Trainingsdaten sind "nur" Mittel zum Zweck.

Diese "neuen" Daten sind per Definition während des Trainings unbekannt. Um trotzdem quantitativ abschätzen zu können, wie genau die Vorhersagen des Modells sein werden auf Daten, welche während des Trainings nicht genutzt wurden, wird der zur Verfügung stehende Datensatz in ein Trainingsset und unabhängiges Testset aufgeteilt. Das Trainingsset wird für das Training des Modells verwendet und erst wenn dieses abgeschlossen ist, wird der Verallgemeinerungsfehler beziehungsweise die Verallgemeinerungsfähigkeit des trainierten Modells mithilfe

von Evaluationsmetriken auf dem unabhängigen Testset abgeschätzt. Je nach Lernproblem werden unterschiedliche Metriken verwendet: Bei Regressionsproblemen werden Fehlermasse (kleiner ist besser - siehe Kapitel 5.2.2.4) verwendet, bei Klassifikationsproblemen sind es Genauigkeitsmasse (grösser ist besser - siehe Kapitel 5.2.3.2).
Eine gängige Aufteilung der zur Verfügung stehenden Daten ist 80% Traingsdaten und 20% Testdaten.

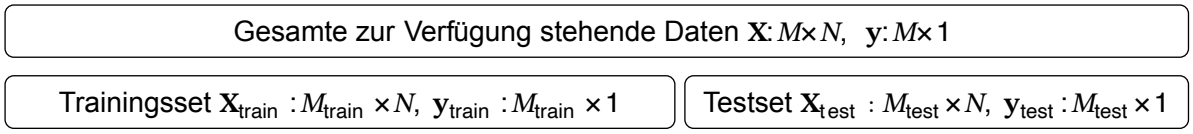


Abbildung 5.1.: Illustration der Aufteilung der für die Modellierung zur Verfügung stehenden Daten in ein Trainings- und ein unabhängiges Testset.

5.2.2. Regression

In Regressionsproblemen handelt es sich bei der Zielvariable um eine numerische Variable: $y_m \in \mathbb{R}$. Beispiele sind die Vorhersage

- von Popularitätswerten (Anzahl Likes oder Re-Tweets) von Posts in sozialen Netzwerken
- des Wertes von Finanzprodukten
- von Autopreisen
- des Verkehrsaufkommens an einem bestimmten Ort zu einer bestimmten Zeit

Im nachstehenden Beispiel wird der Krankheitsverlauf von Diabetes innerhalb eines Jahres (Zielvariable) in Abhängigkeit des Bodymass-Indexes (unabhängige Variable) untersucht. Der Datensatz enthält Messwerte von 20 Patient:innen (Samples). Die Datenmatrix $\mathbf{X}$ besteht also aus 20 Zeilen ($M = 20$) und einer Spalte ($N = 1$). Der Vektor $\mathbf{y}$ enhält für jedes der 20 Samples den Ausgabewert.

In einer Regression wird nun mithilfe eines Lernalgorithmus eine mathematische Funktion auf den vorhandenen Daten “trainiert” oder “gelernt”, sodass für unbekannte BMI-Werte der wahrscheinlichste Wert für den Krankheitsverlauf vorgergesagt werden kann.

Zur Lösung von Regressionsproblemen stehen unterschiedliche Methoden zur Verfügung:

- k-Nächste-Nachbarn-Heuristik (engl. k-nearest neighbors algorithm)
- Lineare Regression (linear regression)
- Regressionsbäume (regression trees)
- Neuronale Netzen (neural networks)
- Support Vector Machine
- ...

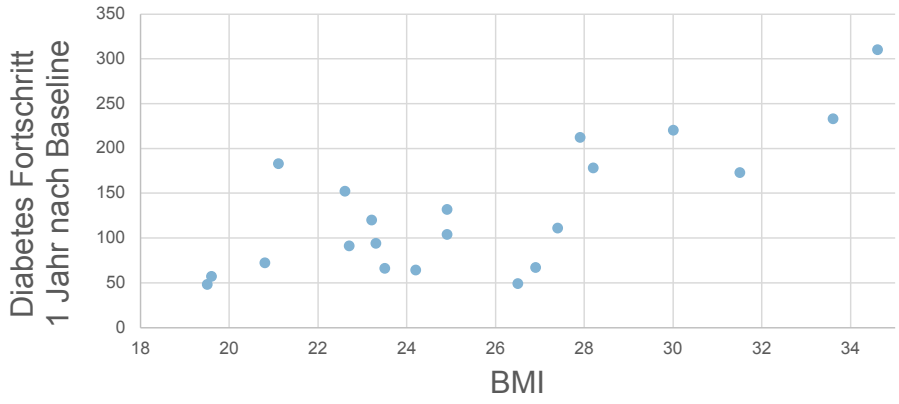


Abbildung 5.2.: Darstellung des Diabetes-Datensatzes.

5.2.2.1. k-Nächste-Nachbarn-Heuristik für Regression

Die k-Nächste-Nachbarn-Heuristik ist eine instanzbasierte Methode, das heisst, für jede Vorhersage auf einer Eingabe $\mathbf{x}$ muss der komplette Trainingsdatensatz zur Verfügung stehen. Zudem muss ein Ähnlichkeitsmass gewählt werden, um die nächstliegenden Samples (Nachbarn) aus den Trainingsdaten identifizieren zu können. Typischerweise wird die euklidische Distanz verwendet. Der Hyperparameter k legt fest, wieviele Nachbarn in der Vorhersage berücksichtigt werden.
Bei Regressionsproblemen wird dann der Mittelwert der Ausgabewerte der nächsten Nachbarn ermittelt und als Vorhersage $\hat{y} = f(\mathbf{x})$ ausgegeben.

Angewendet auf den Diabetes-Datensatz aus Abbildung 5.2 mit der euklidischen Distanz und $k = 4$, werden zunächst die 4 nächstliegenden Samples aus dem Trainingsdatensatz identifziert. Dazu müssen in diesem Fall mit nur einer unabhängigen Variable die 4 Samples mit dem ähnlichsten BMI ausgewählt und der Durchschnitt deren Ausgabwerte berechnet werden:

$$\hat{y}_{BMI=29} = \frac{1}{4}(111 + 212 + 178 + 220)$$

Vorteile der k-Nächste-Nachbarn-Heuristik sind die Einfachheit und Interpretierbarkeit der Vorhersagen. Die Nachteile sind:

- Instanz-basiert: Für die Vorhersage auf einem neuen Sample, müssen immer alle Trainings-Samples zur Verfügung stehen, um die k nächsten Punkte auswählen und den Zielwert berechnen zu können
- Sensitiv auf Ausreisser und Rauschen
- Die weiter entfernten Datenpunkte bleiben für die einzelnen Vorhersagen unberücksichtigt, das heisst die in den Trainingsdaten vorhandene Information wird nicht vollständig genutzt

- Extrapolation über den Wertebereich der Trainingsdaten hinaus ist problematisch
- Fluch der Dimensionalität: Mit steigender Anzahl Features werden alle Trainingsdatenpunkte praktisch gleich weit entfernt vom Query-Punkt

5.2.2.2. Lineare Regression

Im Gegensatz zur Nächste-Nachbarn-Heuristik handelt es sich bei der linearen Regression um einen modellbasierten Ansatz. Das heisst, es werden die Parameter einer mathematischen Funktion auf die Trainingsdaten angepasst (das eigentliche Lernen, Training oder Fitten). Man spricht deshalb auch von einem parametrischen Modell. Nach dem Anpassen der Parameter werden die Trainingsdaten nicht mehr benötigt, sondern das Modell kann Vorhersagen auf neuen Eingabewerten ausschliesslich als Ausgaben der parametrisierten Funktion generieren.

Bei der linearen Regression handelt es sich bei der mathematischen Funktion des Modells $f_{\{\theta_n\}_{n=0}^N}(\mathbf{x})$ um eine Linearkombination der N Eingabewerte (Features) von Sample $\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{pmatrix}$

$$f_{\{\theta_n\}_{n=0}^N}(\mathbf{x}_m) = \theta_0 + \theta_1 \cdot x_1 + \theta_2 \cdot x_2 + ... + \theta_N \cdot x_N = \theta_0 + \sum_{n=1}^{N} \theta_n x_n$$

Die Notation $f_{\{\theta_n\}_{n=0}^N}$ bedeutet, dass das Modell f durch die Werte $\{\theta_n\}_{n=0}^N$ parametrisiert ist. Bei den Modellparametern handelt es sich um reelle Zahlen $\theta_n \in \mathbb{R}$.

Es wird nun angenommen, dass die Ausgabwerte y_m der Daten mithilfe des linearen Modells $f_{\{\theta_n\}_{n=0}^N}$ und der entsprechenden Eingabewerte für ein Sample m, $\mathbf{X}_{m,:}$, bis auf einen Fehlerterm, die sogenannten Residuen ϵ_m, erklärt werden können:

$$y_m = f_{\{\theta_n\}_{n=0}^N}(\mathbf{X}_{m,:}) + \epsilon_m$$

Zwei durch verschiedene $\{\theta_n\}_{n=0}^N$ parametrisierte Modelle werden in der Regel unterschiedliche Vorhersagen liefern, wenn sie auf dasselbe Sample angewendet werden.
Es werden nun die optimalen Werte $\{\hat{\theta}_n\}_{n=0}^N$ gesucht, die zu den besten Übereinstimmungen der vom Modell vorhergesagten Werte $\hat{y}_m = f_{\{\hat{\theta}_n\}_{n=0}^N}(\mathbf{X}_{m,:})$ mit den erwarteten Werten y_m über den gesamten Trainingsdatensatz führen. Dies bedeutet, dass die Residuen

$$\epsilon_m = y_m - f_{\{\theta_n\}_{n=0}^N}(\mathbf{X}_{m,:})$$

möglichst klein werden sollen.

Als Verlustfunktion, welche die Abweichungen der vorgergesagten von den erwarteten Ausgabewerten quantifiziert, wird die Quadratsumme der Residuen (engl. residual sum of squares)

$$RSS = \sum_{m=1}^{M} (e_m)^2 = \sum_{m=1}^{M} \left(y_m - f_{\{\theta_n\}_{n=0}^{N}}(\mathbf{X}_{m,:}) \right)^2,$$

verwendet.

Die optimalen Parameter $\{\hat{\theta}_n\}_{n=0}^{N}$ sind nun diejenigen, welche die Kostenfunktion

$$J(\{\theta_n\}_{n=0}^{N}; \mathbf{X}, \mathbf{y}) = \frac{1}{M} RSS$$

minimieren. Für diese Lösung existiert eine geschlossene Form, welche durch Nullsetzen der partiellen Ableitungen bezüglich der Modellparameter gefunden werden kann.

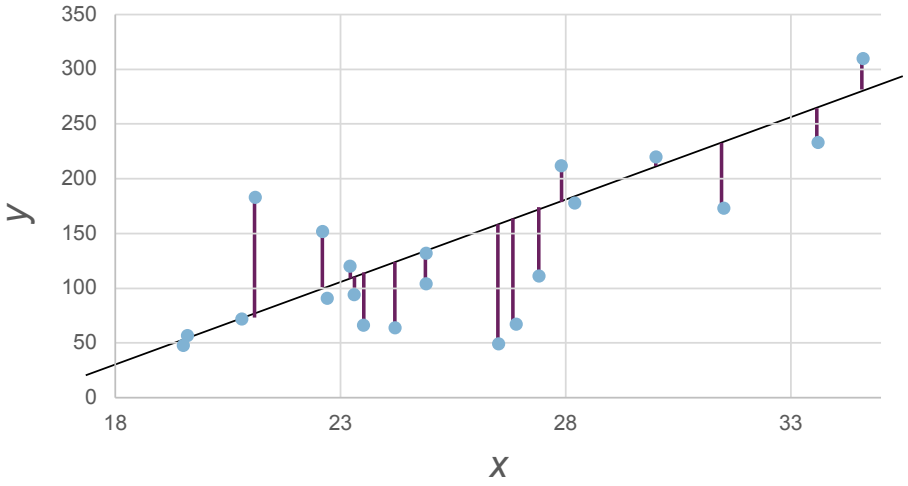


Abbildung 5.3.: Lineare Regression auf dem Diabetes-Datensatz. Trainingsdaten: Blaue Punkte. Lineare Ausgleichsgerade: Schwarze Linie. Residuen: Violette Linien.

Im Fall von nur einer unabhängigen Variable ($N = 1$) spricht man auch von einfacher linearer Regression (engl. simple linear regression). In diesem Fall hat die matrix $\mathbf{X}$ nur eine Spalte und die M Samples entsprechen

$$\mathbf{X} = \begin{pmatrix} x_{1,1} \\ x_{2,1} \\ \vdots \\ x_{M,1} \end{pmatrix}.$$

Das Modell enthält in diesem Fall ausser θ_0 nur einen weiteren Parameter θ_1 und $f_{\{\theta_n\}_{n=0}^{N}}(\mathbf{x})$ entspricht einer Geraden:

$$f_{\{\theta_n\}_{n=0}^1}(x) = \theta_0 + \theta_1 \cdot x$$

In Abbildung 5.3 ist die auf die Diabetes-Daten angepasste Ausgleichsgerade gezeigt, wobei $\hat{\theta}_0$ den Schnittpunkt mit der y-Achse und $\hat{\theta}_1$ die Steigung der Geraden definiert.

Die Formeln für die optimalen Parameterwerte in der einfachen linearen Regression sind (ohne Herleitung):

$$\hat{\theta}_1 = \frac{\sum_{m=1}^{M}(x_m - \bar{x})(y_m - \bar{y})}{\sum_{m=1}^{M}(x_m - \bar{x})^2}$$

$$\hat{\theta}_0 = \bar{y} - \hat{\theta}_1 \bar{x}$$

Die auf den Diabetes-Daten bestimmten Parameter sind:

$$\hat{\theta}_0 = -187.8, \hat{\theta}_1 = 12.4$$

Das Modell kann nun verwendet werden, um einen unbekannten Ausgabewert $\hat{y}^*$ für ein neues Sample x^* vorherzusagen:

$$\hat{y}^* = f_{\{\theta_n\}_{n=0}^1}(x^*) = \hat{\theta}_0 + \hat{\theta}_1 \cdot x^*$$

Zum Beispiel für den BMI-Wert $x^* = 29$

$$\hat{y}^* = -187.8 + 12.4 \cdot 29.0 = 171.8$$

Bei mehr als einem Feature $N > 2$ spricht man von multipler linearer Regression. Das lineare Regressionsmodell $f_{\{\theta_n\}_{n=0}^N}(\mathbf{x})$ entspricht dann nicht mehr einer Geraden, sondern generell einer Hyperebene. Es existiert für diesen Fall ebenfalls eine geschlossene Form für die Lösung der optimalen Parameter.

5.2.2.3. Nicht-Lineare Regression

Die lineare Regression kann auch erweitert werden, um nicht-lineare Funktionen zu lernen. Dazu werden die Features der Daten durch nicht-lineare Funktionen transformiert. Beispielsweise können in der polynomialen Regression quadratische, kubische etc. Terme hinzugefügt werden. Im folgenden Beispiel wurde ein Polynom zweiten Grades (quadratische Funktion) an den Diabetes-Datensatz angepasst:

$$f_{\{\theta_n\}_{n=0}^2}(x) = \theta_0 + \theta_1 \cdot x + \theta_2 \cdot x^2$$

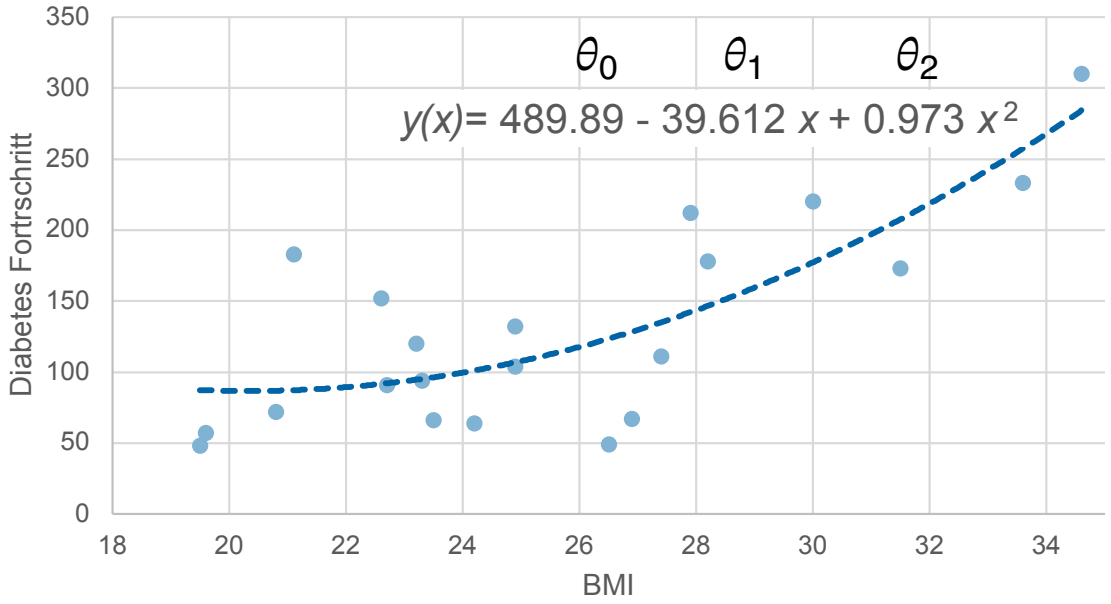


Abbildung 5.4.: Polynomiale Regression zweiten Grades am Beispiel des Diabetes-Datensatzes.

Mit steigendem Grad des Polynoms nimmt die Flexibilität des Modells zu, das heisst, es kann sich besser den Trainingsdaten anpassen. Dies kann aber auch zu einer Überanpassung führen, wenn das Modell so flexibel ist, dass es nicht nur das verallgemeinernde Muster der Daten erfasst, sondern sich an das zufällige Rauschen der Daten anpasst. In diesem Fall werden die Vorhersagen auf nicht in im Trainingsset vorhandene Daten schlechter. Abbildung 5.5 illustriert dieses Problem der Überanpassung anhand eines auf den Diabetes-Daten trainierten Polynoms 10-ten Grades.

5.2.2.4. Evaluation von Regressionsproblemen

Um den Verallgemeinerungsfehler eines Regressionsmodells quantitativ abschätzen zu können, werden Evaluationsmetriken typischerweise auf einem unabhängigen Testset (oder Validationsset) berechnet - das heisst auf Daten, welche nicht zum Training des Modells verwendet wurden (siehe Kapitel 5.2.1):

$$\mathbf{X}_{\text{test}}(\text{Dimension: } M_{\text{test}} \times N), \quad \mathbf{y}_{\text{test}}(\text{Dimension: } M_{\text{test}} \times 1)$$

Die Vorhersagen des trainierten Modells auf den Testdaten $\{\hat{y}_{\text{test}_m}\}_{m=1}^{M_{\text{test}}}$ können mit den erwarteten Werten $\{y_{\text{test}_m}\}_{m=1}^{M_{\text{test}}}$ verglichen werden. Zur Quantifizierung können bei Regressionsproblemen verschiedene Fehlermasse verwendet werden:

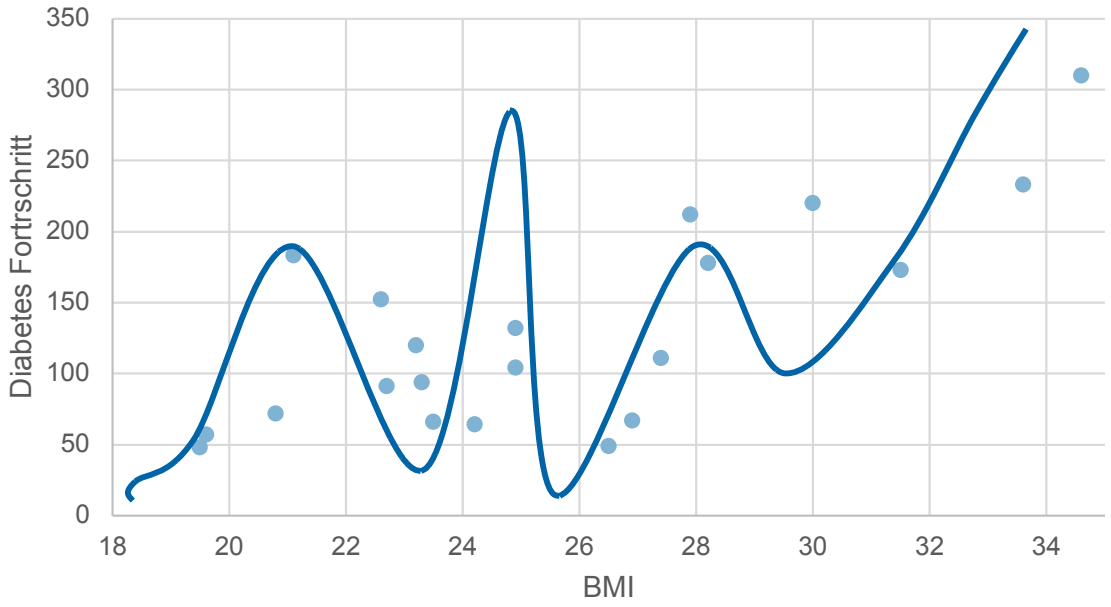


Abbildung 5.5.: Überanpassung eines polynomialen Regressionsmodells 10-ten Grades auf dem Diabetes-Datensatz.

Der Mean Squared Error:

$$MSE = \frac{1}{M_{\text{test}}} \sum_{m=1}^{M_{\text{test}}} \left(y_{\text{test}_m} - \hat{y}_{\text{test}_m} \right)^2 \tag{5.1}$$

Der Root Mean Squared Error (Wurzel der mittleren Fehlerquadrate – $RMSE$ oder auch $RMSD$) misst den Fehler in denselben Einheiten der Ausgabewerte:

$$RMSD = \sqrt{MSE} = \sqrt{\frac{1}{M_{\text{test}}} \sum_{m=1}^{M_{\text{test}}} \left(y_{\text{test}_m} - \hat{y}_{\text{test}_m} \right)^2} \tag{5.2}$$

Der mittlere absolute Fehler (Mean Absolute Error - MAE) ist die mittlere absolute Abweichung des vorgesagten vom erwarteten Ausgabewert:

$$MAE = \frac{1}{M_{\text{test}}} \sum_{m=1}^{M_{\text{test}}} \left| y_{\text{test}_m} - \hat{y}_{\text{test}_m} \right| \tag{5.3}$$

5.2.3. Klassifikation

In Klassifikationsproblemen ist die Zielvariable kategorisch, das heisst die Ausgabewerte gehören zu einem Set von diskreten Klassen:

$$y_m \in \{C_1, C_2, ..., C_K\}$$

In Abhängigkeit von der Anzahl zu unterscheidender Klassen spricht man von binärer (zwei Klassen) und multinomialer Klassifikation (mehr als zwei Klassen, engl: multiclass classification oder multinomial classification) - wobei in beiden Fällen einzelne Samples immer nur jeweils einer Klasse zugeordnet werden. In der Multilabel-Klassifikation (engl. multi-label classification oder multi-output classification) kann jedes Sample mehr als einer Klasse zugeordnet werden. Beispiele:

- Binäre Klassifikation:
  - Spamerkennung: Klassen $\{\text{Spam}, \text{Kein_Spam}\}$
- Multinomiale Klassifikation:
  - Spracherkennung: $\{\text{Französisch}, \text{Deutsch}, \text{Italienisch}, \text{Rätromanisch}\}$
- Multilabel-Klassifikation:
  - Einteilung von Filmen in Genres: $\{\text{Liebesfilm}, \text{Action}, \text{Komödie}\}$. Ein Film kann sowohl "Science Fiction" als auch "Action" zugewiesen werden.

Unterschiedliche Methoden stehen zur Verfügung, um Klassifikationsprobleme zu lösen. In Kapitel 5.2.3.1 wird als instanszbasiertes (nichtparametrisches) Verfahren die k-Nächste-Nachbarn-Heuristik vorgestellt. Zu den modellbasierten (parametrischen) Ansätzen gehören

- Naive Bayes
- Logistische Regression
- Neuronale Netze
- Entscheidungsbäume (Decision Trees)
- Support Vector Machines
- …

5.2.3.1. k-Nächste-Nachbarn-Heuristik für Klassifikation

Die k-Nächste-Nachbarn-Heuristik kann auch auf Klassifikationsprobleme angewendet werden. Wie bereits in der Anwendung auf Regressionsprobleme ausgeführt, ist sie instanzbasiert, das heisst nichtparametrisch (im Gegensatz zu modellbasierten, parametrischen Ansätzen). Im Gegensatz zu parametrischen Lernalgorithmen, die es ermöglichen, die Trainingsdaten nach der

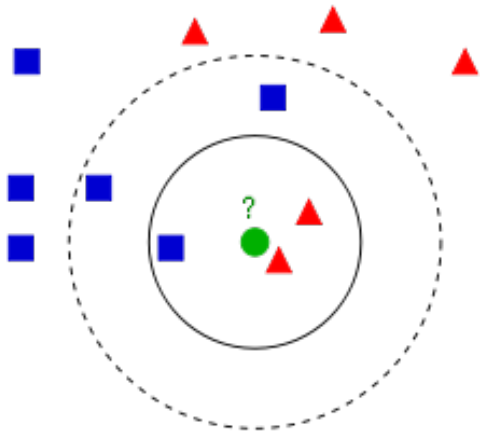


Abbildung 5.6.: Illustration der k-Nächste-Nachbarn-Heuristik zur Klassifikation eines Datensatzes bestehend aus zwei Klassen: Blaue Quadrate und rote Dreiecke. Für ein neues Sample (grüner Punkt) wird die Klassenzuweisung gesucht.

Modellbildung zu verwerfen, müssen für Vorhersagen basierend auf kNN für ein neues Sample $\mathbf{x}$ immer alle Trainings-Samples vorliegen. Dazu sucht der kNN-Algorithmus nach den k Trainingsbeispielen, die $\mathbf{x}$ am nächsten liegen und gibt im Falle von Klassifikationsproblemen die am häufigsten vorkommende Klasse als Vorhersage für $\mathbf{x}$ zurück. Als Abstandsfunktion zur Bestimmung der nächsten Nachbarn wird in der Praxis häufig die euklidische Distanz verwendet, aber auch andere Distanz-Metriken, wie die Kosinus-Distanz sind möglich. k muss als Hyperparameter festgelegt werden.
Im Beispiel in Abbildung 5.6 mit $k = 3$ wird für den grünen Punkt die rote Klasse vorhergesagt.

Vor- und Nachteile der k-Nächste-Nachbarn-Heuristik bei der Anwendung auf Klassifikationsprobleme sind dieselben wie bei Regressionsproblemen (Kapitel 5.2.2.1).

5.2.3.2. Evaluation von Klassifikationsproblemen

Die Korrektklassifikationsrate (Accuracy) gibt den Anteil aller Samples an, die korrekt klassifiziert werden:

$$\text{Accuracy} = \frac{\text{richtig klassifizierte Samples}}{\text{totale Anzahl Samples}}$$

Die Accuracy ist problematisch bei unausgewogener Verteilung der Daten (imbalanced data) und unterscheidet nicht zwischen den unterschiedlichen "Auswirkungen" (Kosten) der verschiedenen Fehlerarten: Typ I (False Positive) und Typ II (False Negative).

Die Unterschiede zwischen Typ I und Typ II-Fehler werden am Beispiel eines Spam-Klassifikators deutlich. Es handelt sich um eine binären Klassifikationsaufgabe: Der

Algorithmus unterscheidet zwischen “Spam” (positiv) und “Kein_Spam” (negativ). Typ I-Fehler entsprechen den Emails, welche vom Algorithmus als Spam klassifiziert wurden, tatsächlich aber kein Spam sind. Typ II-Fehler entsprechen den tatsächlichen Spam-Emails, welche vom Algorithmus aber nicht als solche erkannt wurden. Welcher Fehlertyp schwerer wiegt, hängt vom konkreten Anwendungsfall ab. Bei der Spam-Erkennung wiegen die Typ I-Fehler in der Regel schwerer, da als Spam erkannte Emails automatisch im Spam-Ordner landen und diese von der nutzenden Person nicht angeschaut werden. Fälschlicherweise als Spam erkannte Emails werden also verpasst, was unangenehmer ist, als wenn ab und zu ein Spam-Email im Posteingang landed (Typ II-Fehler - False Negative).

Die Konfusionsmatrix ist eine Tabelle, die zusammenfasst, wie erfolgreich das Klassifikationsmodell bei der Vorhersage der Klassenzugehörigkeit von Samples ist. Die beiden Achsen geben die vom Modell vorhergesagten (Spalten) bzw. die erwarteten (Zeilen) Kennzeichnungen an. Bei einer binären Klassifikationsaufgabe sind es jeweils zwei.
Tabelle 5.1 gibt die Ergebnisse für das Beispiel eines Spam-Klassifikators wieder. Insgesamt wurden 592 Emails (Samples) klassifiziert. Von den 24 Samples, die tatsächlich Spam waren, wurden 23 vom Modell richtig als Spam erkannt. Wir sagen in diesem Fall, dass es 23 Samples gibt, die als richtig positiv (True Positive - TP) klassifiziert wurden, also TP = 23. Das Modell hat 1 Beispiel irrtümlich als Kein_Spam klassifiziert. Es gibt also 1, das als falsch negativ (False Negative - FN) klassifiziert wurde, das heisst FN = 1. Des Weiteren wurden von den 568 Samples, die tatsächlich Kein_Spam waren, 556 richtig klassifiziert (True Negative - TN = 556) und 12 wurden falsch klassifiziert (False Positive - FP = 12).

Tabelle 5.1.: Konfusionsmatrix für einen Spam-Klassifikator.

Vorhergesagt → Erwartet ↓	Spam	Kein_Spam
Spam	23 (TP)	1 (FN)
Kein_Spam	12 (FP)	556 (TN)

Aus der Konfusionsmatrix lassen sich nun die gängigsten Evaluationsmetriken für Klassifikationsprobleme berechnen.

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}} \tag{5.4}$$

Die Precision ist definiert als der Anteil der korrekt als positiv klassifizierten Samples (TP) an der Gesamtheit aller als positiv vorhergesagten Samples (erste Spalte der Konfusionmatrix).

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \tag{5.5}$$

Die Precision "bestraft" die FP-Samples. Das heisst für Klassifikationsprobleme, für welche Typ I-Fehler wichtiger sind, ist die Precision die wichtigere Evaluationsmetrik. Die Typ II-Fehler (FN) haben auf die Precision keinen Einfluss.

Der Recall ist der Anteil der korrekt als positiv klassifizierten Samples (TP) an allen positiv erwarteten Samples (erste Zeile der Konfusionmatrix)

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \tag{5.6}$$

Der Recall "bestraft" die FN-Samples. Das heisst für Klassifikationsprobleme, für welche Typ II-Fehler wichtiger sind, ist der Recall die wichtigere Evaluationsmetrik. Die Typ I-Fehler (FP) haben auf den Recall keinen Einfluss.

Um die Bedeutung von Precision und Recall für die Evaluation des Modells zu verstehen, kann es auch nützlich sein, sich die Vorhersageaufgabe als die Abfrage einer Datenbank vorzustellen, in der Dokumente gespeichert sind (Information Retrieval). Dabei geht es um die Beurteilung, ob ein gefundenes Dokument (auch ausgewählt, engl. selected) entsprechend einem definierten Kriterium relevant ist - siehe Abbildung 5.7. Die Precision gibt den Anteil der relevanten Dokumente in der Liste aller gefundenen Dokumente an. Der Recall ist das Verhältnis der relevanten gefundenen Dokumente zur Gesamtzahl aller relevanten Dokumente, die hätten gefunden werden können.

Bei der Spamerkennung ist eine hohe Precision erwünscht (wir wollen vermeiden, dass legitime E-Mails als Spam klassifiziert werden), und nehmen dafür einen niedrigeren Recall in Kauf (wir nehmen einige Spam-E-Mails in unserem Posteingang hin).

In der Praxis müssen wir uns fast immer entweder für eine hohe Precision oder aber für eine große Recall entscheiden. Für gewöhnlich ist es nicht möglich, beides zu erreichen.

Der F_1-Score ist das harmonische Mittel aus Precision und Recall:

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Precision und Recall sind zwar für binäre Klassifikationen definiert, können jedoch auch zur Beurteilung von multionomialen Klassifikationsmodellen verwendet werden. Dazu werden die Metriken jeweils für jede Klasse k separat ermittelt:

$$\text{Precision}_k = \frac{\text{TP}_k}{\text{TP}_k + \text{FP}_k}$$
$$\text{Recall}_k = \frac{\text{TP}_k}{\text{TP}_k + \text{FN}_k}$$

wobei alle Samples der entsprechenden Klasse k der positiven und alle Beispiele der der verbleibenden Klassen der negativen Klasse zugewiesen werden. Die Randhäufigkeit (Support) ist

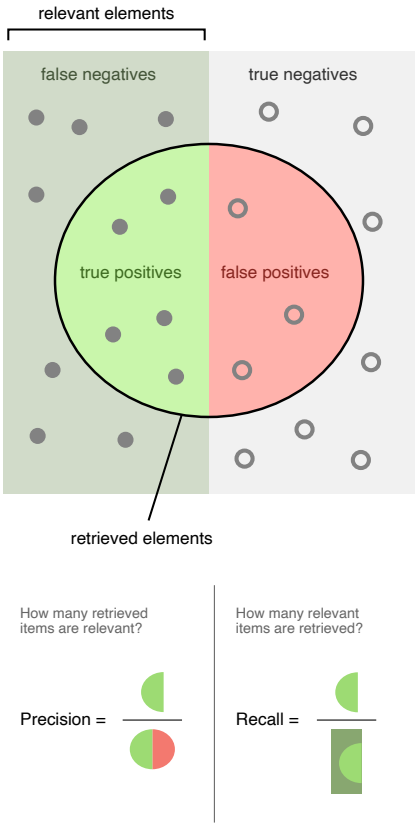


Abbildung 5.7.: Illustration von Precision und Recall anhand der Aufgabe einer Datenbankabfrage [27].

die Gesamtzahl der für diese Klasse erwarteten Samples (Summe alle Einträge in Zeile k der Konfusionsmatrix).

Um die Klassen-spezifischen Metriken zusammenzufassen, kann der ungewichtete Durchschnitt (Macro Average) über die verschiedenen Klassen für jede Metrik berechnet werden. Gerade bei unausgewogener Verteilung der Daten auf die verschiedenen Klassen wird oft auch der Support-gewichtete Durchschnitt berechnet.

Die Accuracy über alle Klassen berechnet sich:

$$\text{Accuracy} = \frac{\sum_{k=1}^{K} \text{TP}_k}{\sum_{k=1}^{K} \text{Support}_k}$$

Im Beispiel Tabelle 5.2 werden bei insgesamt 100 Samples drei Krankheiten ($K = 3$) unterschieden: {Gesund, Erkältung, Grippe}.

Tabelle 5.2.: Konfusionmatrix für ein Klassifikationsmodell mit drei Klassen.

Vorhergesagt → Erwartet ↓	Gesund	Erkältung	Grippe	Support
Gesund	60	8	2	70
Erkältung	4	12	4	20
Grippe	0	2	8	10

Die nachstehende Tabelle enthält für die für die drei Klassen berechneten Evaluationsmetriken.

Tabelle 5.3.: Für das Beispiel in Tabelle 5.2 berechnete Evaluationsmetriken.

Klasse	Precision	Recall	F_1
Gesund	0.94	0.86	0.9
Erkältung	0.54	0.6	0.57
Grippe	0.57	0.8	0.67
Durchschnitt Macro:	0.68	0.75	0.71
Gewichteter Durchschnitt:	0.82	0.80	0.81

5.3. Unüberwachtes Lernen

Bei unüberwachten Lernproblemen enthalten die zur Verfügung stehenden Daten keine Ausgabewerte, beziehungsweise werden diese nicht genutzt. Das Ziel besteht darin, die zugrunde

liegende Verteilung der Daten zu modellieren (die Struktur der Daten zu beschreiben), um sie zu erklären und das Modell dann auf neue Daten anwenden zu können. Dies bringt zusätzliche Herausforderungen im Vergleich zum überwachten Lernen mit sich, denn die Problemstellung ist unschärfer definiert und ohne Testdaten mit erwarteten Ausgabewerten ist die Evaluation generell schwieriger.

5.3.1. Dimensionsreduktion

Ziel der Dimensionsreduktion ist es, die Daten in eine optimale, niedriger dimensionale Repräsentation zu transformieren. Ein Anwendungsfall ist die Visualisierung: Hochdimensionale Datensätze, bestehend aus vielen Features (Spalten in der Datenmatrix $\mathbf{X}$), lassen sich nur schwer visualisieren. Man kann nun Features immer paarweise auswählen, um so 2- oder 3-dimensionalen Visualisierungen zu erzeugen. Dies wird jedoch bereits ab einer relativ geringen Anzahl Features unübersichtlich und die gesuchten Muster bleiben visuell nur schwer zu erfassen. In der Dimensionsreduktion werden nun neue Features, d.h. Dimensionen, bestimmt, welche möglichst viel der relevanten Information im Datensatz kondensieren und somit die sich in den Daten verbergenden Muster bereits mit weniger Dimensionen erkennen lassen.
Methoden der Dimensionsreduktion sind

- Hauptkomponentenanalyse (Principal Component Analysis - PCA)
- t-disributed Stochastic Neighbour Embedding (t-SNE)
- …

Erstere ist eine lineare Methode, zweitere vermag auch nicht-lineare Zusammenhänge zu erfassen. Für ein genaues Verständnis dieser Methoden sei auf weiterführende Literatur im maschinellen Lernen verwiesen. An dieser Stelle soll es nur um ein allgemeines Verständnis für die Dimensionsreduktion im Allgemeinen gehen.

Im Folgenden wird die Dimensionsreduktion anhand des Iris-Datensatzes illustriert. Dieser besteht aus 150 Messungen ($M = 150$) von Länge und Breite des Kronblatts (petal) und Länge und Breites des Kelchblatts (sepal) von Iris-Blüten. Es handelt sich also um vier verschiedene numerische Features: $N = 4$. Die Blüten werden drei verschiedenen Spezies zugeordnet: setosa, versicolor und virginica.

sepal_length	sepal_width	petal_length	petal_width	class
5	3.3	1.4	0.2	Iris-setosa
…				
5.7	2.8	4.1	1.3	Iris-versicolor
…				
6.3	3.3	6	2.5	Iris-virginica
…				

Um nun Beziehungen zwischen den vier Variablen visuell zu erfassen, können Streudiagramme zwischen Variablen paarweise aufziegen. Abbildung 5.8 zeigt die 4×4 Kombinationen der 4 Features im Iris-Datensatz in Streudiagrammen auf einem Gitter angeordnet auf - auch Paardiagramme (pairplots) genannt. Auf der Diagonalen sind jeweils die Plots Kerndichteschätzung (kernel density estimation) entlang der entsprechenden Variable gezeigt. Die Samples sind entsprechend der Spezies eingefärbt.
Es ist abzusehen, dass solche Paardiagramme mit wachsender Anzahl an Features im Datensatz schnell unübersichtlich werden. Zudem vermögen die Streudiagramme in den ursprünglichen Features nur paarweise Zusammenhänge zu erfassen. Komplexere Zusammenhänge werden nicht erfasst.

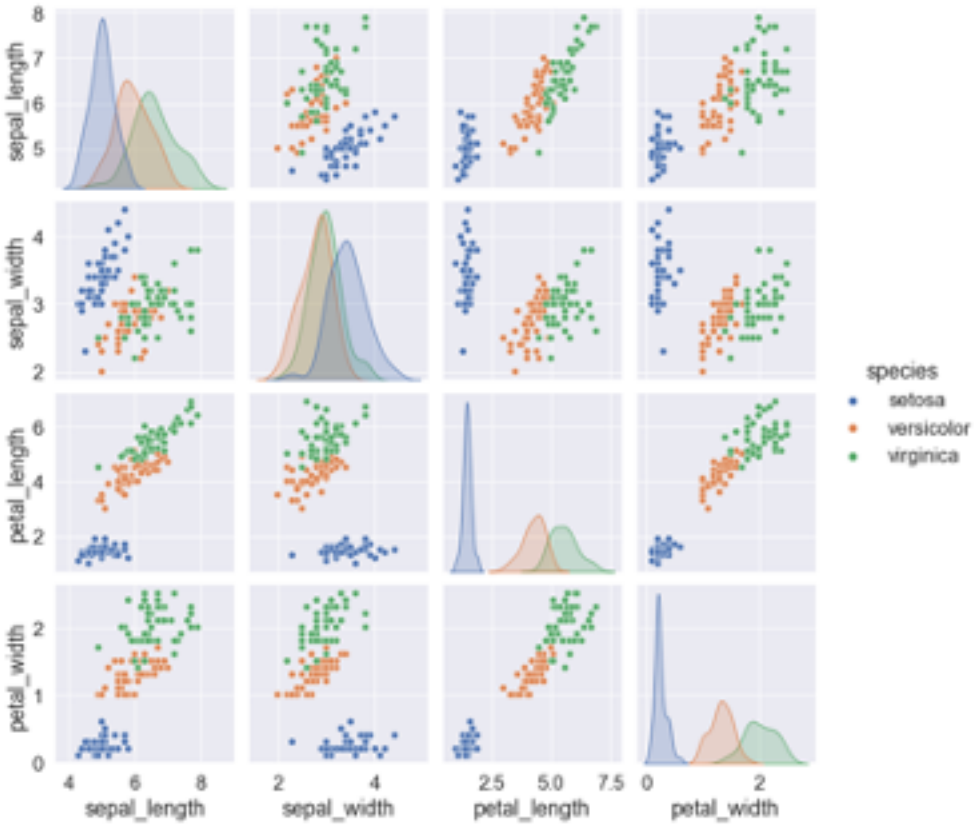


Abbildung 5.8.: Paardiagramm für die 4 Variablen des Iris-Datensatzes.

Mithilfe der Dimensionsreduktion werden nun neue Features ($\triangleq$ Dimensionen) berechnet, welche idealerweise die hauptsächliche Information der Daten zu erfassen vermögen, berechnet. Die Daten können dann auf diese zwei neuen Dimensionsn projeziert werden. Wählt man die zwei aussagekräftigsten Dimensionen aus, so ergibt sich ein neues Streudiagramm, welche die Zusammenhänge im Datensatz deutlicher zeigt als in der ursprünglichen Repräsentantion.
Abbildung 5.9 zeigt den Iris-Datensatz nach einer Dimensionsreduktion projeziert auf die zwei

aussagekräftigsten der neuen Dimensionen. Der Vorteil ist, dass nun eine Darstellung genügt, um die hauptsächliche Struktur, bzw. das Muster in den Daten visuell zu erfassen.

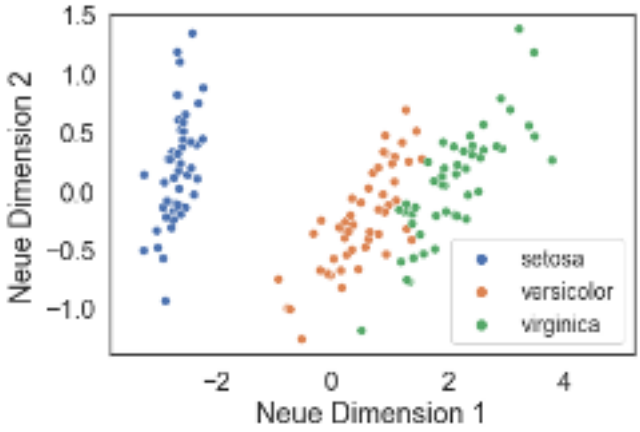


Abbildung 5.9.: Der Iris-Datensatz projeziert auf die zwei aussagekräftigsten Dimensionen, welche mithilfe einer Dimensionsreduktion bestimmt wurden. Wobei Neue Dimension 1 und 2 den ersten beiden Hauptkomponenten aus der Hauptkomponentenanalyse entsprechen.

Die Dimensionsreduktion dient dazu, eine kompaktere Repräsentation der Daten zu berechnen, indem der wesentliche Informationsgehalt in weniger Features repräsentiert werden kann. Diese Repräsentation kann neben der Visualisierung auch dazu genutzt werden, in darauffolgenden Modellierungsschritten wie Clustering, Ausreissererkennung oder auch Methoden des überwachten Lernens zu einer erhöhten Genauigkeit führen kann.

5.3.2. Clusteranalyse

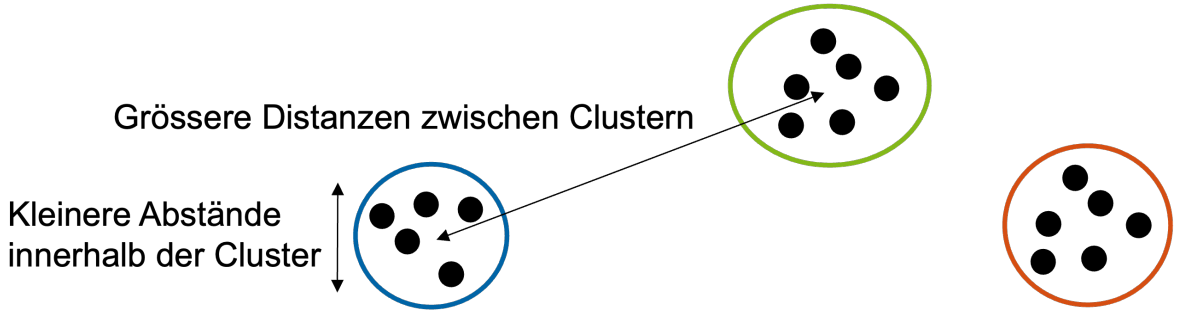


Abbildung 5.10.: Illustration einer Clusteranalyse, in welcher die Samples (schwarze Punkte) in 3 Cluster (blauer, grüner und roter Kreis) eingeteilt werden.

Die Aufgabe in der Clusteranalyse (Clustering) darin, eine Menge von Objekten so zu gruppieren, dass die Objekte in derselben Gruppe (genannt Cluster) einander ähnlicher sind als die Objekte unterschiedlicher Gruppen (vgl. Abbildung 5.10).
Aus dieser Formulierung ergibt sich bereits die Notwendigkeit einer Definition für Ähnlichkeit. Dazu werden werden die in Kapitel **??** beschriebenen Metriken verwendet. Insbesondere die euklidische Distanz und Kosinus-Distanz werden häufig verwendet.

Beispiele für Aufgabenstellungen von Clusteranalysen:

- Marktsegmentierung: Identifizierung von Kundengruppen aus den Nutzungsdaten eines Web-Shops.
- Erkennen von Untergruppen an Krankheitsbildern, um medizinische Behandlungen anpassen zu können

Gängige Methoden für die Clusteranalyse sind:

- k-Means
- Density Based Spatial Clustering for Applications with Noise (DBSCAN)
- Hierarchische Clusteranalyse
- …

5.3.2.1. k-Means-Algorithmus

Ziel von k-Means ist es, den Datensatz so in k Partitionen zu teilen, dass die Summe der quadrierten Abstände der Datenpunkte von den ihnen zugewiesenen Cluster-Mittelpunkten (Means, auch Centroids genannt) minimal ist. Typischerweise wird als Abstandsmass die euklidische Distanz oder die Kosinus-Distanz verwendet. Implizit wird damit eine sphärische Form der Cluster angenommen, was eine drastische Näherung darstellt.
Eine weitere Einschränkung des Verfahrens ist, dass die Anzahl der zu bestimmenden Cluster festgelegt werden muss. In der Praxis müssen in der Regel separate Berechnungen mit verschiedene Werten für k durchgeführt und deren Ergebnisse miteinander verglichen werden, um so eine optimale Clusteranzahl k festlegen zu können.

Der am häufigsten verwendete k-Means-Algorithmus besteht aus drei Schritten:

1. Initialisierung der k Means: Es werden zufällig k Samples aus dem Datensatz ausgewählt.
2. Zuordnung: Jedes Samples des Datensatzes wird dem jeweils nächstgelegenen Mean zugeordnet.

3. Aktualisierung: Die Means als Schwerpunkt der ihnen aktuell zugeordneten Punkte werden neu berechnet.

Die Schritte 2–3 werden dabei so lange wiederholt (Iterationen), bis ein Stopp-Kriterium erfüllt ist. Gängige Stopp-Kriterien sind:

- Vorgegebene maximale Anzahl an Iterationen erreicht
- Koordinaten der Means ändern sich von einer Iteration zur nächsten weniger als ein vorgegebener Grenzwert
- Anzahl der Samples, welche von einer Iteration zur nächsten anderen Means zugeordnet werden, unterschreitet einen vorgegebenen Grenzwert

Das Ergebnis des k-Means-Algorithmus besteht also aus den Positionen der unter den Annahmen des Modells optimalen k Cluster-Mittelpunkte.
Abbildung 5.11 zeigt die auf dem Iris-Datensatz (nach Dimensionsreduktion auf 2D) mithilfe des k-Means-Algorithmus identifizierten Cluster-Schwerpunkte mit $k = 2$.

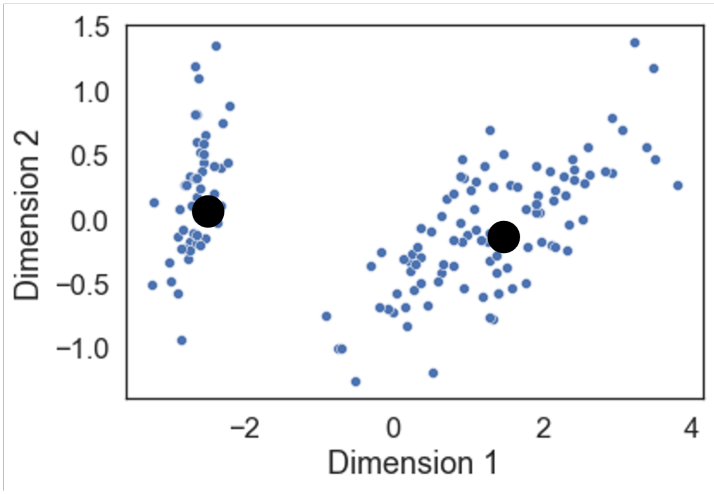


Abbildung 5.11.: Ergebnis der Clusteranalyse mithilfe des k-Means-Algorithmus mit $k = 2$ auf dem Iris-Datensatz nach Dimensionsreduktion auf 2D (blaue Punkte). Die identifizierten Cluster-Schwerpunkte sind schwarz eingezeichnet.

5.3.3. Empfehlungsdienste

Ein Empfehlungsdienst (englisch Recommender System) ist ein Softwaresystem, welches das Ziel hat, eine Vorhersage zu treffen, die quantifiziert, wie stark das Interesse eines Users (nutzende Person des Empfehlungsdienstes, z.B. der/die Kund:in eines Online-Shops) an einem Item ist, um dem User genau die Items aus der Menge aller vorhandenen Objekte zu empfehlen, für die er/sie sich wahrscheinlich am meisten interessiert. Typische Items sind zum Beispiel Produkte eines Webshops, Musikstücke bzw. Künstler oder Filme. Ein Empfehlungsdienst soll dadurch zur Bewältigung der Informationsüberflutung beitragen, indem er dem/der Nutzer:in aus einer unübersichtlichen Menge an Items eine Teilmenge empfiehlt.

Ein guter Empfehlungsdienst macht personalisierte und relevante Vorschläge - deckt das gesamte Interessens-Spektrum des Users ab - ermöglicht Serendipity - und berücksichtigt den Kontext des Users

Idealerweise schlägt er nicht bereits Bekanntes vor, sondern macht im Gegenteil auch in gewissem Grade überraschende Vorschläge, auf die die nutzende Person nicht selbst gekommen wäre, aber die dennoch relevant und interessant für sie sind - Überraschungen im positiven Sinne. Dies wird mit **Serendipity-Effekt** bezeichnet.

Die Berücksichtigung des Kontextes des Users stellt eine grosse Herausforderung dar, da er sich aus verschiedenen Faktoren zusammensetzt, deren relative Gewichtung sich dynamisch der entsprechenden Situation, in der er sich befindet, anpassen muss. Beispiele für Kontext-Aspekte sind

- Zeit: Tageszeit, Arbeitstag/Wochenende, Jahreszeit
- Ort: Zu Hause, am Arbeitsplatz, drinnen/draussen
- Soziales Umfeld: Familie, Freunde, Party

Herkömmlicherweise wird zwischen drei Herangehensweisen zur Berechnung von Empfehlungen unterschieden:

- Popularitätsbasiertes Filtern
- Inhaltsbasiertes Filtern
- Kollaboratives Filtern

Jede dieser Herangehensweisen hat ihre Vor- und Nachteile. Häufig funktionieren Kombinationen aus kollaborativen und inhaltsbasierten Filtern am besten. In diesem Fall spricht man von hybriden Empfehlungsdiensten.

> **Hinweis**
>
> Empfehlungsdienste werden typischerweise dem unüberwachten Lernen zugeordnet, auch wenn das Lernproblem auf den Bewertungen der nutzenden Personen basiert.

5.3.3.1. Popularitätsbasiertes Filtern

Im popularitätsbasierten Filtern werden Items rein basierend auf der Häufigkeit, mit der sie im Datensatz auftreten, empfohlen. Bewertungen oder andere Daten der User werden nicht verwendet.
Beispielsweise können bei einem Online-Magazin die am häufigsten gelesenen Artikel empfohlen werden.
Vorteile sind:

- Geringe Komplexität
- Leicht erklärbar
- Keine User-Daten benötigt
- Keine Repräsentation der Items notwendig

Nachteile:

- Keine Personalisierung möglich
- Eigenschaften der Items werden nicht berücksichtigt

5.3.3.2. Inhaltsbasiertes Filtern

Beim inhaltbasierten Filtern (engl. content based filtering) basieren die Empfehlungen auf Informationen zu den Items selbst. Dabei werden möglichst ähnliche zu den bereits bekannten Items empfohlen.

Beispielsweise werden bei der Nutzung eines Streaming-Dienstes Filme empfohlen, welche den vom User bereits gesehenen möglichst ähnlich sind.

Für die Modellierung müssen die Items in eine numerisch prozessierbare, vektorielle Repräsentation überführt werden. Diese kann beispielsweise auf den Metadaten der Filme, wie Genre, Schauspieler, Regisseur usw. oder auf ihrem Inhalt selbst basieren. Für letzteres gehen die Videos entweder direkt numerisch kodiert in den Algorithmus ein oder es werden bestimmte Merkmale aus den Bild- und Audiodaten extrahiert. Beides ist verhältnismässig aufwändig.

Vorteile sind:

- Keine User-Daten benötigt
- Kein Cold Start-Problem

Nachteile:

- Eine vektorielle Repräsentation der Items wird benötigt.
- Aktuelles Interesse wird aus dem vergangenen Verhalten der anderen Nutzer abgeleitet
- Serendipity wird nicht ermöglicht
- Kontext wird nicht berücksichtigt

5.3.3.3. Kollaboratives Filtern

Kollaboratives Filtern basiert im Gegensatz zum inhaltsbasierten Filtern auf den von den Usern abgegebenen Bewertungen der Items. Wenn beispielsweise zwei User die gleichen zehn Filme sehr gut bewertet haben, dann ist es wahrscheinlicher, dass auf dem Geschmack von User 1 beruhende neue Filmempfehlungen User 2 zusagen (und umgekehrt). Dabei werden die Inhalte der Items nicht explizit berücksichtigt. Beim kollaborativen Filtern liegen die Informationen über die Vorlieben von Usern in Form einer Matrix vor. Jede Zeile dieser Rating-Matrix entspricht einem User, und jede Spalte repräsentiert ein Item. In Abbildung 5.12 sind die Ratings (Bewertungen) als nach oben oder unten zeigende Daumen dargestellt, was z.B. einer numerischen Kodierung $\{-1, 1\}$ entsprechen würde. Auch Bewertungen zwischen 1 und 5 sind

gängig. Diese Rating-Matrix ist für gewöhnlich sehr gross und extrem dünn besetzt, was bedeutet, dass die meisten Zellen leer sind (oder eine Null enthalten). Der Grund dafür ist, dass die meisten User nur einen winzigen Bruchteil der verfügbaren Items konsumieren, beziehungsweise bewerten.

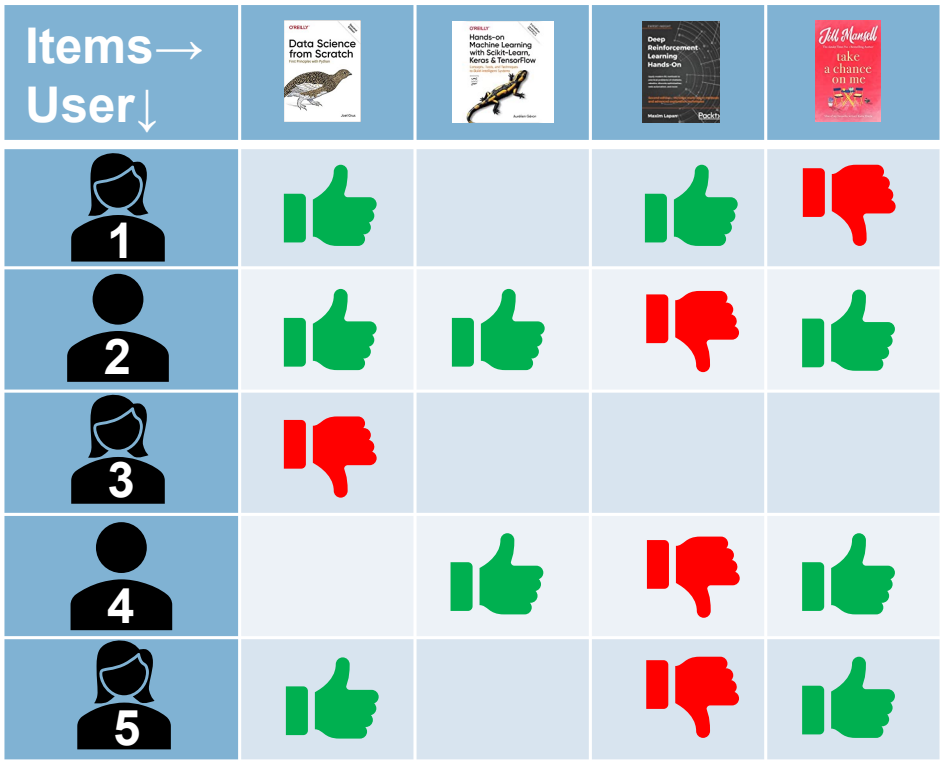


Abbildung 5.12.: Illustration einer Rating-Matrix mit binären Bewertungen: positiv(Daumen hoch)/negativ (Daumen runter).

Tabelle 5.5.: User Symbols with Numbers

User	Symbol
User 1	1
User 2	2
User 3	3
User 4	4
User 5	5

Im kollaborativen Filtern werden nun Empfehlungen basierend auf der Rating-Matrix berechnet. Im Prinzip kann das Lernproblem als ein “Auffüllen” der dünnbesetzten Rating-Matrix verstanden werden: Fehlende Ratings werden mithilfe der vorhandenen Ratings berechnet.

Vorteile sind:

- Keine verktorielle Repräsentation der Items notwendig
- Serendipity möglich

Nachteile:

- Informationen über die Präferenzen der Nutzer werden benötigt
- Cold-Start-Problem
- Methodische Herausforderung durch dünnbesetzte Rating-Matrix
- Aktuelles Interesse wird aus dem vergangenen Verhalten der Nutzer:innen abgeleitet
- Kontext wird nicht berücksichtigt

Alle Methoden für das kollaborative Filtern basieren auf der Rating-Matrix:

- Nächste-Nachbarn-Heuristik
  - User-basiert (Ratings werden als Mittelwert gewichtet nach Ähnlichkeit der User berechnet)
  - Item-basiert (Ratings werden als Mittelwert gewichtet nach Ähnlichkeit der Items berechnet)
- Methoden basierend auf Matrix Faktorisierungen (lineare Methoden): Singular Value Decomposition - SVD
- Basierend auf Neuronalen Netzen (nicht-lineare Methode): Ermöglicht auch eine Kombination von User- und Item-basierter Vorgehensweise

5.3.3.4. Nächste-Nachbarn-Heuristik für Kollaboratives Filtern

Das Prinzip des kollaborativen Filterns mithilfe der Nächste-Nachbarn-Heuristik lässt sich für den einfachsten Fall von nur einem berücksichtigen Nachbarn anhand der Rating-Matrix in Abbildung 5.12 illustrieren. Gesucht ist die Bewertung von Item 2 für Nutzerin 5. Es wird nun der/diejenige Nutzer:in identifiziert, welche:r das der Nutzerin 5 ähnlichste Bewertungsverhalten aufweist und Item 2 bewertet hat. Die Bewertung für Item 2 wird dann von diesem/dieser Nutzer:in übernommen. Im vorliegenden Beispiel weist User 2 die ähnlichsten Bewertungen von Items 1, 3 und 4 im Vergleich mit User 5 auf. Nun wird die Bewertung von Item 2 für User 5 übernommen. Item 2 wird also für User 5 empfohlen.
Im User-basierten kollaborativen Filtern wird also die gesuchte Bewertung über einen Vergleich der Ähnlichkeit der User, das heisst der Zeilen der Rating-Matrix, berechnet.
Im Item-basierten kollaborativen Filtern wird die gesuchte Bewertung über einen Vergleich der Ähnlichkeit der Items, das heisst der Spalten der Rating-Matrix, berechnet. Item 4 hat die ähnlichsten Bewertungen erhalten wie Item 2 (über alle User). Dementsprechend wird die Bewertung von User 5 von Item 4 für Item 2 übernommen. Das heisst, auch dieser Empfehlungsdienst würde Item 2 für User 5 empfehlen.

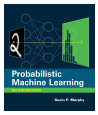
Items→ User↓						
1	1	3	1		5	4
2	5	4	4		1	
3	2		5	4	5	
4		3				5
5		2		5	4	
6			4	4		5

Abbildung 5.13.: Rating-Matrix mit einer Bewertungsskala von 1 bis 5.

Um die fehlenden Ratings basierend auf den vorhandenen Ratings zu berechnen, müssen sie numerisch kodiert vorliegen, beispielsweise auf einer Skala von 1 bis 5 (Abbildung 5.13). Zudem können mehr als ein nächster Nachbar berücksichtigt werden, indem das gesuchte Rating als ähnlichkeitsgewichteter Durchschnitt der Ratings der nächsten Nachbarn berechnet wird.

Im **User-basierten** Ansatz wird ein gesuchtes Rating $\hat{x}^{\mathrm{u}}_{m,n}$ als gewichteter Durchschnitt der Ratings der anderen User für das gesuchte Item n berechnet. Dies entspricht einer normalisierten Linearkombination aus Ähnlichkeitsgewichten $\mathbf{S}^{\mathrm{u}}_{m} = (s^{\mathrm{u}}_{m,1}, s^{\mathrm{u}}_{m,2}, ..., s^{\mathrm{u}}_{m,M})$ und dem Spaltenvektor der Ratings $\mathbf{X}_{:,n} = (x_{1,n}, x_{2,n}, ..., x_{M,n})^T$. Die allgemeine Formel lautet:

$$\hat{x}^{\mathrm{u}}_{m,n} = \frac{1}{|\mathbf{S}^{\mathrm{u}}_{m}|}\mathbf{S}^{\mathrm{u}}_{m} \cdot \mathbf{X}_{:,n} = \frac{1}{\sum_{m'=1}^{N} s^{\mathrm{u}}_{m',m}} \sum_{m'=1}^{M} s^{\mathrm{u}}_{m',m} \cdot x_{m',n} \tag{5.7}$$

wobei nur Terme mit besetzten Ratings $x_{m',n}$ berücksichtigt werden. Die Ähnlichkeitsgewichte $s^{\mathrm{u}}_{m',m}$ entsprechen den Ähnlichkeiten zwischen User m' und m entspricht. Für deren Berechnung stehen die gängigen Ähnlichkeitsmasse (Kapitel **??**) zur Verfügung.

Die Anzahl der berücksichtigten Nachbarn kann über einen Threshold begrenzt werden: Entweder wird eine fixe Anzahl an Nachbarn definiert, oder ein Threshold bezüglich der Ähnlichkeit gesetzt, sodass nur Nachbarn mit einer Ähnlichkeit über diesem Threshold berücksichtigt werden.

Häufig wird im kollaborativen Filtern die Kosinus-Ähnlichkeit verwendet. Damit wird die Ähnlichkeit zwischen User m und m' als normalisiertes Skalarprodukt der beiden Zeilenvektoren der Ratingmatrix, $\mathbf{X}_{m,:}$, $\mathbf{X}_{m',:}$ berechnet:

$$\begin{aligned} s^{\mathrm{u}}_{m,m'} = \cos(\theta_{m,m'}) &= \frac{\mathbf{X}_{m,:} \cdot \mathbf{X}_{m',:}}{|\mathbf{X}_{m,:}| \cdot |\mathbf{X}_{m',:}|} \\ &= \frac{\sum_{n=1}^{N} x_{m,n} \cdot x_{m',n}}{\sqrt{\sum_{n=1}^{N} x^2_{m,n}} \cdot \sqrt{\sum_{n=1}^{N} x^2_{m',n}}} \end{aligned} \tag{5.8}$$

Die dünnbesetzte Matrix stellt für diese paarweisen Ähnlichkeitsberechnungen eine zusätzliche Komplikation dar. Diese wird dadurch umgangen, dass **nur gemeinsam besetzte Ratings berücksichtigt** werden. Der Übersichtlichkeit halber wird dies zwar im mathematischen Ausdruck nicht berücksichtig, soll aber anhand eines konkreten Beispiels von User 2 und 3 aus Abbildung 5.13 verdeutlicht werden: Nur Items 1, 3 und 5 wurden von beiden Usern bewertet und damit wird Gleichung **??** zu

$$s^{\text{u}}_{2,3} = \cos(\theta_{m=2,m'=3}) = \frac{\mathbf{X}_{2,:} \cdot \mathbf{X}_{3,:}}{|\mathbf{X}_{2,:}| \cdot |\mathbf{X}_{3,:}|}$$
$$= \frac{5 \cdot 2 + 4 \cdot 5 + 1 \cdot 5}{\sqrt{5^2 + 4^2 + 1^2} \cdot \sqrt{2^2 + 5^2 + 5^2}} = 0.73$$

Diese paarweisen User-Ähnlichkeitsgewichte $\{s^{\text{u}}_{m,m'}\}_{m=1,\ldots,M;m'=1,\ldots,M}$ ergeben somit eine User-Ähnlichkeitsmatrix $\mathbf{S}^{\text{u}} : M \times M$:

$\mathbf{S}^{\text{u}}$:

User→ User↓	1	2	3	4	5	6
1	1.00	0.57	0.84	0.99	1.00	0.91
2	0.57	1.00	0.73	1.00	0.65	1.00
3	0.84	0.73	1.00	0.00	0.98	0.99
4	0.99	1.00	0.00	1.00	1.00	1.00
5	1.00	0.65	0.98	1.00	1.00	1.00
6	0.91	1.00	0.99	1.00	1.00	1.00

Abbildung 5.14.: User-Ähnlichkeitsmatrix basierend auf der Kosinusähnlichkeit der User aus Abbildung 5.13

Daraus folgt beispielhaft für das gesuchte Rating von User 2 für Item 4 $\hat{x}^{\text{u}}_{2,4}$:

$$\hat{x}^{\text{u}}_{2,4} = \frac{1}{s^{\text{u}}_{2,3} + s^{\text{u}}_{2,5} + s^{\text{u}}_{2,6}} \left(s^{\text{u}}_{2,3} \cdot x_{3,4} + s^{\text{u}}_{2,5} \cdot x_{5,4} + s^{\text{u}}_{2,6} \cdot x_{6,4}\right)$$
$$= \frac{1}{0.73 + 0.65 + 1.0} (0.73 \cdot 4 + 0.65 \cdot 5 + 1.0 \cdot 4) = 4.27$$

Im **Item-basierten** Ansatz ist das Vorgehen analog zum User-basierten Ansatz, ausser dass Zeilen mit Spalten vertauscht werden: Ein gesuchtes Rating $x_{m,n}$ wird als gewichteter Durchschnitt der Ratings desselben Users m für alle von ihm/ihr bewerteten items berechnet. Die allgemeine Formel lautet:

$$\hat{x}^{\text{i}}_{m,n} = \frac{1}{|\mathbf{S}^{\text{i}}_n|} \mathbf{S}^{\text{i}}_n \cdot \mathbf{X}_{m,:} = \frac{1}{\sum_{n'=1}^{N} s^{\text{i}}_{n',n}} \sum_{n'=1}^{N} s^{\text{i}}_{n',n} \cdot x_{m,n'} \tag{5.9}$$

Wobei auch hier nur besetzte Rating $x_{m,n'}$ berücksichtigt werden. Die Ähnlichkeitsgewichte sind nun Elemente der item-Ähnlichkeitsmatrix $\mathbf{S}^{\mathrm{i}} : N \times N$. Unter Verwendung der Kosinusähnlichkeit ergibt sich daraus:

$$\begin{aligned} s^{\mathrm{i}}_{n,n'} = \cos(\theta_{n,n'}) &= \frac{\mathbf{X}_{:,n} \cdot \mathbf{X}_{:,n'}}{|\mathbf{X}_{:,n}| \cdot |\mathbf{X}_{:,n'}|} \\ &= \frac{\sum_{m=1}^{M} x_{m,n} \cdot x_{m,n'}}{\sqrt{\sum_{m=1}^{M} x^2_{m,n}} \cdot \sqrt{\sum_{m=1}^{M} x^2_{m,n'}}} \end{aligned} \tag{5.10}$$

Auch hier werden wiederum nur gemeinsam besetzte Items berücksichtigt. Beispiel für die Ähnlichkeit zwischen item 2 und 3:

$$\begin{aligned} s^{\mathrm{i}}_{3,4} = \cos(\theta_{n=3,m'=4}) &= \frac{\mathbf{X}_{:,3} \cdot \mathbf{X}_{:,4}}{|\mathbf{X}_{:,3}| \cdot |\mathbf{X}_{:,4}|} \\ &= \frac{5 \cdot 4 + 4 \cdot 4}{\sqrt{5^2 + 4^2} \cdot \sqrt{4^2 + 4^2}} = 0.99 \end{aligned}$$

$\mathbf{S}^{\mathrm{i}}$:

Item→ Item↓	1	2	3	4	5	6
1	1.00	0.90	0.87	1.00	0.51	1.00
2	0.90	1.00	0.92	1.00	0.83	0.99
3	0.87	0.92	1.00	0.99	0.73	0.91
4	1.00	1.00	0.99	1.00	0.98	1.00
5	0.51	0.83	0.73	0.98	1.00	0.98
6	1.00	0.99	0.91	1.00	0.98	1.00

Abbildung 5.15.: Item-Ähnlichkeitsmatrix basierend auf der Kosinusähnlichkeit der Items aus Abbildung 5.13

Daraus folgt für das gesuchte Rating von User 2 für Item 4 $\hat{x}^{\mathrm{i}}_{2,4}$:

$$\begin{aligned} \hat{x}^{\mathrm{i}}_{2,4} &= \frac{1}{s^{\mathrm{i}}_{4,1} + s^{\mathrm{i}}_{4,2} + s^{\mathrm{i}}_{4,3} + s^{\mathrm{i}}_{4,5}} \left(s^{\mathrm{i}}_{4,1} \cdot x_{2,1} + s^{\mathrm{i}}_{4,2} \cdot x_{2,2} + s^{\mathrm{i}}_{4,3} \cdot x_{2,3} + s^{\mathrm{i}}_{4,5} \cdot x_{2,5} \right) \\ &= \frac{1}{1.00 + 1.00 + 0.99 + 0.98} \left(1.00 \cdot 5 + 1.00 \cdot 4 + 0.99 \cdot 4 + 0.98 \cdot 1 \right) = 5.51 \end{aligned}$$

Auch im Item-basierten Ansatz kann die Anzahl der berücksichtigten Nachbarn über einen Threshold begrenzt werden: Entweder wird eine fixe Anzahl an Nachbarn definiert, oder ein Threshold bezüglich der Ähnlichkeit gesetzt, sodass nur Nachbarn mit einer Ähnlichkeit über diesem Threshold berücksichtigt werden.

Wie im obigen Beispiel ersichtlich, liefern User- und Item-basierte Varianten oft unterschiedliche Ergebnisse. Verschiedene Methoden und/oder Hyperparameter-Konfigurationen können mithilfe von Evaluationsmetriken miteinander verglichen werden.

5.3.3.5. Evaluation von Empfehlungsdiensten

Da die die Genauigkeit eines Empfehlungsdienstes nur auf bereits bewerteten Items (und Usern, welche Bewertungen abgegeben haben) bestimmt werden kann, muss zu diesem Zweck ein unabhängiger Testdatensatz x_t aus den vorhandenen Rating-Daten separiert werden. Im besten Fall wird ein Feedback zu den generierten Empfehlungen von aktiven Nutzer:innen eingeholt.

Obwohl die Ratings eine kategorische Variable (ordinal skaliert) darstellen, sieht man häufig die Berechnung der Root Mean Square Deviation ($RMSD$) auf den Test-Ratings Gleichung 5.2.

Von den von den Klassifizierungsproblemen bekannten Metriken ist die Accuracy (Gleichung 5.4) problematisch einerseits aufgrund der unausgewogenen Daten und andererseits aufgrund der gleichen Gewichtung von FN und FP. Bei Empfehlungsdiensten ist jedoch viel wichtiger, korrekt vorherzusagen, was der/die Nutzer:in mag, als was er/sie nicht mag.

Recall (Gleichung 5.6) wird ebenfalls selten verwendet, da typischerweise nur die Top-3 bis Top-5 Empfehlungen von den Nutzer:innen beachtet werden ("User Limited Attention Span"). Deshalb ist es meist unerheblich, welcher Anteil der relevanten Items "verpasst" wurde (FN), solange unter den Top-3 bis Top-5 die relevantesten Items empfohlen werden. wenn hingegen unter den Top-Vorschlägen zu viele unpassend sind, wird der Empfehlungsdienst nicht mehr verwendet. Deshalb sollten die False Positives (FP) minimiert werden.

Dementsprechend basieren die in der Regel verwendeten Metriken auf der Precision (Gleichung 5.5), dem Anteil der relevanten unter den vorgeschlagenen Items. Zur Auswahl der vorgeschlagenen Items wird typischerweise ein Rating-Grenzwert angesetzt, z.B. 3.5 bei einer Ratingspanne von 1 bis 5: Ratings ≥ 3.5 werden als "positiv" gewertet. "Positiv vorgeschlagen" sind nun Ratings über 3.5, welche vom Empfehlungsdienst vorhergesagt wurden. "Relevant" sind dann die im Test-Datensatz vorhandene Ratings über 3.5. Dies entspricht einer Übersetzung in ein ein binäres Klassifikaitonsproblem.
Die Precision@k ($P@k$) ist nun für einen User der Anteil der korrekt positiv vorgeschlagenen unter k vorgeschlagenen Items. Dazu müssen wir zunächst definieren, was eine positive Bewertung darstellt.

$$P@\mathbf{k} = \frac{\text{Anzahl positiv vorgeschlagene unter den } k \text{ relevanten Items}}{\text{Anzahl positiv vorgeschlagene Items}} \tag{5.11}$$

Die Average Precision@k ($AP@k$) ist der Mittelwert

$$AP@k = \frac{1}{k}\sum_{i=1}^{k} AP@i \tag{5.12}$$

Tabelle 5.6.: Erwartete und vom Empfehlungsdienst vorhergesagte Ratings für einen User in einem Testdatensatz.

Item	Erwartet	Vorhergesagt
1	4	2.3
2	2	3.6
3	3	3.4
4		4.3
5	5	4.5
6		2.3
7	2	4.9
8		4.3
9		3.3
10	4	4.3

Tabelle 5.6 enthält die Testdaten für die Berechnung von AP@3 für einen User mit einem Threshold für positive Bewertungen bei 3.5. Alle Ratings ≥ 3.5 sind fett markiert (relevant in Spalte "Erwartet" und positiv vorgeschlagen in Spalte "Vorhergesagt").
Von den positiv vorgeschlagen Items 2, 4, 5, 7, 8 und 10 sind aber nur Items 5 und 10 im Set der relevanten Items. Damit ist in diesem Beispiel:

$$P@3 = \frac{2}{3} = 0.667$$

$$P@2 = \frac{2}{2} = 1.0$$

$$P@2 = \frac{1}{1} = 1.0$$

$$AP@3 = \frac{1}{3}\left(P@1 + p@2 + P@3\right) = 0.889$$

Die Mean Average Precision@ ($MAP@k$) ist die über alle im Testdatensatz enthaltenden User gemittelte $AP@k$.

6. Evaluation

6.1. Übersicht

In der Phase Evaluation des Data Science-Prozess wird beurteilt, ob die Ergebnisse aus den vorangegangenen Projektphasen den Projektzielen entsprechen. Mit den Auftraggebern und allenfalls anderen Stakeholdern wird entschieden, ob es einer weiteren Iteration durch die Data Mining-Phasen bedarf, oder ob das Projekt in die Bereitstellung übergeht. Im letzteren Fall bilden die Ergebnisse und Entscheidungen aus der Evaluation die Grundlagen für die Planung der Bereitstellungsphase.

Teile der Evaluation	Lieferobjekte
1. Beurteilung der Zielerreichung 2. Planung der nächsten Schritte 3. Checkpoint-Entscheidung	Evaluationsbericht

6.2. Beurteilung der Zielerreichung

Evaluationsschritte aus den vorangegangenen Projektphasen bezogen sich auf Aspekte wie der Qualität und Abdeckung der Daten, Genauigkeit und Generalisierbarkeit eines Modells etc. Nun wird, typischerweise anhand eines "Prototypen", beurteilt, inwieweit die Ergebnisse die Projektziele und Erfolgskriterien auf Ebene der Auftraggeber:innen erfüllen.

Die Ausgestaltung dieses "Prototypen" hängt von der konkreten Aufgabenstellung, den Kompetenzen des Projektteams, den zur Verfügung stehenden Ressourcen und den Bedürfnissen und Erwartungen der verschiedenen Stakeholder (insbesondere Auftraggeber/Sponsor) ab. Dieser kann von einer Powerpoint-Präsentation, über ein interaktives Demo-Skript (z.B. Jupyter Notebook) bis hin zu einer Web-Applikation reichen.

Die Beurteilung sollte sich unter anderem darauf beziehen, ob

- die in der Aufgabendefinition erfassten Anforderungen und Randbedingungen erfüllt wurden,
- während der vorangehenden Projektphasen neu identifizierte oder noch nicht berücksichtigte Aspekte genauer untersucht werden müssen,

- die Qualitätsanforderungen an Daten, Modellierung, Software-Komponenten, Dokumentation, Infrastruktur etc. erfüllt sind
- und ob rechtliche und ethische Herausforderungen identifiziert wurden und inwieweit diese in einer nachfolgenden Bereitstellung berücksichtigt werden müssen.

6.3. Planung der nächsten Schritte

Aus der Beurteilung ergeben sich Empfehlungen für die nächsten Schritte, wie z.B.:

- Erweiterung des Domänenwissens
- Adaption der Projektziele
- Beschaffung weiterer/anderer Daten
- Anwendung weiterer Analyse- Modellierungsverfahren
- Berücksichtigung rechtlicher und ethischer Aspekte
- Bereitstellung:
  - Wie sollen die bis anhin erarbeiteten Resultate genutzt werden?
  - In welcher Form sollen die Resultate und Funktionalitäten bereitgestellt werden?

6.4. Checkpoint-Entscheidung

Basierend auf der vorangehenden Beurteilung der Erreichung der Projektziele inklusive Empfehlungen kann nun über die nächsten Schritte, bzw. im Extremfall Abbruch des Projekts, entschieden werden.

6.5. Evaluationsbericht

Die Analysen, Schlussfolgerungen und Entscheidungen aus der Evaluation werden in einem Evaluationsbericht festgehalten. Dieser kann im einfachsten Fall die Form eines Entscheidungsprotokolls annehmen, sollte aber die Entscheidungen und nachvollziehbar machen.

7. Bereitstellung

7.1. Ziele und Phasen der Bereitstellung

Ziel der Bereitstellung ist es, das datenbasierte Produkt, den verschiedenen Anspruchsgruppen auf möglichst nutzbringende Art zugänglich zu machen. Die Bereitstellung setzt sich wiederum aus mehreren Phasen zusammen, welche iterativ durchlaufen werden:

Teile der Bereitstellung	Lieferobjekte
1. Planung 2. Implementierung 3. Auslieferung (Delivery) 4. Betrieb (Operations)	• Dokumentation der bereitgestellten Lösung (z.B. Software Architektur-Diagramm) • Beschreibung der notwendigen Anpassungen von Prozessen (Change Management)

Die **Planung** umfasst eine Beschreibung der funktionalen und nicht-funktionalen **Anforderungen** an das zu entwickelnde System. Funktionale Anforderungen beschreiben, welche Funktionen eine Anwendung oder ein System erfüllen soll. Sie definieren, was das System tun soll. Nicht-funktionale Anforderungen hingegen beschreiben, wie das System diese Funktionen erfüllen soll. Sie legen die Leistungsstandards und Qualitätsmerkmale fest, die das System erfüllen muss, um die funktionalen Anforderungen zu erfüllen. Ein Beispiel für eine funktionale Anforderung wäre, dass eine E-Commerce-Website in der Lage sein sollte, Bestellungen entgegenzunehmen und zu verarbeiten. Ein Beispiel für eine nicht-funktionale Anforderung wäre, dass die Website innerhalb von 3 Sekunden geladen werden sollte, um eine gute Benutzererfahrung zu gewährleisten.
Desweiteren sind die zur Verfügung stehenden **Ressourcen** wichtig für die Planung. Dazu zählen das Budget, die Infrastruktur und die an der Auslieferung und Umsetzung arbeitenden Teammitglieder. **Randbedingungen** sollten möglichst früh und umfassend identifiziert sein und die zur Verfügung stehende **Zeit**. Daraus lassen sich **Ziele** formulieren und ein (grober) Zeitplan erstellen. Zudem addressiert die Planung die eigentliche Implementierung der Lösung, die Auslieferung, wie die betriebliche Stabilität überwacht und aufrecht erhalten werden kann, allfällige Anpassungen von (betrieblichen) Prozessen der nutzenden Personen(insbesondere betriebliche Prozesse) und wie Feedback der nutzenden Personen möglichst umfassend und effizient gesammelt werden kann. Diese Anforderungen werden in konkrete Arbeitspakete aufgeteilt und deren Umsetzung geplant.

Die **Implementierung** stellt die eigentliche technische Entwicklung des Systems gemäss den Anforderungen dar. Sie umfasst in dieser Darstellung auch die Integration auf der Ebene des Zusammenführen von Codeänderungen verschiedener Entwickler oder Teams in einem gemeinsamen Repository und das Testen auf der technischen Ebene mithilfe von Unit-Tests, Integrationstests und Funktionstests.

In der **Auslieferung** wird die Infrastruktur für die Produktionsumgebung bereitgestellt. Sodass die Software darauf verteilt beziehungsweise installiert werden kann. Automatisierte Prozesse helfen dabei, den Code in der Produktionsumgebung zu implementieren.
Dabei ist auch die Seite der nutzenden Personen mit zu berücksichtigen: Ihnen stehen mit dem neuen Produkt neue Informationen und Möglichkeiten zur Verfügung. Ihr Verhalten ändert sich möglicherweise, woraus sich neue Fragen, Unsicherheiten oder Konflikte ergeben können. Im betrieblichen Kontext müssen möglicherweise Prozesse überdacht und angepasst werden. Diese Aspekte des **Change Managements** sind für den Erfolg des Produktes sehr wichtig, denn bei fehlender Akzeptanz durch die nutzenden Personen und anderen Stakeholdern ist der Erfolg des Produktes gefährdet.

Nach der Auslieferung wird das System im **Betrieb** überwacht, um die Leistung zu überprüfen, Probleme zu erkennen und auf unerwartete Ereignisse zu reagieren. Dies hilft dabei, potenzielle Probleme frühzeitig zu erkennen und zu beheben, um damit die **betriebliche Stabilität** sicherzustellen.
Diese Phase beinhaltet auch das Sammeln von **Rückmeldungen** von nutzenden Personen, Entwicklern und anderen Beteiligten, um Verbesserungen zu identifizieren und in zukünftige Iterationen einzubeziehen.

7.2. Lieferobjekte der Bereitstellung

Auch die in der Bereitstellung gewonnenen Erkenntnisse und entwickelten Lösungen sollen adäquat dokumentiert werden. Dazu können gehören Architektur-Diagramme, Software-Dokumentationen, Berichte und Analysen von Nutzer-Feedback usw.

7.3. Ein Architektur-Blueprint für Machine Learning-Anwendungen

Machine Learning-Modelle können z.B. als Programmbibliothek (Library) in einem Repository oder einer Registry abgelegt werden, um dann in die Codebase einer grösseren Applikation eingebunden zu werden.
Heutzutage ist jedoch eine Microservices-Architektur verbreiteter, in welcher funktionale Einheiten unabhängig voneinander als Webservices entwickelt und bereitgestellt werden, sodass andere Applikationen diese dann bei Bedarf aufrufen können. Typischerweise werden REST (REpresentational State Transfer) Webservices verwendet. Abbildung 7.1 zeigt exemplarisch

die Einbettung eines Machine Learning-Modells als Webservice in einer grösseren Software-Applikation. Die Vorteile einer Microservices-Architektur sind unter anderem:

- Komplexität der Entwicklung und Wartung wird reduziert durch Aufteilung der gesamten Codebasis in Einheiten
- (Sub-)Teams können unabhängig voneinander Komponenten (weiter)entwickeln
- Technologien können für die einzelnen Komponenten unabhängig voneinander gewählt und verändert werden
- Schnellere und kosteneffizientere Skalierbarkeit der gesamten App durch unabhängige Skalierbarkeit der einzelnen Komponenten
- Fehlfunktionen werden isoliert, dadurch schneller identifiziert und behebbar
- Die Wiederverwendbarkeit wird erhöht, da ein Service in vielen Anwendungen verwendet werden kann.

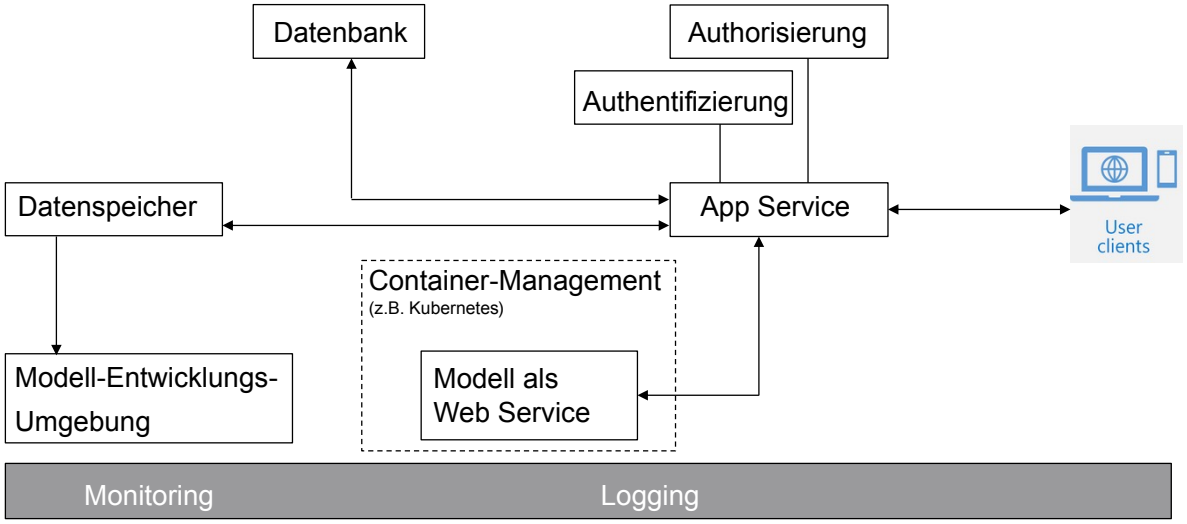


Abbildung 7.1.: Architektur-Blueprint für die Integration einer Machine LEarning-Komponente als Webservice in einer Software-Applikation.

7.4. Machine Learning Operations (MLOps)

Sobald ein Modell bereitgestellt und in einer grösseren Software-Applikation integriert ist, muss es die für Software-Komponenten typischen Standards zur Qualitätssicherung erfüllen:

- Transparenz und Nachvollziehbarkeit Versionierung von Code und Datenpipelines, lückenlose Protokollierung der Komponenten, Konfigurationen und Parameter welche in eine bereitgestellte Pipeline einfliessen

- Tests: Dokumentierte Genauigkeits- und Robustheitsanalysen des Modells (Verzerrungen in den Trainingsdaten).
- Code-Qualität: Einhaltung von Lizenzen, Saubere und wartungsfreundliche Codebasis, Dokumentation
- Separierung von Nutzungsumgebungen: (z.B. DEV, TEST und PROD) mit entsprechenden Change Management und Release-Prozessen
- Automatisierung: von Deployment und Integrationsschritten in der Form von CI/CD-Pipelines
- Sicherheit: Zugriffsbeschränkungen und -Kontrollmechanismen, Verschlüsselung, Anonymisierung
- Monitoring
- Verfügbarkeit: Erreichbarkeit des Web-Services, Latenz, Infrastrukturauslastung
- Genauigkeit: Periodische Überprüfung manuell und/oder automatisiert auf aktualisierten Testdaten. Data/Concept-Drift kann zu Verschlechterungen führen (Model Degradation)
- Nutzer-Feedback: Herausforderungen bezüglich Konsistenz und Aufwand
- Inkrementelle und iterative Weiterentwicklung fokussiert auf die Nutzerbedürfnisse

Teil III.

Ethische Aspekte

8. Ethische Aspekte

8.1. Moral, Ethik und Recht

Moral, Ethik und Recht stehen in einer Dreiecksbeziehung:

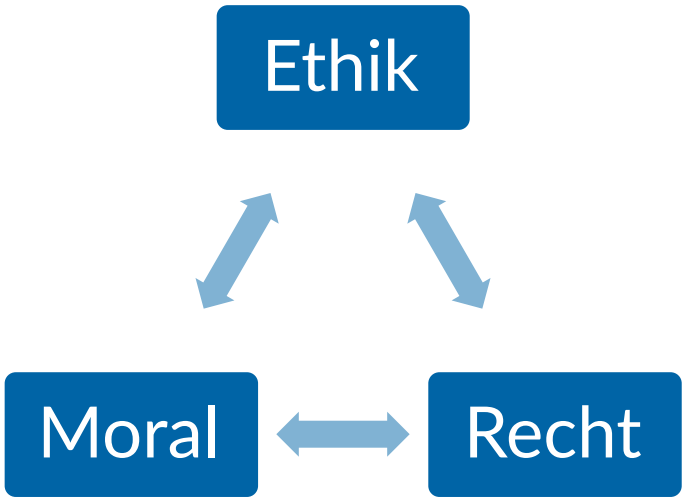


Abbildung 8.1.: Die Dreiecksbeziehung zwischen Moral, Ethik und Recht. Gegenseitige Beeinflussungen werden durch Doppelpfeile dargestellt.

Die **Moral** umfasst die in einer Gesellschaft konkret gelebten Sitten und Gebräuche. Diese Muster sind oft historisch gewachsen und ändern sich im Laufe der Zeit immer wieder.

Seit Aristoteles (4. Jahrhunder v. Chr.) gilt die **Ethik** sie als Unterdisziplin der Philosophie. Als Wissenschaft der Moral reflektiert und systematisiert sie die Moral. Sie schafft entsprechende Wertesysteme, aufgrund derer bestimmte Handlungen als ethisch gut und schlecht beurteilt werden können. Ethisches Handeln kann zu Interessenskonflikten führen:

> Ist das Gebot, stets die Wahrheit zu sagen, dem Gebot, einem Menschen zu helfen, überzuordnen oder nicht? Immanuel Kant (1797)

Das **Recht** setzt die für den Erhalt der Gesellschaft wesentlichen Werte durch, indem Verstöße mit Sanktionen belegt werden. Zugleich muss es klären, wo eigentlich Regelungen und Gesetze

nötig sind, um das Wertesystem durchzusetzen. Dies bedeutet auch, dass die Ethik nicht mit dem Recht gleichzusetzen ist. Nicht alles, was ethisch relevant ist, wird auch rechtlich reguliert. Umgekehrt gibt es auch rechtliche Festlegungen, welchen nicht primär ethische Überlegungen zugrunde liegen.

Die Moral beeinflusst sowohl die Ethik als auch das Recht: Beide werden irrelevant ohne den Bezug zum konkret gelebten Wertesystem.

Das Recht beeinflusst die Moral, indem es bestimmte Aspekte des Wertesystems einer Gesellschaft stärkt und andere durch Sanktionen einschränkt. Auch die Ethik muss in ihrer Wertediskussion die mögliche konkrete Umsetzung ihrer Ergebnisse innerhalb des Rechtsystems beachten und wird damit durch das Recht beeinflusst.

Die Ethik gibt dem moralischen Leben einer Gesellschaft Orientierung. Sie ordnet ein, was als gut und was als schlecht empfunden wird. Auf das Recht wirkt die Ethik ein, indem sie beurteilt, ob das Gesetz sich im Einklang mit den universalen Grundwerten befindet. Auf beide Seiten hin zeigt sie die Richtung möglicher Veränderungen auf.

9. Datenethik

Für die Entwicklung datenbasierter Produkte ist besonders das relativ junge Teilgebiet der digitalen Ethik oder Datenethik relevant. Dabei geht es um die Normen in einer digital geprägten Gesellschaft im Zusammenhang mit

- der datenbasierten Erstellung von Persönlichkeitsprofilen (z.B. für politische Kampagnen)
- dem Einsatz von Algorithmen, insbesondere der künstlichen Intelligenz, zur automatisierten (Unterstützung der) Entscheidungsfindung
  - in der Privatwirtschaft (Kreditvergabe, Stellenvergabe)
  - im staatlichen Bereich (Einsatz in der Justiz und Polizei)
  - in der Medizin und Pflege (maschinelle Diagnoseverfahren, Einsatz von Pflegerobotern)
- sozialen Medien (Filterblasen und Verbreitung von Hassrede oder Fake News)
- dem Einfluss der Automatisierung auf die menschliche Arbeit (Ersatz von Arbeitsstellen durch Roboter)
- …

Als Beispiel für Leitgedanken in der Entwicklung einer digitalen Ethik basierend auf allgemeinen ethischen und rechtlichen Prinzipien sei an dieser Stelle aus dem Gutachten der Deutschen Datenethikkomission [28] zusammengefasst:

- Die Digitalisierung soll dem Wohl der gesamten Gesellschaft dienen und ihren Zusammenhalt stärken
- Menschenzentrierte und werteorientierte Gestaltung der Technologie
- Förderung digitaler Kompetenzen und kritischer Reflexion in der digitalen Welt
- Stärkung des Schutzes von persönlicher Freiheit, Selbstbestimmung und Integrität
- Risikoadaptierte Regulierung und wirksame Kontrolle algorithmischer Systeme
- Wahrung und Förderung von Demokratie
- Ausrichtung digitaler Strategien an Zielen der Nachhaltigkeit

10. Der Ethik-Kodex für Datenbasierte Wertschöpfung

Der Ethik-Kodex für datenbasierte Wertschöpfung [29] wurde von der Expertengruppe "Datenethik" der data innovation alliance erstellt. Er soll als Leitfaden dienen, um in der Entwicklung datenbasierter Produkte die ethischen Erwartungen von Kund:innen, Mitarbeitenden und der Gesellschaft als Ganzes zu berücksichtigen.

Dem Kodex liegen drei ethische **Grundorientierungen** zugrunde, welche für eine Reihe von Werten stehen, die in der Debatte um datenbasierte Wertschöpfung regelmässig auftreten:

1. Schadenvermeidung
    - Werte: Schutz, Sicherheit und Nachhaltigkeit
2. Gerechtigkeit
    - Werte: Gleichheit, Fairness, Solidarität
3. Autonomie
    - Werte: Wahlfreiheit, Privatsphäre, Würde

Diese Grundorientierungen und entsprechenden Werte sind jeweils gegenüber Individuen, Gemeinschaften und auch der Umwelt zu denken. Sie ergänzen die "natürlichen" Unternehmensziele, wie die Bedürfnisse der Kunden zu erfüllen und Gewinn zu erzielen, um dort, wo durch die angebotenen Produkte persönliche oder gesellschaftliche Werte betroffen sind, bestimmte ethische Standards zu gewährleisten. Sie sind jedoch im Unternehmenskontext für sich genommen relativ abstrakt und es stellt sich die Frage, wie sie im Unternehmensalltag umgesetzt werden können. Dazu werden drei **prozedurale Werte** vorgeschlagen, welche etablierte Unternehmensgrundsätze zur Sicherung der Qualität von Produkten und Dienstleistungen und der Kontrolle von Unernehmensrisiken darstellen:

1. Kontrolle
    - klare Prozesse, welche allen Stakeholdern bekannt sind
2. Transparenz
    - Dokumentation der Datenverarbeitungsschritte

3. Rechenschaft

    - klare Zuständigkeiten und Verantwortlichkeiten

In der ethisch verantwortungsvollen Entwicklung von datenbasierten Produkten verbinden diese prozeduralen Werte nun die Grundorientierungen mit konkreten Geschäftsprozessen.

Eine ethische Bewertung der datenbasierten Wertschöpfung im Rahmen des Ethik-Kodex basiert demnach auf dem Grad der Verwirklichung sowohl der Grundorientierungen als auch der prozeduralen Werte. Zielkonflikte zwischen den unterschiedlichen Unternehmenswerten werden damit nicht vermieden, können jedoch auf einer gemeinsamen Ebene transparent und systematisch behandelt werden.

Der Kodex unterteilt den "Daten-Lebenszyklus" in 4 Phasen (vergleiche mit dem Data Science-Prozess):

A) Datenerzeugung und -aqkuirierung (Datenbeschaffung und -erkundung)
B) Datenspeicherung und -management (ebenfalls Datenbeschaffung und -erkundung)
C) Datenanalyse und Wissensgenerierung (Modellierung)
D) Produkte und Dienstleistungen (Bereitstellung)

Die Aktivitäten in jeder Phase sind durch spezifische ethische Herausforderungen geprägt und bauen auf den Ergebnissen früherer Schritte auf - Rückkopplungsschleifen sind dabei sowohl üblich als auch notwendig.

Im Ethik-Kodex werden nun die drei ethischen Grundorientierungen als auch die drei prozeduralen Werte auf die vier Phasen des Daten-Lebenszyklus angewendet, so dass pro Phase sechs Gruppen von Empfehlungen resultieren (Abbildung 10.1). Dazu wird jeweils pro Gruppe erläutert, welche Absichten mit den Empfehlungen verfolgt werden, bevor dann die konkreten Empfehlungen folgen. Zu jeder Gruppe wird anhand eines Beispiels erläutert, wie eine konkrete Umsetzung der Empfehlung aussehen kann.

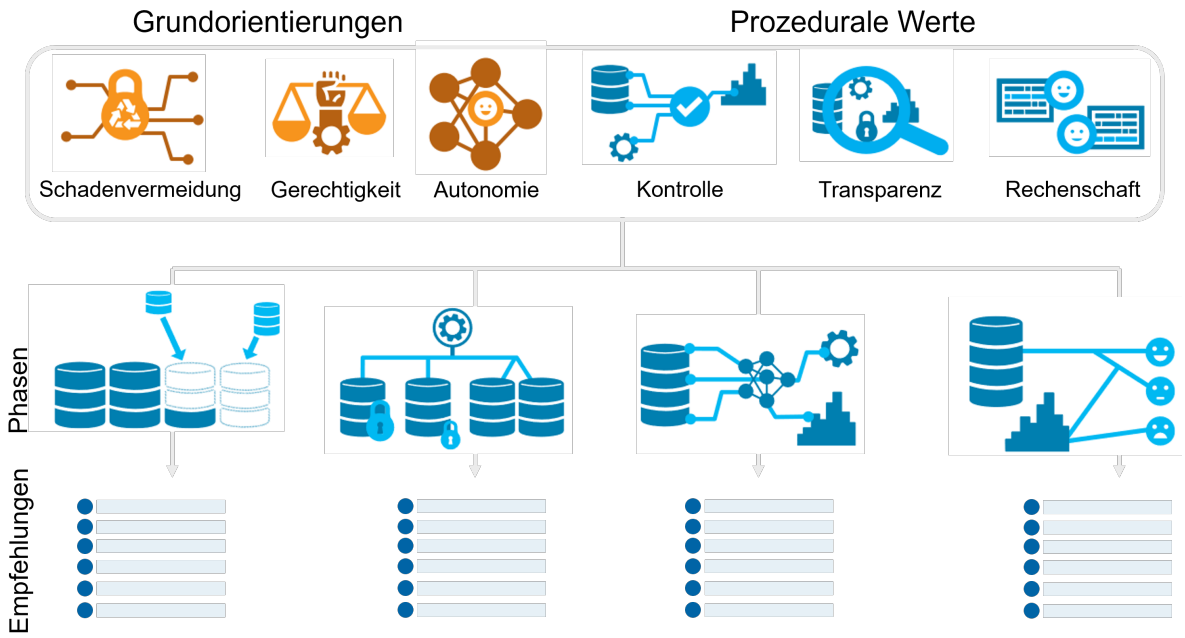


Abbildung 10.1.: Systematik des Ethik-Kodex der Data Innovation Alliance

Teil IV.

Rechtliche Aspekte

Als Ingenieurswissenschaft ist Data Science eine von Natur aus angewandte Disziplin und wird nicht im luftleeren Raum praktiziert und liefert oft Ergebnisse, welche kommerziell verwertet werden oder anderweitig gesellschaftliche Relevanz haben. Daher gehört das Recht zu den vielen Aspekten, welcher in der Entwicklung datenbasierter Produkte zu berücksichtigen sind. Dieses Bewusstsein und die praktische Einbindung dieser Aspekte in den Entwicklungsprozess soll dazu beitragen, rechtliche Probleme in letzter Minute zu vermeiden, welche nicht nur frustrierend, sondern in vielen Fällen auch kostspielig sind.

Dieses Kapitel kann zwar nicht alle rechtlichen Aspekte im Detail beleuchten, soll aber ein gewisses Bewusstsein für wichtige rechtliche Fragen vermitteln, denen man im Kontext der Entwicklung datenbasierter Produkte begegnen kann - und sei es nur, um sich als Data Scientist rechtzeitig Hilfe und Unterstützung von einer Rechtsabteilung oder einem Rechtsberater zu suchen.
Da die Zahl der potenziellen Rechtsfragen sehr groß ist, werden in diesem Abschnitt einige dieser rechtlichen Themen skizziert, um Datenwissenschaftlern einen Bezugsrahmen zu bieten, insbesondere zu:

(1) Überblick zum Rechtssystem in der Schweiz
(2) Strafrecht
(3) Datenschutz
(4) Immaterialgüterrecht

Überblick Rechtssystem/Rechtsordnung In der Schweiz

In der Schweiz kann man unterschiedliche Rechtsbereiche identifizieren. Das **Privatrecht** regelt das Verhältnis zwischen Privaten. Das **öffentliche Recht** regelt das Verhältnis zwischen Staat und Privaten sowie zwischen den Behörden untereinander. Als Teil des öffentlichen Recht ist noch das **Strafrecht** zu bezeichnen.

Das schweizerische Strafrecht bestimmt seinen Geltungsbereich selbst. Es folgt dem **Territorialprinzip**. Geregelt ist dieser Grundsatz in Art. 3 des schweizerischen Strafgesetzbuches (nachfolgend StGB). Das heisst, diesem Gesetz unterworfen ist, wer in der Schweiz ein Verbrechen oder Vergehen (sowie Übertretungen) begeht. Dazu muss eine Tat in der Schweiz ausgeführt oder der Erfolg hier eingetreten sein (Art. 8 StGB).

Das **Datenschutzgesetz** ist in der Mitte zwischen dem Privat- und dem öffentlichen Recht anzusiedeln, da es allgemeine Regelungen, sowie in Ergänzung zu den “allgemeinen Regelungen” bestimmte Regelungen für die “Bearbeitung von Personendaten durch Private” und bestimmte Regelungen für die “Bearbeitung von Personendaten durch Bundeorgane” enthält.

> **Tipp**
>
> Stellen Sie sicher, dass Sie immer die aktuellen Gesetze verwenden, welche in Kraft sind.

11. Strafrecht

Im folgenden werden auf kurzem Raum die wichtigsten Aspekte des Strafrechts bezogen auf Daten erläutert. Für weitergehende Ausführungen wird auf einschlägige Sekundärliteratur verwiesen, z.B. [30,31].

11.1. Aufbau vorsätzliches Handlungsdelikt (grob umrissen)

Damit eine Person wegen ihres Verhaltens strafrechtlich belangt werden kann, muss dieses Verhalten sowohl den Tatbestand erfüllen als auch rechtswidrig sein. Darüber hinaus muss der Verstoss gegen die Rechtsordnung schuldhaft begangen worden sein. Zusammengefasst lässt sich der Deliktsaufbau in die drei Stufen «Tatbestandsmässigkeit», «Rechtswidrigkeit» und «Schuld» unterteilen. Wichtig dabei ist, dass Fahrlässigkeit und Unterlassung bei den vorliegend behandelten Delikten keine Strafbarkeit zur Folge haben. Mit folgendem Prüfschema lässt sich die Strafbarkeit beurteilen:

11.1.1. Prüfschema (grob)

1. **Tatbestand:**
   Ein Verhalten gilt als tatbestandsmässig, wenn es sämtliche objektiven und subjektiven Merkmale erfüllt, die in einem Straftatbestand beschrieben sind. Der objektive Tatbestand bezieht sich auf die äusseren Merkmale des verbotenen Verhaltens, während der subjektive Tatbestand die innere Vorstellung des Täters umfasst.

   1. **Objektiver Tatbestand**: Tatobjekt, Tathandlung, Taterfolg bei Erfolgsdelikten, Kausalität, objektive Zurechnung.
   2. **Subjektiver Tatbestand**: Vorsätzliches Handeln umfasst Wissen und Willen. Der Täter weiss um die objektiven Tatbestandsmerkmale und strebt den Taterfolg an (Vorsatz).
      Der Täter hält den Erfolgseintritt für möglich und nimmt diesen billigend in Kauf (Eventualvorsatz). Gegebenenfalls zu prüfen sind zusätzlich besondere subjektive Unrechtsmerkmale wie die Bereicherungsabsicht.

2. **Rechtswidrigkeit**:
   Sind Rechtfertigungsgründe vorhanden? Falls solche gegeben sind, kann dies zur Unrechtsaufhebung führen.

3. **Schuld**:
   Sind Schuldausschliessungsgründe vorliegend? Auf dieser Stufe wird geprüft, ob dem Täter einen Schuldvorwurf gemacht werden kann. Um die Schuldfähigkeit zu bejahen, muss der Täter gemäss Art. 19 Abs. 1 StGB einsichtsfähig und steuerungsfähig sein, also über die Fähigkeit verfügen, das Unrecht der Tat einzusehen und sich nach dieser Einsicht zu verhalten.
4. **Ergebnis**:
   Schlussfolgerung der Strafbarkeitsprüfung in einem Satz.

11.2. Überblick Computerdelikte (Auswahl)

Mit der Digitalisierung bzw. den digitalen Möglichkeiten sind auch neue Formen der Cyberdelinquenz zu beobachten, unterschieden werden können unter anderem die Verletzung der Privat- und Geheimsphäre mit Hilfe technologischer Mittel (Hacking, Computersabotage, Verkauf von Decodierungs- und Abhörgeräten), Angriffe auf technische Infrastrukturen als Ganzes mit dem Ziel die Funktionsweise lahmzulegen (Cyberterrorismus), klassische Vermögensdelikte begangen unter Nutzung von Computern (Betrug) oder auch Copyright Verletzungen (Immaterialgüterrechtsverletzungen).

Vorliegend im Detail behandelt werden die unbefugte Datenbeschaffung und das Eindringen in ein Datenverarbeitungssystem.

11.2.1. Unbefugte Datenbeschaffung

Die Unbefugte Datenbeschaffung wird auch als Datendiebstahl bekannt.
Art. 143 StGB sagt, dass wer in der Absicht, sich oder einen andern unrechtmässig zu bereichern, sich oder einem andern elektronisch oder in vergleichbarer Weise gespeicherte oder übermittelte Daten beschafft, die nicht für ihn bestimmt und gegen seinen unbefugten Zugriff besonders gesichert sind, mit Freiheitsstrafe bis zu fünf Jahren oder Geldstrafe bestraft wird. Bei der der unbefugte Datenbeschaffung zum Nachteil eines Angehörigen oder Familiengenossen gilt das so genannte Antragsprivileg, was bedeutet, dass die Tat nur auf Antrag verfolgt wird.

Geschützt werden soll die Verfügungsmacht über Computerdaten.

Tatbestandselemente (objektiv und subjektiv):

- gespeicherte oder übermittelte Daten: “Alle Notate, die überhaupt Gegenstand menschlicher Kommunikation sein können, die sich in einem Prozess der automatisierten Datenverarbeitung befinden”
- Berechtigung an Daten: Daten dürfen nicht für den Täter bestimmt sein.

- Besondere Sicherung: Daten müssen gegen den unbefugten Zugriff des konkreten Täters besonders gesichert sein. Unter Zugriff versteht man jede Form der Einwirkungsmöglichkeit, unabhängig ob technisch oder physisch.
- Die Tathandlung ist das Beschaffen, das Zugriffsschranken überwunden oder umgangen und Daten zu eigenem Zwecke gebraucht werden.
- Bereicherungsabsicht

11.2.2. Unbefugtes Eindringen in ein Datenverarbeitungssystem

Gemeint mit diesem Tatbestand ist das Hacking, geregelt in Art. 143 ^{bis} Abs. 1 und 2 StGB.

Hacking begeht, wer auf dem Wege von Datenübertragungseinrichtungen unbefugterweise in ein fremdes, gegen seinen Zugriff besonders gesichertes Datenverarbeitungssystem eindringt. Verfolgt wird Hacking auf Antrag und die Strafandrohung lautet auf Freiheitsstrafe bis zu drei Jahren oder Geldstrafe (Absatz 1).

Wer Passwörter, Programme oder andere Daten, von denen er weiss oder annehmen muss, dass sie zur Begehung einer strafbaren Handlung gemäss Absatz 1 (Hacking) verwendet werden sollen, in Verkehr bringt oder zugänglich macht, wird ebenfalls mit Freiheitsstrafe bis zu drei Jahren oder Geldstrafe bestraft (Absatz 2).

Geschützt wird der so genannte “Computerfrieden”, die Freiheit eines Berechtigten selbst darüber entscheiden zu können, wem Zugang zu einer gesicherten Datenverarbeitungsanlage (und dort vorhandenen Daten) gewährt wird und wem nicht.

Tatbestandselemente (objektiv und subjektiv):

- Datenverarbeitungssysteme: “Technische Einrichtungen, über welche Informationen in nicht direkt lesbarer, üblicherweise kodierter Form entgegengenommen, automatisiert bearbeitet und wieder abgegeben werden”
- Fremd bzw. “nicht für den Täter bestimmt”
- “besonders gesichert”, gemeint sind bspw. Firewalls, Verschlüsselungen oder Passwortschutz
- Die Tathandlung ist das unbefugte Eindringen auf dem Wege von Datenübertragungseinrichtungen
- Subjektiv genügt Eventualvorsatz, eine Tat mit Wissen und Willen begehen, wobei das Einkaufnehmen des Erfolgseintrittes genügt. Eine Bereicherungsabsicht ist nicht zwingend notwendig, um den Tatbestand zu erfüllen. Nicht strafbar ist, wer fahrlässig handelt, indem jemand irrtümlich oder durch einen technischen Mangel ohne es zu Wollen in eine fremde Datenverarbeitungsanlage gelangt, selbst wenn er sich anschliessend eine gewisse Zeit darin aufhält.

11.2.3. Datenbeschädigung

Der Tatbestand der Datenbeschädigung ist in Art. 144 ^{bis} Ziffer 1 StGB statuiert.
Demnach strafbar macht sich, wer unbefugt elektronisch oder in vergleichbarer Weise gespeicherte oder übermittelte Daten verändert, löscht oder unbrauchbar macht. Es handelt sich um ein Antragsdelikt und wird mit Freiheitsstrafe bis zu drei Jahren oder Geldstrafe bestraft. Die Tat wird von Amtes wegen verfolgt, wenn der Täter einen grossen Schaden verursacht. In solchem Fall droht eine Freiheitsstrafe bis zu fünf Jahren oder eine Geldstrafe.

11.2.4. Herstellen von datenschädigenden Programmen

Der so genannte Viren-Tatbestand findet sich in Art. 144 ^{bis} Ziffer 2 StGB.
Dieser besagt, dass wer Programme, von denen er weiss oder annehmen muss, dass sie zu den in Art. 144 ^{bis} Ziffer 1 genannten Zwecken verwendet werden sollen, herstellt, einführt, in Verkehr bringt, anpreist, anbietet oder sonst wie zugänglich macht oder zu ihrer Herstellung Anleitung gibt, mit einer Freiheitsstrafe von bis zu drei Jahren oder einer Geldstrafe bestraft wird. Handelt der Täter gewerbsmässig, so wird er gar mit Freiheitsstrafe von sechs Monaten bis zu zehn Jahren bestraft

11.2.5. Betrügerischer Missbrauch einer Datenverarbeitungsanlage

Der so genannte Computerbetrug ist geregelt in Art. 147 StGB.
Hiernach bestraft mit Freiheitsstrafe bis zu fünf Jahren oder Geldstrafe wird, wer in der Absicht, sich oder einen andern unrechtmässig zu bereichern, durch unrichtige, unvollständige oder unbefugte Verwendung von Daten oder in vergleichbarer Weise auf einen elektronischen oder vergleichbaren Datenverarbeitungs- oder Datenübermittlungsvorgang einwirkt und dadurch eine Vermögensverschiebung zum Schaden eines andern herbeiführt oder eine Vermögensverschiebung unmittelbar danach verdeckt. Handelt der Täter gewerbsmässig, so wird er mit Freiheitsstrafe von sechs Monaten bis zu zehn Jahren bestraft. Der betrügerische Missbrauch einer Datenverarbeitungsanlage zum Nachteil eines Angehörigen oder Familiengenossen wird indessen nur auf Antrag verfolgt (Antragsprivileg).

11.3. Weiterführende Informationen

Hinweis: Überblick-Statistik-digitale Kriminalität

12. Datenschutz

Literaturhinweise zum schweizerischen Datenschutzrecht: [32,33].

12.1. Allgemeines

Datenschutzgesetze sind allgemein formulierte Rahmengesetze. Sie enthalten allgemeine Regelungen - aus diesem Grund werden sie auch als "**formelles**" Recht bezeichnet. Um einen individuellen Sachverhalt datenschutzrechtlich beurteilen zu können, ist zusätzlich jeweils das bereichsspezifische, "**materielle**" Datenschutzrecht beizuziehen und zu konsultieren, gemeint sind die bereichspezifischen Sachgesetze, Verordnungen etc.

Auf internationaler Ebenen haben wir auf Europäischer Stufe die Datenschutzgrundverordnung (DSGVO) deren Anwendungsbereich sich unter Umständen auch auf Schweizer Unternehmen erstreckt.

Das Datenschutzgesetz (DSG) schützt nicht die Daten, sondern die Personen über welche Daten bearbeitet werden. Es fällt damit in den Bereich des **Persönlichkeitsrechts** und das für die Geltendmachung von Ansprüchen zuständige Verfahren ist das **Zivilverfahren**.

12.2. Terminologie

Terminologie meint die Begriffslehre. Im Datenschutz ist die Terminologie deshalb von besonderer Bedeutung, weil an die einzelnen Begriffe bzw. Definitionen **Rechte** oder **Pflichten** anknüpfen.

Personendaten Alle Angaben, die sich auf eine bestimmte oder bestimmbare natürliche Person beziehen.

Besonders schützenswerte Personendaten Als Besonders schützenswert gilt dies Kategorie deshalb, weil bei deren Bearbeitung im Vergleich zur Bearbeitung von regulären Personendaten ein erhöhtes Risiko einer Persönlichkeitsverletzung besteht.
Zu dieser Kategorie abschliessend zählen: Daten über die religiösen, weltanschaulichen, politischen oder gewerkschaftlichen Ansichten oder Tätigkeiten, die Gesundheit, die Intimsphäre oder die Zugehörigkeit zu einer Rase oder Ethnie. Weiter darunter gefasst werden auch Daten über verwaltungs- und strafrechtliche Verfolgungen oder Sanktionen,

sowie Daten über Massnahmen der sozialen Hilfe. Auch genetische Daten und biometrische Daten, die eine natürliche Person eindeutig identifizieren fallen darunter.

Profiling und Profiling mit hohem Risiko Profiling meint jede Art der automatisierten Bearbeitung von Personendaten, die darin besteht, dass diese Daten verwendet werden, um bestimmte persönliche Aspekte, die sich auf eine natürliche Person beziehen, zu bewerten, insbesondere um Aspekte bezüglich Arbeitsleistung, wirtschaftliche Lage, Gesundheit, persönlicher Vorlieben, Interessen, Zuverlässigkeit, Verhalten, Aufenthaltsort oder Ortswechsel dieser natürlichen Person zu analysieren oder vorherzusagen.

Betroffene Person Natürliche Person, über die Daten bearbeitet werden.

Bearbeiten Jeder Umgang mit Personendaten, unabhängig von den angewandten Mitteln und Verfahren, insbesondere das Beschaffen, Speichern, Aufbewahren, Verwenden, Verändern, Bekanntgeben, Archivieren, Löschen oder Vernichten von Daten.

Bekanntgabe Bekannt geben meint das Übermitteln oder zugänglich machen von Personendaten.

Verantwortlicher und Auftragsbearbeiter nach DSG Als **Verantwortlicher** gilt die private Person oder das Bundesorgan, die oder das allein oder zusammen mit anderen über den Zweck und die Mittel der Bearbeitung entscheidet während als **Auftragsbearbeiter** die private Person oder das Bundesorgan verstanden wird, die oder das im Auftrag des Verantwortlichen Personendaten bearbeitet.

Pseudonymisierte Daten Bei einer Pseudonymisierung von Daten oder Datensätzen wird der Personenbezug reversibel entfernt, das heisst diejenigen Informationen, welche dafür sorgen, dass sie einer bestimmten oder bestimmbaren Person zugeordnet werden können, werden entfernt und durch andere Variablen (Zeichen oder Buchstaben) ersetzt. Diese entfernten Informationen mit deren Hilfe eine Re-identifizierung bzw. mit deren Hilfe die Person wieder bestimmbar gemacht werden kann, werden nicht vernichtet, sondern bleiben bestehen. Für Personen, welche Zugang zu den separaten Informationen haben, bleibt es eine Bearbeitung von Personendaten.

Anonymisierte Daten Bei einer Anonymisierung von Daten oder Datensätzen wird der Personenbezug ebenfalls entfernt, jedoch irreversibel, was bedeutet, dass niemand mehr über die zusätzlichen Informationen, mit deren Hilfe die Daten wieder einer bestimmten oder bestimmbaren Person zugeordnet werden könnten, verfügt. Es handelt sich nicht mehr um Personendaten im Sinne des Datenschutzgesetzes.

12.3. Hinweise zur Revision

Das schweizerische Datenschutzrecht hat im letzten Jahr eine Revision erfahren. Im Raum stand eine Anpassung hinsichtlich der fortschreitenden Digitalisierung sowie eine Angleichung an den Massstab der in der EU geltenden DSGVO. Diese ist bereits seit 2018 in Kraft. Dringend aufgedrängt hat sich eine Erneuerung vor allem auch deshalb, weil für eine vereinfachte Wirtschaftlichkeit hinsichtlich der Datenbekanntgabe ins Ausland die Schweiz aus Sicht der EU als Land mit einem angemessenen Datenschutzniveau gelten sollte. Das heisst mit an-

deren Worten, damit bei einem Datenaustausch ins Ausland vereinfachte Vorschriften zum Tragen kommen, muss das Empfängerland der Daten als Land mit einem angemessenen Datenschutzniveau gelten. Möchte man Daten in ein Land bekanntgeben, welches nicht über ein angemessenes Datenschutzniveau verfügt, ist dies zwar nicht per se verboten, bliebt jedoch nur mit zusätzlichen Massnahmen und auf komplizierterem Wege möglich.

Mit in Kraft treten des revidierten Gesetzestestes folgte im Anschluss auch dieser so genannte Angemessenheitsentscheid seitens EU. Aus Sicht der EU verfügt die Schweiz mit der aktuellen Gesetzeslage über ein angemessenes Datenschutzniveau.

12.4. Grundsätze

Das Schweizer Datenschutzrecht fusst auf sieben Grundsätzen (siehe Abbildung 12.1).

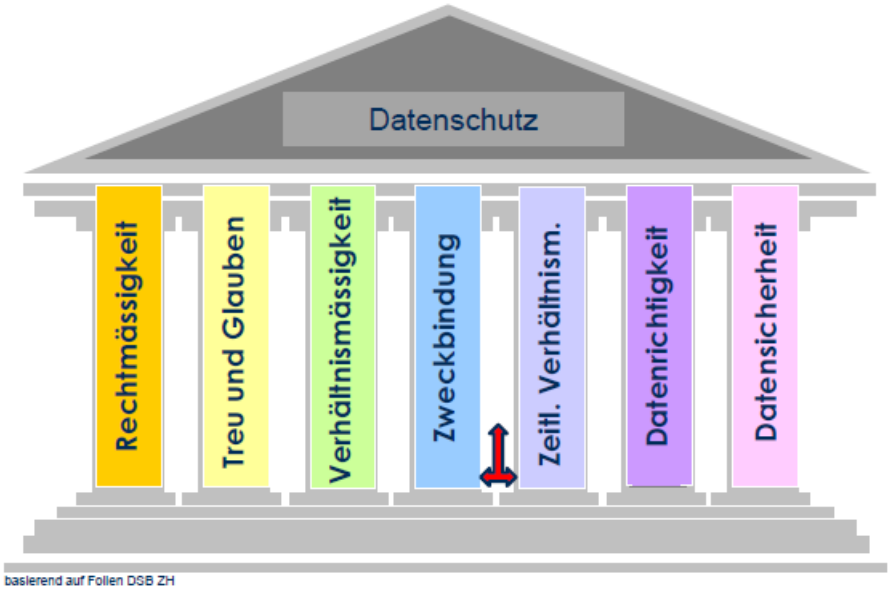


Abbildung 12.1.: Die sieben Grundsätze des Datenschutzrechts.

Die Grundsätze stellen Säulen dar, und der Datenschutz ist sinnbildlich als eine Art *Dach* darüber gesetzt und damit verbunden mit diesen Grundsätzen, dargestellt als tragende Säulen. Diese Darstellung impliziert auch das Zusammenhängen dieser Grundsätze miteinander. Sie greifen wie Zahnräder ineinander. Im Gesetz zu finden sind die Grundsätze bei den allgemeinen Bestimmungen in Art. 6 und 8 zu Beginn des DSG, was bedeutet, dass sie für die Bearbeitung von Personendaten durch Private Personen als auch für die Bearbeitung von Personendaten für Bundesorgane gelten.

Rechtmässigkeit: Personendaten dürfen nur rechtmässig bearbeitet werden (Art. 6 Abs. 1 DSG). Enthalten ist eine Selbstverständlichkeit, nämlich, dass die Bearbeitung von Personendaten nicht gegen eine in der Schweiz geltenden verbindliche Norm verstossen darf.

Die unbefugte Datenbeschaffung dient als Beispiel einer solchen Norm. Das Verhalten bzw. die Beschaffung der Daten beruht auf einem unrechtmässigen Verhalten, worauf in der Regel auch die darauffolgenden Datenbearbeitungen unrechtmässig bleiben und eine Persönlichkeitsverletzung vorliegt.

Der Grundsatz ist für private Personen als Datenbearbeiter und Bundesorgane als Datenbearbeiter unterschiedlich ausgestaltet. Im öffentlich-rechtlichen Bereich herrscht das Legalitätsprinzip, das heisst jegliches staatliche Handeln muss auf einer hinreichend gesetzlichen Grundlage beruhen.

Treu und Glauben: Nach dem Grundsatz von **Treu und Glauben** wird ein loyales und vertrauenswürdiges Verhalten im Rechtsverkehr erwartet. Heimliche Datenbearbeitungen sind in der Regel nicht erlaubt. Das man bei einer Datenpanne (ungewollter Verlust bzw. ungewollte Offenlegung von Personendaten) die Betroffenen informieren muss, steht nicht im Gesetz. Jedoch wird eine solche Informationspflicht aus diesem Grundsatz abgeleitet.

> Tipp
>
> Dieser Grundsatz ist eine Art Generalklausel und damit als Auffanggrundsatz zu verstehen, für wenn andere Grundsätze nicht greifen.

Zweckbindung: Der Zweckbindungsgrundsatz wurde anhand der Revision mit dem vormaligen Grundsatz der Erkennbarkeit zusammengezogen. Demnach dürfen Personendaten nur zu einem bestimmten und für die betroffene Person **erkennbaren** Zweck beschafft werden. Weiter dürfen diese nur so bearbeitet werden, als dies mit eben diesem Zweck vereinbar bleibt. Die Erkennbarkeit ist, verglichen mit *vor der Revision*, nicht als umfassendes Transparenzgebot zu verstehen, sondern bezieht sich neu ausdrücklich auf den **Zweck selbst** und als **relevanten Zeitpunkt** auf die **Beschaffung**. Der zu diesem Moment angegebene Zweck bleibt in der Regel verbindlich. Der Datenbearbeiter muss dafür sorgen, dass die Daten nicht zu anderen Zwecken als bei der Beschaffung ersichtlich oder gesetzlich vorgesehen, verwendet werden.

Speicherbeschränkung: Laut dem Grundsatz der Speicherbeschränkung, geregelt in Art. 6 Abs. 4 DSG, müssen Daten vernichtet oder anonymisiert werden, sobald diese zum Zweck der Bearbeitung nicht mehr erforderlich sind. Diese Vorgabe dient auch der Datenminimierung.

Verhältnismässigkeit: Die Datenbearbeitung muss verhältnismässig, das heisst geeignet und erforderlich sein den verfolgten Zweck zu erreichen und für die betroffene Person als zumutbar erscheinen. Es ist das mildeste der möglichen Mittel, die dafür zur Verfügung stehen, zu wählen. Um die Verhältnismässigkeit beurteilen zu können, ist zunächst der

Zweck zu identifizieren. Die Verhältnismässigkeit ist im konkreten Einzelfall und nach den gesamten Umständen zu beurteilen.

Datenrichtigkeit: Nach Art. 6 Abs. 5 muss sich, wer Personendaten bearbeitet, über deren Richtigkeit vergewissern. Sie oder er muss alle angemessenen Massnahmen treffen, damit Daten berichtigt, gelöscht oder vernichtet werden, die im Hinblick auf den Zweck ihrer Beschaffung oder Bearbeitung unrichtig oder unvollständig sind. Die Angemessenheit der Massnahmen hängt namentlich ab von der Art und dem Umfang der Datenbearbeitung sowie vom Risiko, das die Bearbeitung für die Persönlichkeit oder Grundrechte der betroffenen Personen mit sich bringt. Impliziert gefordert wird auch eine **Pflicht** zur **Nachführung** und regelmässiger **Überprüfung** der Daten.

Datensicherheit: Dieser Grundsatz illustriert die Schnittstelle zwischen Datenschutz und Informationssicherheit, ist separat in Art. 8 DSG geregelt und besagt, dass der Verantwortliche und der Auftragsbearbeiter durch geeignete technische und organisatorische Massnahmen eine dem Risiko angemessene Datensicherheit zu gewährleisten haben. Die Gesetzesbestimmung ist allgemein gehalten und enthält in dem Sinne keine konkreten Vorgaben im Detail in Bezug auf die für die Datensicherheit zu treffenden Massnahmen. Solche finden sich im Verordnungstext der DSV.

Umgesetzt wird ein risikobasierter Ansatz. Bei der Prüfung ist jeweils das gesamte Massnahmenportfolio massgebend und die Beurteilung hat jeweils bezogen auf den konkreten Einzelfall zu erfolgen. Die getroffenen Massnahmen müssen derweil auch dem Verhältnismässigkeitsgrundsatz genügen. Bei der Datensicherheit im Vordergrund stehen die vier Aspekte “Vertraulichkeit”, “Verfügbarkeit”, “Datenintegrität” und “Nachvollziehbarkeit”.

12.5. Bestimmungen zum Datenschutz durch Technik und datenschutzfreundliche Einstellung

Bekannt als “*Privacy by Design, Privacy by Default*” ” enthält das Gesetz eine Bestimmung, welche zwar auch vor der Revision schon Geltung hatte, aber erst mit der Revision Eingang in das Gesetz gefunden hat. Es handelt sich dabei um eine Regel, jedoch nicht um einen Grundsatz im Sinne von Art. 6 und 8 DSG. Ziel der Norm ist eine Art Vorverlagerung des Datenschutzes. Es geht um präventiven Datenschutz. Sind Voreinstellungen mit datenschutzrechtlichem Bezug wählbar, soll als “*Standard*” diejenige Option der Datenbearbeitung vorgesehen sein, welche am wenigstens invasiv ausgestaltet ist für das betroffene Individuum. Zudem ist vom Verantwortlichen verlangt, dass er zum Zeitpunkt der Planung bis zum Ende des Datenbearbeitungsprozesses angemessene technische und organisatorische Massnahmen, also auf den Ebenen Technologie und Organisation, trifft, die helfen dafür zu sorgen, dass Verstösse gegen Datenschutzvorschriften verhindert oder zumindest erschwert werden.

12.6. Zulässige Datenbearbeitung und Rechtfertigung

Die Schweiz richtet sich, was die zulässige Datenbearbeitung anbelangt nach der Regel "Erlaubnis mit Verbotsvorbehalt". Damit gilt, dass eine Datenbearbeitung grundsätzlich erlaubt ist, solange sie nicht verboten ist. Umgekehrtes gilt auf Europäischer Ebene. Gemäss DSGVO gilt, dass eine Datenbearbeitung grundsätzlich verboten ist, solange sie nicht erlaubt ist ("Verbot mit Erlaubnistatbestand"). Gemäss Art. 30 DSG dürfen Personendaten bearbeitet werden, sofern dabei die Persönlichkeit nicht widerrechtlich verletzt wird. Dies impliziert die Konkretisierung des Persönlichkeitsrechts nach Art. 28 ZGB. Eine Persönlichkeitsverletzung liegt vor:

- Wenn Personendaten entgegen den Grundsätzen gemäss Art. 6 und 8 bearbeitet werden
- Wenn Personendaten entgegen einer ausdrücklichen Willenserklärung der betroffenen Person bearbeitet werden; oder
- Wenn eine Bekanntgabe von besonders schützenswerten Personendaten an Dritte erfolgt

Das Gesetz sieht die Möglichkeit vor, solche Persönlichkeitsverletzungen bei Datenbearbeitungen zu rechtfertigen, namentlich stehen dazu die folgenden drei Rechtfertigungsgründe nach Art. 31 DSG zur Auswahl:

- **Einwilligung**

Damit die Einwilligung als Rechtfertigungsgrund greift, muss sie gültig zustande gekommen sein. Dazu muss sich eine Einwilligung unter anderem auf bestimmte Bearbeitungen beziehen, freiwillig abgegeben, und nach angemessener vorheriger Information erfolgen. Zudem kann eine Einwilligung widerrufen werden (vgl. dazu Art. 31 Abs. 1 und Art. 6 Abs. 6 und 7 DSG).

- **Überwiegendes privates oder öffentliches Interesse**

Es ist eine Interessensabwägung vorzunehmen, und um die Rechtfertigung zu erreichen, muss das Interesse am verfolgten Ziel dasjenige an der Datenbearbeitung, welche die Persönlichkeit verletzt, überwiegen.

- **Gesetz**

Sieht eine gesetzliche Grundlage die in Frage gestellte Datenbearbeitung vor, geht diese in Ordnung.

12.7. Rechte und Pflichten nach DSG (Auswahl)

Betroffene Personen im Sinne des DSG können Rechte ausüben und **Verantwortliche** im Sinne des DSG haben gewisse Pflichten zu erfüllen.

12.7.1. Auskunftsrecht

Der Datenschutz kennt das Auskunftsrecht nach Art. 25 DSG, wonach jede Person vom Verantwortlichen (Adressat dieser Regelung) Auskunft darüber verlangen darf, ob Personendaten über sie bearbeitet werden. Diese Auskunft erhält die betroffene Person in der Regel kostenlos und innert 30 Tagen. Im Voraus verzichten kann eine betroffene Person auf dieses Recht nicht.

Das Instrument des Auskunftsrechtes ist wichtig im Zusammenhang mit dem Transparenzgebot, so kann man seine Rechte zur Kontrolle einer rechtmässigen Datenbearbeitung nur dann wahrnehmen, wenn man die Gewissheit hat, wer bzw. welche Unternehmen oder Behörden Personendaten über einem bearbeiten und zu welchem Zweck dies geschieht.

Was den Informationsgehalt anbelangt geht das Auskunftsrecht nach Art. 25 DSG weiter als die dem Verantwortlichen auferlegte Informationspflicht aus Art. 19 DSG. Das heisst über das Auskunftsrecht erfährt die Person in der Regel mehr an Informationen als man ihr im Zeitpunkt der Beschaffung durch die Informationspflicht mitteilen muss.

12.7.2. Informationspflicht

Art. 19 DSG statuiert die Pflicht des Verantwortlichen die betroffene Person angemessen über die Beschaffung von Personendaten zu informieren. Relevant ist damit der "*Zeitpunkt der Beschaffung*", womit eine gewisse **Planmässigkeit** vorausgesetzt ist. Gelangt ein Verantwortlicher aus reinem Zufall oder auf sonstige Weise ungewollt an Personendaten, greift die Informationspflicht aus Art. 19 DSG nicht. Die Informationspflicht geht weniger weit als das Auskunftsrecht.

12.7.3. Informationspflicht bei einer automatisierten Einzelentscheidung

Im Vordergrund der Einführung dieser Regelung steht der Einsatz von KI. In Ausnahmefällen kann es angezeigt sein, eine automatisiert getroffen Entscheidung von einer natürlichen Person überprüfen zu lassen.

12.7.4. Recht Datenherausgabe und -übertragung (Art. 28 und 29 DSG)

Dieses mit der Revision eingeführte Recht ist auch bekannt als Recht auf **Datenportabilität**. Anstelle von Datenschutz könnte man bei dieser Regel auch von Konsumentenschutz sprechen. So besteht das Ziel der Norm darin, dem Konsumenten die Verfügungsmacht über seine Daten zu sichern, auch wenn er diese einem Dienstleiter überlassen hat, für den Fall, dass er sich entscheidet zu einem späteren Zeitpunkt den Dienstleiter zu wechseln, gesetzt dem Fall, dass er die Daten an einem Ort bzw. bei einem anderen Dienstleister nutzen möchte. Die Herausgaben der Daten erfolgt in einem gängigen elektronischen Format.

12.7.5. Bearbeitungsverzeichnis und DSFA

Bei Unternehmen ab einer gewissen Grösse haben die Verantwortlichen und Auftragsbearbeiter je ein Verzeichnis ihrer Bearbeitungstätigkeiten zu führen (Art. 12 DSG).

Nach Art. 22 DSG erstellt der Verantwortliche dann vorgängig eine Datenschutz-Folgenabschätzung, wenn eine Bearbeitung ein hohes Risiko für die Persönlichkeit oder die Grundrechte der betroffenen Person mit sich bringen kann. Ein solches hohes Risiko kann sich beispielsweise bei der Verwendung neuer Technologien bewahrheiten.

12.8. Auslagerung und Bekanntgabe ins Ausland.

Eine Datenbearbeitung an Dritte zu übertragen und durch diese ausführen zu lassen (so genannt *outsourcen*) ist nicht verboten, sondern bei Einhaltung bestimmter Voraussetzungen erlaubt. Gleiches gilt für die Bekanntgabe von Personendaten ins Ausland. Bedient man sich Clouddiensten kann dies ein Erfüllen kumulativer Voraussetzungen hinsichtlich einer zulässigen Auslagerung, zusätzlich zu einer rechtmässigen Bekanntgabe ins Ausland erforderlich machen (Art. 9 und 16 ff. DSG).

12.9. Funktion Datenschutzberater

Die Funktion von Datenschutzberatenden ist abzugrenzen von den Aufsichtsbehörden. Private Personen können freiwillig einen oder eine Datenschutzberater:in vorsehen, während für Bundesorgane dies mit der Revision zu einer Pflicht mutiert ist. Soll ein Berater innerhalb der Unternehmung eingesetzt werden, ist sicherzustellen, dass dieser weisungsungebunden angesiedelt wird und fachlich unabhängig agieren kann.

12.10. DSGVO

Die DSGVO (engl. GDPR) ist eine für die Mitgliedstaaten der EU direkt anwendbare Verordnung. Um Daten rechtmässig zu bearbeiten muss (im Gegensatz zur Schweiz) immer ein Rechtsgrund vorliegen.

Obwohl es sich um EU-Recht handelt, kann die DSGVO auch für Schweizer Unternehmen relevant sein. Dies aufgrund des in Art. 3 DSGVO enthaltenen weiten, extraterritorialen Anwendungsbereich. So findet die Verordnung Anwendung auf die Verarbeitung personenbezogener Daten, soweit diese im Rahmen der Tätigkeiten einer Niederlassung eines Verantwortlichen oder eines Auftragsverarbeiters in der EU erfolgt, unabhängig davon, ob die Verarbeitung in der EU stattfindet.

Ebenfalls Anwendung findet sie, auf die Verarbeitung personenbezogener Daten von betroffenen Personen, die sich in der EU befinden, durch einen nicht in der EU niedergelassenen Verantwortlichen oder Auftragsverarbeiter wenn die Datenverarbeitung in Zusammenhang damit steht

(a) betroffenen Personen in der EU Waren oder Dienstleitungen anzubieten, unabhängig davon, ob von diesen betroffenen Personen eine Zahlung zu leisten ist oder
(b) das Verhalten betroffener Personen zu beobachten, soweit ihr Verhalten in der EU erfolgt.

13. Immaterialgüterrecht

Literaturhinweise [34]

13.1. Rechtliche Einordnung von "Daten", bezogen auf die Schweiz

Das Schweizer Recht kennt keine Sachdatengesetzgebung. Was die Schweiz in ihrer Rechtsordnung kennt, sind Regeln zum Eigentum an Sachen. Art. 641 ZGB erklärt, dass wer Eigentümer einer Sache ist, über diese nach seinem Belieben verfügen kann, solange er sich in den Schranken der Rechtsordnung aufhält. Er hat das Recht die Sache von jedem, der sie ihm vorenthält, herauszuverlangen und jede ungerechtfertigte Einwirkung abzuwehren. Dieses Abwehrrecht ist ausgestaltet als absolutes Recht. Der Anspruch die Sache herauszuverlangen nennt sich ***Vindikation*** und entfaltet Wirkung gegenüber jedermann (erga omnes). Die Qualifikation von Daten sowie die Frage nach deren Eigentum ist umstritten und wird heftig diskutiert. Aktuell existiert **kein sachenrechtliches Eigentum** an Daten. Bislang gilt die Praxis sich den Zugang, den Nutzungsumfang sowie die Integrität mit vertraglichen Massnahmen zu sichern. Nebenbei kann versucht werden über **geistiges Eigentum** eine Schutzwirkung zu erreichen, insbesondere über das Urheberrecht oder beispielsweise auch über das Wettbewerbsrecht, wobei letzteres nicht zu den geistigen Eigentumsrechten gehört. Zu den geistigen Eigentumsrechten zählen das Urheberrecht, das Markenrecht, das Patentrecht und das Designrecht.

Dadurch, dass Daten keine Sachen, also nicht physisch fassbar sind, gehören sie zu den immateriellen Gütern, dem Geistigen Eigentum. Auch an geistigem Eigentum gibt es Rechte, zusammengefasst nennen wir diese Rechte Immaterialgüterrechte (engl. Intellectual property [IP] Rights). Das Immaterialgüterrecht umfasst insgesamt das Urheberrecht, Patentrecht, das Design- und das Markenrecht.

Immateriell sind Güter, welche geistiger Natur entstammen und keinerlei körperliche Existenz aufweisen.

Ähnlich wie bei beim sachenrechtlichen Eigentum schützt die Rechtsordnung immaterielle Güter in dem bestimmten Rechtsinhabern (bei Werken ist dies der Urheber, bei Patenten der Erfinder) ein ausschliessliches, absolutes und subjektives Recht an einem bestimmten Gut gewährt wird. Das diese Rechte absolut ausgestaltet sind, bedeutet das Gleiche wie beim sachenrechtlichen Eigentum, nämlich dass beispielsweise ein Urheber sein Recht gegenüber jedermann geltend machen kann. Damit geniessen auch Immaterialgüterrechte eine erga omnes Wirkung. Besonders an immateriellen Gütern ist die Eigenschaft, dass sie gleichzeitig von einer Vielzahl

Personen zur gleichen Zeit genutzt werden können, ohne dass die Nutzung der einen die gleichzeitige Nutzung einer anderen, weiteren Person ausschliesst. Die Nutzung und der Konsum von immateriellen Gütern sind (komplementär zu körperlichen Gütern) nicht rivalisierend.

Absolute Recht entfalten eine Wirkung gegenüber jedermann, während die so genannt relativen Rechte nur zwischen den Parteien wirken (*inter partes*). Dies ist bei allen vertraglichen Verhältnissen der Fall. Vertraglich vereinbarte Regelungen geltend jeweils nur zwischen den Vertragsparteien.

13.1.1. Vertiefung Urheberrecht:

Geschützt durch das Urheberrecht werden geistige Schöpfungen der Literatur und Kunst, die individuellen Charakter haben. Diese Schöpfungen nennt man Werke und alle Werke, welche die Schutzvoraussetzungen erfüllen, erhalten deren urheberrechtlichen Schutz. Massgebend ist das Vorliegen einer individuellen, geistigen Schöpfung. Um in den Genuss des Urheberrechtes zu kommen ist weder eine Registrierung noch eine Eintragung notwendig, sondern das Recht an seiner Schöpfung erwirbt der Urheber unmittelbar im Zeitpunkt der Entstehung seines Werkes, ohne Weiteres zutun. Er kann damit Dritten die Nutzung seines Werkes verbieten, oder eine solche nur gegen die Entrichtung eines Entgeltes zuzulassen. Im Ergebnis ermöglicht das Urheberrecht dem Urheber sein Werk zu verwerten.

Damit der Schutz des Urheberrechtes greift, müssen die zwei Voraussetzungen, dass es sich um eine geistige Schöpfung handelt und diese einen individuellen Charakter aufweist, kumulativ erfüllt sein:

Geistige Schöpfung

1) Eine geistige Schöpfung in diesem Sinne kann nur ein von Menschen geschaffenes Werk sein. Der Begriff «geistig» bezieht sich auf die Tätigkeit eines Menschen und drückt aus, dass das Werk auf dem menschlichen Willen basieren- und eine Gedankenäusserung widerspiegeln muss.

Im Umkehrschluss bedeutet dies, dass zum Beispiel von Tieren geschaffene Werke unter anderem deshalb nicht urheberrechtlich geschützt sind, weil nicht ein menschlicher Geist über das Ergebnis entscheiden hat. Gleiches gilt für Werke die allein von Computern generierte Schöpfungen darstellen. Etwas anders gestaltet sich die Lage, wenn Werke lediglich mit Hilfe von Computern geschaffen werden. Demnach liegt ein noch von Menschen geschaffenes Werk vor, wenn der Computer lediglich als Werkzeug qualifiziert werden kann. Die Abgrenzung kann jedoch insbesondere beim Einsatz von KI schwierig sein. Es existieren Algorithmen, die kontrolliert oder aber eben auch selbständig abstrakte Fähigkeiten lernen und anwenden. Es gilt das Abgrenzungskriterium, dass so lange ein Mensch im Hinblick auf das angestrebte Ziel die Parameter der Daten und deren Reihenfolge wählt und regelmässig Anpassungen vornimmt, bis dieses in seinen Augen stimmt, darf von einer menschlichen Gedankenäusserung ausgegangen werden.

Individuelle Charakteristik

2) Damit ein urheberrechtlicher Schutz greifen kann, muss die Schöpfung auch ein bestimmtes Mass an kreativ-geistigem Gehalt aufweisen. Es geht um eine Beurteilung der Individualität als Gesamteindruck. Es bedarf unverkennbar charakteristische Züge eines Werkes, der Umstand allein, dass es neu ist und es dieses zuvor noch nicht gegeben hat, genügt zur Erfüllung dieser Voraussetzung nicht. Das Werk muss in seiner Gesamtheit etwas Besonderes, etwas Einmaliges sein.

Computerprogramme (den Begriff Software kennt das Schweizer URG nicht) können als Werke urheberrechtlich geschützt sein. Bei Computerprogrammen gelten gewisse Sondervorschriften und die Voraussetzung bzw. die Anforderung an den individuellen Charakter ist bei einer Software bereits dann als erfüllt anzusehen, wenn diese neu ist und nicht alltäglich.

13.1.2. Vertiefung Wettbewerbsrecht

Das Bundesgesetzt gegen unlauteren Wettbewerb (UWG) untersagt bestimmte Handlungen bzw. qualifiziert bestimmte Handlungen als unlauter.

Nach Art. 5 lit. c UWG unlauter handelt insbesondere, wer das marktreife Arbeitsergebnis eines anderen ohne angemessenen eigenen Aufwand durch technische Reproduktionsverfahren als solches übernimmt und verwertet.

Bei der Frage, ob die Verwertung «ohne angemessene Anstrengung» erfolgt ist, ist anhand des konkreten Sachverhalts zu prüfen. Es geht um das Vergleichen zwischen dem Aufwand des Erstanbieters zum Aufwand des potenziellen Verletzers. Zudem sollte geprüft werden, ob der Erstanbieter zum Zeitpunkt der Vervielfältigung und Verwertung bereits die Möglichkeit hatte, seine Kosten zu decken.

Art. 6 UWG schützt Fabrikations- und Geschäftsgeheimnisse, wenn diese durch Spionage bekannt geworden sind oder auf andere Weise unrechtmässig erlangt wurden. Die Verwertung von Geschäftsgeheimnissen oder deren Weitergabe an Dritte stellt ebenfalls unlauteren Wettbewerb dar, ein solches Verhalten untersagt.

Auch im Strafrecht nach Art. 162 StGB ist eine Offenbarung von Fabrikations- oder Geschäftsgeheimnissen durch eine Person, die gesetzlich oder vertraglich zur Geheimhaltung verpflichtet ist, sowie die Verwertung solcher Fabrikations- oder Geschäftsgeheimnisse strafbar. Der Vorsatz bezieht sich dabei auf das Wissen, dass die Information aus einer Verletzung der Geheimhaltungspflicht herrührt und dennoch im Wissen darum gehandelt wird.

13.2. Lizenzvertrag:

Die Formulierung “Lizenzvertrag” findet sich nicht im Gesetztext, das Wort kommt aus dem lateinischen und bedeutet “gewähren lassen”. Mit Hilfe einer **Lizenz** wird ein **immaterielles Gut** zur Nutzung überlassen. Die Regelungen in solchen Verträgen unterstehen der Privatautonomie.

Als Beispiel: Der Urheber überlässt ein nicht-materielles Gut, die Software, einem Dritten zum Gebrauch. Das Gesetz spricht auch von einer «Vermietung» von Computerprogrammen (Art. 10 Abs. 3, Art. 67 Abs. 1 URG). Denn es ist in der Regel der Urheber allein, der das alleinige und ausschliessliche Recht am Werk selbst innehat und er hat auch das alleinige und ausschliessliche Bestimmungsrecht wer was wann und wo mit dem Werk machen darf oder eben nicht machen darf oder unter welchen Bedingungen (Art.9-11 URG). Diese Einräumung von Lizenzen an Software gehört heutzutage zum Alltag.

13.3. Open Source-Software:

Beim Thema Open Source Software sind diverse Begriffsabgrenzungen vorzunehmen. Als erstes ist die Open Source Software von der proprietären Software zu unterscheiden. Bei der proprietären Software wird der Softwarecode nicht offengelegt. Mit anderen Worten gilt die von Menschen lesbare Version des Softwarecodes, auch unter dem Überbegriff *Sourcecode* bekannt, als Geschäftsgeheimnis. Kunden von proprietärer Software erhalten dabei lediglich eine so genannt kompilierte, also für Maschinen lesbare Version in Form einer Lizenz. Sinn und Zweck ist der Schutz vor Missbrauch (z.B. black copy, Spionage etc.).

Wörtlich übersetzen kann man den Begriff **Open Source** als “offene Quelle”, die Person, welche die Software entwickelt hat, legt auch deren Code offen. Mit dem Einsatz von Open Source Produkten sind Geheimhaltungsvereinbarungen betreffend Softwarecode obsolet geworden.

Um den Begriff Open Source zu definieren und von weiteren Ausdrücken abzugrenzen kann man sich der so genannten “10 Geboten” von Open Source behelfen. Es handelt sich dabei um eine Art Kriterienkatalog, welche Eigenschaften Vertriebsbedingungen von Open Source Software aufweisen sollten, nebst dem Zugriff auf den Quellcode.

Abzugrenzen ist der Begriff Open Source weiter von den Begriffen “Freeware” und “Publicdomain”-Software. Bei *Freeware* existiert gar kein Quellcode, sondern es besteht lediglich eine Gratislizenz während bei *Publicdomain-Software* der Urheber sein Urheberrecht gänzlich aufgibt und sämtliche Rechte am Programm der Öffentlichkeit überlässt. Weiter unterscheiden lassen sich auch **Copy-left** und **Non-Copyleft-Lizenzen**. Bei Ersteren hat die jeweilige Lizenznehmerin Änderungen oder Weiterentwicklungen an einem Open Source-Programm wiederum der Öffentlichkeit frei zur Verfügung zu stellen und zwar unter den gleichen Lizenzbedingungen wie beim originären Programm während bei Non-Copyleft

Open-Source-Lizenzen die Programmiererin welche eine Open Source verändert oder weiterentwickelt hat, selber darüber entscheiden kann, ob sie den neuen Quelltext geheim halten will oder ihn der Öffentlichkeit zugänglich machen möchte.

Literaturverzeichnis

1. Doemer D, Kempf M. Is It Ops That Make Data Science Scientific? Archives of Data Science, Series A (Online First) [Internet]. 2022;8:12. Verfügbar unter: https://publikationen.bibliothek.kit.edu/1000150238

2. Thilo, Jürg CMM, Stadelmann. Data Products. In: Thilo, Martin SKB, Stadelmann, Herausgeber. Applied Data Science: Lessons Learned for the Data-Driven Business [Internet]. Springer International Publishing; 2019. S. 47–61. Verfügbar unter: https://doi.org/10.1007/978-3-030-11821-1_4

3. Kotler P, Keller KL, Chernev A. Marketing Management [Internet]. Pearson; 2021. Verfügbar unter: https://www.pearson.ch/HigherEducation/Pearson/EAN/9781292404813/Marketing-Management-Global-Edition

4. Conway D. The Data Science Venn Diagram [Internet]. Zero Intelligence Agents. 2010. Verfügbar unter: http://drewconway.com/zia/2013/3/26/the-data-science-venn-diagram

5. Uludag O, Harders NM, Matthes F. Documenting recurring concerns and patterns in large-scale agile development. In: ACM International Conference Proceeding Series. Association for Computing Machinery; 2019.

6. Aljaber T. Das Magische Dreieck der Planung [Internet]. Atlassian Agile Coach. Verfügbar unter: https://www.atlassian.com/de/agile/agile-at-scale/agile-iron-triangle

7. Agiles Arbeiten – iterativ und inkrementell - Agile Academy [Internet]. Verfügbar unter: https://www.agile-academy.com/de/scrum-master/agiles-arbeiten-iterativ-und-inkrementell/

8. Knapp J, Zeratsky J, Kowitz B. Sprint: How to Solve Big Problems and Test New Ideas in Just Five Days [Internet]. Simon & Schuster; 2016. Verfügbar unter: https://books.google.ch/books?id=ICSpCwAAQBAJ

9. Ries E. The Lean Startup: How Today's Entrepreneurs Use Continuous Innovation to Create Radically Successful Businesses [Internet]. Crown; 2011. Verfügbar unter: https://books.google.ch/books?id=tvfyz-4JILwC

10. Ries E. Lessons Learned: Minimum Viable Product: a guide [Internet]. Verfügbar unter: http://www.startuplessonslearned.com/2009/08/minimum-viable-product-guide.html

11. Scrum.org [Internet]. Verfügbar unter: https://www.scrum.org/

12. Scrum Guides [Internet]. Verfügbar unter: https://scrumguides.org/

13. Anderson DJ. Kanban : Evolutionäres Change Management für IT-Organisationen. 2011;302.

14. Rehkopf M. Was ist ein Kanban Board? | Atlassian [Internet]. Verfügbar unter: https://www.atlassian.com/de/agile/kanban/boards

15. P. C, J C, R K, T K, T R, C S, u. a. CRISP-DM 1.0 Step-by-step Data Mining Guide [Internet]. CRISP-DM consortium; DaimlerChrysler; 2000. Verfügbar unter: http://www.kde.cs.uni-kassel.de/lehre/ws2016-17/kdd/files/CRISPWP-0800.pdf

16. Fayyad U, Piatetsky-Shapiro G, Smyth P. From Data Mining to Knowledge Discovery in Databases. AI Magazine [Internet]. März 1996;17:37. Verfügbar unter: https://ojs.aaai.org/index.php/aimagazine/article/view/1230

17. Fayyad UM, Piatetsky-Shapiro G, Smyth P, Uthurusamy R, Herausgeber. Advances in Knowledge Discovery and Data Mining [Internet]. AAAI Press/MIT Press; 1996. Verfügbar unter: https://mitpress.mit.edu/9780262560979/advances-in-knowledge-discovery-and-data-mining/

18. Kurgan LA, Musilek P. A survey of Knowledge Discovery and Data Mining process models. The Knowledge Engineering Review [Internet]. März 2006;21:1–24. Verfügbar unter: https://www.cambridge.org/core/journals/knowledge-engineering-review/article/survey-of-knowledge-discovery-and-data-mining-process-models/368D6AFE435EB5E30378398D34D61C17

19. Berthold MR, Borgelt C, Höppner F, Klawonn F, Silipo R. Guide to Intelligent Data Science. 2020; Verfügbar unter: http://link.springer.com/10.1007/978-3-030-45574-3

20. What is the Team Data Science Process? [Internet]. Verfügbar unter: https://learn.microsoft.com/en-us/azure/architecture/data-science-process/overview

21. Machine learning operations (MLOps) framework to upscale machine learning lifecycle with Azure Machine Learning [Internet]. Verfügbar unter: https://learn.microsoft.com/en-us/azure/architecture/ai-ml/guide/mlops-technical-paper

22. Osterwalder A, Pigneur Y, Wegberg JTA. Business Model Generation: Ein Handbuch für Visionäre, Spielveränderer und Herausforderer [Internet]. Campus Verlag; 2011. Verfügbar unter: https://books.google.ch/books?id=bygXDuTtd0wC

23. Azure TDSP Project Template [Internet]. Verfügbar unter: https://github.com/Azure/Azure-TDSP-ProjectTemplate

24. Webservice – Wikipedia [Internet]. Verfügbar unter: https://de.wikipedia.org/wiki/Webservice

25. Gower JC. A General Coefficient of Similarity and Some of Its Properties. Biometrics. 1971;27:857–71.

26. Miller GA. WordNet. Communications of the ACM [Internet]. November 1995;38:39–41. Verfügbar unter: https://dl.acm.org/doi/10.1145/219717.219748

27. Walter. Precision and recall - Wikimedia Commons [Internet]. 2014. Verfügbar unter: https://commons.wikimedia.org/wiki/File:Precisionrecall.svg

28. Bundesregierung Deutschland D der. Gutachten der Datenethikkommission - Kurzfassung [Internet]. 2019. S. 1–32. Verfügbar unter: https://www.bmi.bund.de/SharedDocs/downloads/DE/publikationen/themen/it-digitalpolitik/gutachten-datenethikkommission-kurzfassung.html

29. Christen M, Heitz C, Kleiber T, Loi M. Ethik-Kodex für datenbasierte Wertschöpfung [Internet]. Swiss Alliance for Data-Intensive Services; 2020. Verfügbar unter: https://data-innovation.org/data-ethics/

30. Pieth M, Simmler M. Strafrecht Besonderer Teil. 3. Aufl. Helbing Lichenbahn; 2024.

31. Geth C. Strafrecht Allgemeiner Teil. 7. Aufl. Helbing Lichtenbahn Verlag; 2021.

32. Epiney A, Nüesch D, Rovelli S. Datenschutzrecht in der Schweiz: Eine Einführung in das Datenschutzgesetz des Bundes, mit besonderem Akzent auf den für Bundesorgane relevanten Vorgaben. 2023;

33. Bieri A, Powell J, Borrmann AS. DSG: Kommentar zum Schweizerischen Datenschutzgesetz mit weiteren Erlassen. Orell Füssli Verlag; 2023.

34. Sury U. Digital in law = Informatikrecht. 2. Aufl. Stämpfli Verlag; 2021.